

Bayes 报告

于越 / 2236115645

2026 年 5 月 9 日

目录

1	问题描述与模型设定	2
1.1	数据背景	2
1.2	logistic 回归模型	2
2	MCMC 算法描述	3
2.1	随机游动 Metropolis–Hastings	3
2.2	逐分量 Metropolis–Hastings	3
2.3	多元正态建议分布 MH	4
2.4	切片 Gibbs 采样	4
2.5	Hamiltonian Monte Carlo	4
3	变分推断算法描述	4
3.1	标准化与参数变换	4
3.2	均值场高斯变分族	5
3.3	ELBO 目标函数	5
3.4	Score Function 方法	5
3.5	重参数化方法	6
4	实验设置	6
5	实验结果与分析	6
5.1	MCMC 接受率与参数估计	6
5.2	后验均值与 HPD 区间图	7
5.3	MCMC 后验密度比较	7
5.4	MCMC 与变分推断结果比较	8
5.5	联合后验样本分布	9
5.6	收敛性诊断图	9

1 问题描述与模型设定	2
5.7 变分推断的 ELBO 曲线	9
5.8 后验患病概率曲线	10
5.9 调参影响分析	11
5.10 全部方法汇总	11
6 结论	11
A 程序运行说明	12
B 补充图: β_0 的 HMC 诊断图	13

1 问题描述与模型设定

1.1 数据背景

我们考察 $n = 54$ 位老年人的智力测试成绩与是否患有老年痴呆症之间的关系. 记第 i 位老人的智力测试成绩为 x_i , 是否患有老年痴呆症为 y_i , 其中

$$y_i = \begin{cases} 1, & \text{患有老年痴呆症,} \\ 0, & \text{未患有老年痴呆症.} \end{cases}$$

1.2 logistic 回归模型

使用 logistic 回归模型:

$$y_i \sim \text{Bernoulli}(\theta_i), \quad i = 1, \dots, n,$$

因此

$$\theta_i = \frac{\exp(\beta_0 + \beta_1 x_i)}{1 + \exp(\beta_0 + \beta_1 x_i)}.$$

其中 β_0 为截距, β_1 为智力测试成绩对患病对数优势比的影响. 如果 $\beta_1 < 0$, 则表示智力测试成绩越高, 患病概率越低.

对参数设置独立正态先验:

$$\beta_j \sim N(\mu_j, \sigma_j^2), \quad j = 0, 1.$$

按照题意取

$$\mu_0 = \mu_1 = 0, \quad \sigma_0^2 = \sigma_1^2 = 10000,$$

此时先验方差较大, 该先验可视为接近无信息先验.

给定 $\beta = (\beta_0, \beta_1)^\top$ 后, 似然函数为

$$p(y | \beta) = \prod_{i=1}^n \left(\frac{\exp(\beta_0 + \beta_1 x_i)}{1 + \exp(\beta_0 + \beta_1 x_i)} \right)^{y_i} \left(\frac{1}{1 + \exp(\beta_0 + \beta_1 x_i)} \right)^{1-y_i}.$$

因此后验分布满足

$$\pi(\beta_0, \beta_1 | y) \propto \pi(\beta_0, \beta_1) p(y | \beta_0, \beta_1).$$

其对数形式可以写为

$$\begin{aligned} \log \pi(\beta | y) = & \sum_{i=1}^n [y_i(\beta_0 + \beta_1 x_i) - \log\{1 + \exp(\beta_0 + \beta_1 x_i)\}] \\ & - \frac{(\beta_0 - \mu_0)^2}{2\sigma_0^2} - \frac{(\beta_1 - \mu_1)^2}{2\sigma_1^2} + C, \end{aligned}$$

其中 C 与 β 无关由于模型不共轭，后验分布无法直接解析求得，因此需要使用数值方法近似，当然这也是我们的目的。

2 MCMC 算法描述

按照要求我们实现了五种 MCMC 方法求解后验分布。每种方法运行四条链，用于后续收敛诊断。下面进行简单的介绍（课堂中已经详细讲了，我们仅仅简介一下）。

2.1 随机游动 Metropolis–Hastings

随机游动 MH 在当前状态附近提出候选值：

$$\beta^* = \beta^{(t)} + \varepsilon, \quad \varepsilon \sim N(0, \Sigma_q).$$

由于建议分布对称，接受概率为

$$\alpha(\beta^{(t)}, \beta^*) = \min \left\{ 1, \frac{\pi(\beta^* | y)}{\pi(\beta^{(t)} | y)} \right\}.$$

该方法实现简单，但对建议步长较敏感。步长过小会导致链移动缓慢；步长过大则会导致拒绝率升高。

2.2 逐分量 Metropolis–Hastings

逐分量 MH 每次只更新一个参数。在一次完整迭代中，先固定 β_1 更新 β_0 ，再固定 β_0 更新 β_1 。对第 j 个参数提出

$$\beta_j^* = \beta_j^{(t)} + \varepsilon_j, \quad \varepsilon_j \sim N(0, s_j^2).$$

这种方法允许对不同参数设置不同步长，代码也较简单。但当参数后验相关性较强时，逐分量更新可能沿坐标轴缓慢移动。

2.3 多元正态建议分布 MH

多元正态建议分布 MH 使用独立建议分布：

$$\beta^* \sim q(\beta) = N(\hat{\beta}_{\text{MAP}}, c\hat{\Sigma}),$$

其中 $\hat{\beta}_{\text{MAP}}$ 为后验众数, $\hat{\Sigma}$ 为 BFGS 得到的近似后验协方差, c 为协方差放缩系数. 由于建议分布不依赖当前状态, 接受概率为

$$\alpha(\beta^{(t)}, \beta^*) = \min \left\{ 1, \frac{\pi(\beta^* | y)q(\beta^{(t)})}{\pi(\beta^{(t)} | y)q(\beta^*)} \right\}.$$

当建议分布与真实后验接近时, 该方法可以产生自相关较低的样本.

2.4 切片 Gibbs 采样

切片采样通过引入水平切片来构造新样本. 给定一维目标密度 $f(x)$ 和当前点 $x^{(t)}$, 先在密度高度方向采样

$$u \sim \text{Uniform}(0, f(x^{(t)})),$$

再从集合 $\{x : f(x) > u\}$ 中采样新点.

2.5 Hamiltonian Monte Carlo

HMC 引入辅助动量变量 p , 构造 Hamiltonian:

$$H(\beta, p) = U(\beta) + K(p),$$

其中

$$U(\beta) = -\log \pi(\beta | y), \quad K(p) = \frac{1}{2}p^\top M^{-1}p.$$

每轮迭代先采样动量 $p \sim N(0, M)$, 再使用 leapfrog 方法模拟 Hamiltonian dynamics, 并用 Metropolis 步骤校正数值积分误差. HMC 利用梯度信息, 通常比随机游动方法有更好的混合效率, 但需要调节步长、leapfrog 步数和质量矩阵.

3 变分推断算法描述

3.1 标准化与参数变换

为了提高变分优化的数值稳定性, 我们先对数据进行标准化:

$$z_i = \frac{x_i - \bar{x}}{s_x}.$$

在标准化模型中写为

$$\text{logit}(\theta_i) = \alpha_0 + \alpha_1 z_i.$$

由

$$\alpha_0 + \alpha_1 z_i = \left(\alpha_0 - \alpha_1 \frac{\bar{x}}{s_x} \right) + \frac{\alpha_1}{s_x} x_i$$

可得与原参数之间的关系：

$$\beta_1 = \frac{\alpha_1}{s_x}, \quad \beta_0 = \alpha_0 - \alpha_1 \frac{\bar{x}}{s_x}.$$

因此程序在 α 空间中优化变分分布，最后再转换回 β 空间进行解释。

3.2 均值场高斯变分族

设变分分布为均值场高斯：

$$q_\phi(\alpha) = q_{\phi_0}(\alpha_0)q_{\phi_1}(\alpha_1),$$

其中

$$q_{\phi_j}(\alpha_j) = N(m_j, s_j^2), \quad j = 0, 1.$$

为了保证标准差为正，程序中令

$$s_j = \text{softplus}(\rho_j),$$

实际优化参数为 $\phi = (m_0, m_1, \rho_0, \rho_1)$ 。

3.3 ELBO 目标函数

我们通过最大化 ELBO 近似真实后验：

$$\mathcal{L}(\phi) = \mathbb{E}_{q_\phi(\alpha)} [\log p(y, \alpha) - \log q_\phi(\alpha)].$$

其 Monte Carlo 估计为

$$\widehat{\mathcal{L}}(\phi) = \frac{1}{S} \sum_{s=1}^S [\log p(y, \alpha^{(s)}) - \log q_\phi(\alpha^{(s)})], \quad \alpha^{(s)} \sim q_\phi(\alpha).$$

3.4 Score Function 方法

Score Function 方法利用恒等式

$$\nabla_\phi q_\phi(\alpha) = q_\phi(\alpha) \nabla_\phi \log q_\phi(\alpha)$$

得到梯度估计

$$\nabla_\phi \mathcal{L}(\phi) = \mathbb{E}_{q_\phi} [\{\log p(y, \alpha) - \log q_\phi(\alpha)\} \nabla_\phi \log q_\phi(\alpha)].$$

实际计算中加入 baseline：

$$\widehat{\nabla_\phi \mathcal{L}} = \frac{1}{S} \sum_{s=1}^S [\log p(y, \alpha^{(s)}) - \log q_\phi(\alpha^{(s)}) - b] \nabla_\phi \log q_\phi(\alpha^{(s)}),$$

其中 b 为 reward 的移动平均.baseline 不改变梯度估计的期望，但可以降低方差。

3.5 重参数化方法

由于高斯分布可重参数化，可以写为

$$\alpha = m + s \odot \epsilon, \quad \epsilon \sim N(0, I_2).$$

于是 ELBO 可改写为关于 ϵ 的期望：

$$\mathcal{L}(\phi) = \mathbb{E}_{\epsilon \sim N(0, I_2)} [\log p(y, m + s \odot \epsilon) - \log q_\phi(m + s \odot \epsilon)].$$

此时样本是变分参数的可微函数，可以直接使用自动微分和 Adam 优化器最大化 ELBO.

4 实验设置

MCMC 部分每种方法运行 4 条链，每条链总迭代次数为 20000，前 5000 次作为 burn-in. 随机游动 MH 的建议步长由 BFGS 近似后验标准差设置；多元正态建议分布以 MAP 为中心，以近似后验协方差的 1.5 倍作为建议协方差；HMC 使用 BFGS 近似精度矩阵作为质量矩阵，并设置 leapfrog 步长为 0.6，步数为 12. 变分推断部分使用 Adam 优化器，重参数化方法迭代 5000 次，Score Function 方法迭代 8000 次.

5 实验结果与分析

5.1 MCMC 接受率与参数估计

表 1 给出各 MCMC 方法的接受率. 切片 Gibbs 没有传统 MH 接受率，因此对应列为空.

表 1: MCMC 方法接受率汇总

chain	RW	Component β_0	Component β_1	MVN	Slice	HMC
chain 1	0.3227	0.4680	0.5402	0.8033	–	0.9679
chain 2	0.3250	0.4665	0.5427	0.8013	–	0.9674
chain 3	0.3220	0.4601	0.5358	0.8071	–	0.9678
chain 4	0.3259	0.4616	0.5465	0.8019	–	0.9668

表 2 汇总了五种 MCMC 方法对 β_0, β_1 的后验估计结果，包括后验均值、标准差、中位数、95% HPD 区间、MCSE 和 Gelman–Rubin 统计量 $\hat{R}$.

从结果看，五种 MCMC 方法得到的 β_1 后验均值非常接近，均在负值区域. 各方法的 HPD 区间也主要位于负值区域，说明智力测试分数越高，患病概率越低. 从收敛诊断看， $\hat{R}$ 接近 1，MCSE 相对于后验标准差较小，说明采样结果较稳定.

表 2: MCMC 参数估计与收敛诊断

方法	参数	Mean	SD	Median	HPD Lower	HPD Upper	MCSE	$\hat{R}$
RW	β_0	2.7311	1.2999	2.6648	0.0730	5.2003	0.00531	1.0018
RW	β_1	-0.3595	0.1256	-0.3503	-0.6170	-0.1261	0.00051	1.0024
Component	β_0	2.6366	1.2567	2.5691	0.1833	5.1740	0.00513	1.0009
Component	β_1	-0.3503	0.1207	-0.3431	-0.6004	-0.1265	0.00049	1.0009
MVN	β_0	2.6342	1.2511	2.5874	0.2500	5.1180	0.00511	1.0000
MVN	β_1	-0.3505	0.1201	-0.3440	-0.5911	-0.1254	0.00049	1.0000
Slice	β_0	2.6613	1.2401	2.6089	0.2804	5.1087	0.00506	1.0004
Slice	β_1	-0.3529	0.1192	-0.3466	-0.5942	-0.1315	0.00049	1.0004
HMC	β_0	2.6688	1.2512	2.6131	0.2946	5.2113	0.00511	1.0002
HMC	β_1	-0.3533	0.1207	-0.3463	-0.5923	-0.1218	0.00049	1.0002

5.2 后验均值与 HPD 区间图

图 1 将 β_0 和 β_1 的后验均值及 95% HPD 区间并排展示. 相比单纯表格, 区间图能更直观地展示不同方法的估计是否一致.




图 1: 各方法对 β_0 和 β_1 的后验均值及 95% HPD 区间. 点表示后验均值, 线段表示 95% HPD 区间.

图中可以看到, 各方法对 β_1 的估计均落在负值区域, 且区间没有明显跨过 0. 这表明 $\beta_1 < 0$ 的结论在不同算法下较为稳定.

5.3 MCMC 后验密度比较

图 2 给出五种 MCMC 方法对 β_0 和 β_1 的边缘后验密度估计. 不同方法得到的密度曲线基本重合, 说明五种采样方法均能有效探索目标后验分布.




图 2: 五种 MCMC 方法得到的 β_0 和 β_1 边缘后验密度比较.

5.4 MCMC 与变分推断结果比较

表 3 给出两种变分推断方法的参数估计结果.

表 3: 变分推断参数估计结果

方法	参数	Mean	SD	Median	HPD Lower	HPD Upper
VI Reparam	β_0	2.6011	1.2799	2.5951	0.0393	5.0659
VI Reparam	β_1	-0.3439	0.1063	-0.3434	-0.5581	-0.1421
VI Score	β_0	2.6006	1.2752	2.6068	0.0685	5.0548
VI Score	β_1	-0.3440	0.1060	-0.3446	-0.5496	-0.1345

图 3 比较了 HMC、重参数化 VI 与 Score Function VI 的边缘后验密度. 可以看到, 变分推断与 MCMC 的主要结论一致, 即 β_1 的后验集中在负值区域.




图 3: MCMC 与变分推断得到的 β_0 和 β_1 后验密度比较.

5.5 联合后验样本分布

图 4 将 HMC、重参数化 VI 和 Score Function VI 的联合后验样本并排展示。




图 4: (β_0, β_1) 联合后验样本散点图.

5.6 收敛性诊断图

图 5 展示 HMC 方法关于 β_1 的样本路径图和遍历均值图。样本路径图用于观察链是否稳定地在后验区域波动；遍历均值图用于观察样本均值是否随着迭代逐渐稳定。




图 5: HMC 方法对 β_1 的样本路径图与遍历均值图

从图中可以看出，burn-in 之后链在稳定区域内波动，遍历均值也逐渐趋于稳定。这与 $\hat{R}$ 接近 1 的数值诊断结果一致。

5.7 变分推断的 ELBO 曲线

图 6 展示两种变分推断方法的 ELBO 曲线。请注意，虽然理论上重参数化方法通常具有更低的方差，因此曲线更平滑；Score Function 梯度方差较大，曲线波动大，但由于我们初始值设定不同，所以图中出现相反的结果，这并不能说明理论结果有问题。




图 6: Score Function 与重参数化方法的 ELBO 曲线.

5.8 后验患病概率曲线

为了直观解释模型结果, 图 7 使用 HMC 后验样本绘制了不同智力测试分数下的患病概率曲线. 后验均值曲线随 x 增大而下降, 说明智力测试成绩越高, 患病概率越低.




图 7: 基于 HMC 后验样本的患病概率曲线

从 odds ratio 的角度看, 若 $\beta_1 \approx -0.35$, 则

$$\exp(\beta_1) \approx \exp(-0.35) \approx 0.70.$$

这意味着在模型下, 智力测试分数每增加 1 分, 患病 odds 大约变为原来的 70%, 即下降约 30%.

5.9 调参影响分析

表 4 总结了随机游动 MH 和 HMC 的不同调参结果. 随机游动 MH 中, 建议步长过小会导致接受率较高但链移动缓慢; 步长过大则会降低接受率. HMC 中, leapfrog 步长过大可能导致数值积分误差变大, 从而降低接受率. 因此采样算法需要在接受率和样本移动效率之间取得平衡.

表 4: 不同调参设置对采样结果的影响

方法	调参设置	接受率	β_1 Mean	β_1 SD	β_1 MCSE
RW	scale = 0.3	0.5972	-0.3228	0.1054	0.00149
RW	scale = 0.5	0.4328	-0.3559	0.1240	0.00175
RW	scale = 0.7	0.3255	-0.3429	0.1228	0.00174
RW	scale = 1.0	0.2272	-0.3542	0.1170	0.00165
HMC	$\epsilon = 0.2$	0.9975	-0.3511	0.1217	0.00172
HMC	$\epsilon = 0.4$	0.9823	-0.3508	0.1207	0.00171
HMC	$\epsilon = 0.6$	0.9663	-0.3443	0.1121	0.00159
HMC	$\epsilon = 0.8$	0.9533	-0.3508	0.1251	0.00177

5.10 全部方法汇总

表 5 汇总全部 MCMC 与变分推断方法的参数估计结果. 总体看, 所有方法对 β_1 的估计方向一致, 说明结论具有较好的稳定性.

6 结论

本文采用 Bayesian logistic 回归模型研究智力测试成绩与老年痴呆症患病概率之间的关系, 并分别使用五种 MCMC 方法和两种变分推断方法近似后验分布. 实验结果显示, 各 MCMC 方法得到的后验估计高度一致, Gelman-Rubin 统计量接近 1, Monte Carlo 误差较小, 说明采样结果较可靠. 变分推断方法与 MCMC 在主要结论上保持一致.

表 5: 全部方法参数估计结果汇总

方法	参数	Mean	SD	Median	HPD Lower	HPD Upper	MCSE	$\hat{R}$
RW	β_0	2.7311	1.2999	2.6648	0.0730	5.2003	0.00531	1.0018
RW	β_1	-0.3595	0.1256	-0.3503	-0.6170	-0.1261	0.00051	1.0024
Component	β_0	2.6366	1.2567	2.5691	0.1833	5.1740	0.00513	1.0009
Component	β_1	-0.3503	0.1207	-0.3431	-0.6004	-0.1265	0.00049	1.0009
MVN	β_0	2.6342	1.2511	2.5874	0.2500	5.1180	0.00511	1.0000
MVN	β_1	-0.3505	0.1201	-0.3440	-0.5911	-0.1254	0.00049	1.0000
Slice	β_0	2.6613	1.2401	2.6089	0.2804	5.1087	0.00506	1.0004
Slice	β_1	-0.3529	0.1192	-0.3466	-0.5942	-0.1315	0.00049	1.0004
HMC	β_0	2.6688	1.2512	2.6131	0.2946	5.2113	0.00511	1.0002
HMC	β_1	-0.3533	0.1207	-0.3463	-0.5923	-0.1218	0.00049	1.0002
VI Reparam	β_0	2.6011	1.2799	2.5951	0.0393	5.0659	—	—
VI Reparam	β_1	-0.3439	0.1063	-0.3434	-0.5581	-0.1421	—	—
VI Score	β_0	2.6006	1.2752	2.6068	0.0685	5.0548	—	—
VI Score	β_1	-0.3440	0.1060	-0.3446	-0.5496	-0.1345	—	—

从统计结论看, β_1 的后验分布主要集中在负值区域, 说明智力测试分数越高, 老年痴呆症的后验概率越低. 后验患病概率曲线也直观展示了这一趋势.


A 程序运行说明

本实验的完整代码保存在整理后的 Jupyter Notebook 中. 运行 Notebook 后会自动生成如下目录:

- `final_results/`: 保存结果表格;
- `final_results/figures/`: 保存所有报告图像.

具体的代码解释, 我在 Jupyter 文件中以 markdown 格式进行了提示, 代码使用的环境为 Stanford 的 ISLP 环境, 不需要额外下载包.

B 补充图: β_0 的 HMC 诊断图

图 8: β_0 的 HMC 诊断图

Report on Use of AI

AI Tools Used

- **Tool name:** ChatGPT.
- **Model:** GPT-5.5 Thinking.
- **Provider:** OpenAI.
- **Date of use:** May 2026.

在本次编程作业中,我使用了 AI 工具作为辅助工具.AI 的使用主要体现在代码实现和报告整理两个方面,但并未替代我对算法、程序和实验结果的理解与判断.

首先,在代码实现部分,我使用 AI 帮助我将自己在纸上写好的算法思路和伪代码转化为 Python 程序.虽然大部分代码是在 AI 的辅助下完成的,但我对代码进行了逐行运行、检查和理解.对于不理解的部分,我会继续询问 AI 其含义和作用,直到能够明确每一步的逻辑.随后,我根据自己的理解对代码添加或修改了必要的注释.

其次,在实验报告撰写部分,我使用 AI 帮助我梳理 LaTeX 报告的整体结构.AI 也辅助完成了部分语言润色和 LaTeX 格式整理.

本报告中的所有数值结果、表格和图像均由我运行自己的 Python 程序得到.我对后验参数估计、收敛诊断、ELBO 曲线以及结果图进行了检查,并基于自己对 Bayesian logistic 回归、MCMC 方法和变分推断的理解完成最终解释.

参考文献

- [1] 茆诗松, 汤银才. 贝叶斯统计. 第2版. 北京: 中国统计出版社, 2012.
- [2] Metropolis, N., Rosenbluth, A. W., Rosenbluth, M. N., Teller, A. H., and Teller, E. Equation of state calculations by fast computing machines. *The Journal of Chemical Physics*, 21(6):1087–1092, 1953.
- [3] Hastings, W. K. Monte Carlo sampling methods using Markov chains and their applications. *Biometrika*, 57(1):97–109, 1970.
- [4] Neal, R. M. Slice sampling. *The Annals of Statistics*, 31(3):705–767, 2003.
- [5] Duane, S., Kennedy, A. D., Pendleton, B. J., and Roweth, D. Hybrid Monte Carlo. *Physics Letters B*, 195(2):216–222, 1987.
- [6] Gelman, A. and Rubin, D. B. Inference from iterative simulation using multiple sequences. *Statistical Science*, 7(4):457–472, 1992.
- [7] Ranganath, R., Gerrish, S., and Blei, D. M. Black box variational inference. In *Proceedings of the Seventeenth International Conference on Artificial Intelligence and Statistics*, pages 814–822, 2014.
- [8] Kingma, D. P. and Welling, M. Auto-encoding variational Bayes. In *International Conference on Learning Representations*, 2014.