

从经验分布、平滑估计到不确定性量化

于越 / 2236115645

2026 年 5 月 14 日

目录

1 引言: 非参数统计在估计什么	2
2 数据说明与描述性分析	2
2.1 变量说明	3
2.2 描述性统计	4
2.3 初步可视化分析	4
3 经验分布函数与 DKW 置信带	5
3.1 经验分布函数	5
3.2 经验分布函数的基本性质	6
3.3 DKW 不等式与同时置信带	7
4 核密度估计与带宽选择	8
4.1 从分布函数到密度函数	8
4.2 核密度估计的偏差推导	8
4.3 核密度估计的方差推导	9
4.4 AMISE 与最优带宽阶	10
4.5 非参数收敛速度与函数空间复杂度	11
5 非参数回归: 估计未知函数	12
5.1 非参数回归模型	12
5.2 局部线性回归与 LOWESS	12
5.3 平滑样条与 GAM	13
6 Bootstrap 置信带: 非参数估计的不确定性	14
6.1 为什么需要置信带	14
6.2 Bootstrap 的统计含义	14
6.3 Bootstrap 方法	15

1 引言: 非参数统计在估计什么

在参数统计中, 我们通常假设总体分布属于某个有限维分布族, 例如

$$\mathcal{P} = \{P_\theta : \theta \in \Theta \subset \mathbb{R}^p\}.$$

此时统计推断的目标是估计有限维参数 θ . 典型例子包括正态模型中的均值与方差, 以及线性回归模型中的回归系数.

非参数统计的出发点不同. 它通常考虑更大的模型空间. 例如, 对于一个实值随机变量 X , 我们可以不假设其来自正态分布或某个具体参数族, 而是直接考虑

$$\mathcal{P} = \{P : P \text{ is an arbitrary distribution}\}.$$

在回归问题中, 我们也不再强行假设

$$Y = \beta_0 + \beta_1 X + \varepsilon,$$

而是考虑

$$Y = m(X) + \varepsilon,$$

其中 m 是未知函数.

因此, 非参数统计并不是“没有参数”, 而是把未知对象从有限维参数推广为更复杂的对象, 例如

$$F, \quad f, \quad m, \quad T(P).$$

这里 F 是分布函数, f 是密度函数, m 是回归函数, $T(P)$ 是分布的统计泛函.

这种推广带来了更强的灵活性, 但也带来了新的困难. 由于模型空间更大, 估计问题通常更难, 收敛速度也往往慢于参数统计中的 $n^{-1/2}$ 速度. 因此, 非参数统计的核心不只是“放松假设”, 还包括如何控制复杂度, 以及如何量化估计的不确定性.

本文以 Wage 数据为例, 展示非参数统计中的一条统一主线:

$$\boxed{\text{经验分布} \longrightarrow \text{平滑估计} \longrightarrow \text{非参数回归} \longrightarrow \text{不确定性量化}}.$$

更具体地, 本文依次讨论经验分布函数 $\hat{F}_n$, 核密度估计 $\hat{f}_h$, 非参数回归估计 $\hat{m}(x)$, 以及 bootstrap 置信带.

2 数据说明与描述性分析

本文使用 ISLP 中的 Wage 数据作为实验对象. 该数据集记录了美国 Mid-Atlantic 地区 3000 名男性劳动者的工资及相关信息. 数据来自 March 2011 Supplement to Cur-

rent Population Survey, 并被整理为 ISLP 中的教学数据集.¹ 数据集中包含 11 个变量, 主要变量包括年份, 年龄, 婚姻状况, 种族, 教育水平, 工作类别, 健康状况, 医疗保险状况, 对数工资和原始工资.

本文并不试图建立一个完整的工资形成模型. 工资显然受到教育, 职业, 健康状况, 地区, 年份等多个因素影响. 本文只选择其中最直观的两个变量

$$\text{age}, \quad \text{wage}$$

具体来说, 本文从两个角度使用该数据集. 第一, 若只关注工资变量

$$X = \text{wage},$$

则可以研究工资的总体分布函数

$$F(x) = \mathbb{P}(X \leq x),$$

以及密度函数

$$f(x) = F'(x).$$

这对应经验分布函数和核密度估计.

第二, 若关注年龄与工资之间的关系, 令

$$X = \text{age}, \quad Y = \text{wage},$$

则可以研究条件均值函数

$$m(x) = \mathbb{E}(Y \mid X = x).$$

这对应非参数回归问题.

因此, 一个数据集可以自然支持三个层次的非参数问题:

distribution estimation + density estimation + regression function estimation.

2.1 变量说明

表 1 总结了 Wage 数据中与本文有关的主要变量.

¹Wage 数据的官方说明见 ISLP documentation: *Mid-Atlantic Wage Data*. 该文档说明数据包含 3000 名 Mid-Atlantic 地区男性劳动者, 变量包括 year, age, education, jobclass, health, health_ins, logwage 和 wage 等.

变量	类型	含义
year	numerical	工资信息记录年份
age	numerical	劳动者年龄
education	categorical	教育水平
jobclass	categorical	工作类别, 包括 Industrial 与 Information
health	categorical	健康状况
health_ins	categorical	是否拥有医疗保险
logwage	numerical	工资的对数变换
wage	numerical	原始工资水平

表 1: Wage 数据中的主要变量

2.2 描述性统计

表 2 给出了 age 与 wage 的描述性统计.

变量	n	Mean	SD	Min	Q1	Median	Q3	Max
age	3000	42.41	11.54	18.00	33.75	42.00	51.00	80.00
wage	3000	111.70	41.73	20.09	85.38	104.92	128.68	318.34

表 2: Wage 数据中 age 与 wage 的描述统计

从表 2 可以看出, 样本量为 3000. 年龄变量的均值为 42.41, 中位数为 42, 四分位数区间为 [33.75, 51.00], 说明样本主要集中在中青年到中年劳动者范围内. 工资变量的均值为 111.70, 中位数为 104.92, 均值高于中位数, 初步显示工资分布存在右偏. 同时, 工资最大值达到 318.34, 明显高于第三四分位数 128.68, 说明高工资端存在少量较大的观测值.

这一点对后文很重要. 如果工资分布具有右偏和高端尾部, 那么简单正态模型可能无法很好描述其整体分布. 因此, 使用经验分布函数和核密度估计来直接观察分布形态是自然的.

2.3 初步可视化分析

图 1 给出了数据的初步可视化. 左图展示工资变量的直方图和核密度估计, 右图展示年龄与工资的散点图.




图 1: Wage 数据的初步可视化. 左图为工资分布, 右图为年龄与工资的散点图

左图与表 2 的结论一致: 工资分布明显右偏, 大部分观测集中在约 80 到 140 的范围内, 但右侧存在较长尾部. 这说明仅用均值和方差概括工资分布是不充分的. 更合适的做法是直接估计整个分布函数 F 或密度函数 f .

右图显示, 年龄与工资之间的关系也不是简单线性关系. 工资大致在年轻到中年阶段上升, 到中年附近后趋于平缓, 高年龄段可能略有下降或波动. 同时, 相同年龄下工资差异较大, 说明个体工资受到年龄之外的许多因素影响.

因此, 本文不把该数据集当作一个完整的工资解释模型, 而是将其作为展示非参数统计思想的例子. 后文将依次使用经验分布函数估计工资分布, 使用核密度估计观察工资密度, 使用 LOWESS 和 GAM 估计年龄对平均工资的非线性影响, 并使用 bootstrap 置信带描述非参数回归曲线的不确定性.

3 经验分布函数与 DKW 置信带

3.1 经验分布函数

设

$$X_1, \dots, X_n$$

是来自未知分布 F 的独立同分布样本.

Definition 3.1 (经验分布函数). 经验分布函数定义为

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n I(X_i \leq x).$$

它是总体分布函数 $F(x)$ 的自然估计.²

²关于经验分布函数, Glivenko–Cantelli 定理, DKW 不等式和经验过程的更多性质, 可参考 Wasserman, *All of Nonparametric Statistics*, Chapter 2–3. 更系统的处理见 van der Vaart and Wellner, *Weak Con-*

经验分布函数是最基本的非参数估计量之一. 它完全由样本决定, 不需要假设 F 属于任何具体分布族. 换言之, 我们不需要假设数据来自正态分布, 指数分布或其他参数分布, 而是直接用样本本身近似总体分布.

3.2 经验分布函数的基本性质

对固定的 x , 经验分布函数可以写成

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n I(X_i \leq x).$$

由于 $I(X_i \leq x)$ 是 Bernoulli 随机变量, 其成功概率为

$$\mathbb{P}(X_i \leq x) = F(x),$$

因此

$$\mathbb{E}[\hat{F}_n(x)] = F(x).$$

这说明经验分布函数在每个固定点 x 上是 $F(x)$ 的无偏估计.

同时,

$$\text{Var}(\hat{F}_n(x)) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}\{I(X_i \leq x)\} = \frac{F(x)(1-F(x))}{n}.$$

Proposition 3.2. 对任意固定的 x , 经验分布函数满足

$$\mathbb{E}[\hat{F}_n(x)] = F(x),$$

以及

$$\text{Var}(\hat{F}_n(x)) = \frac{F(x)(1-F(x))}{n}.$$

由大数定律可知, 对任意固定 x ,

$$\hat{F}_n(x) \xrightarrow{p} F(x).$$

但非参数统计中更重要的是一致收敛, 即考察

$$\sup_x |\hat{F}_n(x) - F(x)|.$$

这不是单点误差, 而是整个函数的最大误差. Dvoretzky–Kiefer–Wolfowitz 不等式正是对这一整体误差给出控制.

vergence and Empirical Processes. DKW 不等式最早由 Dvoretzky, Kiefer and Wolfowitz 提出, 其 sharp constant 版本由 Massart 给出.

3.3 DKW 不等式与同时置信带

Theorem 3.3 (Dvoretzky–Kiefer–Wolfowitz Inequality). 设 $X_1, \dots, X_n$ 独立同分布, 分布函数为 F , 经验分布函数为 $\hat{F}_n$. 则对任意 $\varepsilon > 0$,

$$\mathbb{P} \left(\sup_x |\hat{F}_n(x) - F(x)| > \varepsilon \right) \leq 2e^{-2n\varepsilon^2}.$$

由 DKW 不等式,

$$\mathbb{P} \left(\sup_x |\hat{F}_n(x) - F(x)| > \varepsilon \right) \leq 2e^{-2n\varepsilon^2}.$$

为了构造置信水平为 $1 - \alpha$ 的同时置信带, 令右端等于 α :

$$2e^{-2n\varepsilon^2} = \alpha.$$

两边取对数, 得到

$$-2n\varepsilon^2 = \log \frac{\alpha}{2}.$$

因此

$$\varepsilon = \sqrt{\frac{1}{2n} \log \frac{2}{\alpha}}.$$

记

$$\varepsilon_n = \sqrt{\frac{1}{2n} \log \frac{2}{\alpha}}.$$

于是以概率至少 $1 - \alpha$,

$$\sup_x |\hat{F}_n(x) - F(x)| \leq \varepsilon_n.$$

这等价于对所有 x 同时成立:

$$\hat{F}_n(x) - \varepsilon_n \leq F(x) \leq \hat{F}_n(x) + \varepsilon_n.$$

Remark 3.4. DKW 置信带是同时置信带, 而不是某个固定点上的点态置信区间. 这体现了非参数推断中对整个函数对象进行控制的思想.

图 2 左图展示工资变量的经验分布函数及其 95% DKW 置信带. 右图将经验分布函数与拟合正态分布的分布函数进行比较.




图 2: 经验分布函数与 DKW 置信带. 左图展示 ECDF 及其 95% 同时置信带, 右图比较 ECDF 与拟合正态分布的 CDF

从右图可以看出, 拟合正态分布在工资分布的中部和尾部都与经验分布函数存在差异. 经验分布函数不依赖任何参数分布假设, 因此能够更直接地反映样本中的分布结构.

4 核密度估计与带宽选择

4.1 从分布函数到密度函数

经验分布函数可以估计 F , 但很多问题中我们更关心密度函数 f . 密度函数描述数据在局部区域的集中程度.

然而, 密度函数是分布函数的导数, 而经验分布函数 $\hat{F}_n$ 是阶梯函数. 直接对经验分布函数求导只会得到一组离散尖峰, 无法形成有意义的连续密度估计. 因此, 当估计目标从分布函数 F 变成密度函数 f 时, 必须引入平滑.

Definition 4.1 (核密度估计). 给定核函数 K 和带宽 $h > 0$, 核密度估计定义为

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right).$$

可以把核密度估计理解为: 在每个样本点 X_i 附近放置一个小的核函数, 然后把把这些核函数叠加起来. 带宽 h 控制每个核函数的宽度, 因此也控制估计曲线的平滑程度.

4.2 核密度估计的偏差推导

为了理解带宽 h 的作用, 我们考察核密度估计的偏差与方差. 首先计算期望:

$$\mathbb{E}[\hat{f}_h(x)] = \frac{1}{h} \int K\left(\frac{x - u}{h}\right) f(u) du.$$

令

$$t = \frac{x - u}{h}, \quad u = x - ht, \quad du = -h dt.$$

则

$$\mathbb{E}[\hat{f}_h(x)] = \int K(t) f(x - ht) dt.$$

若 f 在 x 附近二阶可导, 对 $f(x - ht)$ 作 Taylor 展开:

$$f(x - ht) = f(x) - ht f'(x) + \frac{h^2 t^2}{2} f''(x) + o(h^2).$$

代入上式, 得到

$$\mathbb{E}[\hat{f}_h(x)] = f(x) \int K(t) dt - h f'(x) \int t K(t) dt + \frac{h^2}{2} f''(x) \int t^2 K(t) dt + o(h^2).$$

若核函数满足

$$\int K(t) dt = 1, \quad \int t K(t) dt = 0, \quad \int t^2 K(t) dt = \mu_2(K),$$

则

$$\mathbb{E}[\hat{f}_h(x)] - f(x) = \frac{h^2}{2} \mu_2(K) f''(x) + o(h^2).$$

因此

$$\text{Bias}(\hat{f}_h(x)) = O(h^2).$$

这说明带宽越大, 平滑越强, 偏差通常越大.

4.3 核密度估计的方差推导

由于 $X_1, \dots, X_n$ 独立同分布,

$$\text{Var}(\hat{f}_h(x)) = \frac{1}{n} \text{Var} \left[\frac{1}{h} K \left(\frac{x - X}{h} \right) \right].$$

其主项为

$$\frac{1}{n} \mathbb{E} \left[\frac{1}{h^2} K^2 \left(\frac{x - X}{h} \right) \right].$$

类似地作变量替换 $t = (x - u)/h$, 有

$$\mathbb{E} \left[\frac{1}{h^2} K^2 \left(\frac{x - X}{h} \right) \right] = \frac{1}{h} \int K^2(t) f(x - ht) dt.$$

当 h 较小时,

$$f(x - ht) \approx f(x).$$

于是

$$\text{Var}(\hat{f}_h(x)) \approx \frac{1}{nh} f(x) \int K^2(t) dt.$$

记

$$R(K) = \int K^2(t) dt.$$

则

$$\text{Var}(\hat{f}_h(x)) \approx \frac{1}{nh} f(x) R(K).$$

因此

$$\text{Var}(\hat{f}_h(x)) = O\left(\frac{1}{nh}\right).$$

这说明带宽越小, 每个点附近参与平均的数据越少, 估计方差越大.

Proposition 4.2. 在适当光滑条件下, 若核函数满足常用矩条件, 则

$$\text{Bias}(\hat{f}_h(x)) = O(h^2), \quad \text{Var}(\hat{f}_h(x)) = O\left(\frac{1}{nh}\right).$$

4.4 AMISE 与最优带宽阶

由前面的推导,

$$\text{Bias}^2(\hat{f}_h(x)) = O(h^4), \quad \text{Var}(\hat{f}_h(x)) = O\left(\frac{1}{nh}\right).$$

因此点态均方误差满足

$$\text{MSE}(\hat{f}_h(x)) = O(h^4) + O\left(\frac{1}{nh}\right).$$

更精细地, 对 x 积分可以得到渐近积分均方误差:

$$\text{AMISE}(h) = \frac{h^4}{4} \mu_2^2(K) R(f'') + \frac{1}{nh} R(K),$$

其中

$$R(f'') = \int \{f''(x)\}^2 dx, \quad R(K) = \int K^2(u) du.$$

为了寻找最优带宽, 对

$$C_1 h^4 + \frac{C_2}{nh}$$

关于 h 求导:

$$4C_1 h^3 - \frac{C_2}{nh^2} = 0.$$

于是

$$h^5 = \frac{C_2}{4C_1 n}.$$

因此

$$h_{\text{opt}} \asymp n^{-1/5}.$$

代回均方误差主项可得

$$\text{MSE}_{\text{opt}} \asymp n^{-4/5}.$$

这个速度慢于参数估计中常见的 n^{-1} 均方误差速度, 反映了非参数估计在更大函数空间中进行推断所付出的代价。

图 3 展示了工资变量的核密度估计以及不同带宽对估计结果的影响。




图 3: 核密度估计与带宽选择. 左图展示工资变量的直方图与 KDE, 右图展示不同带宽下的 KDE 曲线

右图清楚展示了带宽的作用. 小带宽对应更波动的曲线, 能够反映更多局部变化, 但可能过拟合. 大带宽对应更平滑的曲线, 但可能抹去真实结构. 这个例子体现了非参数估计中最核心的思想之一: 复杂度控制。

4.5 非参数收敛速度与函数空间复杂度

在参数模型中, 未知对象通常是有限维参数 $\theta \in \mathbb{R}^p$. 在正则条件下, 参数估计往往具有

$$\sqrt{n}(\hat{\theta} - \theta) = O_p(1)$$

的收敛性质, 因此均方误差通常是 $O(n^{-1})$.

非参数问题不同. 未知对象可能是整个函数, 例如密度函数 f 或回归函数 m . 这相当于在无限维空间中估计未知对象. 为了使估计问题可解, 我们通常需要对函数空间施加光滑性条件。

在 Hölder 类或 Sobolev 类等常见光滑函数空间上, 一个典型的 minimax 结论是: 若目标函数具有 β 阶光滑性, 且自变量维度为 d , 那么平方损失下的最优风险速率通常为

$$n^{-\frac{2\beta}{2\beta+d}}.$$

3

³这里说的是典型的 minimax 风险速率, 具体结论依赖于函数空间, 损失函数和观测模型. 详细讨论可参考 Tsybakov, *Introduction to Nonparametric Estimation*, Chapters 1–2; Wasserman, *All of Nonparametric Statistics*, Chapters 5–6; 以及 Giné and Nickl, *Mathematical Foundations of Infinite-Dimensional Statistical Models*.

这个公式揭示了非参数统计中的两个核心现象. 第一, 函数越光滑, 即 β 越大, 估计越容易. 第二, 维度 d 越大, 收敛速度越慢. 这就是所谓的维度灾难. 非参数方法虽然灵活, 但灵活性并不是免费的, 它需要更多数据来支撑.

5 非参数回归: 估计未知函数

5.1 非参数回归模型

除了分布函数和密度函数, 另一个重要的非参数对象是回归函数

$$m(x) = \mathbb{E}(Y | X = x).$$

在本文中,

$$X = \text{age}, \quad Y = \text{wage}.$$

我们希望估计

$$m(x) = \mathbb{E}(\text{wage} | \text{age} = x).$$

参数线性回归假设

$$m(x) = \beta_0 + \beta_1 x.$$

这个假设简单, 可解释, 但可能过于僵硬. 非参数回归则考虑

$$Y_i = m(X_i) + \varepsilon_i,$$

其中 m 是未知函数. 目标是在不预先指定函数形式的情况下, 从数据中估计 m .

5.2 局部线性回归与 LOWESS

一种经典的非参数回归方法是局部线性回归. 对固定点 x , 局部线性回归近似认为在 x 附近

$$m(u) \approx a + b(u - x).$$

因此估计问题变成加权最小二乘:

$$(\hat{a}, \hat{b}) = \arg \min_{a, b} \sum_{i=1}^n w_i(x) \{Y_i - a - b(X_i - x)\}^2,$$

其中

$$w_i(x) = K_h(X_i - x).$$

记

$$Z_x = \begin{pmatrix} 1 & X_1 - x \\ 1 & X_2 - x \\ \vdots & \vdots \\ 1 & X_n - x \end{pmatrix}, \quad W_x = \text{diag}\{w_1(x), \dots, w_n(x)\}, \quad Y = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}.$$

则

$$\begin{pmatrix} \hat{a} \\ \hat{b} \end{pmatrix} = (Z_x^\top W_x Z_x)^{-1} Z_x^\top W_x Y.$$

最终

$$\hat{m}(x) = \hat{a}.$$

这个形式说明, 局部线性回归本质上不是黑箱方法, 而是在每个点 x 附近做一次加权线性回归. 核函数决定权重, 带宽或 span 决定邻域大小.

在一维情形下, 若 m 足够光滑, 局部线性估计通常也具有类似的偏差和方差结构:

$$\text{Bias}(\hat{m}(x)) = O(h^2), \quad \text{Var}(\hat{m}(x)) = O\left(\frac{1}{nh}\right).$$

因此非参数回归中的带宽选择与密度估计类似, 同样体现偏差和方差的权衡.

LOWESS 可以理解为局部加权回归的一种常用实现. 它通过 span 参数控制每次局部拟合所使用的数据比例. span 较小, 曲线更灵活. span 较大, 曲线更平滑. 因此, span 在非参数回归中扮演着类似 KDE 带宽的角色.

5.3 平滑样条与 GAM

另一类重要的非参数回归方法是平滑样条. 它通过求解

$$\hat{f} = \arg \min_f \left\{ \sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \int \{f''(t)\}^2 dt \right\}$$

来估计未知函数.

这个目标函数中, 第一项

$$\sum_{i=1}^n (y_i - f(x_i))^2$$

要求曲线贴近数据. 第二项

$$\int \{f''(t)\}^2 dt$$

惩罚曲线过度弯曲. 平滑参数 λ 控制拟合与光滑之间的折中. 当 λ 较小时, 曲线更灵活. 当 λ 较大时, 曲线更平滑.

广义加性模型, Generalized Additive Model, 简称 GAM, 可以看作平滑样条思想的推广. 在单变量情形下, GAM 可以写成

$$Y_i = f(X_i) + \varepsilon_i.$$

在多变量情形下, 它可以写成

$$Y_i = \beta_0 + f_1(X_{i1}) + f_2(X_{i2}) + \cdots + f_p(X_{ip}) + \varepsilon_i.$$

它保留了加性结构的可解释性, 同时允许每个变量以非线性函数的形式影响响应变量.

图 4 左图比较了线性回归, LOWESS 和 GAM 对年龄效应的估计. 右图展示不同 span 下 LOWESS 曲线的变化.




图 4: 非参数回归估计年龄效应. 左图比较线性回归, LOWESS 和 GAM, 右图展示不同 span 对 LOWESS 平滑程度的影响

从左图可以看到, 线性回归只能给出整体线性趋势, 而 LOWESS 和 GAM 更自然地刻画了年龄与工资之间的非线性关系. 工资在年轻到中年阶段上升较快, 之后趋于平缓甚至略有下降. 右图说明, 不同 span 会改变曲线平滑程度, 但总体年龄效应较为稳定. 这说明非参数回归并不是为了随意画出复杂曲线, 而是在灵活性和稳定性之间进行控制.

6 Bootstrap 置信带: 非参数估计的不确定性

6.1 为什么需要置信带

前面的非参数回归给出了估计曲线

$$\hat{m}(x).$$

但是这条曲线本身也是随机的, 因为它依赖于样本. 仅仅给出一条估计曲线是不够的, 我们还需要描述它的不确定性.

对于许多非参数估计量, 解析推导其抽样分布比较困难. Bootstrap 提供了一种通用的重抽样方法, 用来近似估计量的抽样分布.

6.2 Bootstrap 的统计含义

设 $\hat{m}$ 是由原始样本

$$\mathcal{D}_n = \{(X_i, Y_i) : i = 1, \dots, n\}$$

得到的非参数估计曲线. 由于 $\mathcal{D}_n$ 是随机样本, $\hat{m}(x)$ 也是随机变量. 理论上, 我们关心的是

$$\hat{m}(x) - m(x)$$

的抽样分布.

但是在非参数回归中, 这个分布通常难以显式写出. Bootstrap 的思想是用经验分布 $\hat{P}_n$ 替代未知总体分布 P . 从原始样本中有放回抽样, 等价于从经验分布 $\hat{P}_n$ 中重新抽样. 每一次 bootstrap 样本都会产生一条新的曲线

$$\hat{m}^*(x).$$

这些曲线的变动可以用来近似原估计量 $\hat{m}(x)$ 的抽样变动.

因此, bootstrap 不是在估计个体工资的随机波动, 而是在估计非参数回归曲线本身的不确定性.

6.3 Bootstrap 方法

具体做法如下:

1. 从原始样本中有放回地抽取 n 个观测, 得到 bootstrap 样本.
2. 在该样本上重新拟合非参数回归曲线.
3. 在同一组网格点上记录预测值.
4. 重复上述过程 B 次.
5. 对每个网格点上的 B 个预测值取分位数, 得到置信带.

记第 b 次 bootstrap 得到的曲线为

$$\hat{m}^{*(b)}(x), \quad b = 1, \dots, B.$$

则可以定义点态置信带:

$$L(x) = q_{0.025} \{ \hat{m}^{*(1)}(x), \dots, \hat{m}^{*(B)}(x) \},$$

$$U(x) = q_{0.975} \{ \hat{m}^{*(1)}(x), \dots, \hat{m}^{*(B)}(x) \}.$$

其中 $q_{0.025}$ 和 $q_{0.975}$ 分别表示经验 2.5% 和 97.5% 分位数.

图 5 展示了 LOWESS 回归曲线的 bootstrap 置信带, 以及 bootstrap 重抽样产生的一族可能曲线.




图 5: 非参数回归曲线的 bootstrap 不确定性. 左图展示 LOWESS 曲线及其 95% bootstrap 置信带, 右图展示多次 bootstrap 重抽样得到的曲线

需要注意的是, 这里的置信带描述的是条件均值函数 $m(x)$ 的估计不确定性, 而不是单个个体工资的预测区间. 由于样本量较大, 均值函数的置信带可能相对较窄. 这并不表示个体工资波动小, 而是表示对平均趋势的估计相对稳定.

7 方法之间的统一观点

本文涉及的几个非参数方法看似不同, 但它们可以从统一角度理解.

非参数对象	估计方法	调节参数	对应图像
分布函数 F	经验分布函数 $\hat{F}_n$	无	图 2
密度函数 f	核密度估计 $\hat{f}_h$	带宽 h	图 3
回归函数 $m(x)$	LOWESS / GAM	span / λ	图 4
估计不确定性	Bootstrap	重抽样次数 B	图 5

表 3: 本文实验中的非参数对象, 估计方法与复杂度控制方式

经验分布函数展示了非参数估计的最基本形式: 完全由样本构造总体分布的估计. DKW 不等式说明, 非参数方法也可以有分布无关的有限样本保证.

核密度估计说明, 当估计目标从分布函数变为密度函数时, 平滑是不可避免的. 带宽选择本质上是在偏差和方差之间折中.

非参数回归进一步把平滑思想推广到条件均值函数估计. LOWESS 通过局部窗口控制复杂度, GAM 或平滑样条通过惩罚项控制复杂度.

Bootstrap 则用于刻画非参数估计的不确定性. 当估计量的解析分布难以处理时, 重抽样方法可以提供一种实用的近似推断方式.

因此, 非参数统计的统一思想可以概括为:

少模型假设 + 复杂度控制 + 不确定性量化.

参考文献

1. Wasserman, L. *All of Nonparametric Statistics*. Springer Texts in Statistics, Springer, New York, 2006.
2. van der Vaart, A. W. and Wellner, J. A. *Weak Convergence and Empirical Processes: With Applications to Statistics*. Springer Series in Statistics, Springer, New York, 1996.
3. Dvoretzky, A., Kiefer, J. and Wolfowitz, J. Asymptotic minimax character of the sample distribution function and of the classical multinomial estimator. *The Annals of Mathematical Statistics*, 27(3):642–669, 1956.
4. Massart, P. The tight constant in the Dvoretzky–Kiefer–Wolfowitz inequality. *The Annals of Probability*, 18(3):1269–1283, 1990.
5. Silverman, B. W. *Density Estimation for Statistics and Data Analysis*. Monographs on Statistics and Applied Probability, Chapman and Hall, London, 1986.
6. Cleveland, W. S. Robust locally weighted regression and smoothing scatterplots. *Journal of the American Statistical Association*, 74(368):829–836, 1979.
7. Hastie, T. J. and Tibshirani, R. J. *Generalized Additive Models*. Chapman and Hall, London, 1990.
8. Efron, B. and Tibshirani, R. J. *An Introduction to the Bootstrap*. Chapman and Hall/CRC, New York, 1993.
9. Tsybakov, A. B. *Introduction to Nonparametric Estimation*. Springer Series in Statistics, Springer, New York, 2009.
10. James, G., Witten, D., Hastie, T., Tibshirani, R. and Taylor, J. *An Introduction to Statistical Learning with Applications in Python*. Springer Texts in Statistics, Springer, Cham, 2023.
11. Giné, E. and Nickl, R. *Mathematical Foundations of Infinite-Dimensional Statistical Models*. Cambridge University Press, Cambridge, 2016.