

时间序列分析

作者: Yukina

时间: 2026 年 6 月 20 日

目录

1	预备知识	1
1.1	简介	1
1.2	平稳时间序列	1
1.3	时间序列的预处理	5
1.4	方法性工具	9
2	ARMA 模型	14
2.1	AR 模型	14
2.2	MA 模型	22
2.3	ARMA 模型	25
3	参数估计	35
3.1	AR 模型的参数估计	35
3.2	MA 模型的参数估计	41
3.3	ARMA 模型的参数估计	46
4	预测	50
4.1	条件期望预测	50
4.2	ARMA 模型的预测	51
4.3	预测的修正	58
4.4	习题	60

Chapter 1

预备知识

§1.1 简介

时间序列分析的研究方法通常包括:

- 描述性时间序列分析. 早期的研究方法, 囿于当时时代的局限性, 统计工具并不发达, 人们仅能通过直观的数据比较或绘图观测, 寻找序列中蕴含的发展规律.
- 统计时间序列分析. 利用统计学分析时间序列. 该方法的研究重心在分析序列值内在的相关关系. 其可进一步分为一下两类:
 - 频域分析方法.
 - 时域分析方法.

时域分析方法具有相对固定的分析套路, 通常遵循如下分析步骤:

1. 考察观察值序列的特征 (描述性分析);
2. 选择适当的模型;
3. 根据序列的观察数据确定模型的口径 (参数估计);
4. 检验模型, 优化模型;
5. 利用拟合好的模型来推断序列其他的统计性质或预测序列未来的发展.

§1.2 平稳时间序列

1.2.1 特征统计量

Definition 1.1 对于时间序列 $\{X_t, t \in \mathbb{Z}\}$, 任取正整数 m , 任取

$$t_1, t_2, \dots, t_m \in \mathbb{Z},$$

则 m 维随机向量

$$(X_{t_1}, X_{t_2}, \dots, X_{t_m})^\top$$

的联合分布函数记为

$$F_{t_1, \dots, t_m}(x_1, \dots, x_m).$$

由所有这些有限维联合分布函数构成的全体

$$\{F_{t_1, \dots, t_m}(x_1, \dots, x_m) : m \in \mathbb{N}^+, t_1, \dots, t_m \in \mathbb{Z}\}$$

称为时间序列 $\{X_t\}$ 的概率分布族.

Definition 1.2 (均值函数) 对时间序列 $\{X_t, t \in \mathbb{Z}\}$, 若 X_t 的分布函数为 $F_t(x)$, 且

$$\int_{-\infty}^{+\infty} |x| dF_t(x) < \infty,$$

则定义

$$\mu_t := \mathbb{E}(X_t) = \int_{-\infty}^{+\infty} x dF_t(x).$$

称 μ_t 为时间序列在 t 时刻的均值函数.

Definition 1.3 (方差函数) 若

$$\int_{-\infty}^{+\infty} x^2 dF_t(x) < \infty,$$

则定义时间序列 $\{X_t\}$ 在 t 时刻的方差为

$$\sigma_t^2 = \mathbb{E}(X_t - \mu_t)^2 = \int_{-\infty}^{+\infty} (x - \mu_t)^2 dF_t(x).$$

称 σ_t^2 为时间序列的方差函数.

Definition 1.4 (ACF) 对时间序列 $\{X_t, t \in \mathbb{Z}\}$, 任取 $t, s \in \mathbb{Z}$, 定义

$$\gamma(t, s) = \mathbb{E}[(X_t - \mu_t)(X_s - \mu_s)].$$

称 $\gamma(t, s)$ 为时间序列 $\{X_t\}$ 的自协方差函数. 若方差非零, 进一步定义

$$\rho(t, s) = \frac{\gamma(t, s)}{\sqrt{\text{Var}(X_t)}\sqrt{\text{Var}(X_s)}}.$$

称 $\rho(t, s)$ 为时间序列 $\{X_t\}$ 的自相关系数, 简称 ACF.

1.2.2 平稳性

Definition 1.5 (严平稳) 设 $\{X_t, t \in \mathbb{Z}\}$ 为时间序列. 若对任意正整数 m , 任意

$$t_1, t_2, \dots, t_m \in \mathbb{Z}$$

和任意整数 $k \in \mathbb{Z}$, 随机向量

$$(X_{t_1}, X_{t_2}, \dots, X_{t_m})^\top$$

与

$$(X_{t_1+k}, X_{t_2+k}, \dots, X_{t_m+k})^\top$$

同分布, 则称 $\{X_t\}$ 为严平稳时间序列.

Definition 1.6 (宽平稳) 若时间序列 $\{X_t, t \in \mathbb{Z}\}$ 满足以下三个条件:

1. 对任意 $t \in \mathbb{Z}, \mathbb{E}(X_t^2) < \infty$;
2. 对任意 $t \in \mathbb{Z}, \mathbb{E}(X_t) = \mu$;
3. 对任意 $t, s \in \mathbb{Z}, \mathbb{E}[(X_t - \mu)(X_s - \mu)] = \gamma(t - s)$,

则称 $\{X_t\}$ 为宽平稳时间序列.

1.2.3 白噪声

Definition 1.7 (正态时间序列) 时间序列 $\{X_t, t \in \mathbb{Z}\}$ 称为正态时间序列, 如果任取正整数 n , 任取

$$t_1, t_2, \dots, t_n \in \mathbb{Z},$$

有限维随机向量

$$(X_{t_1}, X_{t_2}, \dots, X_{t_n})^\top$$

服从 n 维正态分布.

Remark 1.8 由于多元正态分布由均值向量和协方差矩阵唯一决定, 所以对正态时间序列而言, 宽平稳等价于严平稳.

Definition 1.9 (白噪声) 若时间序列 $\{\varepsilon_t, t \in \mathbb{Z}\}$ 满足:

1. 对任意 $t \in \mathbb{Z}, \mathbb{E}(\varepsilon_t) = \mu$;
2. 对任意 $t, s \in \mathbb{Z}$,

$$\gamma(t, s) = \begin{cases} \sigma^2, & t = s, \\ 0, & t \neq s, \end{cases}$$

则称 $\{\varepsilon_t\}$ 为白噪声, 记作 $\{\varepsilon_t\} \sim WN(\mu, \sigma^2)$.

Example 1.10 (布朗白噪声) 设 $\{B_t : t \in [0, \infty)\}$ 为标准布朗运动. 令

$$\varepsilon_t = B_{t+1} - B_t, \quad t = 1, 2, \dots$$

证明 $\{\varepsilon_t\}$ 是标准正态白噪声.

Proof. 由布朗运动增量分布可知, 对任意 t , $\varepsilon_t = B_{t+1} - B_t \sim N(0, 1)$, 因而 $\mathbb{E}(\varepsilon_t) = 0$ 且 $\text{Var}(\varepsilon_t) = 1$. 若 $t \neq s$, 则区间 $[t, t+1]$ 与 $[s, s+1]$ 对应的增量相互独立, 所以

$$\text{Cov}(\varepsilon_t, \varepsilon_s) = 0.$$

因此 $\{\varepsilon_t\} \sim WN(0, 1)$. 又因为每个 ε_t 都服从 $N(0, 1)$ 且不同时间之间相互独立, 所以它是独立标准正态白噪声. $\square$

Example 1.11 (泊松白噪声) 设 $\{N_t : t \in [0, \infty)\}$ 为参数 $\lambda > 0$ 的泊松过程. 令

$$\varepsilon_t = N_{t+1} - N_t - \lambda, \quad t = 1, 2, \dots$$

证明 $\{\varepsilon_t\}$ 是白噪声.

Proof. 由泊松过程增量分布可知, $N_{t+1} - N_t \sim P(\lambda)$. 因此

$$\mathbb{E}(\varepsilon_t) = \mathbb{E}(N_{t+1} - N_t) - \lambda = \lambda - \lambda = 0,$$

并且

$$\text{Var}(\varepsilon_t) = \text{Var}(N_{t+1} - N_t) = \lambda.$$

若 $t \neq s$, 则对应的泊松过程增量相互独立, 从而

$$\text{Cov}(\varepsilon_t, \varepsilon_s) = 0.$$

所以 $\{\varepsilon_t\} \sim WN(0, \lambda)$. 此外, 由于泊松过程具有独立增量, $\{\varepsilon_t\}$ 实际上是独立白噪声, 其边际分布满足 $\varepsilon_t + \lambda \sim P(\lambda)$. $\square$

1.2.4 平稳时间序列的统计性质

Proposition 1.12 若 $\{X_t, t \in \mathbb{Z}\}$ 是宽平稳时间序列, 则有:

1. 常数均值: $\mathbb{E}(X_t) = \mu, \forall t \in \mathbb{Z}$.
2. 自协方差函数只依赖于时间平移长度: $\gamma(t, s) = \gamma(t+k, s+k), \forall t, s, k \in \mathbb{Z}$.
3. 自相关系数也只依赖于时间平移长度: $\rho(t, s) = \rho(t+k, s+k), \forall t, s, k \in \mathbb{Z}$.

Proposition 1.13 设 $\{X_t\}$ 是宽平稳时间序列, 其自协方差函数为 $\gamma(k)$. 则:

1. 对称性: $\gamma(k) = \gamma(-k), \forall k \in \mathbb{Z}$.
2. 非负定性: 对任意 $n \in \mathbb{N}^+$, 自协方差矩阵

$$\Gamma_n = \begin{pmatrix} \gamma(0) & \gamma(1) & \cdots & \gamma(n-1) \\ \gamma(1) & \gamma(0) & \cdots & \gamma(n-2) \\ \vdots & \vdots & \ddots & \vdots \\ \gamma(n-1) & \gamma(n-2) & \cdots & \gamma(0) \end{pmatrix}$$

为对称非负定矩阵.

3. 有界性: $|\gamma(k)| \leq \gamma(0), \forall k \in \mathbb{Z}$.

Proof. 对称性来自协方差的对称性:

$$\gamma(k) = \text{Cov}(X_t, X_{t-k}) = \text{Cov}(X_{t-k}, X_t) = \gamma(-k).$$

下面证明非负定性. 任取 $a = (a_1, \dots, a_n)^\top \in \mathbb{R}^n$, 由宽平稳性,

$$\begin{aligned} a^\top \Gamma_n a &= \sum_{i=1}^n \sum_{j=1}^n a_i a_j \gamma(i-j) \\ &= \sum_{i=1}^n \sum_{j=1}^n a_i a_j \mathbb{E}[(X_i - \mu)(X_j - \mu)] \\ &= \mathbb{E} \left[\left(\sum_{i=1}^n a_i (X_i - \mu) \right)^2 \right] \geq 0. \end{aligned}$$

所以 Γ_n 非负定. 最后证明有界性. 令 $Y_t = X_t - \mu$, 由 Cauchy-Schwarz 不等式,

$$|\gamma(k)| = |\mathbb{E}(Y_t Y_{t+k})| \leq \sqrt{\mathbb{E}(Y_t^2) \mathbb{E}(Y_{t+k}^2)} = \sqrt{\gamma(0) \gamma(0)} = \gamma(0).$$

□

Example 1.14 设 α, β, λ 是常数, 随机变量 U 在 $(-\pi, \pi)$ 上服从均匀分布. 证明:

$$X_t = \alpha \sin(\lambda t + U) + \beta \cos(\lambda t + U), \quad t \in \mathbb{Z}$$

是宽平稳序列.

Proof. 直接计算得:

$$\begin{aligned} \mathbb{E}(X_t) &= 0 \\ \mathbb{E}(X_t X_s) &= \frac{\alpha^2 + \beta^2}{2} \cos(\lambda(t-s)) \\ \mathbb{E}(X_t^2) &= \frac{\alpha^2 + \beta^2}{2} < \infty \end{aligned}$$

于是 $\{X_t\}$ 为宽平稳序列.

□

§1.3 时间序列的预处理

时间序列建模通常遵循如下基本流程:

$$\text{Time Series} \longrightarrow \text{Stationarity Test} \longrightarrow \begin{cases} \text{Non-stationary} \longrightarrow \text{Stationarization,} \\ \text{Stationary} \longrightarrow \text{WN Test.} \end{cases}$$

进一步地,

$$\text{WN Test} \rightarrow \begin{cases} \text{WN} \rightarrow \text{STOP}, \\ \text{Non-WN} \rightarrow \text{ARMA Modeling}. \end{cases}$$

也就是说, 时间序列建模的第一步不是直接拟合模型, 而是先判断序列是否平稳; 若序列非平稳, 则需要先进行平稳化处理; 若序列已经平稳, 则进一步判断它是否为白噪声. 若平稳序列已经可以视为白噪声, 则说明序列中没有明显可提取的线性相关结构, 继续建立 ARMA 模型的意义不大.

1.3.1 平稳性检验

平稳性检验主要包括两类方法:

$$\begin{cases} \text{图检验法} \rightarrow \begin{cases} \text{时序图}, \\ \text{ACF 图}, \end{cases} \\ \text{假设检验} \rightarrow \text{单位根检验}. \end{cases}$$

图检验法是一种描述性方法. 从时序图上看, 平稳序列通常围绕某个稳定水平上下波动, 没有明显趋势、周期或方差随时间变化的现象. 从 ACF 图上看, 许多短记忆平稳序列的自相关系数会较快衰减到零; 相反, 非平稳序列的 ACF 往往衰减缓慢, 甚至在较大滞后阶数下仍保持较高水平.

下面通过五类典型序列说明时序图和 ACF 图的判别方法:

WN, Stationary AR(1), Trend Nonstationary Series, Seasonal Series, Random Walk.

Example 1: White Noise




Figure 1.1: 白噪声序列围绕常数水平随机波动, ACF 图中非零滞后阶数的样本自相关系数基本落在两倍标准差范围内, 因此该序列可以视为白噪声序列.


Example 2: Stationary AR(1), $\phi = 0.7$ 

Figure 1.2: 平稳 AR(1) 序列没有明显趋势和周期, 整体波动较为稳定; 但 ACF 图呈指数衰减拖尾, 说明序列存在短期相关性. 因此该序列是平稳非白噪声序列.


Example 3: Trend Nonstationary Series

Figure 1.3: 趋势型非平稳序列在时序图中表现出明显上升或下降趋势, ACF 图通常衰减缓慢, 说明序列具有强烈的时间依赖结构. 建模前通常需要先进行去趋势或差分处理.


Example 4: Seasonal Series

Figure 1.4: 该序列时序图呈现明显周期波动, ACF 图呈振荡结构, 并在季节滞后阶数附近出现显著相关, 因此该序列具有季节性. 建模前通常需要考虑季节差分或加入季节项.




Figure 1.5: 随机游走序列在时序图中呈现随机漂移, ACF 图长期保持较高水平且衰减很慢, 因此是典型的非平稳序列. 对纯随机游走进行一阶差分后, 通常可以得到白噪声序列.

1.3.2 白噪声检验

在完成基本的平稳性判断后, 还需要进一步判断序列是否为白噪声. 白噪声序列的核心特征是不同的滞后阶数之间不存在自相关, 即

$$\rho_k = 0, \quad \forall k \neq 0.$$

因此, 白噪声检验的基本思想就是: 考察序列在前若干个滞后阶数内是否存在显著的自相关结构.

白噪声检验在时间序列分析中有两种常见用途:

1. 对原始序列进行检验. 若原始序列不能拒绝白噪声假设, 则说明序列中没有明显的线性相关结构, 继续建立 ARMA 等模型的意义不大.
2. 对模型残差进行检验. 若残差不能拒绝白噪声假设, 则说明模型已经较充分地提取了序列中的线性相关信息; 若残差仍然拒绝白噪声假设, 则说明模型拟合不足, 还需要进一步改进.

理论上, 若 $\{X_t\}$ 是白噪声, 则对任意 $k \neq 0$ 都有 $\rho_k = 0$. 但在实际样本中, 样本自相关系数

$$\hat{\rho}_k = \frac{\sum_{t=k+1}^n (x_t - \bar{x})(x_{t-k} - \bar{x})}{\sum_{t=1}^n (x_t - \bar{x})^2}$$

不会严格等于零, 而只会在零附近随机波动. 这也是白噪声 ACF 图中仍然会出现少量非零样本自相关的原因.

Theorem 1.15 (Bartlett) 若 $\{X_t\}$ 是白噪声, 且观测长度为 n , 则在非零滞后阶数 k 下, 样本自相关系数近似满足

$$\hat{\rho}_k \sim N\left(0, \frac{1}{n}\right), \quad k \neq 0.$$

Remark 1.16 由 Bartlett 近似可得在白噪声假设下, $\hat{\rho}_k$ 的近似 95% 置信区间为

$$\left(-\frac{1.96}{\sqrt{n}}, \frac{1.96}{\sqrt{n}}\right),$$

实际作图时常近似写作 $\pm 2/\sqrt{n}$. 若大多数样本自相关系数落在这两条界限内, 则序列较可能是白噪声; 若有较多样本自相关系数超出界限, 则序列可能不是白噪声.

单独观察 ACF 图存在一个问题: 如果同时观察很多个滞后阶数, 即使序列本身是真正的白噪声, 也可能因为随机波动而出现个别样本自相关系数超出界限. 因此, 更合理的方法不是逐个检验每一个 ρ_k , 而是同时检验前若干阶自相关系数是否整体为零. 这类检验称为 port-manteau 检验, 也就是白噪声的整体检验. 设最大滞后阶数为 m . 白噪声检验通常考察

$$H_0: \rho_k = 0 \quad 1 \leq k \leq m$$

是否成立. 注意 m 不宜取得过大. 平稳短记忆序列的显著相关性通常集中在较小滞后阶数, 若 m 过大, 反而可能削弱检验对短期相关性的敏感性.

Box 和 Pierce 提出了用于整体检验前 m 阶自相关系数的统计量

$$Q = n \sum_{k=1}^m \hat{\rho}_k^2 \stackrel{H_0}{\sim} \chi^2(m).$$

但 Q 统计量仅在大样本情形下有良好分布, 为此 Ljung 和 Box 提出了修正统计量

$$LB = n(n+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{n-k}.$$

在原假设成立时,

$$LB \sim \chi^2(m).$$

该统计量性质显著优于 Q 统计量, 实际应用中往往使用 LB 统计量进行白噪声检验.

§1.4 方法性工具

1.4.1 差分与延迟算子

时间序列分析中常需要对序列进行平移、差分和滤波. 这些操作可以用延迟算子统一表示.

Definition 1.17 (延迟算子) 设 $\{X_t, t \in \mathbb{Z}\}$ 为时间序列. 称满足

$$BX_t = X_{t-1}$$

的算子 B 为延迟算子, 也称为向后推移算子. 更一般地, $B^p X_t = X_{t-p}$, 其中 $p \geq 1$.

Proposition 1.18 设 B 为延迟算子, 则有:

1. $B^0 = 1$, 且对任意 $p \geq 1$, $B^p X_t = X_{t-p}$.

2. 对任意常数 c , $B(cX_t) = cBX_t = cX_{t-1}$.

3. 对任意两个时间序列 $\{X_t\}$ 和 $\{Y_t\}$, $B(X_t \pm Y_t) = X_{t-1} \pm Y_{t-1}$.

4. 对任意常数 $c_0, c_1, \dots, c_n$,

$$\left(\sum_{i=0}^n c_i B^i \right) X_t = \sum_{i=0}^n c_i X_{t-i}.$$

5. 对任意正整数 d ,

$$(1 - B)^d = \sum_{i=0}^d (-1)^i \binom{d}{i} B^i.$$

6. 当 $|\phi| < 1$ 时, 在形式幂级数意义下有

$$(1 - \phi B)^{-1} = 1 + \phi B + \phi^2 B^2 + \dots.$$

Definition 1.19 (p 阶差分) 设 $p \geq 1$, 我们递归的定义序列 $\{X_t\}$ 的 p 阶差分:

$$\nabla^p X_t = \nabla^{p-1} X_t - \nabla^{p-1} X_{t-1} = \sum_{i=0}^p (-1)^i \binom{p}{i} X_{t-i}.$$

特别地

1. $p = 1$ 时, $\nabla X_t = X_t - X_{t-1}$;

2. $p = 2$ 时, $\nabla^2 X_t = \nabla(X_t - X_{t-1}) = X_t - 2X_{t-1} + X_{t-2}$.

Definition 1.20 (k 步差分) 称

$$\nabla_k X_t = X_t - X_{t-k} = (1 - B^k)X_t$$

为 k 步差分. 当 $k = 1$ 时, 它就是通常的一阶差分.

Remark 1.21 差分的主要作用是消除某些非平稳结构. 例如, 一阶差分常用于消除线性趋势或随机游走中的单位根结构; 季节差分 $(1 - B^s)X_t = X_t - X_{t-s}$ 常用于消除周期为 s 的季节性结构.

1.4.2 线性过程

Definition 1.22 (线性过程) 时间序列 $\{X_t, t \in \mathbb{Z}\}$ 称为线性过程, 如果它可以表示为

$$X_t = \sum_{j=-\infty}^{\infty} G_j \varepsilon_{t-j},$$

其中 $\{\varepsilon_t\}$ 是零均值白噪声序列, 即 $\mathbb{E}(\varepsilon_t) = 0$ 且 $\text{Var}(\varepsilon_t) = \sigma_\varepsilon^2$, 并且系数序列满足

$$\sum_{j=-\infty}^{\infty} G_j^2 < \infty.$$

条件 $\sum G_j^2 < \infty$ 保证上式在二阶意义下收敛.

Definition 1.23 (因果线性过程) 若线性过程满足 $G_j = 0, j < 0$, 则

$$X_t = \sum_{j=0}^{\infty} G_j \varepsilon_{t-j}.$$

此时称 $\{X_t\}$ 为因果线性过程. 因果性表示 X_t 只依赖当前扰动 ε_t 和过去扰动 $\varepsilon_{t-1}, \varepsilon_{t-2}, \dots$, 而不依赖未来扰动. 若进一步取 $G_0 = 1$, 则称其为规范化的因果线性过程.

Theorem 1.24 (线性过程的平稳性) 设

$$X_t = \sum_{j=-\infty}^{\infty} G_j \varepsilon_{t-j},$$

其中 $\{\varepsilon_t\}$ 是零均值白噪声序列, 且 $\sum_{j=-\infty}^{\infty} G_j^2 < \infty$. 则 $\{X_t\}$ 是宽平稳序列.

Proof. 由于 $\sum G_j^2 < \infty$, 线性过程在二阶意义下收敛. 首先,

$$\mathbb{E}(X_t) = \sum_{j=-\infty}^{\infty} G_j \mathbb{E}(\varepsilon_{t-j}) = 0.$$

因此均值为常数.

其次, 由白噪声不同时刻互不相关可得

$$\text{Var}(X_t) = \text{Var}\left(\sum_{j=-\infty}^{\infty} G_j \varepsilon_{t-j}\right) = \sigma_{\varepsilon}^2 \sum_{j=-\infty}^{\infty} G_j^2 < \infty.$$

所以二阶矩存在.

最后计算自协方差. 按照约定, 记 $\gamma(k) = \text{Cov}(X_t, X_{t-k})$. 则

$$\gamma(k) = \mathbb{E}(X_t X_{t-k}) = \mathbb{E}\left[\left(\sum_{j=-\infty}^{\infty} G_j \varepsilon_{t-j}\right) \left(\sum_{l=-\infty}^{\infty} G_l \varepsilon_{t-k-l}\right)\right].$$

由于 ε_{t-j} 与 ε_{t-k-l} 只有在 $t-j = t-k-l$ 时才可能相关, 即 $l = j-k$, 因此

$$\gamma(k) = \sigma_{\varepsilon}^2 \sum_{j=-\infty}^{\infty} G_j G_{j-k}.$$

该级数收敛, 因为由 Cauchy-Schwarz 不等式,

$$\sum_{j=-\infty}^{\infty} |G_j G_{j-k}| \leq \left(\sum_{j=-\infty}^{\infty} G_j^2\right)^{1/2} \left(\sum_{j=-\infty}^{\infty} G_{j-k}^2\right)^{1/2} < \infty.$$

因此 $\{X_t\}$ 是宽平稳序列. □

1.4.3 线性差分方程

Definition 1.25 (线性差分方程) 给定实数 $a_1, a_2, \dots, a_p$, 其中 $a_p \neq 0$, 以及 t 的已知函数 $h(t)$, 称

$$X_t - a_1 X_{t-1} - a_2 X_{t-2} - \dots - a_p X_{t-p} = h(t)$$

为 p 阶线性差分方程. 若 $h(t) = 0$, 则称为齐次线性差分方程; 若 $h(t) \neq 0$, 则称为非齐次线性差分方程.

Definition 1.26 (特征方程与特征根) 对齐次线性差分方程

$$X_t - a_1 X_{t-1} - a_2 X_{t-2} - \dots - a_p X_{t-p} = 0,$$

称

$$\lambda^p - a_1 \lambda^{p-1} - a_2 \lambda^{p-2} - \dots - a_p = 0$$

为其特征方程. 特征方程的根称为该差分方程的特征根.

线性差分方程的解

齐次线性差分方程的解由特征根决定. 常见情形如下表.

特征根类型	特征根形式	对应的线性无关解
单实根	λ	λ^t
d 重实根	λ	$\lambda^t, t\lambda^t, \dots, t^{d-1}\lambda^t$
一对共轭复根	$re^{\pm i\omega}$	$r^t \cos(\omega t), r^t \sin(\omega t)$
d 重共轭复根	$re^{\pm i\omega}$	$r^t t^j \cos(\omega t), r^t t^j \sin(\omega t), j = 0, \dots, d-1$

对非齐次方程, 只需考虑其对应齐次通解和一个非齐次特解.

$h(t)$ 的形式	特解的试探形式
b	C
$P_m(t)$	$Q_m(t)$
$b\alpha^t$	$C\alpha^t$
$P_m(t)\alpha^t$	$Q_m(t)\alpha^t$
$\cos(\omega t), \sin(\omega t)$	$A \cos(\omega t) + B \sin(\omega t)$
$r^t \cos(\omega t), r^t \sin(\omega t)$	$r^t \{A \cos(\omega t) + B \sin(\omega t)\}$

Example 1.27 解齐次线性差分方程

$$X_t - 5X_{t-1} + 9X_{t-2} - 8X_{t-3} + 4X_{t-4} = 0.$$

Solution. 特征根为

$$\lambda_1 = \lambda_2 = 2, \lambda_{3,4} = \frac{1 \pm \sqrt{3}i}{2}.$$

故原方程的通解为

$$X_t = (C_1 + C_2 t)2^t + C_3 \cos\left(\frac{\pi t}{3}\right) + C_4 \sin\left(\frac{\pi t}{3}\right).$$

□

Example 1.28 解非齐次线性差分方程

$$X_t - 3X_{t-1} + 2X_{t-2} = 2^t + t.$$

ARMA 模型

§2.1 AR 模型

2.1.1 AR 模型的定义

Definition 2.1 (AR(p) 模型) 称时间序列 $\{X_t, t \in \mathbb{Z}\}$ 满足 p 阶自回归模型, 简记为 AR(p) 模型, 如果

$$X_t = \phi_0 + \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} + \varepsilon_t,$$

其中 $\phi_p \neq 0$, 且 $\{\varepsilon_t\}$ 是零均值白噪声序列, 即

$$\mathbb{E}(\varepsilon_t) = 0, \quad \text{Var}(\varepsilon_t) = \sigma_\varepsilon^2, \quad \mathbb{E}(\varepsilon_t \varepsilon_s) = 0, \quad t \neq s.$$

此外, 通常还要求 ε_t 与过去序列值不相关, 即

$$\mathbb{E}(X_s \varepsilon_t) = 0, \quad s < t.$$

1. 若 $\phi_0 = 0$, 则称该模型为中心化 AR(p) 模型.
2. 若 $\phi_0 \neq 0$, 则称其为非中心化 AR(p) 模型. 可以在非中心化模型两边减去

$$\mu = \frac{\phi_0}{1 - \phi_1 - \cdots - \phi_p}$$

得到对应的中心化模型.

2.1.2 AR 模型的平稳性判别

对中心化 AR(p) 模型引入延迟算子 B , 即 $BX_t = X_{t-1}$. 则模型可写为

$$\Phi(B)X_t = \varepsilon_t,$$

其中

$$\Phi(u) = 1 - \phi_1 u - \phi_2 u^2 - \cdots - \phi_p u^p$$

称为 AR(p) 模型的自回归系数多项式.

Definition 2.2 (平稳域) 称使中心化 AR(p) 模型平稳的参数集合为平稳域, 即

$$\{(\phi_1, \dots, \phi_p) : \Phi(B)X_t = \varepsilon_t \text{ 是平稳的}\}.$$

Theorem 2.3 中心化 AR(p) 模型 $\Phi(B)X_t = \varepsilon_t$ 平稳的充要条件是自回归系数多项式

$$\Phi(u) = 1 - \phi_1 u - \phi_2 u^2 - \dots - \phi_p u^p$$

的所有根都在单位圆外. 等价地, 齐次差分方程对应的特征方程

$$\lambda^p - \phi_1 \lambda^{p-1} - \phi_2 \lambda^{p-2} - \dots - \phi_p = 0$$

的所有特征根都在单位圆内.

Example 2.4 (AR(2) 平稳) AR(2) 模型

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \varepsilon_t$$

平稳的充要条件为

$$\phi_1 + \phi_2 < 1, \quad \phi_2 - \phi_1 < 1, \quad \phi_2 > -1.$$

等价地, 其平稳域为

$$\{(\phi_1, \phi_2) : \phi_1 + \phi_2 < 1, \phi_2 - \phi_1 < 1, \phi_2 > -1\}.$$

Proof. 由韦达定理

$$\lambda_1 + \lambda_2 = \phi_1, \quad \lambda_1 \lambda_2 = -\phi_2.$$

模型平稳等价于 $|\lambda_1| < 1, |\lambda_2| < 1$, 于是

$$|\phi_2| = |\lambda_1 \lambda_2| < 1 \implies \phi_2 > -1,$$

$$\phi_1 + \phi_2 = \lambda_1 + \lambda_2 - \lambda_1 \lambda_2 < 1, \quad \phi_2 - \phi_1 = -\lambda_1 - \lambda_2 - \lambda_1 \lambda_2 < 1.$$

□

表 2.1: AR(1), AR(2), AR(3) 模型平稳域汇总

模型	平稳域
AR(1)	$ \phi_1 < 1$
AR(2)	$\phi_2 \pm \phi_1 < 1, \phi_2 > -1$
AR(3)	$\phi_2 \pm (\phi_1 + \phi_3) < 1, \phi_3 < 1, \phi_2 + \phi_1 \phi_3 > -1$

2.1.3 AR 模型的统计性质

均值和方差

对 $AR(p)$ 模型来说, 均值的计算比较直接, 而方差和协方差的计算则需要借助 Yule-Walker 方程或者 Green 函数表示. 对 $AR(p)$ 两边同时取数学期望并化简即可得到:

$$\mathbb{E}(X_t) = \mu = \frac{\phi_0}{1 - \phi_1 - \cdots - \phi_p}.$$

Theorem 2.5 (Yule-Walker 方程) 设 $\{X_t\}$ 是平稳中心化 $AR(p)$ 序列,

$$X_t = \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + \varepsilon_t.$$

记 $\gamma_k = \text{Cov}(X_t, X_{t-k})$, $\rho_k = \gamma_k / \gamma_0$. 则对任意 $k \geq 1$,

$$\gamma_k = \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2} + \cdots + \phi_p \gamma_{k-p}.$$

等价地,

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2} + \cdots + \phi_p \rho_{k-p}.$$

特别地, 令 $k = 1, \dots, p$, 得到矩阵形式

$$\begin{pmatrix} \rho_0 & \rho_1 & \cdots & \rho_{p-1} \\ \rho_1 & \rho_0 & \cdots & \rho_{p-2} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p-1} & \rho_{p-2} & \cdots & \rho_0 \end{pmatrix} \begin{pmatrix} \phi_1 \\ \phi_2 \\ \vdots \\ \phi_p \end{pmatrix} = \begin{pmatrix} \rho_1 \\ \rho_2 \\ \vdots \\ \rho_p \end{pmatrix}.$$

Proof. 对 $AR(p)$ 模型两边同乘 X_{t-k} 并取期望. 当 $k \geq 1$ 时, X_{t-k} 是过去变量, 因而 $\mathbb{E}(X_{t-k}\varepsilon_t) = 0$. 于是

$$\mathbb{E}(X_t X_{t-k}) = \sum_{i=1}^p \phi_i \mathbb{E}(X_{t-i} X_{t-k}).$$

由平稳性, $\mathbb{E}(X_t X_{t-k}) = \gamma_k$, 且 $\mathbb{E}(X_{t-i} X_{t-k}) = \gamma_{k-i}$. 因此

$$\gamma_k = \phi_1 \gamma_{k-1} + \cdots + \phi_p \gamma_{k-p}.$$

□

Remark 2.6 令 $\Gamma_p = (\gamma_0, \gamma_1, \dots, \gamma_p)^\top$. 则 Γ_p 由下面的方程组唯一决定:

$$\begin{cases} \gamma_0 - \sum_{i=1}^p \phi_i \gamma_i = \sigma_\varepsilon^2, \\ \gamma_k - \sum_{i=1}^p \phi_i \gamma_{|k-i|} = 0, & k = 1, \dots, p. \end{cases}$$

解出 Γ_p 后, γ_0 即为所求方差.

Example 2.7 (AR(2) 的方差) 设平稳 AR(2) 模型为

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \varepsilon_t.$$

则其方差为

$$\gamma_0 = \text{Var}(X_t) = \frac{(1 - \phi_2)\sigma_\varepsilon^2}{(1 + \phi_2)(1 - \phi_1 - \phi_2)(1 + \phi_1 - \phi_2)}.$$

方法 1. 由上面的注, 直接列方程

$$\begin{cases} \gamma_0 = \phi_1^2 \gamma_0 + \phi_2^2 \gamma_0 + 2\phi_1 \phi_2 \gamma_1 + \sigma_\varepsilon^2, \\ \gamma_1 = \phi_1 \gamma_0 + \phi_2 \gamma_1. \end{cases}$$

解下侧的方程得到 $\gamma_1 = \frac{\phi_1}{1 - \phi_2} \gamma_0$. 再带回上侧方程并化简得

$$\gamma_0 = \frac{(1 - \phi_2)\sigma_\varepsilon^2}{(1 + \phi_2)(1 - \phi_1 - \phi_2)(1 + \phi_1 - \phi_2)}.$$

□

下面我们介绍 Green 函数, 其也叫脉冲响应函数. 它回答的是下面这个问题:

某一时刻的随机扰动 ε_t 会如何影响现在和未来的 X ?

即序列的因果性.

Theorem 2.8 若中心化 AR(p) 模型 $\Phi(B)X_t = \varepsilon_t$ 平稳, 则它具有因果表示

$$X_t = \sum_{j=0}^{\infty} G_j \varepsilon_{t-j}, \quad G_0 = 1.$$

其中 Green 函数 $\{G_j\}_{j \geq 0}$ 满足递推关系

$$G_0 = 1, \quad G_j = \sum_{k=1}^j \phi'_k G_{j-k}, \quad j \geq 1,$$

其中

$$\phi'_k = \begin{cases} \phi_k, & k \leq p, \\ 0, & k > p. \end{cases}$$

Proof. 因为

$$\Phi(B)X_t = \varepsilon_t,$$

所以形式上有

$$X_t = \frac{1}{\Phi(B)} \varepsilon_t.$$

平稳性保证 $\Phi(B)^{-1}$ 可以展开成关于 B 的非负幂级数:

$$\frac{1}{\Phi(B)} = \sum_{j=0}^{\infty} G_j B^j.$$

因此

$$X_t = \sum_{j=0}^{\infty} G_j B^j \varepsilon_t = \sum_{j=0}^{\infty} G_j \varepsilon_{t-j}.$$

另一方面, 由 $\Phi(B) \sum_{j=0}^{\infty} G_j B^j = 1$ 可得

$$\left(1 - \sum_{k=1}^p \phi_k B^k\right) \left(\sum_{j=0}^{\infty} G_j B^j\right) = 1.$$

依次比较系数得到结论. □

Proposition 2.9 若平稳 AR(p) 模型具有因果表示

$$X_t = \sum_{j=0}^{\infty} G_j \varepsilon_{t-j},$$

则对 $h \geq 0$,

$$\gamma_h = \text{Cov}(X_t, X_{t-h}) = \sigma_{\varepsilon}^2 \sum_{j=0}^{\infty} G_j G_{j+h}.$$

下面我们利用 Green 函数来给出求解 AR(2) 模型方差的另一种方式.

方法 2. 考虑平稳 AR(2) 模型的 Green 函数表示

$$X_t = \sum_{j=0}^{\infty} G_j \varepsilon_{t-j},$$

其中

$$G_j = \begin{cases} \frac{\lambda_1^{j+1} - \lambda_2^{j+1}}{\lambda_1 - \lambda_2}, & \lambda_1 \neq \lambda_2, \\ (j+1)\lambda^j, & \lambda_1 = \lambda_2 = \lambda. \end{cases}$$

其中 $\lambda_{1,2}$ 为其特征方程根 (请自行计算, 这个结论并不显然). 因此

$$\text{Var}(X_t) = \sigma_{\varepsilon}^2 \sum_{j=0}^{\infty} G_j^2.$$

当 $\lambda_1 \neq \lambda_2$ 时,

$$\begin{aligned} \text{Var}(X_t) &= \frac{\sigma_{\varepsilon}^2}{(\lambda_1 - \lambda_2)^2} \sum_{j=0}^{\infty} (\lambda_1^{j+1} - \lambda_2^{j+1})^2 \\ &= \frac{\sigma_{\varepsilon}^2}{(\lambda_1 - \lambda_2)^2} \left[\frac{\lambda_1^2}{1 - \lambda_1^2} + \frac{\lambda_2^2}{1 - \lambda_2^2} - \frac{2\lambda_1\lambda_2}{1 - \lambda_1\lambda_2} \right]. \end{aligned}$$

当 $\lambda_1 = \lambda_2 = \lambda$ 时,

$$\text{Var}(X_t) = \sigma_{\varepsilon}^2 \sum_{j=0}^{\infty} (j+1)^2 \lambda^{2j}.$$

利用

$$\sum_{j=0}^{\infty} (j+1)^2 x^j = \frac{1+x}{(1-x)^3}, \quad |x| < 1,$$

令 $x = \lambda^2$, 得到

$$\text{Var}(X_t) = \sigma_\varepsilon^2 \frac{1+\lambda^2}{(1-\lambda^2)^3}.$$

另一方面, 由

$$\lambda_1 + \lambda_2 = \phi_1, \quad \lambda_1 \lambda_2 = -\phi_2,$$

可将上述结果统一写为

$$\text{Var}(X_t) = \frac{(1-\phi_2)\sigma_\varepsilon^2}{(1+\phi_2)(1-\phi_1-\phi_2)(1+\phi_1-\phi_2)}.$$

□

自相关函数

对 $\text{AR}(p)$ 模型而言, ACF 可以直接由 Yule-Walker 方程推出. 其核心特征是:

$\text{AR}(p)$ 模型的 ACF 一般拖尾.

Proposition 2.10 平稳 $\text{AR}(p)$ 模型的自相关函数一般是拖尾的, 即 ρ_k 通常不会在有限阶之后恒为零, 而是随着 k 增大逐渐衰减到零.

Proof. 由 Yule-Walker 方程,

$$\rho_k = \phi_1 \rho_{k-1} + \cdots + \phi_p \rho_{k-p}.$$

这是一个 p 阶齐次线性差分方程. 设其对应的特征方程为

$$\lambda^p - \phi_1 \lambda^{p-1} - \cdots - \phi_p = 0.$$

在无重根情形下, 其通解可写为 $\rho_k = \sum_{i=1}^p c_i \lambda_i^k$, 其中 $\lambda_1, \dots, \lambda_p$ 是特征根. 平稳性保证

$$|\lambda_i| < 1, \quad i = 1, \dots, p.$$

因此 $\rho_k \rightarrow 0$. 但是除非系数发生特殊抵消, ρ_k 一般不会从某一阶开始恒等于零. 因此, AR 模型的自相关函数具有拖尾性. □

偏自相关函数

ACF 衡量的是 X_t 与 X_{t-k} 之间的总体相关性. 但这种相关性可能是通过中间变量

$$X_{t-1}, X_{t-2}, \dots, X_{t-k+1}$$

间接传递产生的.

PACF 的思想是: 在给定中间 $k-1$ 个变量

$$X_{t-1}, X_{t-2}, \dots, X_{t-k+1}$$

之后, 再度量 X_{t-k} 对 X_t 的影响.

Definition 2.11 (偏自相关系数) 设 $\{X_t\}$ 是平稳时间序列. 对给定的滞后阶数 $k \geq 1$, 考虑中间变量

$$X_{t-1}, X_{t-2}, \dots, X_{t-k+1}.$$

$$\widehat{\mathbb{E}}(X_{t-k}) = \mathbb{E}(X_{t-k} \mid X_{t-1}, X_{t-2}, \dots, X_{t-k+1}).$$

令

$$u_t = X_t - \widehat{\mathbb{E}}(X_t), \quad u_{t-k} = X_{t-k} - \widehat{\mathbb{E}}(X_{t-k}).$$

称 u_t 与 u_{t-k} 的相关性度量延迟 k 阶偏自相关系数, 记为

$$\phi_{kk} = \rho(X_t, X_{t-k} \mid X_{t-1}, X_{t-2}, \dots, X_{t-k+1}).$$

或者

$$\phi_{kk} = \frac{\mathbb{E} \left\{ \left[X_t - \widehat{\mathbb{E}}(X_t) \right] \left[X_{t-k} - \widehat{\mathbb{E}}(X_{t-k}) \right] \right\}}{\sqrt{\mathbb{E} \left\{ \left[X_t - \widehat{\mathbb{E}}(X_t) \right]^2 \right\} \mathbb{E} \left\{ \left[X_{t-k} - \widehat{\mathbb{E}}(X_{t-k}) \right]^2 \right\}}}.$$

Proposition 2.12 对任意 $k \geq 1$, 线性预测系数

$$\phi_{k,1}, \phi_{k,2}, \dots, \phi_{k,k}$$

满足方程组

$$\begin{cases} \rho_1 = \phi_{k,1}\rho_0 + \phi_{k,2}\rho_1 + \dots + \phi_{k,k}\rho_{k-1}, \\ \rho_2 = \phi_{k,1}\rho_1 + \phi_{k,2}\rho_0 + \dots + \phi_{k,k}\rho_{k-2}, \\ \vdots \\ \rho_k = \phi_{k,1}\rho_{k-1} + \phi_{k,2}\rho_{k-2} + \dots + \phi_{k,k}\rho_0. \end{cases}$$

即矩阵形式为

$$\begin{pmatrix} \rho_0 & \rho_1 & \cdots & \rho_{k-1} \\ \rho_1 & \rho_0 & \cdots & \rho_{k-2} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{k-1} & \rho_{k-2} & \cdots & \rho_0 \end{pmatrix} \begin{pmatrix} \phi_{k,1} \\ \phi_{k,2} \\ \vdots \\ \phi_{k,k} \end{pmatrix} = \begin{pmatrix} \rho_1 \\ \rho_2 \\ \vdots \\ \rho_k \end{pmatrix}.$$

Proposition 2.13 (Durbin–Levinson 递推) 设 $\{X_t\}$ 是中心化平稳序列, 若已知自相关系数 $\rho_1, \rho_2, \dots$, 则

$$\phi_{1,1} = \rho_1.$$

当已知 $\phi_{k,1}, \dots, \phi_{k,k}$ 时, 有

$$\phi_{k+1,k+1} = \frac{\rho_{k+1} - \sum_{j=1}^k \phi_{k,j} \rho_{k+1-j}}{1 - \sum_{j=1}^k \phi_{k,j} \rho_j},$$

并且

$$\phi_{k+1,j} = \phi_{k,j} - \phi_{k+1,k+1} \phi_{k,k+1-j}, \quad j = 1, \dots, k.$$

因此

$$\alpha_{k+1} = \phi_{k+1,k+1}.$$

特别地,

$$\alpha_1 = \rho_1, \quad \alpha_2 = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2}.$$

Proposition 2.14 设 $\{X_t\}$ 是中心化平稳序列. 对任意 $k \geq 1$, 令

$$\Gamma_k = \begin{pmatrix} \rho_0 & \rho_1 & \cdots & \rho_{k-1} \\ \rho_1 & \rho_0 & \cdots & \rho_{k-2} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{k-1} & \rho_{k-2} & \cdots & \rho_0 \end{pmatrix}, \quad \mathbf{r}_k = \begin{pmatrix} \rho_1 \\ \rho_2 \\ \vdots \\ \rho_k \end{pmatrix}.$$

若 Γ_k 可逆, 则由 Yule-Walker 方程

$$\Gamma_k \begin{pmatrix} \phi_{k,1} \\ \phi_{k,2} \\ \vdots \\ \phi_{k,k} \end{pmatrix} = \mathbf{r}_k$$

可得

$$\alpha_k = \phi_{k,k} = \frac{\det \Gamma_k^{(k)}}{\det \Gamma_k},$$

其中 $\Gamma_k^{(k)}$ 表示将 Γ_k 的第 k 列替换为 $\mathbf{r}_k$ 后得到的矩阵.

Example 2.15 当 $k = 2$ 时,

$$\Gamma_2 = \begin{pmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{pmatrix}, \quad \mathbf{r}_2 = \begin{pmatrix} \rho_1 \\ \rho_2 \end{pmatrix}.$$

将 Γ_2 的第二列替换为 $\mathbf{r}_2$, 得

$$\Gamma_2^{(2)} = \begin{pmatrix} 1 & \rho_1 \\ \rho_1 & \rho_2 \end{pmatrix}.$$

因此

$$\alpha_2 = \frac{\det \Gamma_2^{(2)}}{\det \Gamma_2} = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2}.$$

Theorem 2.16 平稳中心化 $\text{AR}(p)$ 序列的偏自相关系数具有 p 步截尾性, 即

$$\phi_{k,k} = 0, \quad \forall k > p.$$

Remark 2.17 (AR 模型识别原则) AR 模型的识别常依赖两个典型特征:

ACF 拖尾, PACF 截尾.

具体来说, 若一个平稳序列的 ACF 逐渐衰减, 而 PACF 在 p 阶之后近似为零, 则可以优先考虑使用 $\text{AR}(p)$ 模型.

§2.2 MA 模型

2.2.1 MA 模型的定义

Definition 2.18 (MA(q) 模型) 称时间序列 $\{X_t, t \in \mathbb{Z}\}$ 满足 q 阶滑动平均模型, 简记为 MA(q) 模型, 如果

$$X_t = \mu + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots - \theta_q \varepsilon_{t-q},$$

其中 $\theta_q \neq 0$, 且 $\{\varepsilon_t\}$ 是零均值白噪声序列, 即

$$\mathbb{E}(\varepsilon_t) = 0, \quad \text{Var}(\varepsilon_t) = \sigma_\varepsilon^2, \quad \mathbb{E}(\varepsilon_t \varepsilon_s) = 0, \quad t \neq s.$$

1. 若 $\mu = 0$, 则称该模型为中心化 MA(q) 模型.
2. 若 $\mu \neq 0$, 则称该模型为非中心化 MA(q) 模型.

对中心化 MA(q) 模型引入延迟算子 B , 则中心化 MA(q) 模型可以写成

$$X_t = \Theta(B)\varepsilon_t,$$

其中

$$\Theta(u) = 1 - \theta_1 u - \theta_2 u^2 - \cdots - \theta_q u^q$$

称为 MA(q) 模型的移动平均系数多项式

2.2.2 MA 模型的平稳性

Theorem 2.19 MA(q) 模型总是平稳的.

Proof. 只需对中心化 MA(q) 模型进行证明. 设

$$X_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots - \theta_q \varepsilon_{t-q}.$$

对等式两边取期望, 得到

$$\mathbb{E}(X_t) = \mathbb{E}(\varepsilon_t) - \theta_1 \mathbb{E}(\varepsilon_{t-1}) - \cdots - \theta_q \mathbb{E}(\varepsilon_{t-q}) = 0.$$

故有常数均值. 下面计算自协方差函数. 对 $k \geq 0$, 有

$$\gamma_k = \text{Cov}(X_t, X_{t-k}) = \mathbb{E}(X_t X_{t-k}).$$

当 $k = 0$ 时,

$$\gamma_0 = \text{Var}(X_t) = (1 + \theta_1^2 + \theta_2^2 + \cdots + \theta_q^2) \sigma_\varepsilon^2.$$

当 $1 \leq k \leq q$ 时, 公共扰动项为

$$\varepsilon_{t-k}, \varepsilon_{t-k-1}, \dots, \varepsilon_{t-q}.$$

于是

$$\gamma_k = -\theta_k \sigma_\varepsilon^2 + \sum_{i=1}^{q-k} \theta_i \theta_{k+i} \sigma_\varepsilon^2.$$

即

$$\gamma_k = \left(-\theta_k + \sum_{i=1}^{q-k} \theta_i \theta_{k+i} \right) \sigma_\varepsilon^2, \quad 1 \leq k \leq q.$$

当 $k > q$ 时, X_t 与 X_{t-k} 中不含相同的白噪声项, 因此 $\gamma_k = 0$.

综上, 自协方差函数为

$$\gamma_k = \begin{cases} (1 + \theta_1^2 + \cdots + \theta_q^2) \sigma_\varepsilon^2, & k = 0, \\ \left(-\theta_k + \sum_{i=1}^{q-k} \theta_i \theta_{k+i} \right) \sigma_\varepsilon^2, & 1 \leq k \leq q, \\ 0, & k > q. \end{cases}$$

因此, γ_k 只依赖于滞后阶数 k , 不依赖于时间 t . 所以 MA(q) 模型平稳. □

2.2.3 MA 模型的可逆性

这部分结果的证明可以完全参考 AR 模型传递形式, 故略去.

Definition 2.20 (可逆性) 设中心化 MA(q) 模型为

$$X_t = \Theta(B) \varepsilon_t.$$

若它能够等价地表示成收敛的 AR(∞) 形式

$$\varepsilon_t = I(B) X_t,$$

其中

$$I(B) = 1 + I_1 B + I_2 B^2 + \cdots + I_j B^j + \cdots$$

是收敛的无穷级数, 则称该 MA(q) 模型是可逆模型.

Theorem 2.21 中心化 MA(q) 模型

$$X_t = \Theta(B) \varepsilon_t$$

可逆的充要条件是移动平均系数多项式

$$\Theta(u) = 1 - \theta_1 u - \theta_2 u^2 - \cdots - \theta_q u^q$$

的所有根都在单位圆外.

Remark 2.22 MA(q) 模型的可逆性与 AR(p) 模型的平稳性具有对偶关系:

$$\Theta(u) = 0 \text{ 的根都在单位圆外} \iff \text{MA}(q) \text{ 模型可逆},$$

$$\Phi(u) = 0 \text{ 的根都在单位圆外} \iff \text{AR}(p) \text{ 模型平稳}.$$

Theorem 2.23 (MA(q) 模型逆函数的递推公式) 若 MA(q) 模型

$$X_t = \Theta(B)\varepsilon_t$$

可逆, 则它可以写成逆转形式

$$\varepsilon_t = I(B)X_t,$$

其中

$$I(B) = 1 + I_1B + I_2B^2 + \cdots + I_jB^j + \cdots.$$

称 $\{I_j\}_{j \geq 0}$ 为 MA(q) 模型的逆函数. 其递推公式为

$$I_0 = 1, \quad I_j = \sum_{k=1}^j \theta'_k I_{j-k}, \quad j \geq 1,$$

其中

$$\theta'_k = \begin{cases} \theta_k, & k \leq q, \\ 0, & k > q. \end{cases}$$

2.2.4 MA 模型的统计性质

在证明 MA(q) 模型平稳时我们已经给出了其均值方差和自相关系数的显示解, 这部分我们主要讨论其偏自相关函数.

Proposition 2.24 (可逆 MA 模型 PACF 的拖尾性) 可逆 MA(q) 模型的偏自相关函数一般具有拖尾性.

Proof. 若 MA(q) 模型可逆, 则

$$X_t = \Theta(B)\varepsilon_t$$

可以等价地写成收敛的 AR(∞) 形式:

$$I(B)X_t = \varepsilon_t.$$

也就是说, 可逆 MA(q) 模型等价于一个无限阶自回归模型.

由于 AR(p) 模型的 PACF 在 p 阶后截尾, 而 AR(∞) 模型可以理解为阶数无限的自回归模型, 因此可逆 MA(q) 模型的 PACF 一般不会有有限阶后截尾, 而是表现为拖尾. $\square$

Example 2.25 (可逆 MA(1) 模型的偏自相关系数) 设可逆 MA(1) 模型为

$$X_t = \varepsilon_t - \theta_1\varepsilon_{t-1}.$$

由偏自相关系数的定义, 第 k 阶偏自相关系数是将序列按 AR(k) 形式处理时最高阶滞后项前的系数:

$$X_t = \phi_{k,1}X_{t-1} + \phi_{k,2}X_{t-2} + \cdots + \phi_{k,k}X_{t-k} + \varepsilon_t.$$

因此

$$\alpha_k = \phi_{k,k}.$$

利用 Yule-Walker 方程并结合 Cramer 法则, 可以得到

$$\begin{aligned}\phi_{1,1} &= -\frac{\theta_1}{1 + \theta_1^2}, \\ \phi_{2,2} &= -\frac{\theta_1^2}{1 + \theta_1^2 + \theta_1^4}, \\ \phi_{3,3} &= -\frac{\theta_1^3}{1 + \theta_1^2 + \theta_1^4 + \theta_1^6}.\end{aligned}$$

以此类推,

$$\phi_{k,k} = -\frac{\theta_1^k}{\sum_{j=0}^{k-1} \theta_1^{2j}}, \quad k = 1, 2, 3, \dots$$

所以

$$\alpha_k = -\frac{\theta_1^k}{\sum_{j=0}^{k-1} \theta_1^{2j}}, \quad k = 1, 2, 3, \dots$$

这说明 MA(1) 模型的 PACF 不会在有限阶后严格为零, 而是随着 k 增大逐渐衰减, 表现为拖尾.

Remark 2.26 (MA 模型识别原则) MA 模型的识别常依赖如下典型特征:

ACF 截尾, PACF 拖尾.

具体来说, 若一个平稳序列的 ACF 在 q 阶之后近似为零, 而 PACF 逐渐衰减或振荡衰减, 则可以优先考虑使用 MA(q) 模型.

§ 2.3 ARMA 模型

2.3.1 ARMA 模型的定义

Definition 2.27 (ARMA(p, q) 模型) 称时间序列 $\{X_t, t \in \mathbb{Z}\}$ 满足自回归滑动平均模型, 简记为 ARMA(p, q) 模型, 如果

$$X_t = \phi_0 + \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q},$$

其中 $\phi_p \neq 0, \theta_q \neq 0$, 且 $\{\varepsilon_t\}$ 是零均值白噪声序列, 即

$$\mathbb{E}(\varepsilon_t) = 0, \quad \text{Var}(\varepsilon_t) = \sigma_\varepsilon^2, \quad \mathbb{E}(\varepsilon_t \varepsilon_s) = 0, \quad t \neq s.$$

此外, 通常还要求当期随机扰动与过去序列值不相关, 即

$$\mathbb{E}(X_s \varepsilon_t) = 0, \quad s < t.$$

Remark 2.28 ARMA(p, q) 模型包含 AR 模型和 MA 模型作为特例:

1. 当 $q = 0$ 时, ARMA(p, q) 模型退化为 AR(p) 模型;
2. 当 $p = 0$ 时, ARMA(p, q) 模型退化为 MA(q) 模型.

对中心化 ARMA(p, q) 模型引入延迟算子 B , 则模型可以写成

$$\Phi(B)X_t = \Theta(B)\varepsilon_t,$$

通常要求 $\Phi(B)$ 和 $\Theta(B)$ 没有公因子. 若二者有公因子, 则模型可以约去公因子, 从而化为更低阶的 ARMA 模型.

2.3.2 ARMA 模型的平稳性与可逆性

平稳性条件

Theorem 2.29 中心化 ARMA(p, q) 模型

$$\Phi(B)X_t = \Theta(B)\varepsilon_t$$

平稳的充要条件是自回归系数多项式

$$\Phi(u) = 1 - \phi_1 u - \phi_2 u^2 - \cdots - \phi_p u^p$$

的所有根都在单位圆外.

可逆性条件

Theorem 2.30 中心化 ARMA(p, q) 模型

$$\Phi(B)X_t = \Theta(B)\varepsilon_t$$

可逆的充要条件是滑动平均系数多项式

$$\Theta(u) = 1 - \theta_1 u - \theta_2 u^2 - \cdots - \theta_q u^q$$

的所有根都在单位圆外.

Remark 2.31 ARMA(p, q) 模型的平稳性和可逆性分别由两个部分决定:

平稳性由自回归部分 $\Phi(B)$ 决定,

可逆性由滑动平均部分 $\Theta(B)$ 决定.

因此, 当

$$\Phi(u) = 0, \quad \Theta(u) = 0$$

的所有根都在单位圆外时, ARMA(p, q) 模型平稳且可逆.

2.3.3 ARMA 模型的传递形式和逆转形式

传递形式

Theorem 2.32 若中心化 ARMA(p, q) 模型

$$\Phi(B)X_t = \Theta(B)\varepsilon_t$$

平稳, 则它可以写成传递形式, 即 MA(∞) 形式:

$$X_t = \sum_{j=0}^{\infty} G_j \varepsilon_{t-j}.$$

其中 $\{G_j\}_{j \geq 0}$ 称为 Green 函数, 满足递推公式

$$\begin{aligned} G_0 &= 1, \\ G_j &= \sum_{k=1}^j \phi'_k G_{j-k} - \theta'_j, \quad j \geq 1, \end{aligned}$$

其中

$$\phi'_k = \begin{cases} \phi_k, & k \leq p, \\ 0, & k > p, \end{cases} \quad \theta'_k = \begin{cases} \theta_k, & k \leq q, \\ 0, & k > q. \end{cases}$$

Example 2.33 (ARMA(1, 1) 模型的 Green 函数) 设平稳 ARMA(1, 1) 模型为

$$X_t = \phi_1 X_{t-1} + \varepsilon_t - \theta_1 \varepsilon_{t-1}.$$

其算子形式为

$$(1 - \phi_1 B)X_t = (1 - \theta_1 B)\varepsilon_t.$$

于是

$$X_t = \frac{1 - \theta_1 B}{1 - \phi_1 B} \varepsilon_t.$$

由于平稳性要求

$$|\phi_1| < 1,$$

所以

$$\frac{1}{1 - \phi_1 B} = 1 + \phi_1 B + \phi_1^2 B^2 + \cdots.$$

因此

$$\begin{aligned} X_t &= (1 - \theta_1 B)(1 + \phi_1 B + \phi_1^2 B^2 + \cdots) \varepsilon_t \\ &= [1 + (\phi_1 - \theta_1)B + (\phi_1^2 - \theta_1 \phi_1)B^2 + (\phi_1^3 - \theta_1 \phi_1^2)B^3 + \cdots] \varepsilon_t. \end{aligned}$$

所以

$$X_t = \varepsilon_t + \sum_{j=1}^{\infty} (\phi_1^j - \theta_1 \phi_1^{j-1}) \varepsilon_{t-j}.$$

从而

$$\begin{aligned} G_0 &= 1, \\ G_j &= \phi_1^j - \theta_1 \phi_1^{j-1} = (\phi_1 - \theta_1) \phi_1^{j-1}, \quad j = 1, 2, \dots \end{aligned}$$

Example 2.34 (ARMA(2, 1) 模型的 Green 函数) 设平稳 ARMA(2, 1) 模型为

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \varepsilon_t - \theta_1 \varepsilon_{t-1}.$$

其算子形式为

$$(1 - \phi_1 B - \phi_2 B^2)X_t = (1 - \theta_1 B)\varepsilon_t.$$

设

$$1 - \phi_1 B - \phi_2 B^2 = (1 - \lambda_1 B)(1 - \lambda_2 B),$$

其中 $1/\lambda_1, 1/\lambda_2$ 是自回归系数多项式

$$\Phi(u) = 1 - \phi_1 u - \phi_2 u^2$$

的两个根. 则

$$X_t = \frac{1 - \theta_1 B}{(1 - \lambda_1 B)(1 - \lambda_2 B)} \varepsilon_t.$$

当 $\lambda_1 \neq \lambda_2$ 时, 作部分分式分解:

$$\frac{1 - \theta_1 B}{(1 - \lambda_1 B)(1 - \lambda_2 B)} = \frac{\lambda_1 - \theta_1}{\lambda_1 - \lambda_2} \cdot \frac{1}{1 - \lambda_1 B} + \frac{\lambda_2 - \theta_1}{\lambda_2 - \lambda_1} \cdot \frac{1}{1 - \lambda_2 B}.$$

因此

$$X_t = \sum_{j=0}^{\infty} \left[\left(\frac{\lambda_1 - \theta_1}{\lambda_1 - \lambda_2} \right) \lambda_1^j + \left(\frac{\lambda_2 - \theta_1}{\lambda_2 - \lambda_1} \right) \lambda_2^j \right] \varepsilon_{t-j}.$$

所以

$$G_j = \left(\frac{\lambda_1 - \theta_1}{\lambda_1 - \lambda_2} \right) \lambda_1^j + \left(\frac{\lambda_2 - \theta_1}{\lambda_2 - \lambda_1} \right) \lambda_2^j, \quad j = 0, 1, 2, \dots$$

逆转形式

Theorem 2.35 若中心化 ARMA(p, q) 模型

$$\Phi(B)X_t = \Theta(B)\varepsilon_t$$

可逆, 则它可以写成逆转形式, 即 AR(∞) 形式:

$$\varepsilon_t = \sum_{j=0}^{\infty} I_j X_{t-j}.$$

其中 $\{I_j\}_{j \geq 0}$ 称为逆函数, 满足递推公式

$$I_0 = 1,$$

$$I_j = \sum_{k=1}^j \theta'_k I_{j-k} - \phi'_j, \quad j \geq 1,$$

其中

$$\theta'_k = \begin{cases} \theta_k, & k \leq q, \\ 0, & k > q, \end{cases} \quad \phi'_k = \begin{cases} \phi_k, & k \leq p, \\ 0, & k > p. \end{cases}$$

Remark 2.36 与传递形式完全相同的计算方式, 请自行验证 ARMA(1, 1) 和 ARMA(1, 2) 的逆函数.

2.3.4 ARMA 模型的统计性质

均值

Proposition 2.37 (ARMA(p, q) 模型的均值) 平稳中心化 ARMA(p, q) 模型

$$\Phi(B)X_t = \Theta(B)\varepsilon_t$$

的均值为

$$\mathbb{E}(X_t) = 0.$$

平稳非中心化 ARMA(p, q) 模型

$$\Phi(B)X_t = \phi_0 + \Theta(B)\varepsilon_t$$

的均值为

$$\mathbb{E}(X_t) = \frac{\phi_0}{1 - \phi_1 - \cdots - \phi_p},$$

其中要求

$$1 - \phi_1 - \cdots - \phi_p \neq 0.$$

Proof. 对非中心化 ARMA(p, q) 模型两边取期望. 由于

$$\mathbb{E}(\varepsilon_t) = 0,$$

并且平稳序列均值为常数, 记

$$\mathbb{E}(X_t) = \mu,$$

则

$$\mu = \phi_0 + \phi_1\mu + \cdots + \phi_p\mu.$$

因此

$$(1 - \phi_1 - \cdots - \phi_p)\mu = \phi_0.$$

所以

$$\mu = \frac{\phi_0}{1 - \phi_1 - \cdots - \phi_p}.$$

特别地, 当 $\phi_0 = 0$ 时,

$$\mathbb{E}(X_t) = 0.$$

□

自协方差函数和自相关函数

Proposition 2.38 (ARMA(p, q) 模型的自协方差函数) 设平稳中心化 ARMA(p, q) 模型具有传递形式

$$X_t = \sum_{j=0}^{\infty} G_j \varepsilon_{t-j}.$$

则其自协方差函数为

$$\gamma_k = \text{Cov}(X_t, X_{t+k}) = \sigma_\varepsilon^2 \sum_{j=0}^{\infty} G_j G_{j+k}, \quad k \geq 0.$$

Proof. 由传递形式,

$$X_t = \sum_{j=0}^{\infty} G_j \varepsilon_{t-j},$$

$$X_{t+k} = \sum_{i=0}^{\infty} G_i \varepsilon_{t+k-i}.$$

因此

$$\gamma_k = \mathbb{E}(X_t X_{t+k}) = \mathbb{E} \left[\left(\sum_{j=0}^{\infty} G_j \varepsilon_{t-j} \right) \left(\sum_{i=0}^{\infty} G_i \varepsilon_{t+k-i} \right) \right].$$

由于白噪声序列不同时刻不相关, 只有当

$$t - j = t + k - i$$

即

$$i = j + k$$

时, 乘积期望才不为零. 于是

$$\gamma_k = \sigma_\varepsilon^2 \sum_{j=0}^{\infty} G_j G_{j+k}.$$

□

Proposition 2.39 (ARMA(p, q) 模型的自相关函数) 平稳中心化 ARMA(p, q) 模型的自相关函数为

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \frac{\sum_{j=0}^{\infty} G_j G_{j+k}}{\sum_{j=0}^{\infty} G_j^2}, \quad k \geq 0.$$

Proof. 由自相关函数定义,

$$\rho_k = \frac{\gamma_k}{\gamma_0}.$$

又

$$\gamma_k = \sigma_\varepsilon^2 \sum_{j=0}^{\infty} G_j G_{j+k},$$

$$\gamma_0 = \sigma_\varepsilon^2 \sum_{j=0}^{\infty} G_j^2.$$

两式相除, 即得

$$\rho_k = \frac{\sum_{j=0}^{\infty} G_j G_{j+k}}{\sum_{j=0}^{\infty} G_j^2}.$$

□

ACF 和 PACF 的拖尾性

Proposition 2.40 (ARMA(p, q) 模型 ACF 的拖尾性) 平稳 ARMA(p, q) 模型的自相关函数一般具有拖尾性.

Proof. 平稳 ARMA(p, q) 模型可以写成传递形式

$$X_t = \sum_{j=0}^{\infty} G_j \varepsilon_{t-j}.$$

这说明平稳 ARMA(p, q) 模型可以看作一个 MA(∞) 模型.

由于 MA(q) 模型的自相关函数在 q 阶后截尾, 而 MA(∞) 模型可以理解为阶数无限的滑动平均模型, 所以 ARMA(p, q) 模型的自相关函数一般不会在有限阶后截尾, 而是表现为拖尾.

□

Proposition 2.41 (ARMA(p, q) 模型 PACF 的拖尾性) 平稳可逆 ARMA(p, q) 模型的偏自相关函数一般具有拖尾性.

Proof. 若 ARMA(p, q) 模型可逆, 则它可以写成逆转形式

$$\varepsilon_t = \sum_{j=0}^{\infty} I_j X_{t-j}.$$

这说明可逆 ARMA(p, q) 模型可以看作一个 AR(∞) 模型.

由于 AR(p) 模型的偏自相关函数在 p 阶后截尾, 而 AR(∞) 模型可以理解为阶数无限的自回归模型, 所以 ARMA(p, q) 模型的偏自相关函数一般不会在有限阶后截尾, 而是表现为拖尾.

□

Remark 2.42 (ARMA 模型识别原则) ARMA(p, q) 模型的典型识别特征为

ACF 拖尾, PACF 拖尾.

也就是说, 若某个平稳序列的 ACF 与 PACF 均不表现出明显截尾, 而是逐渐衰减或振荡衰减, 则可以考虑使用 ARMA 模型.

ARMA(1, 1) 模型的统计性质

Example 2.43 (ARMA(1, 1) 模型的方差、自协方差函数和自相关函数) 设平稳可逆 ARMA(1, 1) 模型为

$$X_t = \phi_1 X_{t-1} + \varepsilon_t - \theta_1 \varepsilon_{t-1}.$$

其 Green 函数为

$$G_0 = 1,$$

$$G_j = \phi_1^j - \theta_1 \phi_1^{j-1} = (\phi_1 - \theta_1) \phi_1^{j-1}, \quad j = 1, 2, \dots$$

首先, 方差为

$$\gamma_0 = \text{Var}(X_t) = \sigma_\varepsilon^2 \sum_{j=0}^{\infty} G_j^2.$$

因此

$$\begin{aligned} \gamma_0 &= \sigma_\varepsilon^2 \left[1 + \sum_{j=1}^{\infty} (\phi_1 - \theta_1)^2 \phi_1^{2j-2} \right] \\ &= \sigma_\varepsilon^2 \left[1 + (\phi_1 - \theta_1)^2 \sum_{j=1}^{\infty} \phi_1^{2j-2} \right] \\ &= \sigma_\varepsilon^2 \left[1 + \frac{(\phi_1 - \theta_1)^2}{1 - \phi_1^2} \right] \\ &= \frac{1 - 2\theta_1\phi_1 + \theta_1^2}{1 - \phi_1^2} \sigma_\varepsilon^2. \end{aligned}$$

其次, 当 $k \geq 1$ 时, 自协方差函数为

$$\gamma_k = \sigma_\varepsilon^2 \sum_{j=0}^{\infty} G_j G_{j+k}.$$

由 $G_0 = 1$ 和

$$G_j = (\phi_1 - \theta_1) \phi_1^{j-1}, \quad j \geq 1,$$

可得

$$\begin{aligned} \gamma_k &= \sigma_\varepsilon^2 \left[G_0 G_k + \sum_{j=1}^{\infty} G_j G_{j+k} \right] \\ &= \sigma_\varepsilon^2 \left[(\phi_1 - \theta_1) \phi_1^{k-1} + \sum_{j=1}^{\infty} (\phi_1 - \theta_1)^2 \phi_1^{j-1} \phi_1^{j+k-1} \right] \\ &= \sigma_\varepsilon^2 \left[(\phi_1 - \theta_1) \phi_1^{k-1} + (\phi_1 - \theta_1)^2 \phi_1^k \sum_{j=1}^{\infty} \phi_1^{2j-2} \right] \\ &= \sigma_\varepsilon^2 \left[(\phi_1 - \theta_1) \phi_1^{k-1} + \frac{(\phi_1 - \theta_1)^2 \phi_1^k}{1 - \phi_1^2} \right] \\ &= \frac{(1 - \theta_1 \phi_1)(\phi_1 - \theta_1)}{1 - \phi_1^2} \phi_1^{k-1} \sigma_\varepsilon^2. \end{aligned}$$

因此, 自相关函数为

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \frac{(1 - \theta_1 \phi_1)(\phi_1 - \theta_1)}{1 - 2\theta_1 \phi_1 + \theta_1^2} \phi_1^{k-1}, \quad k = 1, 2, \dots$$

我们将本章的内容总结为下表.

图 2.1-图 2.3 展示了三类常见平稳时间序列模型的典型图形识别特征.

表 2.2: AR、MA 与 ARMA 模型的性质对比

特征	AR(p)	MA(q)	ARMA(p, q)
模型方程	$\Phi(B)X_t = \varepsilon_t$	$X_t = \Theta(B)\varepsilon_t$	$\Phi(B)X_t = \Theta(B)\varepsilon_t$
平稳性条件	$\Phi(u) \neq 0, u \leq 1$	无条件平稳	$\Phi(u) \neq 0, u \leq 1$
可逆性条件	无条件可逆	$\Theta(u) \neq 0, u \leq 1$	$\Theta(u) \neq 0, u \leq 1$
传递形式	$X_t = \Phi^{-1}(B)\varepsilon_t$	$X_t = \Theta(B)\varepsilon_t$	$X_t = \Phi^{-1}(B)\Theta(B)\varepsilon_t$
逆转形式	$\varepsilon_t = \Phi(B)X_t$	$\varepsilon_t = \Theta^{-1}(B)X_t$	$\varepsilon_t = \Theta^{-1}(B)\Phi(B)X_t$
自相关函数	拖尾	q 阶截尾	拖尾
偏自相关函数	p 阶截尾	拖尾	拖尾




Figure 2.1: AR(3) 模型的 ACF 拖尾与 PACF 三阶截尾




Figure 2.2: MA(2) 模型的 ACF 二阶截尾与 PACF 拖尾




Figure 2.3: ARMA(2,1) 模型的 ACF 拖尾与 PACF 拖尾

Chapter 3

参数估计

§3.1 AR 模型的参数估计

考虑非中心化 AR(p) 模型

$$X_t = \phi_0 + \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + \varepsilon_t, \quad \{\varepsilon_t\} \sim WN(0, \sigma_\varepsilon^2).$$

若模型平稳, 则均值为

$$\mu = \frac{\phi_0}{1 - \phi_1 - \cdots - \phi_p}.$$

令

$$Y_t = X_t - \mu,$$

则中心化序列满足

$$Y_t = \phi_1 Y_{t-1} + \cdots + \phi_p Y_{t-p} + \varepsilon_t.$$

因此, 估计 AR 系数时常先讨论中心化模型, 再由均值关系恢复截距项 ϕ_0 .

3.1.1 记号约定

记

$$\phi = (\phi_1, \dots, \phi_p)', \quad Z_t = (X_{t-1}, X_{t-2}, \dots, X_{t-p})'.$$

中心化 AR(p) 模型可以写成

$$X_t = Z_t' \phi + \varepsilon_t.$$

给定一段样本

$$x_1, x_2, \dots, x_n.$$

则样本统计量有如下表示

1. 样本均值:

$$\hat{\mu} = \bar{x} = \frac{1}{n} \sum_{t=1}^n x_t.$$

2. 样本自协方差:

$$\hat{\gamma}(k) = \frac{1}{n-k} \sum_{t=1}^{n-k} (x_t - \bar{x})(x_{t+k} - \bar{x}), \quad 0 < k < n.$$

3. 样本方差:

$$\hat{\gamma}(0) = \frac{1}{n-1} \sum_{t=1}^n (x_t - \bar{x})^2.$$

4. 样本自相关系数:

$$\hat{\rho}(k) = \frac{\hat{\gamma}(k)}{\hat{\gamma}(0)} = \frac{(n-1) \sum_{t=1}^{n-k} (x_t - \bar{x})(x_{t+k} - \bar{x})}{(n-k) \sum_{t=1}^n (x_t - \bar{x})^2}, \quad 0 < k < n.$$

在 Yule-Walker 估计中, 记

$$\hat{R}_p = \begin{pmatrix} 1 & \hat{\rho}(1) & \cdots & \hat{\rho}(p-1) \\ \hat{\rho}(1) & 1 & \cdots & \hat{\rho}(p-2) \\ \vdots & \vdots & \ddots & \vdots \\ \hat{\rho}(p-1) & \hat{\rho}(p-2) & \cdots & 1 \end{pmatrix}, \quad \hat{r}_p = \begin{pmatrix} \hat{\rho}(1) \\ \hat{\rho}(2) \\ \vdots \\ \hat{\rho}(p) \end{pmatrix},$$

3.1.2 Yule-Walker 估计

Yule-Walker 估计就是 AR 模型中的矩估计. 其基本思想是用样本自相关函数替代理论自相关函数.

对中心化 AR(p) 模型

$$X_t = \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + \varepsilon_t,$$

Yule-Walker 方程为

$$R_p \phi = r_p.$$

若 R_p 非奇异, 则

$$\phi = R_p^{-1} r_p.$$

用样本自相关替代理论自相关, 得到

$$\boxed{\hat{\phi}_{YW} = \hat{R}_p^{-1} \hat{r}_p}.$$

白噪声方差由

$$\gamma(0) = \phi_1 \gamma(1) + \cdots + \phi_p \gamma(p) + \sigma_\varepsilon^2$$

给出, 因此

$$\sigma_\varepsilon^2 = \gamma(0) - \sum_{j=1}^p \phi_j \gamma(j).$$

对应估计量为

$$\hat{\sigma}_{YW}^2 = \hat{\gamma}(0) - \sum_{j=1}^p \hat{\phi}_j \hat{\gamma}(j).$$

若原模型含有截距项 ϕ_0 , 则用

$$\mu = \frac{\phi_0}{1 - \phi_1 - \cdots - \phi_p}$$

得到

$$\hat{\phi}_{0,YW} = \bar{x} \left(1 - \hat{\phi}_1 - \cdots - \hat{\phi}_p \right).$$

下面是在 Matlab 中实现 AR(2) 模型的矩估计.

```

1 function result = AR2MM(y)
2     n = length(y);
3     mu = mean(y);
4     x = y - mu;
5
6     g0 = sum(x(1:n).*x(1:n))/n;
7     g1 = sum(x(2:n).*x(1:n-1))/n;
8     g2 = sum(x(3:n).*x(1:n-2))/n;
9
10    r1 = g1/g0;
11    r2 = g2/g0;
12
13    phi2hat = (r2 - r1^2)/(1 - r1^2);
14    phi1hat = r1*(1 - r2)/(1 - r1^2);
15    phi0hat = mu*(1 - phi1hat - phi2hat);
16
17    result = [phi0hat phi1hat phi2hat];
18 end
    
```

Listing 3.1: AR(2) 模型的矩估计

3.1.3 最小二乘估计

AR(p) 模型可以写成回归形式

$$X_t = Z_t' \phi + \varepsilon_t, \quad Z_t = (X_{t-1}, \dots, X_{t-p})'.$$

给定样本 $x_1, \dots, x_n$, 从 $t = p + 1$ 开始构造残差平方和

$$S(\phi) = \sum_{t=p+1}^n (x_t - Z_t' \phi)^2.$$

这里在代入样本后,

$$Z_t = (x_{t-1}, \dots, x_{t-p})'.$$

OLS 估计定义为

$$\hat{\phi}_{\text{OLS}} = \arg \min_{\phi} S(\phi).$$

对 $S(\phi)$ 求导, 得正规方程

$$\sum_{t=p+1}^n Z_t x_t = \left(\sum_{t=p+1}^n Z_t Z_t' \right) \hat{\phi}_{\text{OLS}}.$$

若矩阵 $\sum_{t=p+1}^n Z_t Z_t'$ 非奇异, 则

$$\hat{\phi}_{\text{OLS}} = \left(\sum_{t=p+1}^n Z_t Z_t' \right)^{-1} \left(\sum_{t=p+1}^n Z_t x_t \right).$$

令

$$y = \begin{pmatrix} x_{p+1} \\ x_{p+2} \\ \vdots \\ x_n \end{pmatrix}, \quad z = \begin{pmatrix} x_p & x_{p-1} & \cdots & x_1 \\ x_{p+1} & x_p & \cdots & x_2 \\ \vdots & \vdots & \ddots & \vdots \\ x_{n-1} & x_{n-2} & \cdots & x_{n-p} \end{pmatrix}.$$

则样本回归形式为

$$y = z\phi + e.$$

于是

$$\hat{\phi}_{\text{OLS}} = (z'z)^{-1}z'y.$$

OLS 残差为

$$\hat{\varepsilon}_t = x_t - \hat{\phi}_0 - \hat{\phi}_1 x_{t-1} - \cdots - \hat{\phi}_p x_{t-p}, \quad t = p+1, \dots, n.$$

残差方差估计可取

$$\hat{\sigma}_{\text{OLS}}^2 = \frac{1}{n-p} \sum_{t=p+1}^n \hat{\varepsilon}_t^2.$$

Remark 3.1 若估计非中心化 AR(p) 模型, 则令

$$w = \begin{pmatrix} 1 & x_p & x_{p-1} & \cdots & x_1 \\ 1 & x_{p+1} & x_p & \cdots & x_2 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n-1} & x_{n-2} & \cdots & x_{n-p} \end{pmatrix}, \quad \beta = (\phi_0, \phi_1, \dots, \phi_p)'. \quad \beta = (\phi_0, \phi_1, \dots, \phi_p)'.$$

此时 $y = w\beta + e$, 并且 $\hat{\beta}_{\text{OLS}} = (w'w)^{-1}w'y$.

Example 3.2 (AR(1) 的 OLS 估计) 若模型为中心化 AR(1)

$$X_t = \phi_1 X_{t-1} + \varepsilon_t,$$

则

$$S(\phi_1) = \sum_{t=2}^n (x_t - \phi_1 x_{t-1})^2.$$

由一阶条件得到

$$\hat{\phi}_{1,OLS} = \frac{\sum_{t=2}^n x_t x_{t-1}}{\sum_{t=2}^n x_{t-1}^2}.$$

Example 3.3 (AR(2) 的 OLS 估计) 若模型为中心化 AR(2)

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \varepsilon_t,$$

则

$$\begin{pmatrix} \hat{\phi}_1 \\ \hat{\phi}_2 \end{pmatrix}_{OLS} = \left(\sum_{t=3}^n \begin{pmatrix} x_{t-1}^2 & x_{t-1}x_{t-2} \\ x_{t-1}x_{t-2} & x_{t-2}^2 \end{pmatrix} \right)^{-1} \left(\sum_{t=3}^n \begin{pmatrix} x_{t-1}x_t \\ x_{t-2}x_t \end{pmatrix} \right).$$

记

$$\begin{aligned} S_{11} &= \sum_{t=3}^n x_{t-1}^2, & S_{22} &= \sum_{t=3}^n x_{t-2}^2, & S_{12} &= S_{21} = \sum_{t=3}^n x_{t-1}x_{t-2}, \\ S_{1y} &= \sum_{t=3}^n x_{t-1}x_t, & S_{2y} &= \sum_{t=3}^n x_{t-2}x_t, \end{aligned}$$

系数矩阵行列式

$$D = S_{11}S_{22} - S_{12}^2,$$

由二阶矩阵求逆法则展开得到分量形式:

$$\begin{cases} \hat{\phi}_{1,OLS} = \frac{S_{1y}S_{22} - S_{2y}S_{12}}{D} = \frac{\sum_{t=3}^n x_{t-1}x_t \sum_{t=3}^n x_{t-2}^2 - \sum_{t=3}^n x_{t-2}x_t \sum_{t=3}^n x_{t-1}x_{t-2}}{\sum_{t=3}^n x_{t-1}^2 \sum_{t=3}^n x_{t-2}^2 - (\sum_{t=3}^n x_{t-1}x_{t-2})^2}, \\ \hat{\phi}_{2,OLS} = \frac{S_{11}S_{2y} - S_{12}S_{1y}}{D} = \frac{\sum_{t=3}^n x_{t-2}x_t \sum_{t=3}^n x_{t-1}^2 - \sum_{t=3}^n x_{t-1}x_t \sum_{t=3}^n x_{t-1}x_{t-2}}{\sum_{t=3}^n x_{t-1}^2 \sum_{t=3}^n x_{t-2}^2 - (\sum_{t=3}^n x_{t-1}x_{t-2})^2}. \end{cases}$$

3.1.4 条件极大似然估计

进一步假设

$$\varepsilon_t \sim N(0, \sigma_\varepsilon^2),$$

且相互独立. 给定初始值

$$x_1, \dots, x_p,$$

对 $t = p+1, \dots, n$, 有

$$X_t | X_{t-1}, \dots, X_{t-p} \sim N(\tilde{Z}_t' \beta, \sigma_\varepsilon^2),$$

其中

$$\tilde{Z}_t = (1, X_{t-1}, \dots, X_{t-p})'.$$

代入样本后, 条件似然为

$$L_c(\beta, \sigma_\varepsilon^2) = \prod_{t=p+1}^n \frac{1}{\sqrt{2\pi\sigma_\varepsilon^2}} \exp \left\{ -\frac{1}{2\sigma_\varepsilon^2} (x_t - \tilde{z}_t' \beta)^2 \right\},$$

其中

$$\tilde{z}_t = (1, x_{t-1}, \dots, x_{t-p})'.$$

条件对数似然为

$$\ell_c(\beta, \sigma_\varepsilon^2) = -\frac{n-p}{2} \log(2\pi) - \frac{n-p}{2} \log \sigma_\varepsilon^2 - \frac{1}{2\sigma_\varepsilon^2} \sum_{t=p+1}^n (x_t - \tilde{z}_t' \beta)^2.$$

因此, 对固定的 σ_ε^2 , 最大化条件似然等价于最小化残差平方和. 所以在正态误差下,

$$\boxed{\hat{\beta}_{\text{CMLE}} = \hat{\beta}_{\text{OLS}}}.$$

进一步,

$$\boxed{\hat{\sigma}_{\text{CMLE}}^2 = \frac{1}{n-p} \sum_{t=p+1}^n (x_t - \tilde{z}_t' \hat{\beta}_{\text{CMLE}})^2}.$$

3.1.5 极大似然估计

条件极大似然只使用条件密度

$$f(x_{p+1}, \dots, x_n \mid x_1, \dots, x_p).$$

极大似然则使用完整联合密度

$$f(x_1, \dots, x_n) = f(x_1, \dots, x_p) \prod_{t=p+1}^n f(x_t \mid x_{t-1}, \dots, x_{t-p}).$$

在正态平稳 AR(p) 模型下, 初始向量

$$X_{(p)} = (X_1, \dots, X_p)'$$

服从 p 维正态分布

$$X_{(p)} \sim N(\mu \mathbf{1}_p, \Gamma_p),$$

其中

$$\Gamma_p = (\gamma(|i-j|))_{i,j=1}^p.$$

因此精确对数似然为

$$\begin{aligned} \ell(\beta, \sigma_\varepsilon^2) = & -\frac{p}{2} \log(2\pi) - \frac{1}{2} \log |\Gamma_p| - \frac{1}{2} (x_{(p)} - \mu \mathbf{1}_p)' \Gamma_p^{-1} (x_{(p)} - \mu \mathbf{1}_p) \\ & - \frac{n-p}{2} \log(2\pi) - \frac{n-p}{2} \log \sigma_\varepsilon^2 - \frac{1}{2\sigma_\varepsilon^2} \sum_{t=p+1}^n (x_t - \tilde{z}_t' \beta)^2. \end{aligned}$$

其中

$$x_{(p)} = (x_1, \dots, x_p)', \quad \mu = \frac{\phi_0}{1 - \phi_1 - \dots - \phi_p}.$$

精确极大似然估计定义为

$$(\hat{\beta}_{\text{MLE}}, \hat{\sigma}_{\text{MLE}}^2) = \arg \max_{\beta, \sigma_{\varepsilon}^2} \ell(\beta, \sigma_{\varepsilon}^2).$$

精确 MLE 比 CMLE 多考虑了初始向量 $(X_1, \dots, X_p)'$ 的平稳联合分布, 因此理论上更完整, 但通常需要数值优化.

Example 3.4 (AR(1) 的精确 MLE) 对平稳 AR(1)

$$X_t = \phi_0 + \phi_1 X_{t-1} + \varepsilon_t,$$

有

$$X_1 \sim N\left(\mu, \frac{\sigma_{\varepsilon}^2}{1 - \phi_1^2}\right), \quad \mu = \frac{\phi_0}{1 - \phi_1}.$$

因此精确似然为

$$f(x_1, \dots, x_n) = f(x_1) \prod_{t=2}^n f(x_t | x_{t-1}),$$

其中

$$X_t | X_{t-1} \sim N(\phi_0 + \phi_1 X_{t-1}, \sigma_{\varepsilon}^2).$$

精确 MLE 通常通过数值优化获得.

§3.2 MA 模型的参数估计

MA 模型的参数估计比 AR 模型更复杂. 主要原因是 MA 模型中的扰动项

$$\varepsilon_t, \varepsilon_{t-1}, \dots$$

不可直接观测, 因而不能像 AR 模型那样直接写成普通线性回归形式. 因此 MA 模型通常不使用 OLS 作为主要估计方法, 而是使用矩估计, 条件极大似然估计和精确极大似然估计.

考虑 MA(q) 模型

$$X_t = \mu + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q}, \quad \{\varepsilon_t\} \sim WN(0, \sigma_{\varepsilon}^2).$$

令

$$Y_t = X_t - \mu,$$

则中心化模型为

$$Y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q}.$$

3.2.1 矩估计

MA(q) 模型的自协方差函数为

$$\gamma(k) = \begin{cases} (1 + \theta_1^2 + \cdots + \theta_q^2)\sigma_\varepsilon^2, & k = 0, \\ \left(-\theta_k + \sum_{i=1}^{q-k} \theta_i \theta_{k+i}\right) \sigma_\varepsilon^2, & 1 \leq k \leq q, \\ 0, & k > q. \end{cases}$$

因此理论自相关系数为

$$\rho(k) = \frac{-\theta_k + \sum_{i=1}^{q-k} \theta_i \theta_{k+i}}{1 + \theta_1^2 + \cdots + \theta_q^2}, \quad k = 1, \dots, q.$$

矩估计的思想是用样本自相关

$$\hat{\rho}(1), \dots, \hat{\rho}(q)$$

替代理论自相关

$$\rho(1), \dots, \rho(q),$$

从而解非线性方程组

$$\hat{\rho}(k) = \frac{-\theta_k + \sum_{i=1}^{q-k} \theta_i \theta_{k+i}}{1 + \theta_1^2 + \cdots + \theta_q^2}, \quad k = 1, \dots, q.$$

解得

$$\hat{\theta}_1, \dots, \hat{\theta}_q.$$

再由

$$\gamma(0) = (1 + \theta_1^2 + \cdots + \theta_q^2)\sigma_\varepsilon^2$$

得到方差估计

$$\hat{\sigma}_{\varepsilon, \text{MM}}^2 = \frac{\hat{\gamma}(0)}{1 + \hat{\theta}_1^2 + \cdots + \hat{\theta}_q^2}.$$

若模型含有均值项, 通常取

$$\hat{\mu}_{\text{MM}} = \bar{x}.$$

MA(q) 的矩估计一般要求解非线性方程组. 当 $q = 1$ 时可以写出显式解, 但当 $q \geq 2$ 时通常需要数值求解. 此外, 为保证估计唯一, 通常需要加入可逆性约束.

Example 3.5 (MA(1) 的矩估计) 考虑可逆 MA(1) 模型

$$X_t = \mu + \varepsilon_t - \theta_1 \varepsilon_{t-1}.$$

中心化后有

$$Y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1}.$$

其一阶自相关系数为

$$\rho(1) = -\frac{\theta_1}{1 + \theta_1^2}.$$

用样本自相关替代理论自相关, 得

$$\hat{\rho}(1) = -\frac{\theta_1}{1 + \theta_1^2}.$$

整理得

$$\hat{\rho}(1)\theta_1^2 + \theta_1 + \hat{\rho}(1) = 0.$$

因此

$$\theta_1 = \frac{-1 \pm \sqrt{1 - 4\hat{\rho}^2(1)}}{2\hat{\rho}(1)}.$$

由于可逆 MA(1) 要求

$$|\theta_1| < 1,$$

所以取满足可逆性条件的根. 即

$$\hat{\theta}_{1,MM} = \frac{-1 + \sqrt{1 - 4\hat{\rho}^2(1)}}{2\hat{\rho}(1)}$$

或等价地, 取两个根中绝对值小于 1 的那个. 若

$$\hat{\rho}(1) = 0,$$

则取

$$\hat{\theta}_{1,MM} = 0.$$

方差估计为

$$\hat{\sigma}_{\varepsilon,MM}^2 = \frac{\hat{\gamma}(0)}{1 + \hat{\theta}_{1,MM}^2}.$$

3.2.2 条件极大似然估计

进一步假设

$$\varepsilon_t \sim N(0, \sigma_{\varepsilon}^2),$$

且相互独立. MA 模型中的扰动项不可观测, 但在给定参数后可以由递推公式计算出来.

对 MA(q) 模型

$$X_t = \mu + \varepsilon_t - \theta_1\varepsilon_{t-1} - \cdots - \theta_q\varepsilon_{t-q},$$

给定参数

$$\eta = (\mu, \theta_1, \dots, \theta_q)',$$

定义递推残差

$$\varepsilon_t(\eta) = x_t - \mu + \theta_1\varepsilon_{t-1}(\eta) + \cdots + \theta_q\varepsilon_{t-q}(\eta).$$

通常取初始残差

$$\varepsilon_0(\eta) = \varepsilon_{-1}(\eta) = \cdots = \varepsilon_{1-q}(\eta) = 0.$$

于是条件平方和为

$$S_c(\eta) = \sum_{t=1}^n \varepsilon_t^2(\eta).$$

在正态假定下, 条件对数似然为

$$\ell_c(\eta, \sigma_\varepsilon^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma_\varepsilon^2 - \frac{1}{2\sigma_\varepsilon^2} \sum_{t=1}^n \varepsilon_t^2(\eta).$$

因此, 对固定的 σ_ε^2 , 最大化条件似然等价于最小化条件平方和:

$$\hat{\eta}_{\text{CMLE}} = \arg \min_{\eta \in \Theta_{\text{inv}}} \sum_{t=1}^n \varepsilon_t^2(\eta).$$

其中 Θ_{inv} 表示可逆参数空间.

将估计量代入条件似然, 得到

$$\hat{\sigma}_{\varepsilon, \text{CMLE}}^2 = \frac{1}{n} \sum_{t=1}^n \varepsilon_t^2(\hat{\eta}_{\text{CMLE}}).$$

MA 模型的条件极大似然估计与条件最小二乘估计在正态假定下等价. 但与 AR 模型不同, 这里的残差递推式对参数是非线性的, 所以一般没有显式解, 通常需要数值优化.

Example 3.6 (MA(1) 的条件极大似然估计) 对 MA(1) 模型

$$X_t = \mu + \varepsilon_t - \theta_1 \varepsilon_{t-1},$$

给定参数

$$\eta = (\mu, \theta_1)',$$

递推残差为

$$\varepsilon_t(\eta) = x_t - \mu + \theta_1 \varepsilon_{t-1}(\eta), \quad \varepsilon_0(\eta) = 0.$$

条件平方和为

$$S_c(\mu, \theta_1) = \sum_{t=1}^n \varepsilon_t^2(\mu, \theta_1).$$

因此

$$(\hat{\mu}_{\text{CMLE}}, \hat{\theta}_{1, \text{CMLE}}) = \arg \min_{\mu, |\theta_1| < 1} S_c(\mu, \theta_1).$$

对应方差估计为

$$\hat{\sigma}_{\varepsilon, \text{CMLE}}^2 = \frac{1}{n} S_c(\hat{\mu}_{\text{CMLE}}, \hat{\theta}_{1, \text{CMLE}}).$$

3.2.3 精确极大似然估计

精确极大似然估计直接使用

$$(x_1, \dots, x_n)'$$

的联合密度. 在正态 MA(q) 模型下,

$$X_n = (X_1, \dots, X_n)'$$

服从 n 维正态分布

$$X_n \sim N(\mu \mathbf{1}_n, \Gamma_n),$$

其中

$$\Gamma_n = (\gamma(|i-j|))_{i,j=1}^n.$$

这里的自协方差函数由 MA(q) 模型给出:

$$\gamma(k) = \begin{cases} (1 + \theta_1^2 + \cdots + \theta_q^2) \sigma_\varepsilon^2, & k = 0, \\ \left(-\theta_k + \sum_{i=1}^{q-k} \theta_i \theta_{k+i} \right) \sigma_\varepsilon^2, & 1 \leq k \leq q, \\ 0, & k > q. \end{cases}$$

因此精确对数似然为

$$\ell(\mu, \theta, \sigma_\varepsilon^2) = -\frac{n}{2} \log(2\pi) - \frac{1}{2} \log |\Gamma_n| - \frac{1}{2} (x_n - \mu \mathbf{1}_n)' \Gamma_n^{-1} (x_n - \mu \mathbf{1}_n),$$

其中

$$x_n = (x_1, \dots, x_n)'.$$

精确极大似然估计定义为

$$(\hat{\mu}_{\text{MLE}}, \hat{\theta}_{\text{MLE}}, \hat{\sigma}_{\varepsilon, \text{MLE}}^2) = \arg \max_{\mu, \theta, \sigma_\varepsilon^2} \ell(\mu, \theta, \sigma_\varepsilon^2).$$

精确 MLE 利用了完整协方差矩阵 Γ_n , 理论上最完整. 但 Γ_n 依赖 θ 和 σ_ε^2 , 并且需要计算行列式与矩阵逆, 所以实际计算通常依赖数值优化.

Example 3.7 (MA(1) 的精确 MLE) 对正态 MA(1) 模型

$$X_t = \mu + \varepsilon_t - \theta_1 \varepsilon_{t-1},$$

有

$$\gamma(0) = (1 + \theta_1^2) \sigma_\varepsilon^2, \quad \gamma(1) = -\theta_1 \sigma_\varepsilon^2, \quad \gamma(k) = 0, \quad k \geq 2.$$

因此

$$X_n = (X_1, \dots, X_n)' \sim N(\mu \mathbf{1}_n, \Gamma_n),$$

其中 Γ_n 是三对角 Toeplitz 矩阵:

$$\Gamma_n = \sigma_\varepsilon^2 \begin{pmatrix} 1 + \theta_1^2 & -\theta_1 & 0 & \cdots & 0 \\ -\theta_1 & 1 + \theta_1^2 & -\theta_1 & \cdots & 0 \\ 0 & -\theta_1 & 1 + \theta_1^2 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & -\theta_1 \\ 0 & 0 & 0 & -\theta_1 & 1 + \theta_1^2 \end{pmatrix}.$$

将该协方差矩阵代入 n 维正态密度, 即可得到 MA(1) 的精确似然. 精确 MLE 通常通过数值优化获得.

§3.3 ARMA 模型的参数估计

ARMA 模型同时含有 AR 部分和 MA 部分. 它可以看作 AR 模型和 MA 模型的组合, 但估计难度更接近 MA 模型. 主要原因是扰动项不可直接观测, 需要通过递推残差或联合正态密度进行估计.

考虑 ARMA(p, q) 模型

$$X_t = \phi_0 + \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t-q}.$$

中心化形式为

$$Y_t = \phi_1 Y_{t-1} + \cdots + \phi_p Y_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t-q},$$

其中

$$Y_t = X_t - \mu, \quad \mu = \frac{\phi_0}{1 - \phi_1 - \cdots - \phi_p}.$$

下面主要讨论中心化模型的估计思想. 非中心化模型可通过同时估计均值或截距项处理.

3.3.1 矩估计

ARMA(p, q) 的矩估计利用自相关函数满足的递推关系. 当滞后阶数 $k > q$ 时, MA 部分不再影响自协方差递推, 因有

$$\rho(k) = \phi_1 \rho(k-1) + \cdots + \phi_p \rho(k-p), \quad k > q.$$

因此可以利用

$$k = q+1, q+2, \dots, q+p$$

处的自相关方程估计 AR 部分参数:

$$\begin{pmatrix} \rho(q) & \rho(q-1) & \cdots & \rho(q-p+1) \\ \rho(q+1) & \rho(q) & \cdots & \rho(q-p+2) \\ \vdots & \vdots & \ddots & \vdots \\ \rho(q+p-1) & \rho(q+p-2) & \cdots & \rho(q) \end{pmatrix} \begin{pmatrix} \phi_1 \\ \phi_2 \\ \vdots \\ \phi_p \end{pmatrix} = \begin{pmatrix} \rho(q+1) \\ \rho(q+2) \\ \vdots \\ \rho(q+p) \end{pmatrix}.$$

用样本自相关替代理论自相关, 可得

$$\hat{\phi}_{MM}.$$

估计出 AR 部分以后, 可令

$$W_t = X_t - \hat{\phi}_1 X_{t-1} - \cdots - \hat{\phi}_p X_{t-p}.$$

理论上

$$W_t \approx \varepsilon_t - \theta_1 \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t-q},$$

于是可以继续把 W_t 看作 MA(q) 模型, 用 MA 模型的矩估计方法估计

$$\theta_1, \dots, \theta_q.$$

ARMA 模型的矩估计计算直观, 但只使用有限个样本自相关系数, 信息浪费较多. 因此它更适合作为条件极大似然估计或条件最小二乘估计的初始值.

Example 3.8 (ARMA(2,1) 的矩估计) 考虑中心化 ARMA(2,1) 模型

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \varepsilon_t - \theta_1 \varepsilon_{t-1}.$$

当 $k > 1$ 时, 自协方差函数满足 AR(2) 递推:

$$\rho(k) = \phi_1 \rho(k-1) + \phi_2 \rho(k-2).$$

取 $k = 2, 3$, 得

$$\rho(2) = \phi_1 \rho(1) + \phi_2,$$

$$\rho(3) = \phi_1 \rho(2) + \phi_2 \rho(1).$$

解得

$$\boxed{\phi_1 = \frac{\rho(1)\rho(2) - \rho(3)}{\rho^2(1) - \rho(2)}}, \quad \boxed{\phi_2 = \frac{\rho(1)\rho(3) - \rho^2(2)}{\rho^2(1) - \rho(2)}}.$$

用样本自相关替代理论自相关, 得

$$\boxed{\hat{\phi}_{1,MM} = \frac{\hat{\rho}(1)\hat{\rho}(2) - \hat{\rho}(3)}{\hat{\rho}^2(1) - \hat{\rho}(2)}},$$

$$\boxed{\hat{\phi}_{2,MM} = \frac{\hat{\rho}(1)\hat{\rho}(3) - \hat{\rho}^2(2)}{\hat{\rho}^2(1) - \hat{\rho}(2)}}.$$

接着令

$$w_t = x_t - \hat{\phi}_{1,MM} x_{t-1} - \hat{\phi}_{2,MM} x_{t-2}.$$

则 w_t 近似满足 MA(1) 模型

$$w_t \approx \varepsilon_t - \theta_1 \varepsilon_{t-1}.$$

于是可由

$$\rho_w(1) = -\frac{\theta_1}{1 + \theta_1^2}$$

得到

$$\boxed{\hat{\theta}_{1,MM} = \frac{-1 + \sqrt{1 - 4\hat{\rho}_w^2(1)}}{2\hat{\rho}_w(1)}}$$

并取满足可逆性条件的根. 最后由残差序列 w_t 的样本方差估计 σ_ε^2 .

3.3.2 条件极大似然估计

进一步假设

$$\varepsilon_t \sim N(0, \sigma_\varepsilon^2),$$

且相互独立. 对 ARMA(p, q) 模型, 设

$$\eta = (\phi_0, \phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q)'$$

给定参数 η , 可由递推公式计算残差:

$$\varepsilon_t(\eta) = x_t - \phi_0 - \phi_1 x_{t-1} - \cdots - \phi_p x_{t-p} + \theta_1 \varepsilon_{t-1}(\eta) + \cdots + \theta_q \varepsilon_{t-q}(\eta).$$

通常取初始残差为零:

$$\varepsilon_0(\eta) = \varepsilon_{-1}(\eta) = \cdots = \varepsilon_{1-q}(\eta) = 0.$$

给定前 p 个观测值后, 条件平方和为

$$S_c(\eta) = \sum_{t=p+1}^n \varepsilon_t^2(\eta).$$

条件对数似然为

$$\ell_c(\eta, \sigma_\varepsilon^2) = -\frac{n-p}{2} \log(2\pi) - \frac{n-p}{2} \log \sigma_\varepsilon^2 - \frac{1}{2\sigma_\varepsilon^2} \sum_{t=p+1}^n \varepsilon_t^2(\eta).$$

因此, 对固定的 σ_ε^2 , 最大化条件似然等价于最小化条件平方和:

$$\hat{\eta}_{\text{CMLE}} = \arg \min_{\eta \in \Theta} \sum_{t=p+1}^n \varepsilon_t^2(\eta).$$

其中 Θ 通常需要包含平稳性与可逆性约束.

将估计量代回条件似然, 得到

$$\hat{\sigma}_{\varepsilon, \text{CMLE}}^2 = \frac{1}{n-p} \sum_{t=p+1}^n \varepsilon_t^2(\hat{\eta}_{\text{CMLE}}).$$

ARMA 模型的 CMLE 与 MA 模型类似, 一般没有显式解. 其核心是先递推残差, 再最小化残差平方和.

Example 3.9 (ARMA(1,1) 的条件极大似然估计) 考虑 ARMA(1,1) 模型

$$X_t = \phi_0 + \phi_1 X_{t-1} + \varepsilon_t - \theta_1 \varepsilon_{t-1}.$$

给定参数

$$\eta = (\phi_0, \phi_1, \theta_1)',$$

递推残差为

$$\varepsilon_t(\eta) = x_t - \phi_0 - \phi_1 x_{t-1} + \theta_1 \varepsilon_{t-1}(\eta).$$

取初始残差

$$\varepsilon_1(\eta) = 0$$

或给定其他初值. 条件平方和为

$$S_c(\eta) = \sum_{t=2}^n \varepsilon_t^2(\eta).$$

因此

$$\hat{\eta}_{\text{CMLE}} = \arg \min_{\eta \in \Theta} S_c(\eta).$$

其中 Θ 通常要求

$$|\phi_1| < 1, \quad |\theta_1| < 1.$$

方差估计为

$$\hat{\sigma}_{\varepsilon, \text{CMLE}}^2 = \frac{1}{n-1} S_c(\hat{\eta}_{\text{CMLE}}).$$

3.3.3 精确极大似然估计

在正态 ARMA(p, q) 模型下,

$$X_n = (X_1, \dots, X_n)'$$

服从 n 维正态分布

$$X_n \sim N(\mu \mathbf{1}_n, \Gamma_n).$$

其中

$$\Gamma_n = (\gamma(|i-j|))_{i,j=1}^n,$$

而自协方差函数 $\gamma(k)$ 由 ARMA(p, q) 模型的理论自协方差决定.

因此精确对数似然为

$$\ell(\eta, \sigma_\varepsilon^2) = -\frac{n}{2} \log(2\pi) - \frac{1}{2} \log |\Gamma_n| - \frac{1}{2} (x_n - \mu \mathbf{1}_n)' \Gamma_n^{-1} (x_n - \mu \mathbf{1}_n),$$

其中

$$x_n = (x_1, \dots, x_n)'.$$

精确极大似然估计定义为

$$(\hat{\eta}_{\text{MLE}}, \hat{\sigma}_{\varepsilon, \text{MLE}}^2) = \arg \max_{\eta, \sigma_\varepsilon^2} \ell(\eta, \sigma_\varepsilon^2).$$

精确 MLE 直接利用完整联合正态密度, 理论上最完整. 但由于 ARMA 模型的协方差矩阵 Γ_n 依赖 AR 参数, MA 参数和 σ_ε^2 , 一般需要数值优化.

Chapter 4

预测

§4.1 条件期望预测

4.1.1 预测问题的基本形式

设当前时刻为 t , 已经观测到平稳时间序列在时刻 t 及其以前的样本值

$$X_t, X_{t-1}, X_{t-2}, \dots$$

现在用这些已知信息对未来时刻 $t+l$ 的取值 X_{t+l} 进行预测. 这种预测称为以 t 为预测原点, 向前步长为 l 的预测, 预测值记为

$$\hat{X}_t(l).$$

预测误差定义为

$$e_t(l) = X_{t+l} - \hat{X}_t(l).$$

若采用均方误差作为预测优劣的度量, 则预测的均方误差为

$$\mathbb{E}[e_t^2(l)] = \mathbb{E} \left[X_{t+l} - \hat{X}_t(l) \right]^2.$$

4.1.2 条件期望的最优预测性质

设随机序列 $\{X_t\}$ 满足

$$\mathbb{E}(X_t) = \mu, \quad \mathbb{E}(X_t^2) < \infty.$$

记历史信息向量为

$$\mathbf{X}_n = (X_1, X_2, \dots, X_n).$$

我们希望用 $\mathbf{X}_n$ 的函数 $f(\mathbf{X}_n)$ 来预测未来值 X_{n+l} .

Theorem 4.1 设 $X_{n+l} \in L^2$. 则在所有形如 $f(\mathbf{X}_n)$ 的平方可积预测量中, 条件期望

$$\hat{X}_n(l) = \mathbb{E}(X_{n+l} \mid \mathbf{X}_n)$$

使均方预测误差达到最小, 即对任意平方可积函数 f ,

$$\mathbb{E}[X_{n+l} - \mathbb{E}(X_{n+l} | \mathbf{X}_n)]^2 \leq \mathbb{E}[X_{n+l} - f(\mathbf{X}_n)]^2.$$

等号成立当且仅当

$$f(\mathbf{X}_n) = \mathbb{E}(X_{n+l} | \mathbf{X}_n) \quad \text{a.s.}$$

进一步地, 在给定 $\mathbf{X}_n$ 的条件下, 条件期望也使条件均方误差达到最小, 即

$$\mathbb{E}\{[X_{n+l} - \mathbb{E}(X_{n+l} | \mathbf{X}_n)]^2 | \mathbf{X}_n\} \leq \mathbb{E}\{[X_{n+l} - f(\mathbf{X}_n)]^2 | \mathbf{X}_n\}.$$

Proof. 记 $m(\mathbf{X}_n) = \mathbb{E}(X_{n+l} | \mathbf{X}_n)$. 对任意平方可积函数 $f(\mathbf{X}_n)$, 有分解

$$X_{n+l} - f(\mathbf{X}_n) = [X_{n+l} - m(\mathbf{X}_n)] + [m(\mathbf{X}_n) - f(\mathbf{X}_n)].$$

两边平方并对 $\mathbf{X}_n$ 取条件期望并注意到 $\mathbb{E}[X_{n+l} - m(\mathbf{X}_n) | \mathbf{X}_n] = 0$, 得

$$\mathbb{E}\{[X_{n+l} - f(\mathbf{X}_n)]^2 | \mathbf{X}_n\} = \mathbb{E}\{[X_{n+l} - m(\mathbf{X}_n)]^2 | \mathbf{X}_n\} + [m(\mathbf{X}_n) - f(\mathbf{X}_n)]^2.$$

由于第二项非负, 条件均方误差不等式成立. 再对两边取期望, 得

$$\mathbb{E}[X_{n+l} - f(\mathbf{X}_n)]^2 = \mathbb{E}[X_{n+l} - m(\mathbf{X}_n)]^2 + \mathbb{E}[m(\mathbf{X}_n) - f(\mathbf{X}_n)]^2.$$

所以

$$\mathbb{E}[X_{n+l} - f(\mathbf{X}_n)]^2 \geq \mathbb{E}[X_{n+l} - m(\mathbf{X}_n)]^2.$$

等号成立当且仅当

$$\mathbb{E}[m(\mathbf{X}_n) - f(\mathbf{X}_n)]^2 = 0,$$

即

$$f(\mathbf{X}_n) = m(\mathbf{X}_n) = \mathbb{E}(X_{n+l} | \mathbf{X}_n) \quad \text{a.s.}$$

定理得证. □

§4.2 ARMA 模型的预测

开始本节叙述前, 我们先看一下因果模型传递形式的预测.

Theorem 4.2 设平稳因果模型具有 Green 函数表示

$$X_t = \sum_{j=0}^{\infty} G_j \varepsilon_{t-j}, \quad G_0 = 1,$$

其中 $\{\varepsilon_t\}$ 是零均值白噪声, 且

$$\text{Var}(\varepsilon_t) = \sigma_\varepsilon^2.$$

则站在时刻 t 对 X_{t+l} 的 l 步预测为

$$\hat{X}_t(l) = \sum_{j=l}^{\infty} G_j \varepsilon_{t+l-j}.$$

预测误差为

$$e_t(l) = X_{t+l} - \hat{X}_t(l) = \sum_{j=0}^{l-1} G_j \varepsilon_{t+l-j}.$$

因此

$$\mathbb{E}[e_t(l)] = 0, \quad \text{Var}[e_t(l)] = \mathbb{E}[e_t^2(l)] = \left(\sum_{j=0}^{l-1} G_j^2 \right) \sigma_\varepsilon^2.$$

由于 $G_0 = 1$, 上式也可写为

$$\text{Var}[e_t(l)] = (1 + G_1^2 + \cdots + G_{l-1}^2) \sigma_\varepsilon^2.$$

若进一步假设 $\{\varepsilon_t\}$ 为独立正态白噪声, 则

$$X_{t+l} | X_t, X_{t-1}, \dots \sim N \left(\hat{X}_t(l), \text{Var}[e_t(l)] \right).$$

于是置信水平为 $1 - \alpha$ 的预测区间为

$$\hat{X}_t(l) \pm z_{1-\alpha/2} \sqrt{(1 + G_1^2 + \cdots + G_{l-1}^2) \sigma_\varepsilon^2}.$$

特别地, 95% 预测区间为

$$\hat{X}_t(l) \pm 1.96 \sqrt{(1 + G_1^2 + \cdots + G_{l-1}^2) \sigma_\varepsilon^2}.$$

Proof. 由 Green 函数表示,

$$X_{t+l} = \sum_{j=0}^{\infty} G_j \varepsilon_{t+l-j} = \sum_{j=0}^{l-1} G_j \varepsilon_{t+l-j} + \sum_{j=l}^{\infty} G_j \varepsilon_{t+l-j}.$$

第一项只含未来冲击

$$\varepsilon_{t+1}, \dots, \varepsilon_{t+l},$$

其关于历史信息 $X_t, X_{t-1}, \dots$ 的条件期望为零. 第二项只含当前及过去冲击

$$\varepsilon_t, \varepsilon_{t-1}, \dots,$$

在给定历史信息后可看作已知量. 因此

$$\hat{X}_t(l) = \mathbb{E}(X_{t+l} | X_t, X_{t-1}, \dots) = \sum_{j=l}^{\infty} G_j \varepsilon_{t+l-j}.$$

从而

$$e_t(l) = X_{t+l} - \hat{X}_t(l) = \sum_{j=0}^{l-1} G_j \varepsilon_{t+l-j}.$$

由于白噪声不同时刻不相关,

$$\text{Var}[e_t(l)] = \text{Var} \left(\sum_{j=0}^{l-1} G_j \varepsilon_{t+l-j} \right) = \sum_{j=0}^{l-1} G_j^2 \sigma_\varepsilon^2.$$

若 $\{\varepsilon_t\}$ 为独立正态白噪声, 则 $e_t(l)$ 是未来正态冲击的线性组合, 因而服从正态分布. 又

$$X_{t+l} = \hat{X}_t(l) + e_t(l),$$

所以得到正态预测分布和相应预测区间. □

Remark 4.3 若模型不是零均值模型, 而是

$$X_t - \mu = \sum_{j=0}^{\infty} G_j \varepsilon_{t-j},$$

则应先预测中心化序列 $X_t - \mu$, 再加回均值 μ . 此时

$$\hat{X}_t(l) = \mu + \sum_{j=l}^{\infty} G_j \varepsilon_{t+l-j},$$

而预测误差方差仍为

$$\text{Var}[e_t(l)] = (1 + G_1^2 + \cdots + G_{l-1}^2) \sigma_\varepsilon^2.$$

4.2.1 自回归模型的预测

Theorem 4.4 设零均值平稳 AR(p) 模型为

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} + \varepsilon_t.$$

站在时刻 t , 对未来值 X_{t+l} 进行预测. 约定

$$\hat{X}_t(0) = X_t, \quad \hat{X}_t(-j) = X_{t-j}, \quad j = 1, \dots, p-1.$$

则 l 步预测满足递推公式

$$\hat{X}_t(l) = \phi_1 \hat{X}_t(l-1) + \phi_2 \hat{X}_t(l-2) + \cdots + \phi_p \hat{X}_t(l-p), \quad l \geq 1.$$

若该 AR(p) 模型具有因果表示

$$X_t = \sum_{j=0}^{\infty} G_j \varepsilon_{t-j}, \quad G_0 = 1,$$

其中

$$G_j = \phi_1 G_{j-1} + \phi_2 G_{j-2} + \cdots + \phi_p G_{j-p}, \quad j \geq 1,$$

并约定 $G_j = 0, j < 0$, 则预测误差为

$$e_t(l) = X_{t+l} - \hat{X}_t(l) = \varepsilon_{t+l} + G_1 \varepsilon_{t+l-1} + \cdots + G_{l-1} \varepsilon_{t+1}.$$

因此

$$\text{Var}[e_t(l)] = (1 + G_1^2 + \cdots + G_{l-1}^2) \sigma_\varepsilon^2.$$

Proof. 由 AR(p) 模型,

$$X_{t+l} = \phi_1 X_{t+l-1} + \cdots + \phi_p X_{t+l-p} + \varepsilon_{t+l}.$$

对两边取关于 $X_t, X_{t-1}, \dots$ 的条件期望, 并利用

$$\mathbb{E}(\varepsilon_{t+l} \mid X_t, X_{t-1}, \dots) = 0,$$

得到

$$\hat{X}_t(l) = \sum_{i=1}^p \phi_i \mathbb{E}(X_{t+l-i} \mid X_t, X_{t-1}, \dots).$$

当 $l-i > 0$ 时,

$$\mathbb{E}(X_{t+l-i} \mid X_t, X_{t-1}, \dots) = \hat{X}_t(l-i).$$

当 $l-i \leq 0$ 时, X_{t+l-i} 已经被观测到, 按约定写成

$$\hat{X}_t(l-i) = X_{t+l-i}.$$

因此

$$\hat{X}_t(l) = \sum_{i=1}^p \phi_i \hat{X}_t(l-i).$$

另一方面, 由 Green 函数预测公式,

$$e_t(l) = \sum_{j=0}^{l-1} G_j \varepsilon_{t+l-j} = \varepsilon_{t+l} + G_1 \varepsilon_{t+l-1} + \dots + G_{l-1} \varepsilon_{t+1}.$$

由于白噪声不同时刻不相关,

$$\text{Var}[e_t(l)] = \sum_{j=0}^{l-1} G_j^2 \sigma_\varepsilon^2 = (1 + G_1^2 + \dots + G_{l-1}^2) \sigma_\varepsilon^2.$$

定理得证. □

Remark 4.5 (非零均值情形) 若 $\text{AR}(p)$ 模型含有非零均值 μ , 即

$$X_t - \mu = \phi_1(X_{t-1} - \mu) + \dots + \phi_p(X_{t-p} - \mu) + \varepsilon_t,$$

则令 $Y_t = X_t - \mu$. 先对中心化序列 Y_t 进行预测, 再加回均值 μ . 因此

$$\hat{X}_t(l) = \mu + \hat{Y}_t(l),$$

其中

$$\hat{Y}_t(l) = \phi_1 \hat{Y}_t(l-1) + \dots + \phi_p \hat{Y}_t(l-p).$$

特别地, 对非零均值 $\text{AR}(1)$ 模型

$$X_t - \mu = \phi(X_{t-1} - \mu) + \varepsilon_t,$$

有

$$\hat{X}_t(l) = \mu + \phi^l(X_t - \mu).$$

Example 4.6 (AR(1) 模型的预测) 考虑零均值平稳 $\text{AR}(1)$ 模型

$$X_t = \phi X_{t-1} + \varepsilon_t, \quad |\phi| < 1.$$

此时 $G_j = \phi^j, j \geq 0$. 由 $\text{AR}(p)$ 预测递推公式可得

$$\hat{X}_t(l) = \phi^l X_t.$$

4.2.2 滑动平均模型的预测

Theorem 4.7 设零均值可逆 MA(q) 模型为

$$X_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots - \theta_q \varepsilon_{t-q}, \quad \{\varepsilon_t\} \sim WN(0, \sigma_\varepsilon^2).$$

可逆性保证当前及过去扰动

$$\varepsilon_t, \varepsilon_{t-1}, \dots$$

可以由历史观测值确定. 则站在时刻 t 的 l 步预测为

$$\hat{X}_t(l) = \begin{cases} -\theta_l \varepsilon_t - \theta_{l+1} \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t+l-q}, & 1 \leq l \leq q, \\ 0, & l > q. \end{cases}$$

预测误差为

$$e_t(l) = \begin{cases} \varepsilon_{t+l} - \theta_1 \varepsilon_{t+l-1} - \cdots - \theta_{l-1} \varepsilon_{t+1}, & 1 \leq l \leq q, \\ X_{t+l}, & l > q. \end{cases}$$

因此预测误差方差为

$$\text{Var}[e_t(l)] = \begin{cases} (1 + \theta_1^2 + \cdots + \theta_{l-1}^2) \sigma_\varepsilon^2, & 1 \leq l \leq q, \\ (1 + \theta_1^2 + \cdots + \theta_q^2) \sigma_\varepsilon^2, & l > q. \end{cases}$$

Proof. 当 $1 \leq l \leq q$ 时,

$$\begin{aligned} X_{t+l} &= \varepsilon_{t+l} - \theta_1 \varepsilon_{t+l-1} - \cdots - \theta_{l-1} \varepsilon_{t+1} \\ &\quad - \theta_l \varepsilon_t - \theta_{l+1} \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t+l-q}. \end{aligned}$$

其中 $\varepsilon_{t+1}, \dots, \varepsilon_{t+l}$ 是未来冲击, 条件期望为零. 而 $\varepsilon_t, \varepsilon_{t-1}, \dots, \varepsilon_{t+l-q}$ 是当前及过去冲击, 在可逆条件下由历史观测值确定. 因此

$$\hat{X}_t(l) = -\theta_l \varepsilon_t - \theta_{l+1} \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t+l-q}.$$

从而

$$e_t(l) = \varepsilon_{t+l} - \theta_1 \varepsilon_{t+l-1} - \cdots - \theta_{l-1} \varepsilon_{t+1}.$$

由于白噪声不同时刻不相关,

$$\text{Var}[e_t(l)] = (1 + \theta_1^2 + \cdots + \theta_{l-1}^2) \sigma_\varepsilon^2.$$

当 $l > q$ 时,

$$X_{t+l} = \varepsilon_{t+l} - \theta_1 \varepsilon_{t+l-1} - \cdots - \theta_q \varepsilon_{t+l-q},$$

右端全部由未来冲击构成, 故

$$\hat{X}_t(l) = 0.$$

于是

$$e_t(l) = X_{t+l}, \quad \text{Var}[e_t(l)] = \text{Var}(X_{t+l}) = (1 + \theta_1^2 + \cdots + \theta_q^2) \sigma_\varepsilon^2.$$

定理得证. □

Remark 4.8 (非零均值情形) 若 MA(q) 模型为

$$X_t = \mu + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t-q},$$

则先对中心化序列 $Y_t = X_t - \mu$ 进行预测, 再加回均值 μ . 因此

$$\hat{X}_t(l) = \begin{cases} \mu - \theta_l \varepsilon_t - \theta_{l+1} \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t+l-q}, & 1 \leq l \leq q, \\ \mu, & l > q. \end{cases}$$

对应的预测误差方差不受均值 μ 影响, 仍为

$$\text{Var}[e_t(l)] = \begin{cases} (1 + \theta_1^2 + \cdots + \theta_{l-1}^2) \sigma_\varepsilon^2, & 1 \leq l \leq q, \\ (1 + \theta_1^2 + \cdots + \theta_q^2) \sigma_\varepsilon^2, & l > q. \end{cases}$$

Example 4.9 (MA(1) 模型的预测) 考虑零均值可逆 MA(1) 模型

$$X_t = \varepsilon_t - \theta_1 \varepsilon_{t-1}.$$

由 MA(q) 预测公式可得

$$\hat{X}_t(l) = \begin{cases} -\theta_1 \varepsilon_t, & l = 1, \\ 0, & l \geq 2. \end{cases}$$

当 $l = 1$ 时,

$$e_t(1) = X_{t+1} - \hat{X}_t(1) = \varepsilon_{t+1},$$

所以

$$\text{Var}[e_t(1)] = \sigma_\varepsilon^2.$$

当 $l \geq 2$ 时,

$$e_t(l) = X_{t+l},$$

所以

$$\text{Var}[e_t(l)] = \text{Var}(X_{t+l}) = (1 + \theta_1^2) \sigma_\varepsilon^2.$$

因此

$$\text{Var}[e_t(l)] = \begin{cases} \sigma_\varepsilon^2, & l = 1, \\ (1 + \theta_1^2) \sigma_\varepsilon^2, & l \geq 2. \end{cases}$$

该例说明, 零均值 MA(1) 模型从两步预测开始回到均值 0.

4.2.3 自回归滑动平均模型的预测

Theorem 4.10 设零均值因果可逆 ARMA(p, q) 模型为

$$X_t = \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t-q}.$$

约定

$$\hat{X}_t(0) = X_t, \quad \hat{X}_t(-j) = X_{t-j}, \quad j = 1, \dots, p-1.$$

则站在时刻 t 的 l 步预测为

$$\hat{X}_t(l) = \sum_{i=1}^p \phi_i \hat{X}_t(l-i) - \sum_{j=l}^q \theta_j \varepsilon_{t+l-j}, \quad l \geq 1.$$

其中当 $l > q$ 时, 第二个求和为空, 因而

$$\hat{X}_t(l) = \sum_{i=1}^p \phi_i \hat{X}_t(l-i), \quad l > q.$$

若该模型具有 Green 函数表示

$$X_t = \sum_{j=0}^{\infty} G_j \varepsilon_{t-j}, \quad G_0 = 1,$$

则预测误差为

$$e_t(l) = X_{t+l} - \hat{X}_t(l) = \varepsilon_{t+l} + G_1 \varepsilon_{t+l-1} + \cdots + G_{l-1} \varepsilon_{t+1}.$$

因此

$$\text{Var}[e_t(l)] = (1 + G_1^2 + \cdots + G_{l-1}^2) \sigma_\varepsilon^2.$$

Remark 4.11 (非零均值情形) 若 ARMA(p, q) 模型含有非零均值 μ , 即

$$X_t - \mu = \phi_1(X_{t-1} - \mu) + \cdots + \phi_p(X_{t-p} - \mu) + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t-q},$$

则令 $Y_t = X_t - \mu$. 先对中心化序列 Y_t 进行预测, 再加回均值 μ . 因此

$$\hat{X}_t(l) = \mu + \hat{Y}_t(l),$$

其中

$$\hat{Y}_t(l) = \sum_{i=1}^p \phi_i \hat{Y}_t(l-i) - \sum_{j=l}^q \theta_j \varepsilon_{t+l-j}.$$

这里约定

$$\hat{Y}_t(0) = X_t - \mu, \quad \hat{Y}_t(-j) = X_{t-j} - \mu, \quad j = 1, \dots, p-1.$$

Example 4.12 (ARMA(1, 1) 模型的预测) 考虑零均值因果可逆 ARMA(1, 1) 模型

$$X_t = \phi X_{t-1} + \varepsilon_t - \theta \varepsilon_{t-1}.$$

由 ARMA 预测公式可得

$$\hat{X}_t(1) = \phi X_t - \theta \varepsilon_t.$$

当 $l \geq 2$ 时, MA 部分只含未来冲击, 条件期望为零, 所以

$$\hat{X}_t(l) = \phi \hat{X}_t(l-1).$$

因此

$$\hat{X}_t(l) = \begin{cases} \phi X_t - \theta \varepsilon_t, & l = 1, \\ \phi^{l-1}(\phi X_t - \theta \varepsilon_t), & l \geq 2. \end{cases}$$

该模型的 Green 函数由

$$\frac{1 - \theta B}{1 - \phi B} = (1 - \theta B)(1 + \phi B + \phi^2 B^2 + \cdots)$$

得到. 因此

$$G_0 = 1, \quad G_j = (\phi - \theta)\phi^{j-1}, \quad j \geq 1.$$

所以

$$\text{Var}[e_t(1)] = \sigma_\varepsilon^2.$$

当 $l \geq 2$ 时,

$$\text{Var}[e_t(l)] = [1 + (\phi - \theta)^2(1 + \phi^2 + \cdots + \phi^{2l-4})] \sigma_\varepsilon^2.$$

若 $|\phi| < 1$, 则

$$\text{Var}[e_t(l)] \rightarrow \left[1 + \frac{(\phi - \theta)^2}{1 - \phi^2}\right] \sigma_\varepsilon^2.$$

该例说明, ARMA(1, 1) 的一步预测同时使用 X_t 和 ε_t , 两步以后预测值按 AR 部分递推.

§4.3 预测的修正

预测修正的本质是: 新观测值到来后, 新冲击进入可观测信息中. 例如观测到 X_{t+1} 后, 一步预测误差

$$X_{t+1} - \hat{X}_t(1)$$

就识别出了新的冲击 ε_{t+1} . 该冲击会通过 Green 函数继续影响更远期的预测值.

Theorem 4.13 (多期预测修正公式) 站在时刻 t , 对 X_{t+l} 的预测为 $\hat{X}_t(l)$. 若之后又观测到

$$X_{t+1}, X_{t+2}, \dots, X_{t+r}, \quad 1 \leq r < l,$$

则新的预测原点为 $t+r$, 同一个目标 X_{t+l} 的预测步长变为 $l-r$. 此时修正后的预测值为

$$\hat{X}_{t+r}(l-r) = \hat{X}_t(l) + G_{l-r}\varepsilon_{t+r} + G_{l-r+1}\varepsilon_{t+r-1} + \cdots + G_{l-1}\varepsilon_{t+1}.$$

其中每个新冲击可由一步预测误差识别:

$$\varepsilon_{t+s} = X_{t+s} - \hat{X}_{t+s-1}(1), \quad s = 1, 2, \dots, r.$$

修正后的预测误差为

$$e_{t+r}(l-r) = \varepsilon_{t+l} + G_1\varepsilon_{t+l-1} + \cdots + G_{l-r-1}\varepsilon_{t+r+1}.$$

因此

$$\text{Var}[e_{t+r}(l-r)] = (1 + G_1^2 + \cdots + G_{l-r-1}^2)\sigma_\varepsilon^2.$$

与原预测相比, 预测误差方差减少

$$\text{Var}[e_t(l)] - \text{Var}[e_{t+r}(l-r)] = (G_{l-r}^2 + G_{l-r+1}^2 + \cdots + G_{l-1}^2)\sigma_\varepsilon^2.$$

Proof. 由 Green 函数预测公式,

$$\hat{X}_t(l) = \sum_{j=l}^{\infty} G_j \varepsilon_{t+l-j} = G_l \varepsilon_t + G_{l+1} \varepsilon_{t-1} + \cdots.$$

当预测原点更新为 $t+r$ 时,

$$\begin{aligned} \hat{X}_{t+r}(l-r) &= \sum_{j=l-r}^{\infty} G_j \varepsilon_{t+l-j} \\ &= G_{l-r} \varepsilon_{t+r} + \cdots + G_{l-1} \varepsilon_{t+1} + G_l \varepsilon_t + G_{l+1} \varepsilon_{t-1} + \cdots. \end{aligned}$$

与 $\hat{X}_t(l)$ 相比, 新预测多出了

$$G_{l-r} \varepsilon_{t+r} + G_{l-r+1} \varepsilon_{t+r-1} + \cdots + G_{l-1} \varepsilon_{t+1},$$

故得到修正公式.

又由一步预测误差公式,

$$e_{t+s-1}(1) = X_{t+s} - \hat{X}_{t+s-1}(1) = \varepsilon_{t+s}, \quad s = 1, \dots, r.$$

所以新观测值等价于识别出了新的冲击 $\varepsilon_{t+1}, \dots, \varepsilon_{t+r}$.

原预测误差为

$$e_t(l) = \varepsilon_{t+l} + G_1 \varepsilon_{t+l-1} + \cdots + G_{l-1} \varepsilon_{t+1}.$$

识别出 $\varepsilon_{t+1}, \dots, \varepsilon_{t+r}$ 后, 这些项不再属于预测误差, 因而

$$e_{t+r}(l-r) = \varepsilon_{t+l} + G_1 \varepsilon_{t+l-1} + \cdots + G_{l-r-1} \varepsilon_{t+r+1}.$$

由白噪声不同时刻不相关, 得到方差公式和方差减少量. 定理得证. $\square$

Remark 4.14 预测修正不是重新建立模型, 而是更新信息集. 新观测 X_{t+s} 到来后, 一步预测误差

$$X_{t+s} - \hat{X}_{t+s-1}(1)$$

识别出新冲击 ε_{t+s} . 这些新冲击原本属于预测误差, 现在变成已知信息, 因此会修正预测值并降低预测误差方差.

Example 4.15 (一期预测修正) 若只新观测到 X_{t+1} , 则 $r = 1$. 此时

$$\varepsilon_{t+1} = X_{t+1} - \hat{X}_t(1).$$

原来站在时刻 t 对 X_{t+l} 的预测为 $\hat{X}_t(l)$. 观测到 X_{t+1} 后, 新预测为

$$\hat{X}_{t+1}(l-1) = \hat{X}_t(l) + G_{l-1} \varepsilon_{t+1}.$$

也就是

$$\hat{X}_{t+1}(l-1) = \hat{X}_t(l) + G_{l-1} [X_{t+1} - \hat{X}_t(1)].$$

修正前预测误差为

$$e_t(l) = \varepsilon_{t+l} + G_1\varepsilon_{t+l-1} + \cdots + G_{l-1}\varepsilon_{t+1}.$$

修正后, ε_{t+1} 已经可观测, 所以新的预测误差为

$$e_{t+1}(l-1) = \varepsilon_{t+l} + G_1\varepsilon_{t+l-1} + \cdots + G_{l-2}\varepsilon_{t+2}.$$

因此

$$\text{Var}[e_{t+1}(l-1)] = (1 + G_1^2 + \cdots + G_{l-2}^2)\sigma_\varepsilon^2,$$

且

$$\text{Var}[e_t(l)] - \text{Var}[e_{t+1}(l-1)] = G_{l-1}^2\sigma_\varepsilon^2.$$

§4.4 习题

Example 4.16 已知某地区每年常驻人口数量近似服从 MA(3) 模型

$$X_t = 100 + \varepsilon_t - 0.8\varepsilon_{t-1} - 0.6\varepsilon_{t-2} - 0.2\varepsilon_{t-3}, \quad \varepsilon_t \sim WN(0, 25).$$

2002–2004 年的常驻人口数量以及一步预测数量如下表.

年份	2002	2003	2004
人口数量	104	108	105
一步预测数量	110	100	109

站在 2004 年, 预测未来五年该地区常驻人口数量的 95% 预测区间.

Solution. 由一步预测误差可得

$$\varepsilon_{2002} = 104 - 110 = -6, \quad \varepsilon_{2003} = 108 - 100 = 8, \quad \varepsilon_{2004} = 105 - 109 = -4.$$

站在 2004 年, 未来五年的预测值分别为

$$\hat{X}_{2004}(1) = 100 - 0.8\varepsilon_{2004} - 0.6\varepsilon_{2003} - 0.2\varepsilon_{2002} = 99.6,$$

$$\hat{X}_{2004}(2) = 100 - 0.6\varepsilon_{2004} - 0.2\varepsilon_{2003} = 100.8,$$

$$\hat{X}_{2004}(3) = 100 - 0.2\varepsilon_{2004} = 100.8.$$

由于模型为 MA(3), 所以超过三步后预测回到均值,

$$\hat{X}_{2004}(4) = 100, \quad \hat{X}_{2004}(5) = 100.$$

根据 MA(q) 模型的预测误差方差公式,

$$\text{Var}[e_t(l)] = \begin{cases} (1 + \theta_1^2 + \cdots + \theta_{l-1}^2)\sigma_\varepsilon^2, & 1 \leq l \leq q, \\ (1 + \theta_1^2 + \cdots + \theta_q^2)\sigma_\varepsilon^2, & l > q. \end{cases}$$

因此

$$\text{Var}[e_{2004}(1)] = 25, \quad \text{Var}[e_{2004}(2)] = (1 + 0.8^2)25 = 41,$$

$$\text{Var}[e_{2004}(3)] = (1 + 0.8^2 + 0.6^2)25 = 50,$$

$$\text{Var}[e_{2004}(4)] = \text{Var}[e_{2004}(5)] = (1 + 0.8^2 + 0.6^2 + 0.2^2)25 = 51.$$

于是 95% 预测区间为

$$\hat{X}_{2004}(l) \pm 1.96\sqrt{\text{Var}[e_{2004}(l)]}.$$

计算得

预测年份	预测值	95%预测区间
2005	99.6	(89.8, 109.4)
2006	100.8	(88.25, 113.35)
2007	100.8	(86.94, 114.66)
2008	100	(86.00, 114.00)
2009	100	(86.00, 114.00)

□

Example 4.17 已知某超市月销售额近似服从 AR(2) 模型

$$X_t = 10 + 0.6X_{t-1} + 0.3X_{t-2} + \varepsilon_t, \quad \varepsilon_t \sim N(0, 36).$$

第一季度的月销售额分别为

$$X_1 = 101, \quad X_2 = 96, \quad X_3 = 97.2.$$

1. 求该商场第二季度月销售额的 95% 预测区间.
2. 若一个月后知道四月真实销售额为 $X_4 = 100$, 求五月和六月销售额的修正预测区间.

Solution. 先计算四月, 五月, 六月的预测值.

$$\hat{X}_3(1) = 10 + 0.6X_3 + 0.3X_2 = 97.12.$$

$$\hat{X}_3(2) = 10 + 0.6\hat{X}_3(1) + 0.3X_3 = 97.432.$$

$$\hat{X}_3(3) = 10 + 0.6\hat{X}_3(2) + 0.3\hat{X}_3(1) = 97.5952.$$

该 AR(2) 模型的 Green 函数满足

$$G_0 = 1, \quad G_1 = 0.6, \quad G_2 = 0.6G_1 + 0.3G_0 = 0.66.$$

所以

$$\text{Var}[e_3(1)] = G_0^2\sigma_\varepsilon^2 = 36,$$

$$\text{Var}[e_3(2)] = (G_0^2 + G_1^2)\sigma_\varepsilon^2 = 48.96,$$

$$\text{Var}[e_3(3)] = (G_0^2 + G_1^2 + G_2^2)\sigma_\varepsilon^2 = 64.6416.$$

因此修正前第二季度的 95% 预测区间为

预测月份	预测值	95%预测区间
四月	97.12	(85.36, 108.88)
五月	97.432	(83.72, 111.15)
六月	97.5952	(81.84, 113.35)

下面进行预测修正. 已知四月真实销售额为

$$X_4 = 100.$$

因此新识别出的冲击为

$$\varepsilon_4 = X_4 - \hat{X}_3(1) = 100 - 97.12 = 2.88.$$

由预测修正公式

$$\hat{X}_{t+1}(l-1) = \hat{X}_t(l) + G_{l-1}\varepsilon_{t+1},$$

可得五月的修正预测为

$$\hat{X}_4(1) = \hat{X}_3(2) + G_1\varepsilon_4 = 97.432 + 0.6(2.88) = 99.16.$$

六月的修正预测为

$$\hat{X}_4(2) = \hat{X}_3(3) + G_2\varepsilon_4 = 97.5952 + 0.66(2.88) = 99.496.$$

修正后, 五月是一阶预测, 六月是二阶预测, 因此

$$\text{Var}[e_4(1)] = 36, \quad \text{Var}[e_4(2)] = 48.96.$$

于是修正后的 95% 预测区间为

预测月份	修正预测值	95%修正预测区间
五月	99.16	(87.40, 110.92)
六月	99.496	(85.79, 113.21)

□

图展示了新观测值到来后预测修正的过程. 黑色折线表示截至 4 月的已观测值, 蓝色虚线表示站在 3 月时得到的原预测, 绿色实线表示在观测到 4 月真实值 $X_4 = 100$ 后得到的修正预测. 蓝色阴影区域表示原预测的 95% 预测区间, 绿色阴影区域表示修正后的 95% 预测区间.

由于新观测值识别出新的冲击

$$\varepsilon_4 = X_4 - \hat{X}_3(1) = 2.88,$$

故后续各步预测会相应调整. 从图中还可以看到, 修正后的预测区间比原预测区间更窄, 说明随着信息集的扩大, 预测误差方差减小, 预测精度得到提高.




Figure 4.1: Forecast revision after a new observation in an AR(2) model

参考文献

- [1] 何书元. (2023). 应用时间序列分析. 第 2 版. 北京: 北京大学出版社.
- [2] Brockwell, P. J., and Davis, R. A. (2016). *Introduction to Time Series and Forecasting*. 3rd ed. Cham: Springer.
- [3] Brockwell, P. J., and Davis, R. A. (1991). *Time Series: Theory and Methods*. 2nd ed. New York: Springer-Verlag.
- [4] Wold, H. (1938). *A Study in the Analysis of Stationary Time Series*. Uppsala: Almqvist & Wiksells Boktryckeri-A.-B.
- [5] Bartlett, M. S. (1946). On the Theoretical Specification and Sampling Properties of Auto-correlated Time-Series. *Supplement to the Journal of the Royal Statistical Society*, 8(1), 27–41.