



## 数理统计笔记

作者：徐知南而北游  
时间：2025年7月7日

---

## 目录

---

<b>1</b>	<b>统计量及其分布</b>	<b>1</b>
1.1	总体和样本	1
1.2	统计量	1
1.2.1	样本均值	2
1.2.2	样本方差与样本矩	4
1.2.3	次序统计量	5
1.2.4	充分统计量	6
1.3	常见分布族	10
1.3.1	Gamma 分布族	10
1.3.2	正态分布族	10
1.3.3	指数族	11
1.4	三大抽样分布	12
1.4.1	卡方分布	12
1.4.2	F 分布	14
1.4.3	t 分布	15
1.4.4	重要推论	16
1.5	统计量的极限分布	16
<b>2</b>	<b>点估计</b>	<b>17</b>
2.1	参数估计方法	17
2.1.1	矩估计	17
2.1.2	极大似然估计	19
2.2	点估计的性质	19
2.2.1	无偏性	19
2.2.2	均方误差	22
2.2.3	相合性	23
2.2.4	渐进正态性	23
2.3	一致最小方差无偏估计	24
<b>3</b>	<b>区间估计</b>	<b>27</b>
3.1	基础概念	27
3.2	枢轴量-正态总体参数的置信区间	27
3.2.1	单个正态总体的置信区间	28
3.2.2	两个正态总体参数的置信区间	29

# Chapter 1

## 统计量及其分布

### §1.1 总体和样本

- **总体:** 所要研究对象的全体被称为总体, 总体中的元素被称为个体
- **样本:** 从总体中随机抽取  $n$  个个体, 记其指标为  $X_1, \dots, X_n$ , 则称  $X_1, \dots, X_n$  是来自总体的一个样本, 其中  $n$  称为样本量。

【命题 1.1】 设总体  $X$  的概率 (密度) 函数为  $f(x)$  (分布函数为  $F(x)$ ), 则

1.  $X_1, \dots, X_n$  独立同分布于  $X$ , 记为  $X_1, \dots, X_n \sim f(x)$ 。
2.  $X_1, \dots, X_n$  的联合概率函数为

$$f(x_1, \dots, x_n) = f_{X_1}(x_1) \cdots f_{X_n}(x_n) = f(x_1) \cdots f(x_n) = \prod_{i=1}^n f(x_i).$$

3.  $X_1, \dots, X_n$  的联合分布函数

$$F(x_1, \dots, x_n) = F_{X_1}(x_1) \cdots F_{X_n}(x_n) = F(x_1) \cdots F(x_n) = \prod_{i=1}^n F(x_i).$$

【例题 1.2】 设总体  $X \sim N(\mu, \sigma^2)$ ,  $X_1, \dots, X_n$  是来自总体  $X$  的一组样本, 求  $X_1, \dots, X_n$  的联合概率函数。

解. 由于

$$\begin{aligned} f(x) \sim N(\mu, \sigma^2) &\implies f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\} \\ \implies f(x_1, \dots, x_n) &= \prod_{i=1}^n f(x_i) = \left(\frac{1}{\sigma\sqrt{2\pi}}\right)^n \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} \end{aligned}$$

□

### §1.2 统计量

- **统计量:** 是样本的函数, 且不含任何未知参数. 是可以由样本算出的量 (完全由样本决定的量), 通常用  $T = T(X_1, \dots, X_n)$  表示。

**【例题 1.3】** 设  $X_1, \dots, X_n$  是来自  $N(\mu, \sigma^2)$  的样本, 其中  $\mu$  已知,  $\sigma^2$  未知. 令  $X_{(1)} = \min[X_1, \dots, X_n]$ ,  $X_{(n)} = \max[X_1, \dots, X_n]$ , 判断

1.  $X_{(n)} - X_{(1)}$  和  $\frac{1}{2}(X_{(n)} + X_{(1)})$  是否为统计量
2.  $\frac{1}{2}(X_{(n)} + X_{(1)}) - \mu$  和  $\frac{1}{\sigma}(X_{(n)} - X_{(1)})$  是否为统计量.

### 1.2.1 样本均值

**【定义 1.4】(样本均值)** 设  $X_1, \dots, X_n$  是来自  $f(x; \theta)$  的样本, 称

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

为样本均值.

**【定理 1.5】** 设总体  $X$  的均值  $E(X) = \mu$ , 方差  $\text{var}(X) = \sigma^2 < +\infty$ , 令  $X_1, \dots, X_n$  是来自  $X$  的随机样本, 样本均值为

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n x_i,$$

则

$$E(\bar{X}_n) = \mu, \quad \text{var}(\bar{X}_n) = \sigma^2/n.$$

**证明.** 直接计算得

$$E(\bar{X}_n) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} E\left(\sum_{i=1}^n X_i\right) = \mu$$

方差同理

□

**【注 1.6】** 1. 根据辛钦大数定律

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| < \epsilon) = 1, \text{ 即 } \bar{X}_n \xrightarrow{p} \mu$$

2. 根据 Chebyshev 不等式 (假设二阶矩存在),

$$P(|\bar{X}_n - \mu| < \epsilon) \geq 1 - \frac{\sigma^2}{n\epsilon^2}.$$

**【例题 1.7】** 假设某一分布的均值未知, 方差为 1, 则为了使得样本均值  $\bar{X}_n$  和总体均值  $\mu$  的差异以至少 0.95 的概率在 0.5 之内, 则至少需要多少样本?

**解.** 使用切比雪夫不等式

$$P(|\bar{X}_n - \mu| \geq \epsilon) \leq \frac{\sigma^2/n}{\epsilon^2}$$

代入  $\sigma^2 = 1, \epsilon = 0.5$ :

$$P(|\bar{X}_n - \mu| \geq 0.5) \leq \frac{1/n}{(0.5)^2} = \frac{4}{n}$$

$\Rightarrow$

$$\frac{4}{n} \leq 0.05 \Rightarrow n \geq \frac{4}{0.05} = 80$$

故最小样本量为 80.

□

对于一些具有可加性的分布, 可以精确计算其样本均值的分布, 见下例

**【例题 1.8】** 分别计算下列分布对应的样本均值  $\bar{X}$  的精确分布

1. 伯努利分布  $B(1, p)$

2. 泊松分布  $P(\lambda)$
3. 指数分布  $\exp(\theta)$
4. 柯西分布  $\text{Cauchy}(a, b)$
5. 正态分布  $N(\mu, \sigma^2)$

解.

1. 注意到

$$X_k \sim B(1, p) \quad iid \implies \sum X_k \sim B(n, p)$$

$\implies$

$$P\left(\sum_{i=1}^n X_i = k\right) = \binom{n}{k} p^k (1-p)^{n-k} \quad k = 0, \dots, n.$$

$\implies$

$$P\left(\bar{X}_n = \frac{k}{n}\right) = \binom{n}{k} p^k (1-p)^{n-k} \quad k = 0, \dots, n.$$

2. 注意到

$$X_k \sim P(\lambda) \quad iid \implies \sum X_k \sim P(n\lambda)$$

$\implies$

$$P\left(\sum_{i=1}^n X_i = k\right) = \frac{(n\lambda)^k}{k!} e^{-n\lambda}, \quad \forall k \in \mathbb{Z}_{>0}$$

$\implies$

$$P\left(\bar{X}_n = \frac{k}{n}\right) = P\left(\sum_{i=1}^n X_i = k\right) = \frac{(n\lambda)^k}{k!} e^{-n\lambda}$$

3. 注意到

$$X_k \sim \exp(\theta) \quad iid \implies Y := \sum X_k \sim \text{Ga}(n, \theta)$$

$\implies$

$$f_Y(y) = \frac{\theta^n}{\Gamma(n)} y^{n-1} \exp(-\theta y) \quad y > 0$$

$\implies$

$$f_{\bar{X}}(x) = f_Y(nx)n \sim \text{Ga}(n, n\theta)$$

- 4.

5. 注意到

$$X_k \sim N(\mu, \sigma^2) \quad iid \implies \sum X_k \sim N(n\mu, n\sigma^2) \implies \bar{X}_n = \frac{1}{n} \sum X_k \sim N\left(\mu, \sigma^2/n\right).$$

□

对于一般的分布，仍然可以考虑其样本均值的渐进分布 (CLT)

**【定理 1.9】(中心极限定理)** 设  $f(x)$  是一个具有均值  $\mu$  和方差  $\sigma^2$  的概率密度函数。设  $\bar{X}_n$  为来自  $f(x)$  的大小为  $n$  的随机样本的样本均值。定义  $Z_n$

$$Z_n = \frac{\bar{X}_n - \mu}{\sqrt{\text{var}(\bar{X}_n)}} = \frac{\bar{X}_n - \mu}{\sqrt{\sigma^2/n}}$$

则有

$$Z_n \xrightarrow{d} N(0, 1) \iff \bar{X}_n \xrightarrow{d} N\left(\mu, \frac{\sigma^2}{n}\right)$$

【例题 1.10】 下图对比了  $n = 1, 5, 30, 100$  时，总体  $X \sim \exp(1)$  的渐进分布和精确分布的差异

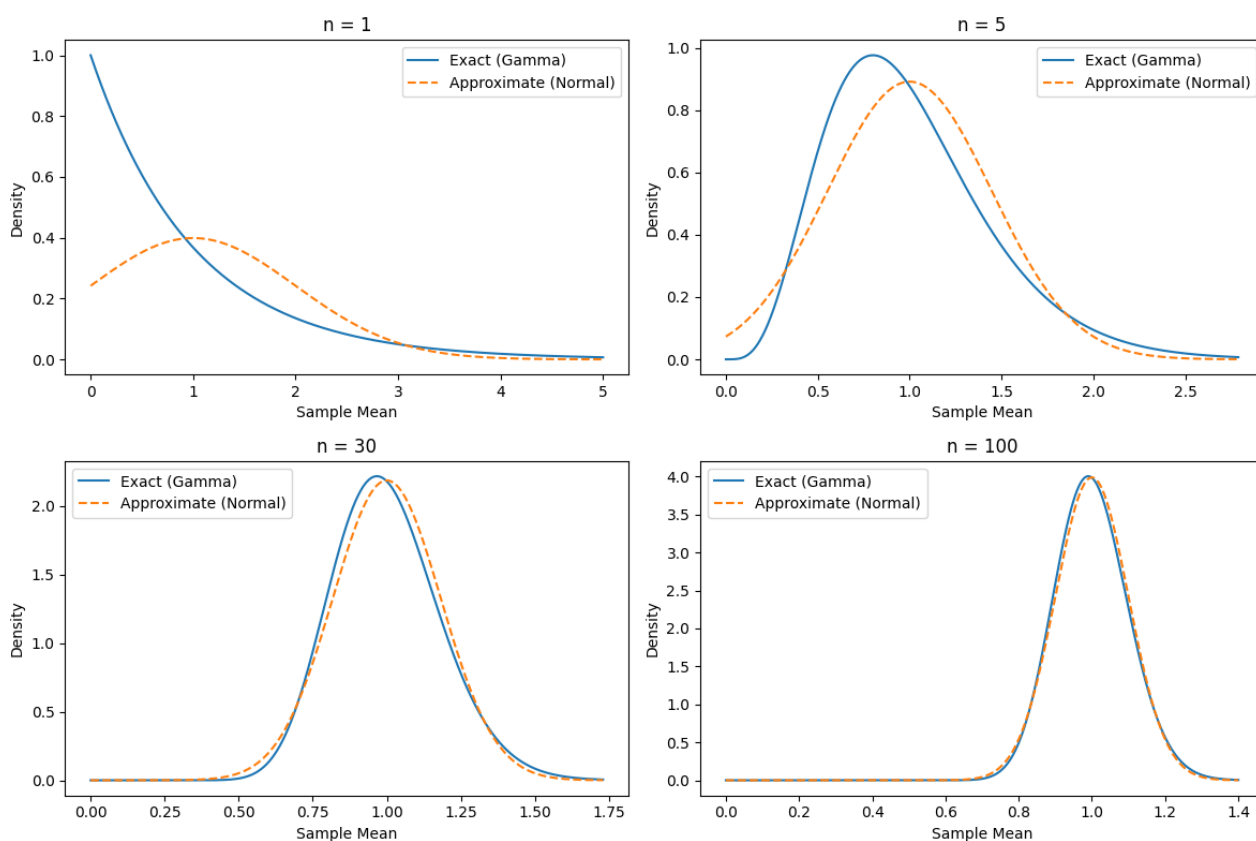


图 1.1: 指数分布

## 1.2.2 样本方差与样本矩

【定义 1.11】 (样本方差) 设  $X_1, \dots, X_n$  是来自  $f(x)$  的一个样本，且  $\bar{X}_n$  为样本均值。则称

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \quad (n > 1)$$

为样本方差。

【定理 1.12】 设  $X_1, \dots, X_n$  是来自  $f(x)$  的样本，且

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

则

$$E(S^2) = \sigma^2, \quad \text{var}(S^2) = \frac{1}{n} \left( \mu_4 - \frac{n-3}{n-1} \sigma^4 \right) \quad n > 1$$

其中  $\sigma^2 = \text{var}(X)$  为总体方差， $\mu_4 = E[(X - E(X))^4]$  为总体四阶中心矩。

【注 1.13】 关于样本方差的计算大多要用到恒等变形

$$\sum_{i=1}^n (X_i - \bar{X}_n)^2 = \sum_{i=1}^n X_i^2 - n\bar{X}_n^2$$

以及

$$\sum_{i=1}^n (X_i - \bar{X}_n)^2 = \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X}_n - \mu)^2$$

**证明.**

1. 直接计算得

$$\begin{aligned}(n-1)\mathbb{E}(S^2) &= \mathbb{E}\left(\sum_{i=1}^n x_i^2 - n\bar{X}_n^2\right) = n\mathbb{E}\left(\sum_{i=1}^n x_i^2\right) - n\mathbb{E}(\bar{X}_n^2) \\ &= n(\mu + \sigma^2) - n\left(\mu + \frac{\sigma^2}{n}\right) = (n-1)\sigma^2\end{aligned}$$

两边消去  $n-1$  即可

2. 我们考虑中心化变换  $Y_i = X_i - \mu$  则由注解知

$$S^2 = \frac{1}{n-1} \left( \sum y_i^2 - n\bar{y}^2 \right)$$

则

$$\begin{aligned}(n-1)^2 E\left[(S^2)^2\right] &= E\left[\left(\sum y_i^2 - n\bar{y}^2\right)^2\right] \\ &= E\left(\sum y_i^2\right)^2 - 2nE\left(\sum y_i^2 \bar{y}^2\right) + n^2 E(\bar{y}^4) \\ &= E\left(\sum y_i^2\right)^2 - 2n^2 E\left(y_1^2 \bar{y}^2\right) + n^2 E\left(y_1 \bar{y}^3\right) \\ &= E\left(\sum y_i^2\right)^2 - 2E\left(y_1^2 (\sum y_i)^2\right) + \frac{1}{n} E\left[y_1 (\sum y_i)^3\right]\end{aligned}$$

分别计算得

$$\begin{aligned}E\left(\sum y_i^2\right)^2 &= E\left(\sum y_i^4 + 2\sum_{i<j} y_i^2 y_j^2\right) = n\mu_4 + n(n-1)\sigma^4 \\ E\left[y_1^2 (\sum y_i)^2\right] &= E\left(y_1^4 + \sum_{i\neq 1} y_1^2 y_i^2\right) = \mu_4 + (n-1)\sigma^4 \quad \text{独立} \implies \text{交叉项期望为0} \\ E\left[y_1 (\sum y_i)^3\right] &= E\left(y_1^4\right) + \binom{3}{1} E\left(y_1^2 \sum_{i\neq 1} y_i^2\right) \quad \text{独立} \implies \text{其他交叉项期望为0} \\ &= \mu_4 + 3(n-1)\sigma^4\end{aligned}$$

相加并比较系数得

$$\begin{aligned}(n-1)^2 E\left[(S^2)^2\right] &= \left(n-2+\frac{1}{n}\right)\mu_4 + \left(n^2-n-2n+2+3-\frac{3}{n}\right)\sigma^4 \\ &= \frac{(n-1)^2}{n}\mu_4 + \left[(n-1)^2 - \frac{n^2-4n+3}{n}\right]\sigma^4 \\ \implies \text{Var}(S^2) &= E\left[(S^2)^2\right] - \sigma^4 \\ &= \frac{\mu_4}{n} - \frac{(n-1)(n-3)}{n(n-1)^2}\sigma^4 \\ &= \frac{\mu_4}{n} - \frac{n-3}{n(n-1)}\sigma^4\end{aligned}$$

□

**1.2.3 次序统计量**

**【定义 1.14】(次序统计量)** 设  $X_1, \dots, X_n$  是来自累积分布函数  $F(x)$  的容量为  $n$  的随机样本, 则

$$Y_1 \leq \dots \leq Y_n$$

或

$$X_{(1)} \leq \cdots \leq X_{(n)}$$

**【注 1.15】**  $Y_1, \cdots, Y_n$  是统计量, 且为随机样本  $X_1, \cdots, X_n$  的函数, 但  $Y_1, \cdots, Y_n$  并不独立。若  $Y_i > y$ , 则  $Y_j > y$  对所有  $j = i+1, \cdots, n$  成立。

## 次序统计量的边缘分布

**【例题 1.16】** 最小次序统计量  $Y_1 = \min \{X_1, \cdots, X_n\}$  的分布函数和密度函数

解.

### 1. 分布函数

$$\begin{aligned} F_{Y_1}(y) &= P(Y_1 \leq y) = 1 - P(Y_1 > y) = 1 - P(\min \{X_1, \cdots, X_n\} > y) \\ &= 1 - P(X_1 > y, \cdots, X_n > y) = 1 - \prod_{i=1}^n P(X_i > y) \\ &= 1 - [1 - F_X(y)]^n. \end{aligned}$$

### 2. 密度函数

$$f_{Y_1}(y) = n [1 - F_X(y)]^{n-1} f_X(y).$$

□

**【例题 1.17】** 最大次序统计量  $Y_n = \max \{X_1, \cdots, X_n\}$  的分布函数和密度函数

解.

### 1. 分布函数

$$\begin{aligned} F_{Y_n}(y) &= P(Y_n \leq y) = P(\max \{X_1, \cdots, X_n\} \leq y) \\ &= \prod_{i=1}^n P(X_i \leq y) = [F_X(y)]^n \end{aligned}$$

### 2. 密度函数

$$f_{Y_n}(y) = n F_X(y)^{n-1} f_X(y).$$

□

## 次序统计量的联合分布

### 1.2.4 充分统计量

**【定义 1.18】(充分统计量)** 设  $(x_1, x_2, \cdots, x_n)$  是总体  $X$  的样本, 其分布函数为  $F(x; \theta)$  如果有

$$P_{\theta}((x_1 \cdots x_n) | T = t) = P((x_1 \cdots x_n) | T = t)$$

则称  $T(x_1 \cdots x_n)$  为  $\theta$  的充分统计量

**【例题 1.19】** 设  $X = (X_1, X_2, \cdots, X_n)$  为从 0-1 分布中抽取的简单样本, 则  $T(X) = \sum_{i=1}^n X_i$  为充分统计量.

解. 直接计算

$$\begin{aligned} P(X_1 = x_1, \cdots, X_n = x_n | T = t_0) &= \frac{P(X_1 = x_1, \cdots, X_n = x_n, T = t_0)}{P(T = t_0)} \\ &= \frac{P(X_1 = x_1, \cdots, X_n = t_0 - \sum_{i=1}^{n-1} x_i)}{P(T = t_0)} = \frac{\theta^{t_0} (1 - \theta)^{n-t_0}}{\binom{n}{t_0} \theta^{t_0} (1 - \theta)^{n-t_0}} = \frac{1}{\binom{n}{t_0}}, \end{aligned}$$



因此有

$$P(X_1 = x_1, \dots, X_n = x_n \mid T = t_0) = \begin{cases} \frac{1}{\binom{n}{t_0}}, & \sum_{i=1}^n x_i = t_0 \\ 0, & \sum_{i=1}^n x_i \neq t_0 \end{cases}$$

上述条件概率与  $\theta$  无关, 因此  $T(\mathbf{X}) = \sum_{i=1}^n X_i$  为  $\theta$  的充分统计量.  $\square$

**【例题 1.20】** 设  $X = (X_1, X_2, \dots, X_n)$  为从正态总体  $N(\theta, 1)$  中抽取的简单样本, 则  $T(\mathbf{X}) = \sum_{i=1}^n X_i/n = \bar{X}$  为  $\theta$  的充分统计量.

**解.** 作正交变换

$$(Y_1, \dots, Y_n)' = A(X_1, \dots, X_n)'$$

其中正交阵

$$A = \begin{pmatrix} \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \cdots & \frac{1}{\sqrt{n}} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}$$

由 Schmidt 正交化方法可知上述正交阵  $A$  是存在的. 变换的 Jacobi 行列式的绝对值为  $|J| = 1$ .

$$\begin{cases} Y_1 = \frac{1}{\sqrt{n}} \sum_{i=1}^n X_i = \sqrt{n} \bar{X} \\ Y_j = \sum_{k=1}^n a_{jk} X_k, \quad j = 2, \dots, n \end{cases}$$

由于  $\sum_{i=1}^n Y_i^2 = \sum_{i=1}^n X_i^2$ , 且  $Y_1, Y_2, \dots, Y_n$  是相互独立的,

$$Y_1 \sim N(\sqrt{n}\theta, 1), Y_i \sim N(0, 1), i = 2, \dots, n$$

$\bar{X}$  对原样本  $\mathbf{X}$  的充分性等价于  $Y_1$  对  $(Y_1, Y_2, \dots, Y_n)$  的充分性. 因此只要证明给定  $Y_1 = y_1$  时,  $(Y_1, Y_2, \dots, Y_n)$  的条件密度与  $\theta$  无关, 易见  $Y_1, \dots, Y_n$  的联合密度为

$$f(y_1, \dots, y_n) = (2\pi)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2} \sum_{i=2}^n y_i^2 - \frac{1}{2} (y_1 - \sqrt{n}\theta)^2 \right\}$$

$Y_1$  的边缘密度函数为

$$f_{Y_1}(y_1) = \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} (y_1 - \sqrt{n}\theta)^2 \right\}$$

给定  $Y_1 = y_1$  时,  $(Y_1, \dots, Y_n)$  的条件密度是

$$f(y_1, \dots, y_n \mid y_1) = \frac{f(y_1, \dots, y_n)}{f_{Y_1}(y_1)} = (2\pi)^{-\frac{n-1}{2}} \exp \left\{ -\frac{1}{2} \sum_{i=2}^n y_i^2 \right\},$$

与  $\theta$  无关  $\square$

**【例题 1.21】** 设  $\mathbf{X} = (X_1, \dots, X_n)$  为从指数分布  $\text{Exp}(\theta)$  中抽取的简单样本, 其密度函数为  $f(x, \theta) = \theta e^{-\theta x} I_{[x>0]}$ , 则  $T(\mathbf{X}) = \sum_{i=1}^n X_i$  为  $\theta$  的充分统计量.

**解.**  $\mathbf{X}$  的联合密度为

$$f(\mathbf{x}, \theta) = \theta^n \exp \left\{ -\theta \sum_{i=1}^n x_i \right\} I_{[x_i > 0, i=1, 2, \dots, n]},$$

作变换

$$\begin{cases} Y_1 = X_1 \\ \dots\dots\dots \\ Y_{n-1} = X_{n-1} \\ Y_n = X_1 + X_2 + \dots + X_n = T \end{cases}$$

变换的 Jacobi 行列式的绝对值为  $|J| = 1$  显然,  $T(\mathbf{X}) = \sum_{i=1}^n X_i$  对原样本  $\mathbf{X}$  的充分性等价于  $Y_n = T$  对  $(Y_1, Y_2, \dots, Y_n)$  的充分性. 因此只要证明给定  $Y_n = y_n$  (即  $T = t$ ) 时,  $(Y_1, Y_2, \dots, Y_n)$  的条件密度与  $\theta$  无关. 易见  $(Y_1, \dots, Y_{n-1}, Y_n)$  的联合密度为

$$f(y_1, y_2, \dots, y_{n-1}, t, \theta) = \theta^n e^{-\theta t} I_{[y_i > 0, i=1, 2, \dots, n-1, y_1 + \dots + y_{n-1} < t]}$$

由于  $T(\mathbf{X}) = \sum_{i=1}^n X_i \sim \Gamma(n, \theta)$ , 因此  $T = T(\mathbf{X})$  有密度函数

$$f_T(t) = \frac{\theta^n}{\Gamma(n)} t^{n-1} e^{-\theta t} I_{[t > 0]} = \frac{\theta^n}{(n-1)!} t^{n-1} e^{-\theta t} I_{[t > 0]}$$

给定  $T = t$  时,  $(Y_1, \dots, Y_n)$  的条件密度为

$$\begin{aligned} f(y_1, \dots, y_n | t) &= \frac{f(y_1, \dots, y_{n-1}, t)}{f_T(t)} \\ &= \frac{(n-1)! \theta^n e^{-\theta t} \cdot I_{[y_i > 0, i=1, \dots, n-1, y_1 + \dots + y_{n-1} < t]}}{\theta^n t^{n-1} e^{-\theta t} I_{[t > 0]}} \\ &= \frac{(n-1)! I_{[y_i > 0, i=1, \dots, n-1, y_1 + \dots + y_{n-1} < t]}}{t^{n-1} I_{[t > 0]}} \end{aligned}$$

□

**【定理 1.22】(因子分解)** 设样本  $\mathbf{X} = (X_1, \dots, X_n)$  的概率函数  $f(\mathbf{x}, \theta)$  依赖于参数  $\theta$ ,  $T = T(\mathbf{X})$  是一个统计量, 则  $T$  为充分统计量的充要条件是  $f(\mathbf{x}, \theta)$  可以分解为

$$f(\mathbf{x}, \theta) = g(t(\mathbf{x}), \theta) h(\mathbf{x})$$

的形状. 注意此处函数  $h(\mathbf{x}) = h(x_1, \dots, x_n)$  不依赖于  $\theta$ ,  $t(\mathbf{x})$  为  $T(\mathbf{X})$  的观察值.

**【推论 1.23】** 设  $T = T(\mathbf{X})$  为  $\theta$  的充分统计量,  $S = \varphi(T)$  是单值可逆函数, 则  $S = \varphi(T)$  也是  $\theta$  的充分统计量.

**【注 1.24】** 若  $T(\mathbf{X}) = \sum_{i=1}^n X_i$  是充分统计量, 则  $\bar{X}$  也是充分统计量.

**【例题 1.25】** 设  $\mathbf{X} = (X_1, \dots, X_n)$  为从正态总体  $N(a, \sigma^2)$  中抽取的简单样本, 令  $\theta = (a, \sigma^2)$ , 则  $(\bar{X}, S^2)$  为  $\theta$  的充分统计量, 此处  $\bar{X}, S^2$  分别为样本均值和样本方差.

**解.** 样本  $\mathbf{X}$  的联合密度为

$$\begin{aligned} f(\mathbf{x}, \theta) &= \left( \frac{1}{\sqrt{2\pi}\sigma} \right)^n \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - a)^2 \right\} \\ &= \left( \frac{1}{\sqrt{2\pi}\sigma} \right)^n \exp \left\{ -\frac{1}{2\sigma^2} \left( \sum_{i=1}^n x_i^2 - 2a \sum_{i=1}^n x_i + na^2 \right) \right\} \\ &= g(t(\mathbf{x}), \theta) \cdot h(\mathbf{x}) \end{aligned}$$

此处  $h(\mathbf{x}) \equiv 1$ , 由因子分解定理可知  $T(\mathbf{X}) = \left( \sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2 \right)$  为  $\theta$  的充分统计量. 由于  $\left( \sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2 \right)$  与  $(\bar{X}, S^2)$  为一一对应的变换, 由推论可知  $(\bar{X}, S^2)$  也是  $\theta$  的充分统计量. □

**解.** 将平方项展开并分解:

$$\sum_{i=1}^n (x_i - \mu)^2 = \sum_{i=1}^n (x_i - \bar{X})^2 + n(\bar{X} - \mu)^2,$$

代入联合密度函数得:

$$f(x, \mu, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{n(\bar{X} - \mu)^2 + (n-1)S^2}{2\sigma^2} \right\}.$$

进一步分解为:

$$f(x, \mu, \sigma^2) = \underbrace{(2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{n(\bar{X} - \mu)^2}{2\sigma^2} \right\}}_{g(\bar{X}, S^2; \mu, \sigma^2)} \exp \left\{ -\frac{(n-1)S^2}{2\sigma^2} \right\} \cdot \underbrace{1}_{h(x)}.$$

□

**【例题 1.26】** 设  $\mathbf{X} = (X_1, \dots, X_n)$  为从总体  $b(1, \theta)$  中抽取的简单样本, 则  $T(\mathbf{X}) = \sum_{i=1}^n X_i$  是  $\theta$  的充分统计量.

**解.** 样本  $\mathbf{X}$  的联合分布是

$$\begin{aligned} f(\mathbf{x}, \theta) &= P_\theta(X_1 = x_1, \dots, X_n = x_n) \\ &= \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} = g(t(\mathbf{x}), \theta) h(\mathbf{x}) \end{aligned}$$

其中  $h(\mathbf{x}) \equiv 1$ , 由因子分解定理可知  $T(\mathbf{X}) = \sum_{i=1}^n X_i$  为  $\theta$  的充分统计量.

□

**【例题 1.27】(次序统计量的充分性)** 设  $\mathcal{F} = \{F\}$  为一维分布族, 这里对分布函数  $F$  没有任何限制. 设  $\mathbf{X} = (X_1, \dots, X_n)$  是从某个  $F$  中抽出的简单样本,  $T(\mathbf{X}) = (X_{(1)}, X_{(2)}, \dots, X_{(n)})$  为次序统计量, 则次序统计量  $T(\mathbf{X})$  是充分的.

**解.** 特别地, 若  $F$  有密度  $f$ , 则

$$f(x_1, \dots, x_n) = f(x_1) \cdots f(x_n) = f(x_{(1)}) \cdots f(x_{(n)}) h(\mathbf{x}),$$

其中  $h(\mathbf{x}) \equiv 1$ ,  $f$  起着参数  $\theta$  的作用, 则由因子分解定理可知  $T(\mathbf{X}) = (X_{(1)}, \dots, X_{(n)})$  为充分统计量.

□

**【例题 1.28】** 设  $\mathbf{X} = (X_1, \dots, X_n)$  为从均匀分布  $U(0, \theta)$  中抽取的简单样本, 则  $T(\mathbf{X}) = X_{(n)} = \max\{X_1, \dots, X_n\}$  为  $\theta$  的充分统计量.

**解.** 样本  $\mathbf{X}$  的联合密度为

$$f(\mathbf{x}, \theta) = \frac{1}{\theta^n} I_{(0, \theta)}(x_{(n)}) = g(t(\mathbf{x}), \theta) h(\mathbf{x}),$$

其中  $h(\mathbf{x}) \equiv 1$ . 由因子分解定理可知  $T(\mathbf{X}) = X_{(n)}$  为  $\theta$  的充分统计量.

□

**【例题 1.29】** 若  $\mathbf{X} = (X_1, \dots, X_n)$  为从指数族中抽取的简单样本, 则  $T(\mathbf{X}) = (T_1(\mathbf{X}), \dots, T_k(\mathbf{X}))$  为充分统计量.

**解.** 样本  $\mathbf{X}$  的联合密度为

$$f(\mathbf{x}, \theta) = C(\theta) \exp \left\{ \sum_{i=1}^k Q_i(\theta) t_i(\mathbf{x}) \right\} h(\mathbf{x}) = g(t(\mathbf{x}), \theta) h(\mathbf{x}),$$

其中  $g(t(\mathbf{x}), \theta) = C(\theta) \exp \left\{ \sum_{i=1}^k Q_i(\theta) t_i(\mathbf{x}) \right\}$ ,  $t(\mathbf{x})$  为  $T(\mathbf{X})$  的观察值. 由因子分解定理立得  $T(\mathbf{X}) = (T_1(\mathbf{X}), \dots, T_k(\mathbf{X}))$  为  $\theta$  的充分统计量.

□

**【定义 1.30】** 设  $T$  是分布族  $\mathcal{F}$  的充分统计量, 若对  $\mathcal{F}$  的任一充分统计量  $S(\mathbf{X})$ , 存在一个函数  $q_S(\cdot)$  使得  $T(\mathbf{X}) = q_S(S(\mathbf{X}))$ , 则称  $T(\mathbf{X})$  是此分布族的极小充分统计量.

## § 1.3 常见分布族

### 1.3.1 Gamma 分布族

**【定义 1.31】(Gamma 分布)** 如果  $X$  的密度是

$$f(x; \alpha, \lambda) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} \chi_{(0, \infty)}(x),$$

就称  $X$  服从参数  $\alpha, \lambda$  的 Gamma 分布，记做  $X \sim \text{Ga}(\alpha; \lambda)$ ，其中  $\alpha > 0$  为形状参数， $\lambda > 0$  为尺度参数。




图 1.2: Caption

### 1.3.2 正态分布族

**【定义 1.32】(多元正态分布)** 设  $X \in \mathbb{R}^n$  若  $X$  密度为

$$f_X(x) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(X - \mu)^T \Sigma^{-1} (X - \mu)\right)$$

则称其为多元正态分布，记为  $X \sim N(\mu, \Sigma)$

**【注 1.33】** 考虑积分

$$\int_{\mathbb{R}^n} f_X(x) dx = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \int_{\mathbb{R}^n} \exp\left(-\frac{1}{2}(X - \mu)^T \Sigma^{-1} (X - \mu)\right) dx$$

由于  $\Sigma$  正定，做特征分解  $\Sigma = U^T \Lambda U$  其中  $U^T U = U U^T = I, \Lambda = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$ ，故

$$\int_{\mathbb{R}^n} \exp\left(-\frac{1}{2}(X - \mu)^T \Sigma^{-1} (X - \mu)\right) dx = \int_{\mathbb{R}^n} \exp\left(-\frac{1}{2}Y^T \Lambda^{-1} Y\right) dy$$

其中  $Y = U(X - \mu)$ ，且有对应 Jacobi 行列式为 1，最后注意到  $|\Sigma|^{1/2} = \prod_{k=1}^n \sigma_k$

$$\frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \int_{\mathbb{R}^n} \exp\left(-\frac{1}{2}Y^T \Lambda^{-1} Y\right) dy = 1$$

即原表达式的确是一个密度函数

**【定理 1.34】** 设  $X \sim N(\mu, \Sigma)$  则对应特征函数  $\phi_X(\omega) = \exp(j\omega^T \mu - \frac{1}{2}\omega^T \Sigma \omega)$

**证明.** 直接计算得

$$\phi_X(\omega) = \mathbb{E} \left[ \exp(j\omega^T X) \right] = \int_{\mathbb{R}^n} \exp(j\omega^T x) f_X(x) dx$$

考虑配方

$$-\frac{1}{2} (x - \mu - j\Sigma\omega)^T \Sigma^{-1} (x - \mu - j\Sigma\omega) + j\omega^T \mu - \frac{1}{2} \omega^T \Sigma \omega.$$

则原积分

$$I = \exp \left( j\omega^T \mu - \frac{1}{2} \omega^T \Sigma \omega \right) \cdot \frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}} \int_{\mathbb{R}^n} \exp(*) dx.$$

其中(\*)是配方之后的二次型, 则后面积分值必为1, 故得到特征函数

$$\phi_X(\omega) = \exp(j\omega^T \mu - \frac{1}{2} \omega^T \Sigma \omega)$$

□

**【定理 1.35】(线性性)** 设  $X \sim N_n(\mu, \Sigma)$ ,  $A$  为任一  $r \times n$  阶阵, 令  $Y = AX$ , 则

$$Y \sim N_r(A\mu, A\Sigma A^T)$$

**证明.** 直接计算  $Y$  的特征函数

$$\begin{aligned} \phi_Y(\omega) &= \mathbb{E}[\exp(j\omega^T AX)] = \mathbb{E}[\exp(j(A^T \omega)^T X)] = \phi_X(A^T \omega) \\ &= \exp \left( j(A^T \omega)^T \mu - \frac{1}{2} (A^T \omega)^T \Sigma (A^T \omega) \right) \\ &= \exp \left( j\omega^T A\mu - \frac{1}{2} \omega^T A\Sigma A^T \omega \right) \end{aligned}$$

由特征函数唯一性, 显然有  $Y \sim N_r(A\mu, A\Sigma A^T)$

□

**【推论 1.36】(边缘分布)**

**证明.**

□

**【注 1.37】** 这个命题的逆是错的

将上面几个定理总结如下:

- 正态变量的线性变换仍然是正态变量.
- 正态分布的边缘分布仍然是正态分布
- 正态分布变量独立等价于不相关
- 正态分布的条件分布仍然是正态分布

### 1.3.3 指数族

**【定义 1.38】** 设  $\mathcal{F} = \{f(x, \theta) : \theta \in \Theta\}$  是定义在样本空间  $\Omega$  上的分布族, 其中  $\Theta$  为参数空间. 若其概率函数  $f(x, \theta)$  可表示成如下形式:

$$f(x, \theta) = C(\theta) \exp \left\{ \sum_{i=1}^k Q_i(\theta) T_i(x) \right\} h(x)$$

则称此分布族为指数型分布族, 其中  $k$  为正整数,  $C(\theta) > 0$  和  $Q_i(\theta) (i = 1, 2, \dots, k)$  都是定义在参数空间  $\Theta$  上的函数,  $h(x) > 0$  和  $T_i(x) (i = 1, 2, \dots, k)$  都是定义在样本空间  $\Omega$  上的函数.

**【注 1.39】** 指数族的一个重要性质是族中的所有分布具有共同的支撑集 ( $G(x)$  称为概率函数  $f(x, \theta)$  的支撑集, 若  $G(x) = \{x : f(x, \theta) > 0\}$ ). 由定义可见指数族的支撑集  $\{x : f(x, \theta) > 0\} = \{x : h(x) > 0\}$  与  $\theta$  无关. 任一分布族若其支撑集与  $\theta$  有关, 则族中分布不再具有共同支撑集, 因而必不是指数族.

**【命题 1.40】** 容易验证下列分布族是指数族

1.  $X = (X_1, \dots, X_n)$  为从正态分布  $N(\mu, \sigma^2)$  中抽取的简单样本
2.  $X = (X_1, \dots, X_n)$  为从 Gamma 分布  $\Gamma(\gamma, \lambda)$  中抽取的简单样本
3. 二项分布族  $\{b(n, \theta) : 0 < \theta < 1\}$
4. Poisson 分布族  $\{P(\theta) : \theta > 0\}$

**证明.**

- 1.
- 2.
- 3.
- 4.

□

**解.** 样本  $X$  的联合密度为

$$f(x; \mu, \sigma^2) = (\sqrt{2\pi}\sigma)^{-n} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\}.$$

记  $\theta = (\mu, \sigma^2)$ , 则参数空间为  $\theta = \{(\mu, \sigma^2) : -\infty < \mu < +\infty, \sigma^2 > 0\}$ .

$$\begin{aligned} f(x, \theta) &= (\sqrt{2\pi}\sigma)^{-n} e^{-\frac{n\mu^2}{2\sigma^2}} \exp \left\{ \frac{\mu}{\sigma^2} \sum_{i=1}^n x_i - \frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 \right\} \\ &= C(\theta) \exp \{Q_1(\theta)T_1(x) + Q_2(\theta)T_2(x)\} h(x), \end{aligned}$$

其中  $C(\theta) = (\sqrt{2\pi}\sigma)^{-n} \exp \left\{ -n\mu^2 / (2\sigma^2) \right\}$ ,  $Q_1(\theta) = \mu/\sigma^2$ ,  $Q_2(\theta) = -1/(2\sigma^2)$ ,  $T_1(x) = \sum_{i=1}^n x_i$ ,  $T_2(x) = \sum_{i=1}^n x_i^2$ ,  $h(x) \equiv 1$ . 因此, 由定义可知上述样本分布族是指数族. □

**【例题 1.41】** 均匀分布族  $\{U(0, \theta), \theta > 0\}$  和双参数指数分布不是指数族.

**解.** 均匀分布族  $\{U(0, \theta), \theta > 0\}$  的支撑集为  $\{x : f(x, \theta) > 0\} = (0, \theta)$  与  $\theta$  有关, 因此它不是指数族.

双参数指数分布族的密度函数如下:

$$p(x; \mu, \sigma) = \frac{1}{\sigma} \exp \left\{ -\frac{x - \mu}{\sigma} \right\} I_{[x > \mu]}, \quad -\infty < \mu < +\infty, \quad \sigma > 0$$

其中  $\mu$  和  $\sigma$  为两个参数, 它的支撑集为  $\{x : p(x; \mu, \sigma) > 0\} = (\mu, \infty)$  与未知参数  $\mu$  有关, 故它也不是指数族. 但若  $\mu$  已知, 如  $\mu = 0$ , 则单参数指数分布族  $\text{Exp}(1/\sigma)$  属于指数族. □

## §1.4 三大抽样分布

### 1.4.1 卡方分布

**【定义 1.42】(卡方分布)** 如果随机变量  $X$  的密度函数为

$$f(x) = \frac{(1/2)^{k/2}}{\Gamma(k/2)} x^{\frac{k}{2}-1} e^{-\frac{x}{2}} \quad x > 0,$$

则称  $X$  服从自由度为  $k$  的卡方分布, 记为  $X \sim \chi^2(k)$




图 1.3: 不同自由度卡方分布对比

**【命题 1.43】** 由 Gamma 分布族的知识立刻推出卡方分布具有以下事实:

1. 卡方分布是参数为  $k/2$  和  $1/2$  的伽马分布  $Ga\left(\frac{k}{2}, \frac{1}{2}\right)$
2. 随机变量  $X \sim \chi^2(k)$ , 则

$$E(X) = \frac{k/2}{1/2} = k, \quad \text{var}(X) = \frac{k/2}{(1/2)^2} = 2k$$

$$m_X(t) = (1 - 2t)^{-k/2}, \quad \psi_X(t) = (1 - 2it)^{-k/2}$$

3. 设  $X \sim \chi^2(k_1), Y \sim \chi^2(k_2)$ , 且  $X$  和  $Y$  独立, 则  $X + Y \sim \chi^2(k_1 + k_2)$ .

**【定理 1.44】** 设随机变量  $X_1, \dots, X_k \text{ iid} \sim N(0, 1)$  则  $X = \sum_{j=1}^k X_j^2 \sim \chi(k)$

**证明.** 概率法:

$$X_i \sim N(0, 1) \implies f_X(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) \implies f_Y(y) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{y}{2}\right) \frac{1}{\sqrt{y}}$$

显然有  $Y \sim Ga\left(\frac{1}{2}, \frac{1}{2}\right)$  则  $\sum X_j^2 = \sum Y_j \sim Ga\left(\frac{k}{2}, \frac{1}{2}\right) = \chi(k)$  □

**【推论 1.45】** 如果随机变量  $X_1, \dots, X_k$  相互独立, 且  $X_i \sim N(\mu_i, \sigma_i^2)$ , 则

$$\sum_{i=1}^k \left( \frac{X_i - \mu_i}{\sigma_i} \right)^2$$

服从自由度为  $k$  的卡方分布.

**【推论 1.46】** 如果  $X_1, \dots, X_k$  是来自正态总体  $N(\mu, \sigma^2)$  的随机样本, 则

$$\sum_{i=1}^k \left( \frac{X_i - \mu}{\sigma} \right)^2$$

服从自由度为  $k$  的卡方分布.

### 1.4.2 F 分布

**【定义 1.47】(F 分布)** 如果随机变量  $X$  有如下密度函数

$$f(x) = \frac{\Gamma\left(\frac{m+n}{2}\right)}{\Gamma(m/2)\Gamma(n/2)} \left(\frac{m}{n}\right)^{m/2} \frac{x^{\frac{(m-2)}{2}}}{[1 + (m/n)x]^{(m+n)/2}}, \quad x > 0$$

则称  $X$  为具有自由度  $m$  和  $n$  的 F 分布, 记为  $X \sim F(m, n)$ .

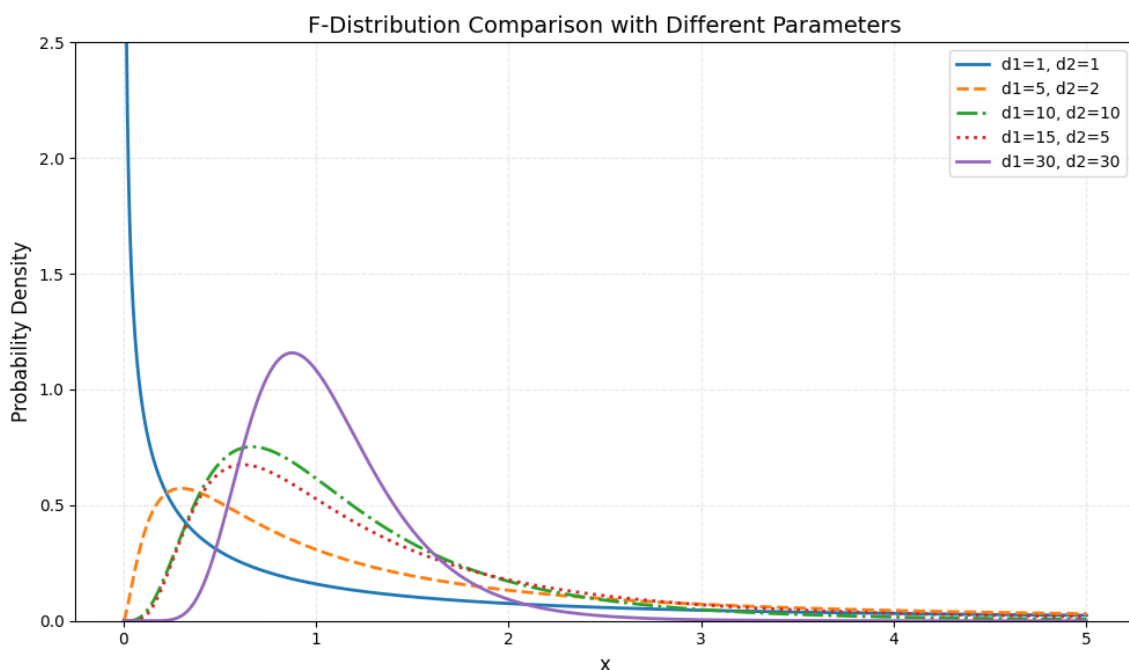


图 1.4: 不同自由度 F 分布对比

**【定理 1.48】** 令  $U \sim \chi^2(m)$ ,  $V \sim \chi^2(n)$ , 且  $U$  和  $V$  独立, 则随机变量

$$X = \frac{U/m}{V/n}$$

服从自由度为  $m$  和  $n$  的 F 分布

**证明.** 令

$$\begin{cases} X = \frac{U/m}{V/n} \\ Y = V \end{cases} \implies \begin{cases} U = \frac{m}{n}XY \\ V = Y \end{cases}$$

变换矩阵的行列式:

$$J = \begin{vmatrix} \frac{\partial u}{\partial x} & \frac{\partial u}{\partial y} \\ \frac{\partial v}{\partial x} & \frac{\partial v}{\partial y} \end{vmatrix} = \begin{vmatrix} \frac{m}{n}y & \frac{m}{n}x \\ 0 & 1 \end{vmatrix} = \frac{m}{n}y$$

□

**【定理 1.49】**



## 1.4.3 t 分布

【定义 1.50】 设  $X \sim N(0,1), Y \sim \chi_n^2$  且  $X$  和  $Y$  独立, 则称

$$T = \frac{X}{\sqrt{Y/n}}$$

是自由度为  $n$  的  $t$  变量, 其分布称为自由度为  $n$  的  $t$  分布, 记为  $T \sim t_n$ .

【定理 1.51】 设随机变量  $T \sim t_n$ , 则其密度函数为

$$t_n(x) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)\sqrt{n\pi}} \left(1 + \frac{x^2}{n}\right)^{-(n+1)/2}, \quad -\infty < x < \infty$$

证明.

□




图 1.5: 不同参数  $t$  分布对比

【注 1.52】 如果  $X \sim t(k)$ , 则

1. 当  $k = 1$  时,  $f(x) = \frac{1}{\pi(1+x^2)}$ , 即  $t(1)$  是标准的 Cauchy 分布.
2.  $\lim_{k \rightarrow \infty} f(x; k) = \phi(x)$ .
3. 当  $k > 1, E(X) = 0$ ; 当  $k > 2$  时,  $\text{var}(X) = \frac{k}{k-2}$ .
4. 密度函数关于  $x = 0$  对称, 且在  $x = 0$  处达到最大.

【推论 1.53】 如果  $X_1, \dots, X_n$  是来自正态分布  $N(\mu, \sigma^2)$  的随机样本, 则

$$(\bar{X} - \mu)/(\sigma/\sqrt{n}) \sim N(0,1), \quad \sum_{i=1}^n (X_i - \bar{X})^2 / \sigma^2 \sim \chi^2(n-1)$$

因此

$$\frac{(\bar{X} - \mu)/(\sigma/\sqrt{n})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 / (n-1)\sigma^2}} = \frac{\bar{X} - \mu}{S_n/\sqrt{n}} \sim t_{n-1}$$

其中  $S_n$  是样本标准差.

**【推论 1.54】** 如果  $X_1, \dots, X_m$  是来自正态总体  $X \sim N(\mu_x, \sigma^2)$  的随机样本,  $Y_1, \dots, Y_n$  是来自正态总体  $Y \sim N(\mu_y, \sigma^2)$ , 并且  $X$  和  $Y$  独立, 因此

$$\frac{\bar{X} - \bar{Y} - (\mu_x - \mu_y)}{S_w \sqrt{\frac{1}{m} + \frac{1}{n}}} \sim t(n+m-2)$$

其中

$$S_w^2 = \frac{(m-1)S_x^2 + (n-1)S_y^2}{m+n-2}$$

这里  $S_x^2$  和  $S_y^2$  分别是随机样本  $X_1, \dots, X_m$  和  $Y_1, \dots, Y_n$  的样本方差.

### 1.4.4 重要推论

**【定理 1.55】** 如果  $X_1, \dots, X_n$  是来自  $N(\mu, \sigma^2)$  的随机样本, 则

1.  $\bar{X}$  服从均值为  $\mu$  方差为  $\sigma^2/n$  的正态分布
2.  $\bar{X}$  和  $S^2$  独立
3.  $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$

证明.

1. 略
- 2.
- 3.

□

**【推论 1.56】** 如果  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$  是来自正态总体  $N(\mu, \sigma^2)$  的随机样本的样本方差, 则

$$U = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

**【推论 1.57】**  $S^2$  的密度函数可以根据  $U$  的密度函数导出:

$$f_{S^2}(s) = f_U\left(\frac{(n-1)s}{\sigma^2}\right) \cdot \frac{(n-1)}{\sigma^2} = \left(\frac{n-1}{2\sigma^2}\right)^{\frac{n-1}{2}} \frac{1}{\Gamma\left(\frac{n-1}{2}\right)} s^{\frac{n-3}{2}} e^{-\frac{(n-1)s}{2\sigma^2}}, \quad s > 0.$$

**【例题 1.58】** 设  $X_1, X_2, X_3, X_4$  为来自正态总体  $N(\mu, \sigma^2)$  的样本, 求统计量

$$\frac{X_1 - X_2}{|X_3 + X_4 - 2\mu|}$$

的分布

**【例题 1.59】** 设  $X_1, \dots, X_n$  为来自正态总体  $N(0, \sigma^2)$  的样本,  $\bar{X}_n$  和  $S_n^2$  分别是样本均值和样本方差. 统计量  $T_1 = \bar{X}_n^2 - S_n^2/n, T_2 = \bar{X}_n^2/S_n^2$ , 计算  $T_1$  和  $T_2$  的方差.

## § 1.5

### 统计量的极限分布

# Chapter 2

## 点估计

### §2.1 参数估计方法

#### 2.1.1 矩估计

- 设  $X_1, \dots, X_n$  是来自总体  $f(x; \theta)$  的随机样本, 其中  $\theta = (\theta_1, \theta_2, \dots, \theta_k)^T$ . 令  $M'_r$  是样本  $r$  阶原点矩, 即:

$$M'_r = \frac{1}{n} \sum_{i=1}^n X_i^r,$$

并且  $E(M'_r) = E(X^r) = \mu'_r = \mu'_r(\theta_1, \theta_2, \dots, \theta_k), M'_r \xrightarrow{P} \mu'_r$ .

- 利用样本矩来代替总体矩,  $k$  个参数  $\theta_1, \theta_2, \dots, \theta_k$  列  $k$  个方程:

$$M'_1 = \mu'_1 = \mu'_1(\theta_1, \theta_2, \dots, \theta_k)$$

$$M'_2 = \mu'_2 = \mu'_2(\theta_1, \theta_2, \dots, \theta_k)$$

$\vdots$

$$M'_k = \mu'_k = \mu'_k(\theta_1, \theta_2, \dots, \theta_k).$$

- 令  $\hat{\theta}_1, \dots, \hat{\theta}_k$  是上述方程的解(设上述方程有唯一解), 称  $(\hat{\theta}_1, \dots, \hat{\theta}_k)$  是利用矩方法得到的参数  $(\theta_1, \dots, \theta_k)$  的估计量, 其中  $\hat{\theta}_j$  是对应的  $\theta_j$  的估计.

**【例题 2.1】** 设总体  $X$  的概率密度为

$$f(x; \theta) = \begin{cases} \frac{2x}{\theta} e^{-x^2/\theta}, & x \geq 0, \\ 0 & \text{其它}, \end{cases}$$

其中  $\theta > 0$  是未知参数,  $X_1, \dots, X_n$  为来自总体  $X$  的样本, 求  $\theta$  的矩估计.

解. 因为

$$E(X) = \int_0^\infty x f(x; \theta) dx = \int_0^\infty \frac{2x^2}{\theta} e^{-x^2/\theta} dx = \frac{\sqrt{\theta\pi}}{2},$$

令

$$E(X) = \frac{\sqrt{\theta\pi}}{2} = \bar{X}_n,$$

故  $\theta$  的矩估计为

$$\hat{\theta} = \frac{(2\bar{X}_n)^2}{\pi}.$$

□

**【例题 2.2】** 令  $X_1, \dots, X_n$  是来自正态总体  $N(\mu, \sigma^2)$  的随机样本, 求参数  $\mu$  和  $\sigma^2$  的矩估计.

解. 我们有

$$E(X) = \mu = \frac{1}{n} \sum_{i=1}^n X_i, \quad E(X^2) = \mu^2 + \sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2.$$

则

$$\Rightarrow \begin{cases} \bar{X} = \mu, \\ \frac{1}{n} \sum_{i=1}^n X_i^2 = \mu^2 + \sigma^2 \end{cases}$$

解得

$$\Rightarrow \begin{cases} \hat{\mu} = \bar{X}, \\ \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2. \end{cases}$$

□

**【例题 2.3】**  $X_1, \dots, X_n$  是来自  $(\mu - \sqrt{3}\sigma, \mu + \sqrt{3}\sigma)$  的均匀分布的随机样本. 求  $\mu$  和  $\sigma$  的矩估计.

解.

$$E(X) = \mu = \frac{1}{n} \sum_{i=1}^n X_i, \quad E(X^2) = \mu^2 + \sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2.$$

$$\Rightarrow \begin{cases} \hat{\mu} = \bar{X}, \\ \hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2} \end{cases}$$

□

**【例题 2.4】** 令  $X_1, \dots, X_n$  是来自参数为  $\lambda$  的 Poisson 分布的随机样本, 利用矩方法估计  $\lambda$ .

解.

1. 利用一阶样本原点矩代替一阶原点矩, 得到

$$\frac{1}{n} \sum_{i=1}^n x_i = E(X) = \lambda. \Rightarrow \hat{\lambda} = \bar{X}$$

2. 利用二阶样本原点矩代替二阶原点矩, 得到

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n X_i^2 &= E(X^2) = \lambda^2 + \lambda. \\ \Rightarrow \tilde{\lambda} &= \frac{-1 + \sqrt{1 + \frac{4}{n} \sum_{i=1}^n X_i^2}}{2}. \end{aligned}$$

3. 利用样本方差代替总体方差, 得到

$$\lambda = \text{var}(X) = S_n^2 \Rightarrow \check{\lambda} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

□

**【例题 2.5】** 令  $X_1, \dots, X_n$  是来自总体  $X$  的随机样本,  $X$  的密度函数为

$$f(x; \theta_1, \theta_2) = \frac{\theta_2}{\Gamma((1+\theta_1)/\theta_2)} x^{\theta_1} \exp(-x^{\theta_2}), \quad x > 0$$

其中  $-1 < \theta_1 < +\infty, \theta_2 > 0$ . 求  $\theta_1$  和  $\theta_2$  的矩估计.

**【例题 2.6】** 令  $X_1, \dots, X_n$  是来自正态总体  $X \sim N(\mu, \sigma^2)$  的随机样本, 求  $P(X > 1)$  的矩估计.

**【例题 2.7】** 设  $(X_1, Y_1), \dots, (X_n, Y_n)$  是来自二元总体  $(X, Y)$  中的样本, 设  $E(X^2)$  和  $E(Y^2)$  存在, 求  $\sigma_{XY} = \text{Cov}(X, Y)$  和  $\text{Corr}(X, Y) = \rho$  的矩估计.

## 2.1.2 极大似然估计

**【定义 2.8】(似然函数)** 令  $X_1, \dots, X_n$  是来自总体  $f(x; \theta)$  的随机样本, 则称  $X_1, \dots, X_n$  的联合概率函数为其似然函数, 即  $f_{X_1, \dots, X_n}(x_1, \dots, x_n; \theta)$  被看作参数  $\theta$  的函数. 特别地, 随机样本  $X_1, \dots, X_n$  的似然函数等于

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n; \theta) = f(x_1; \theta) f(x_2; \theta) \cdots f(x_n; \theta).$$

似然函数通常用  $L(\theta; x_1, \dots, x_n)$  或  $L(\theta)$  表示.

- 似然函数是固定  $x_1, \dots, x_n$ , 将其看作定义在参数空间  $\Theta$  上的参数  $\theta$  的函数.
- 如果  $X_1, \dots, X_n$  是来自  $f(x; \theta)$  的随机样本, 则

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta).$$

- 似然函数  $L(\theta)$  度量了随机变量  $X_1, \dots, X_n$  取  $x_1, \dots, x_n$  的可能性.

**【定义 2.9】(MLE)** 令  $L(\theta) = L(\theta; x_1, \dots, x_n)$  是随机变量  $X_1, \dots, X_n$  的似然函数. 如果

$$\hat{\theta} = \operatorname{argmax}_{\theta \in \Theta} L(\theta)$$

称  $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$  是参数  $\theta$  的极大似然估计量,  $\hat{\theta} = \hat{\theta}(x_1, \dots, x_n)$  是参数  $\theta$  的极大似然估计值, 其中  $x_1, \dots, x_n$  是观测值.

- 如果  $L(\theta)$  是可导的, 则 MLE 是方程  $\frac{dL(\theta)}{d\theta} = 0$  的解.
- 因为  $\ln L(\theta)$  是  $L(\theta)$  在同一  $\theta$  处达到最大值, 有时  $\ln L(\theta)$  的最值更容易计算, 故可以通过最大化  $\ln L(\theta)$  求参数的 MLE.
- 如果  $L(\theta)$  关于  $\theta$  不可导, 甚至不连续, 则要从定义出发, 寻找参数的极大似然估计.

**【定理 2.10】(极大似然估计的不变性)** 设总体的概率函数  $f(x; \theta)$ , 假设参数  $\theta$  是一维的, 令  $\hat{\theta}(X_1, \dots, X_n)$  是参数  $\theta$  的极大似然估计. 如果  $\tau(\theta)$  是  $\theta$  的单值可逆函数, 则  $\tau(\theta)$  的极大似然估计是  $\tau(\hat{\theta})$ .

**【注 2.11】** 定理可以从两个方向推广, 极大似然估计的不变性依然成立:

1.  $\theta$  可以是  $k$  维向量;
2.  $\tau(\theta)$  是单值可逆函数的假设可以去掉.

## §2.2 点估计的性质

## 2.2.1 无偏性

**【定义 2.12】** 设  $X_1, \dots, X_n$  是来自总体  $f(x; \theta)$  的随机样本, 其中  $\theta \in \Theta$ .  $T = T(X_1, \dots, X_n)$  是  $\tau(\theta)$  的一个估计量, 如果

$$E_{\theta}(T) = E_{\theta}[T(X_1, \dots, X_n)] = \tau(\theta), \quad \theta \in \Theta,$$

则称  $T = T(X_1, \dots, X_n)$  是  $\tau(\theta)$  的无偏估计.

- 如果  $E_{\theta}(T) \neq \tau(\theta)$ , 则估计量  $T = T(X_1, \dots, X_n)$  是  $\tau(\theta)$  的有偏估计; 称  $\tau(\theta) - E_{\theta}(T)$  是估计量  $T$  的偏
- 如果  $\lim_{n \rightarrow \infty} E_{\theta}(T) = \tau(\theta)$ , 则称估计量  $T$  是  $\tau(\theta)$  的渐近无偏估计

**【例题 2.13】** 令  $X_1, \dots, X_n$  是来自正态总体  $N(\mu, \sigma^2)$  的随机样本. 判断  $\mu$  和  $\sigma^2$  的极大似然估计是否是无偏估计.

**解.**  $\mu$  和  $\sigma^2$  的 MLE 分别为:

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

因为  $E(\hat{\mu}) = E(\bar{X}) = \mu$  故  $\bar{X}$  是无偏的.

因为

$$E(\hat{\sigma}^2) = E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \frac{n-1}{n} \sigma^2 \rightarrow \sigma^2,$$

故  $\hat{\sigma}^2$  是渐近无偏的.  $\hat{\sigma}^2$  的偏为  $= \sigma^2 - E(\hat{\sigma}^2) = \frac{1}{n} \sigma^2 \rightarrow 0$ . □

**【注 2.14】** 说明 MLE 和矩估计可能有偏也可能无偏

**【例题 2.15】** 令  $X_1, \dots, X_n$  是来自指数总体  $\text{Exp}(\lambda)$  的随机样本.

1. 求  $\lambda$  的 MLE  $\hat{\lambda}$
2. 证明  $\hat{\lambda}$  是有偏的.
3. 根据 (2) 中的结果, 构造  $\lambda$  的一个无偏估计.

**解.**

1. 考虑似然函数

$$L(\lambda) = \prod_{i=1}^n f(x_i; \lambda) = \lambda^n \exp\left(-\lambda \sum_{i=1}^n x_i\right) \implies \ln L(\lambda) = n \ln \lambda - \lambda \sum_{i=1}^n x_i.$$

估计方程:

$$\frac{d \ln L(\lambda)}{d \lambda} = \frac{n}{\lambda} - \sum_{i=1}^n x_i = 0 \implies \hat{\lambda} = \frac{1}{\bar{X}}$$

2. 因为  $Z = \sum_{i=1}^n X_i \sim \Gamma(n, \lambda)$ ,

$$E(\hat{\lambda}) = E\left(\frac{1}{\bar{X}}\right) = E\left(\frac{n}{\sum_{i=1}^n X_i}\right) = n \int_0^\infty \frac{1}{z} \frac{\lambda^n}{\Gamma(n)} z^{n-1} e^{-\lambda z} dz = \frac{n}{n-1} \lambda$$

因此  $\hat{\lambda}$  是有偏的.

3. 根据 (2) 中的结果, 我们可得

$$E\left(\frac{n-1}{n} \cdot \frac{1}{\bar{X}}\right) = \lambda$$

是所求无偏估计 □

**【例题 2.16】** 令  $X_1, \dots, X_n$  是来自总体  $N(\mu, \sigma^2)$  的随机样本. 证明  $\hat{\sigma} = \sqrt{S_n^2}$  不是  $\sigma$  的无偏估计, 其中

$$S_n = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

**解.** 因为  $(n-1)S_n^2/\sigma^2 \sim \chi^2(n-1)$ , 故

$$\begin{aligned} E(\hat{\sigma}) &= E\left(\sqrt{S_n^2}\right) = \frac{\sigma}{\sqrt{n-1}} \int_0^\infty \sqrt{t} \frac{2^{-\frac{n-1}{2}}}{\Gamma\left(\frac{n-1}{2}\right)} t^{\frac{n-1}{2}-1} e^{-\frac{t}{2}} dt \\ &= \frac{\sqrt{2}}{\sqrt{n-1}} \cdot \frac{\Gamma\left(\frac{n}{2}\right)}{\Gamma\left(\frac{n-1}{2}\right)} \sigma \neq \sigma, \end{aligned}$$

从而  $\hat{\sigma}$  不是  $\sigma$  的无偏估计. □

【注 2.17】 无偏估计不具有不变性

【例题 2.18】 设  $X_1$  是来自二项分布总体  $B(n, \theta)$  的一个随机样本,  $1/\theta$  是否存在无偏估计?

解. 假设  $T(X_1)$  是  $1/\theta$  的无偏估计. 根据无偏估计的定义, 我们有:

$$E(T(X_1)) = \frac{1}{\theta}, \quad \forall \theta \in (0, 1).$$

则对任意的  $\theta \in (0, 1)$ , 下面等式恒成立:

$$\sum_{x=0}^n T(x) C_n^x \theta^x (1-\theta)^{n-x} = \frac{1}{\theta} \implies \sum_{x=0}^n T(x) C_n^x \theta^{x+1} (1-\theta)^{n-x} - 1 = 0.$$

但注意到这是一个关于  $\theta$  的多项式, 不可能满足对  $\forall \theta \in (0, 1)$  满足方程, 故  $1/\theta$  不存在无偏估计。  $\square$

【注 2.19】 无偏估计可能不存在

【例题 2.20】 设  $X_1, \dots, X_n$  是来自总体  $f(x; \theta) = \theta^{-1} I_{[0, \theta]}(x)$  的样本, 其中  $\theta > 0$ .

1. 求参数  $\theta$  的矩估计  $\hat{\theta}$  和 MLE  $\tilde{\theta}$ .
2. 判断  $\hat{\theta}$  和  $\tilde{\theta}$  是否为无偏估计. 如果不是无偏的, 做适当的修正得到  $\theta$  的无偏估计.
3. 计算矩估计  $\hat{\theta}$  和 MLE  $\tilde{\theta}$  的方差.

解.

1. 由

$$E(X) = \frac{\theta}{2} = \bar{X}_n$$

得  $\theta$  的矩估计为  $\hat{\theta} = 2\bar{X}_n$

似然函数

$$L(\theta) = \frac{1}{\theta^n} \prod_{i=1}^n I_{[0, \theta]}(x_i) = \frac{1}{\theta^n} I_{[0, \theta]}(y_n),$$

其中  $y_n$  是  $x_1, \dots, x_n$  的最大值. 当  $\theta = y_n$  时,  $L(\theta)$  达到最大值, 从而  $\theta$  的极大似然估计为  $\tilde{\theta} = Y_n$ .

2. 因为

$$E(\hat{\theta}) = E(2\bar{X}_n) = 2 \cdot \frac{\theta}{2} = \theta,$$

从而  $\hat{\theta}$  是  $\theta$  的无偏估计. 总体的分布函数为

$$F(x) = \frac{x}{\theta} I_{[0, \theta]}(x),$$

最大次序统计量  $Y_n$  的密度函数

$$f_{Y_n}(y) = n[F(y)]^{n-1} f(y) = \frac{ny^{n-1}}{\theta^n} I_{[0, \theta]}(y),$$

从而

$$E(\tilde{\theta}) = E(Y_n) = \int_0^\theta \frac{ny^n}{\theta^n} dy = \frac{n\theta}{n+1},$$

因此  $\tilde{\theta}$  不是  $\theta$  的无偏估计, 从而

$$\check{\theta} = \frac{n+1}{n} Y_n$$

是  $\theta$  的无偏估计.

3. 矩估计  $\hat{\theta}$  的方差

$$\text{var}(\hat{\theta}) = \text{var}(2\bar{X}_n) = 4 \cdot \frac{\theta^2}{12n} = \frac{\theta^2}{3n}.$$

极大似然估计量  $\tilde{\theta}$  的方差

$$\text{var}(\tilde{\theta}) = E(Y_n^2) - [E(Y_n)]^2 = \int_0^\theta \frac{ny^{n+1}}{\theta^n} dy - [E(Y_n)]^2 = \frac{n\theta^2}{(n+2)(n+1)^2}.$$

改进无偏估计  $\check{\theta}$  的方差

$$\text{var}(\check{\theta}) = \frac{\theta^2}{n(n+2)}.$$

□

【注 2.21】 不难证明  $\text{var}(\tilde{\theta}) \leq \text{var}(\check{\theta}) \leq \text{var}(\hat{\theta})$ . 但是矩估计  $\hat{\theta}$  和改进的极大似然估计  $\check{\theta}$  是无偏的, 极大似然估计量  $\tilde{\theta}$  是有偏的。

【定义 2.22】 (有效性) 令  $T_1$  和  $T_2$  是  $\tau(\theta)$  的两个无偏估计, 如果对任意的  $\theta \in \Theta$ , 有  $\text{var}(T_1) \leq \text{var}(T_2)$ , 并且至少存在一个  $\theta \in \Theta$ , 使得不等号严格成立, 则称  $T_1$  比  $T_2$  更有效。

## 2.2.2 均方误差

【定义 2.23】 (均方误差)  $T = T(X_1, \dots, X_n)$  是  $\tau(\theta)$  的估计, 称

$$E_\theta(T - \tau(\theta))^2$$

为  $T = T(X_1, \dots, X_n)$  的均方误差。

【注 2.24】

$$\text{MSE}_T(\theta) = \int \cdots \int (T(x_1, \dots, x_n) - \tau(\theta))^2 \prod_{i=1}^n f(x_i; \theta) dx_1 \cdots dx_n.$$

【注 2.25】

$$\text{MSE}_T(\theta) = E_\theta(T - E(T) + E(T) - \tau(\theta))^2 = \text{var}(T) + [\text{Bias}(T)]^2$$

故如果  $T$  是  $\tau(\theta)$  的无偏估计, 则  $\text{MSE}_T(\theta) = \text{var}(T)$ 【注 2.26】 如果  $T$  是  $r$  维向量, 则其均方误差定义为

$$\text{MSE}_T(\theta) = E(\|T - \tau(\theta)\|^2) = \sum_{j=1}^r E(T_j - \tau_j(\theta))^2$$

其中  $\|\cdot\|$  表示二范数. 因此, 估计向量的均方误差等于各个分量的均方误差之和。

【例题 2.27】 (例 2.20 续) 设  $X_1, \dots, X_n$  是来自总体  $f(x; \theta) = \theta^{-1} I_{[0, \theta]}(x)$  的样本, 其中  $\theta > 0$ . 求参数  $\theta$  的矩估计  $\hat{\theta}$ , 极大似然估计  $\tilde{\theta}$  和其修正后的无偏估计  $\check{\theta}$  的均方误差。

解.1.  $\hat{\theta}$  的均方误差

$$\text{MSE}_{\hat{\theta}}(\theta) = \text{var}(\hat{\theta}) = \frac{\theta^2}{3n}.$$

2.  $\tilde{\theta}$  均方误差

$$\begin{aligned} \text{MSE}_{\tilde{\theta}}(\theta) &= \text{var}(\tilde{\theta}) + \text{Bias}(\tilde{\theta})^2 \\ &= \frac{n\theta^2}{(n+2)(n+1)^2} + \left(\frac{\theta}{n+1}\right)^2 \\ &= \frac{2\theta^2}{(n+2)(n+1)}. \end{aligned}$$



3.  $\check{\theta}$  的均方误差

$$\text{MSE}_{\check{\theta}}(\theta) = \text{var}(\check{\theta}) = \frac{\theta^2}{n(n+2)}.$$

不难证明:  $\text{MSE}_{\hat{\theta}}(\theta) \leq \text{MSE}_{\check{\theta}}(\theta) \leq \text{MSE}_{\bar{\theta}}(\theta)$

□

## 2.2.3 相合性

**【定义 2.28】(均方相合性)** 令  $T_n = T_n(X_1, \dots, X_n)$  是  $\tau(\theta)$  的一个估计量, 其中  $n$  是样本量. 如果对任意的  $\theta \in \Theta$ , 有

$$\lim_{n \rightarrow \infty} E_{\theta} [T_n - \tau(\theta)]^2 = 0,$$

则称  $T_n$  是  $\tau(\theta)$  的均方相合估计.

**【注 2.29】**  $T_n$  是均方相合的, 意味着  $T_n$  的偏和方差在  $n \rightarrow \infty$  时均趋于零.

**【定义 2.30】(弱相合性)** 令  $T_n = T_n(X_1, \dots, X_n)$  是  $\tau(\theta)$  的一个估计量, 其中  $n$  是样本量. 如果对任意的  $\varepsilon > 0$ , 有

$$\lim_{n \rightarrow \infty} P_{\theta} [|T_n - \tau(\theta)| < \varepsilon] = 1, \theta \in \Theta,$$

则称  $T_n$  是  $\tau(\theta)$  的弱相合估计.

**【定理 2.31】** 设  $\hat{\theta}_n$  是  $\theta$  的估计, 且满足

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta, \quad \lim_{n \rightarrow \infty} \text{var}(\hat{\theta}_n) = 0$$

则  $\hat{\theta}_n$  是  $\theta$  的弱相合估计.

**【定理 2.32】** 如果  $\hat{\theta}_n = (\hat{\theta}_{n1}, \hat{\theta}_{n2}, \dots, \hat{\theta}_{nk})$  是  $\theta = (\theta_1, \dots, \theta_k)$  的弱相合估计, 且  $g(\theta)$  是参数  $\theta$  的连续函数, 则  $g(\hat{\theta}_n)$  是  $g(\theta)$  的弱相合估计.

**【例题 2.33】** 设总体  $X$  的均值为  $\mu$ , 方差为  $\sigma^2 < +\infty$ ,  $X_1, \dots, X_n$  是来自总体  $X$  的随机样本, 证明  $\bar{X}_n$  和  $S_n^2$  分别为  $\mu$  和  $\sigma^2$  的相合估计.

## 2.2.4 渐进正态性

**【定义 2.34】**  $T_n$  是  $\tau(\theta)$  的估计量, 如果  $T_n$  满足如下条件:

- 当  $n \rightarrow \infty$ ,

$$\sqrt{n}(T_n - \tau(\theta)) \rightarrow N(0, \sigma^2(\theta)).$$

- $\forall \varepsilon > 0$ ,

$$\lim_{n \rightarrow \infty} P_{\theta} [|T_n - \tau(\theta)| > \varepsilon] = 0, \theta \in \Theta.$$

则称  $T_n$  是  $\tau(\theta)$  的相合渐近正态估计, 称  $\sigma^2(\theta)$  为  $\sqrt{n}T_n$  的渐近方差. 如果  $T_n$  还同时满足下面条件

- 令  $\{\tilde{T}_n\}$  是  $\tau(\theta)$  的另外一个相合估计, 并且

$$\sqrt{n}(\tilde{T}_n - \tau(\theta)) \xrightarrow{d} N(0, \tilde{\sigma}^2(\theta)).$$

- 对任意的  $\theta \in \Theta$  (参数空间是开区间),  $\sigma^2(\theta) \leq \tilde{\sigma}^2(\theta)$ , 则称  $T_n$  是  $\tau(\theta)$  的最优渐近正态估计

## §2.3 一致最小方差无偏估计

• UMVUE 就是在寻找均方误差最小, 我们只研究无偏的情况

•  $\tau(\theta)$  的无偏估计  $T$  的均方误差可以写为

$$E(T - \tau(\theta))^2 = \text{var}(T) + [\tau(\theta) - E(T)]^2.$$

如果  $T$  是无偏估计, 则  $E(T - \tau(\theta))^2 = \text{var}(T)$ .

**【定义 2.35】** 令  $X_1, \dots, X_n$  是来自  $f(x; \theta)$  的样本。 $\tau(\theta)$  的估计  $T^* = T^*(X_1, \dots, X_n)$  被称为  $\tau(\theta)$  的一致最小方差无偏估计量当且仅当

1.  $E_\theta(T^*) = \tau(\theta)$ , 即  $T^*$  是无偏的;
2.  $\text{var}(T^*) \leq \text{var}(T)$ , 其中  $T = T(X_1, \dots, X_n)$  是  $\tau(\theta)$  的任意一个无偏估计.

### Cramer-Rao 不等式

令  $X_1, \dots, X_n$  是来自  $f(x; \theta)$  的随机样本, 其中  $\theta \in \Theta \subseteq \mathbb{R}$ . 令  $T = T(X_1, \dots, X_n)$  是  $\tau(\theta)$  的无偏估计, 我们假设下列正则条件成立

1. 对所有的  $x \in \{x : f(x; \theta) > 0\}$  和  $\theta \in \Theta$ ,  $\frac{\partial}{\partial \theta} \ln f(x; \theta)$  存在.
2.  $\frac{\partial}{\partial \theta} \int \prod_{i=1}^n f(x_i; \theta) dx_1 \cdots dx_n = \int \frac{\partial}{\partial \theta} \prod_{i=1}^n f(x_i; \theta) dx_1 \cdots dx_n$ .
3.  $\frac{\partial}{\partial \theta} \int T(x_1, \dots, x_n) \prod_{i=1}^n f(x_i; \theta) dx_1 \cdots dx_n = \int T(x_1, \dots, x_n) \frac{\partial}{\partial \theta} \prod_{i=1}^n f(x_i; \theta) dx_1 \cdots dx_n$ .
4.  $\forall \theta \in \Theta, \quad 0 < E \left[ \frac{\partial}{\partial \theta} \ln f(X; \theta) \right]^2 < \infty$ .

**【定理 2.36】(C-R 不等式)** 假设上述正则条件 1-4 成立,  $T = T(X_1, \dots, X_n)$  是  $\tau(\theta)$  的任一无偏估计, 则有下面不等式成立:

$$\text{var}[T] \geq \frac{[\tau'(\theta)]^2}{nE \left[ \frac{\partial}{\partial \theta} \ln f(X; \theta) \right]^2}$$

等号成立当且仅当存在函数  $K(\theta, n)$ , 使得

$$\frac{\partial}{\partial \theta} \sum_{i=1}^n \ln f(x_i; \theta) = \frac{\partial \ell(\theta)}{\partial \theta} = K(\theta, n) [T(x_1, \dots, x_n) - \tau(\theta)].$$

**证明.** 根据假设 1 可得:

$$\begin{aligned} \tau'(\theta) &= \frac{\partial \tau(\theta)}{\partial \theta} = \frac{\partial}{\partial \theta} \int \cdots \int T(x_1, \dots, x_n) \prod_{i=1}^n f(x_i; \theta) dx_1 \cdots dx_n \\ &= \int \cdots \int T(x_1, \dots, x_n) \frac{\partial}{\partial \theta} \left[ \prod_{i=1}^n f(x_i; \theta) \right] dx_1 \cdots dx_n \end{aligned}$$

根据假设 2 可得:

$$\begin{aligned} 0 &= \frac{\partial}{\partial \theta} \int \cdots \int \prod_{i=1}^n f(x_i; \theta) dx_1 \cdots dx_n \\ &= \int \cdots \int \frac{\partial}{\partial \theta} \left[ \prod_{i=1}^n f(x_i; \theta) \right] dx_1 \cdots dx_n \\ &= \int \cdots \int \tau(\theta) \frac{\partial}{\partial \theta} \left[ \prod_{i=1}^n f(x_i; \theta) \right] dx_1 \cdots dx_n \end{aligned}$$

因此

$$\begin{aligned}
 \tau'(\theta) &= \int \cdots \int [T(x_1, \cdots, x_n) - \tau(\theta)] \frac{\partial}{\partial \theta} \left[ \prod_{i=1}^n f(x_i; \theta) \right] dx_1 \cdots dx_n \\
 &= \int \cdots \int [T(x_1, \cdots, x_n) - \tau(\theta)] \frac{\partial}{\partial \theta} \ln \left[ \prod_{i=1}^n f(x_i; \theta) \right] \times \prod_{i=1}^n f(x_i; \theta) dx_1 \cdots dx_n \\
 &= E \left\{ [T(X_1, \cdots, X_n) - \tau(\theta)] \left[ \frac{\partial}{\partial \theta} \ln \prod_{i=1}^n f(X_i; \theta) \right] \right\}
 \end{aligned}$$

根据 Cauchy-Schwarz 不等式

$$[\tau'(\theta)]^2 \leq E[T(X_1, \cdots, X_n) - \tau(\theta)]^2 E \left[ \frac{\partial}{\partial \theta} \ln \prod_{i=1}^n f(X_i; \theta) \right]^2.$$

$\Rightarrow$

$$[\tau'(\theta)]^2 \leq \text{var}[T] E \left[ \frac{\partial}{\partial \theta} \ln \prod_{i=1}^n f(X_i; \theta) \right]^2$$

$\Rightarrow$

$$\text{var}[T] \geq \frac{[\tau'(\theta)]^2}{E \left[ \frac{\partial}{\partial \theta} \ln \prod_{i=1}^n f(X_i; \theta) \right]^2}$$

由于

$$\begin{aligned}
 E \left[ \frac{\partial}{\partial \theta} \ln \prod_{i=1}^n f(X_i; \theta) \right]^2 &= E \left[ \sum_{i=1}^n \frac{\partial}{\partial \theta} \ln f(X_i; \theta) \right]^2 = \sum_{i=1}^n \sum_{j=1}^n E \left\{ \left[ \frac{\partial}{\partial \theta} \ln f(X_i; \theta) \right] \left[ \frac{\partial}{\partial \theta} \ln f(X_j; \theta) \right] \right\} \\
 &= n E \left[ \frac{\partial}{\partial \theta} \ln f(X; \theta) \right]^2 + \sum_{i=1}^n \sum_{j \neq i}^n E \left\{ \left[ \frac{\partial}{\partial \theta} \ln f(X_i; \theta) \right] \left[ \frac{\partial}{\partial \theta} \ln f(X_j; \theta) \right] \right\}
 \end{aligned}$$

注意到

$$E \left[ \frac{\partial}{\partial \theta} \ln f(X; \theta) \right] = \int \left[ \frac{\partial}{\partial \theta} \ln f(x; \theta) \right] f(x; \theta) dx = \int \frac{\partial}{\partial \theta} f(x; \theta) dx = \frac{\partial}{\partial \theta} \int f(x; \theta) dx = 0$$

当  $i \neq j$  时,  $X_i$  和  $X_j$  独立

$$E \left\{ \left[ \frac{\partial}{\partial \theta} \ln f(X_i; \theta) \right] \left[ \frac{\partial}{\partial \theta} \ln f(X_j; \theta) \right] \right\} = 0$$

$\Rightarrow$

$$E \left[ \frac{\partial}{\partial \theta} \ln \prod_{i=1}^n f(X_i; \theta) \right]^2 = n E \left[ \frac{\partial}{\partial \theta} \ln f(X; \theta) \right]^2$$

定理成立, 并且等号成立当且仅当存在常数  $K = K(\theta, n)$  满足

$$\frac{\partial}{\partial \theta} \ln \left[ \prod_{i=1}^n f(x_i; \theta) \right] = K(\theta, n) [T(X_1, \cdots, X_n) - \tau(\theta)]$$

□

**【注 2.37】** 如果  $\theta$  的极大似然估计  $\hat{\theta} = \hat{\theta}(X_1, \cdots, X_n)$  是下面方程的解

$$\frac{\partial}{\partial \theta} \ln L(\theta) \equiv \frac{\partial}{\partial \theta} \ln \prod_{i=1}^n f(x_i; \theta) = 0$$

如果  $T^* = T^*(X_1, \cdots, X_n)$  是  $\tau^*(\theta)$  的无偏估计, 且其方差可以达到 C-R 下界, 则  $T^*(x_1, \cdots, x_n) = \tau^*(\hat{\theta}(x_1, \cdots, x_n))$

**【注 2.38】** 在二阶导数存在, 微分和积分可以交换顺序的假设下, 下列等式成立

$$E \left\{ \left[ \frac{\partial}{\partial \theta} \ln f(X; \theta) \right]^2 \right\} = -E \left[ \frac{\partial^2}{\partial \theta^2} \ln f(X; \theta) \right].$$

**证明.** 注意到

$$E \left[ \frac{\partial}{\partial \theta} \ln f(X; \theta) \right] = 0$$

两端对参数求导:

$$\begin{aligned} 0 &= \frac{\partial}{\partial \theta} E \left[ \frac{\partial}{\partial \theta} \ln f(X; \theta) \right] = \frac{\partial}{\partial \theta} \int \left[ \frac{\partial}{\partial \theta} \ln f(x; \theta) \right] f(x; \theta) dx = \int \frac{\partial^2 \ln f(x; \theta)}{\partial \theta^2} f(x; \theta) dx + \int \left[ \frac{\partial}{\partial \theta} \ln f(x; \theta) \right] \frac{\partial f(x; \theta)}{\partial \theta} dx \\ &= E \left[ \frac{\partial^2}{\partial \theta^2} \ln f(X; \theta) \right] + \int \left[ \frac{\partial}{\partial \theta} \ln f(x; \theta) \right] \frac{\partial \ln f(x; \theta)}{\partial \theta} f(x; \theta) dx = E \left[ \frac{\partial^2}{\partial \theta^2} \ln f(X; \theta) \right] + E \left\{ \left[ \frac{\partial}{\partial \theta} \ln f(X; \theta) \right]^2 \right\}. \end{aligned}$$

□

**【定义 2.39】** C-R 不等式中的

$$I(\theta) = E \left[ \frac{\partial}{\partial \theta} \ln f(X; \theta) \right]^2$$

称为 Fisher 信息量.

**【定理 2.40】(Lehmann-Scheffé)** 令  $X_1, \dots, X_n$  是来自  $f(x; \theta)$  的随机样本. 如果  $S = s(X_1, \dots, X_n)$  是完备充分统计量, 令  $T^* = T^*(S)$  是  $S$  的函数且是  $\tau(\theta)$  的无偏估计, 则  $T^*$  是  $\tau(\theta)$  唯一的 UMVUE.

**证明.** 唯一性:

令  $\tilde{T}$  是  $\tau(\theta)$  的任意一个无偏估计, 且  $\tilde{T} = \tilde{T}(S)$ .

$$\forall \theta \in \Theta, E(T^* - \tilde{T}) \equiv 0$$

即  $T^* - \tilde{T}$  是 0 的无偏估计. 又因为  $T^* - \tilde{T}$  是完备充分统计量  $S$  的函数, 由完备统计量的定义,  $\forall \theta \in \Theta$ ,

$$P(T^*(S) = \tilde{T}(S)) = 1$$

因此, 由  $S$  的函数构成的  $\tau(\theta)$  的无偏估计是唯一的

□

## 练习

**【例题 2.41】** Let  $X_1, \dots, X_n$  be a random sample from  $N(\theta, 1)$ .

1. Find the Cramér-Rao lower bound for the variance of unbiased estimators of  $\theta, \theta^2$ , and  $P[X > 0]$ .
2. Is there an unbiased estimator of  $\theta^2$  for  $n = 1$ ? If so, find it.
3. Is there an unbiased estimator of  $P[X > 0]$ ? If so, find it.
4. What is the maximum-likelihood estimator of  $P[X > 0]$ ?
5. Is there an UMVUE of  $\theta^2$ ? If so, find it.
6. Is there an UMVUE of  $P[X > 0]$ ? If so, find it.

# Chapter 3

## 区间估计

### §3.1 基础概念

**【定义 3.1】** 设  $X_1, \dots, X_n$  是来自  $f(x; \theta)$  的样本. 令  $T_1 = T_1(X_1, \dots, X_n)$  和  $T_2 = T_2(X_1, \dots, X_n)$  是两个统计量, 且满足条件  $T_1 \leq T_2$  和

$$P(T_1 < \tau(\theta) < T_2) \equiv \gamma,$$

其中  $\gamma$  不依赖于参数  $\theta$ , 称  $\gamma$  为置信系数; 称随机区间  $(T_1, T_2)$  是  $\tau(\theta)$  的置信系数为  $\gamma$  的置信区间;  $T_1$  和  $T_2$  分别为  $\tau(\theta)$  的置信下限和置信上限. 随机区间  $(T_1, T_2)$  取值  $(t_1, t_2)$  也称为  $\tau(\theta)$  的置信系数为  $\gamma$  的置信区间.

**【注 3.2】**  $T_1, T_2$  满足概率  $P(T_1 \leq \tau(\theta) \leq T_2) \equiv \gamma$ , 称  $[T_1, T_2]$  是  $\tau(\theta)$  的置信区间.

**【定义 3.3】** 设  $X_1, \dots, X_n$  是来自  $f(x; \theta)$  的随机样本. 令  $T_1 = T_1(X_1, \dots, X_n)$  是统计量, 且满足

$$P(T_1 < \tau(\theta)) \equiv \gamma$$

则称  $T_1$  为  $\tau(\theta)$  的单边置信下限. 同样地, 令  $T_2 = T_2(X_1, \dots, X_n)$  是统计量, 且满足

$$P(\tau(\theta) < T_2) \equiv \gamma$$

则称  $T_2$  为  $\tau(\theta)$  的单边置信上限 ( $\gamma$  不依赖于  $\theta$ )

**【注 3.4】** 如果  $\tau(\theta)$  是  $\theta$  的严格单调增函数,  $\theta$  的置信系数为  $\gamma$  的置信区间是  $(T_1, T_2)$ , 则  $\tau(\theta)$  的置信区间是  $(\tau(T_1), \tau(T_2))$ , 因为

$$P(\tau(T_1) < \tau(\theta) < \tau(T_2)) = P(T_1 < \theta < T_2) = \gamma$$

### §3.2 枢轴量-正态总体参数的置信区间

**【定义 3.5】 (枢轴量)** 我们称满足下列条件的统计量  $S(T, \theta)$  为枢轴变量

1.  $S(T, \theta)$  包含优良点估计  $T$  并且是  $\theta$  的函数
2.  $S(T, \theta)$  的分布与  $\theta$  无关
3.  $\forall a < b \quad a \leq S(T, \theta) \leq b \implies A \leq \theta \leq B$

## 3.2.1 单个正态总体的置信区间

假设  $\mathbf{X} = (X_1, \dots, X_n)$  是从正态总体  $N(\mu, \sigma^2)$  抽取的简单随机样本. 记

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

即  $\bar{X}$  和  $S^2$  分别为样本均值和样本方差.

1.  $\sigma^2$  已知, 求  $\mu$  的置信区间

解. 显然,  $\mu$  的一个良好的点估计是  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ , 其分布为  $\bar{X} \sim N(\mu, \sigma^2/n)$ , 将其标准化得

$$U = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1)$$

其分布与  $\mu$  无关. 由正态分布的对称性, 可得

$$P_{\mu} \left( \left| \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \right| \leq u_{\alpha/2} \right) = 1 - \alpha \iff P_{\mu} \left( \bar{X} - \frac{\sigma}{\sqrt{n}} u_{\alpha/2} < \mu < \bar{X} + \frac{\sigma}{\sqrt{n}} u_{\alpha/2} \right) = 1 - \alpha$$

此处  $u_{\alpha/2}$  为标准正态分布的上侧  $\alpha/2$  分位数. 因此

$$\left[ \bar{X} - \frac{\sigma}{\sqrt{n}} u_{\alpha/2}, \bar{X} + \frac{\sigma}{\sqrt{n}} u_{\alpha/2} \right]$$

为  $\mu$  的置信系数  $1 - \alpha$  的置信区间. □

2.  $\sigma^2$  未知, 求  $\mu$  的置信区间

解.  $\mu$  的良好点估计仍为  $\bar{X}$ , 由于  $\sigma^2$  未知, 随机变量  $U = \sqrt{n}(\bar{X} - \mu)/\sigma$  在此不能作为枢轴变量, 将其中的  $\sigma$  用  $S$  ( $S^2$  是样本方差) 代替, 得到

$$T = \frac{\sqrt{n}(\bar{X} - \mu)}{S} \sim t_{n-1}.$$

可见  $T$  的表达式与  $\mu$  有关, 而其分布与  $\mu$  无关, 故取  $T$  为枢轴变量. 由于  $t$  分布关于原点对称, 令

$$P(|T| \leq c) = P\left(-c \leq \frac{\sqrt{n}(\bar{X} - \mu)}{S} \leq c\right) = 1 - \alpha$$

置信区间

$$\left[ \bar{X} - \frac{S}{\sqrt{n}} t_{n-1}(\alpha/2), \bar{X} + \frac{S}{\sqrt{n}} t_{n-1}(\alpha/2) \right],$$

□

3.  $\mu$  已知, 求  $\sigma^2$  的置信区间

解. 当  $\mu$  已知时,  $\sigma^2$  的一个良好的无偏估计为  $S_{\mu}^2 = \sum_{i=1}^n (X_i - \mu)^2 / n$ , 且  $nS_{\mu}^2 / \sigma^2 \sim \chi_n^2$ , 则取  $T = nS_{\mu}^2 / \sigma^2$  为枢轴变量, 其表达式与  $\sigma^2$  有关, 但其分布与  $\sigma^2$  无关, 找  $c_1$  和  $c_2$  使得

$$P_{\sigma^2} \left( c_1 \leq \frac{nS_{\mu}^2}{\sigma^2} \leq c_2 \right) = 1 - \alpha$$

一般令  $c_1$  和  $c_2$  满足下列要求:

$$P_{\sigma^2} \left( \frac{nS_{\mu}^2}{\sigma^2} < c_1 \right) = \frac{\alpha}{2}, \quad P_{\sigma^2} \left( \frac{nS_{\mu}^2}{\sigma^2} > c_2 \right) = \frac{\alpha}{2}$$

由  $\chi^2$  分布的上侧分位数表可知  $c_1 = \chi_n^2(1 - \alpha/2)$ ,  $c_2 = \chi_n^2(\alpha/2)$ , 即有

$$P_{\sigma^2} \left( \chi_n^2 \left( 1 - \frac{\alpha}{2} \right) \leq \frac{nS_{\mu}^2}{\sigma^2} \leq \chi_n^2 \left( \frac{\alpha}{2} \right) \right) = 1 - \alpha$$

置信区间

$$\left[ \frac{nS_{\mu}^2}{\chi_n^2(\alpha/2)}, \frac{nS_{\mu}^2}{\chi_n^2(1-\alpha/2)} \right]$$

□

4.  $\mu$  未知, 求  $\sigma^2$  的置信区间

解. 记  $\theta = (\mu, \sigma^2)$ 。此时  $S^2 = \sum_{i=1}^n (X_i - \bar{X})^2 / (n-1)$  是  $\sigma^2$  的良好估计, 它是无偏的, 且  $(n-1)S^2 / \sigma^2 \sim \chi_{n-1}^2$ 。取  $T = (n-1)S^2 / \sigma^2$  为枢轴变量, 其表达式与  $\sigma^2$  有关, 而其分布与  $\sigma^2$  无关。找  $d_1$  和  $d_2$ , 使得

$$P_{\theta} \left( d_1 \leq \frac{(n-1)S^2}{\sigma^2} \leq d_2 \right) = 1 - \alpha$$

类似于 3, 取  $d_1 = \chi_{n-1}^2(1-\alpha/2), d_2 = \chi_{n-1}^2(\alpha/2)$ , 故有

$$P_{\theta} \left( \chi_{n-1}^2(1-\alpha/2) \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi_{n-1}^2(\alpha/2) \right) = 1 - \alpha$$

置信区间

$$\left[ \frac{(n-1)S^2}{\chi_{n-1}^2(\alpha/2)}, \frac{(n-1)S^2}{\chi_{n-1}^2(1-\alpha/2)} \right].$$

□

## 3.2.2 两个正态总体参数的置信区间

设  $X_1, \dots, X_m$  是自正态总体  $N(a, \sigma_1^2)$  抽取的简单随机样本,  $Y_1, \dots, Y_n$  是自正态总体  $N(b, \sigma_2^2)$  抽取的简单随机样本, 且  $X_1, \dots, X_m$  和  $Y_1, \dots, Y_n$  独立。设  $\bar{X}, \bar{Y}$  和  $S_1^2, S_2^2$  分别为这两组样本的样本均值和样本方差。

A. 均值差  $b - a$  的置信区间

1. 当  $m = n$  时, 令  $Z_i = Y_i - X_i, i = 1, 2, \dots, n$ , 且记  $\tilde{\mu} = b - a, \tilde{\sigma}^2 = \sigma_1^2 + \sigma_2^2$ , 则有

$$Z_i \sim N(\tilde{\mu}, \tilde{\sigma}^2), \quad i = 1, 2, \dots, n$$

这就转化为单个正态总体当  $\tilde{\sigma}^2$  未知, 求其均值  $\tilde{\mu}$  的置信区间问题。显见  $\bar{Z} = \bar{Y} - \bar{X}$  是  $\tilde{\mu}$  的一个良好的无偏估计, 枢轴变量

$$T_Z = \frac{\sqrt{n}(\bar{Z} - \tilde{\mu})}{S_Z} \sim t_{n-1}$$

此处  $S_Z^2 = \sum_{i=1}^n (Z_i - \bar{Z})^2 / (n-1)$ ,  $T_Z$  的表达式与  $\tilde{\mu} = b - a$  有关, 但其分布与  $\tilde{\mu}$  无关, 因此取  $T_Z$  为枢轴变量。由前面已讨论过的情形的结果, 可知  $\tilde{\mu} = b - a$  的置信系数为  $1 - \alpha$  的置信区间为

$$\left[ \bar{Z} - \frac{S_Z}{\sqrt{n}} t_{n-1}(\alpha/2), \bar{Z} + \frac{S_Z}{\sqrt{n}} t_{n-1}(\alpha/2) \right]$$

2. 当  $\sigma_1^2$  和  $\sigma_2^2$  已知时, 易知  $\bar{Y} - \bar{X}$  为  $b - a$  的一个良好的无偏估计, 且

$$\bar{Y} - \bar{X} \sim N(b - a, \sigma_1^2/m + \sigma_2^2/n) \implies U := \frac{\bar{Y} - \bar{X} - (b - a)}{\sqrt{\sigma_1^2/m + \sigma_2^2/n}} \sim N(0, 1)$$

$U$  的表达式与  $b - a$  有关, 但其分布与  $b - a$  无关, 取  $U$  为枢轴变量, 故有

$$P_{a,b} \left( \left| \frac{\bar{Y} - \bar{X} - (b - a)}{\sqrt{\sigma_1^2/m + \sigma_2^2/n}} \right| \leq u_{\alpha/2} \right) = 1 - \alpha.$$

等价变形得到  $b - a$  的置信系数为  $1 - \alpha$  的置信区间为

$$\left[ \bar{Y} - \bar{X} - u_{\alpha/2} \sqrt{\sigma_1^2/m + \sigma_2^2/n}, \bar{Y} - \bar{X} + u_{\alpha/2} \sqrt{\sigma_1^2/m + \sigma_2^2/n} \right].$$

3. 当  $\sigma_1^2 = \sigma_2^2 = \sigma^2$  未知时, 令

$$S_\omega^2 = \frac{1}{m+n-2} \left[ (m-1)S_1^2 + (n-1)S_2^2 \right] = \frac{1}{m+n-2} \left[ \sum_{i=1}^m (X_i - \bar{X})^2 + \sum_{i=1}^n (Y_i - \bar{Y})^2 \right]$$

显然  $\bar{Y} - \bar{X}$  是  $b - a$  的无偏估计,

$$T_\omega = \frac{\bar{Y} - \bar{X} - (b - a)}{S_\omega} \sqrt{\frac{mn}{m+n}} \sim t_{m+n-2}$$

$T_\omega$  的表达式与  $b - a$  有关, 但其分布与  $b - a$  无关, 取  $T_\omega$  为枢轴变量, 故有

$$P \left( \left| \frac{\bar{Y} - \bar{X} - (b - a)}{S_\omega} \right| \sqrt{\frac{mn}{m+n}} \leq t_{m+n-2}(\alpha/2) \right) = 1 - \alpha$$

$b - a$  的置信系数为  $1 - \alpha$  的置信区间为

$$\left[ \bar{Y} - \bar{X} - S_\omega t_{m+n-2} \left( \frac{\alpha}{2} \right) \sqrt{\frac{1}{m} + \frac{1}{n}}, \bar{Y} - \bar{X} + S_\omega t_{m+n-2} \left( \frac{\alpha}{2} \right) \sqrt{\frac{1}{m} + \frac{1}{n}} \right],$$

4. 当  $\sigma_1^2 \neq \sigma_2^2$  皆未知时, 求  $b - a$  的置信区间问题. 这是著名的 Behrens-Fisher 问题

- 当  $m$  与  $n$  都充分大时可用大样本方法, 由于

$$\frac{\bar{Y} - \bar{X} - (b - a)}{\sqrt{\sigma_1^2/m + \sigma_2^2/n}} \sim N(0, 1),$$

且当  $m \rightarrow \infty$  时  $S_1^2 \xrightarrow{P} \sigma_1^2$ , 当  $n \rightarrow \infty$  时  $S_2^2 \xrightarrow{P} \sigma_2^2$ , 将式 (4. 2. 8) 中的  $\sigma_1^2$  和  $\sigma_2^2$  分别用  $S_1^2$  和  $S_2^2$  代入, 利用引理 2. 5. 1 可知, 当  $m, n \rightarrow \infty$  时, 有

$$\tilde{U} = \frac{\bar{Y} - \bar{X} - (b - a)}{\sqrt{S_1^2/m + S_2^2/n}} = \frac{\bar{Y} - \bar{X} - (b - a)}{\sqrt{\sigma_1^2/m + \sigma_2^2/n}} \cdot \frac{\sqrt{\sigma_1^2/m + \sigma_2^2/n}}{\sqrt{S_1^2/m + S_2^2/n}} \xrightarrow{\mathcal{L}} N(0, 1).$$

因此, 取  $\tilde{U}$  为枢轴变量. 当  $m, n$  充分大时,  $b - a$  的置信系数近似为  $1 - \alpha$  的置信区间是

$$\left[ \bar{Y} - \bar{X} - u_{\alpha/2} \sqrt{\frac{S_1^2}{m} + \frac{S_2^2}{n}}, \bar{Y} - \bar{X} + u_{\alpha/2} \sqrt{\frac{S_1^2}{m} + \frac{S_2^2}{n}} \right]$$

•

## B. 方差比 $\sigma_1^2/\sigma_2^2$ 的置信区间

1. 若  $a$  和  $b$  已知, 记  $S_a^2 = \sum_{i=1}^m (X_i - a)^2 / m$ ,  $S_b^2 = \sum_{i=1}^n (Y_i - a)^2 / n$ , 显见  $mS_a^2/\sigma_1^2 \sim \chi_m^2$ ,  $nS_b^2/\sigma_2^2 \sim \chi_n^2$ , 且  $S_a^2$  为  $\sigma_1^2$  的无偏估计,  $S_b^2$  为  $\sigma_2^2$  的无偏估计, 且二者独立, 故由推论 2. 4. 4 可知

$$F = \frac{S_a^2/\sigma_1^2}{S_b^2/\sigma_2^2} = \frac{S_a^2}{S_b^2} \cdot \frac{\sigma_2^2}{\sigma_1^2} \sim F_{m,n}$$