



统计极限理论

作者：Yukina

时间：2025 年 12 月 31 日

目录

1	测度理论	1
1.1	集类与其运算	1
1.1.1	随机事件	1
1.1.2	乘积空间与乘积 σ 代数	2
1.2	集函数, 测度, 概率	3
1.2.1	集函数与测度	3
1.3	随机变量及其分布函数	4
1.4	收敛方式	5
1.4.1	几乎必然收敛	5
1.4.2	依概率收敛	8
1.4.3	依分布收敛	11
1.5	例子	14
2	积分理论	15
2.1	o_p, O_p 记号	15
2.1.1		18
2.2	例——线性模型的收敛速率	20
3	渐进理论	24
3.1	引入	24
3.2	Taylor 展开	24
3.3	Delta 方法及其应用	27
3.3.1	基本定理	27
3.3.2	例子	28
3.4	逆矩阵方法	30
3.5	Laplace 方法	30
4	估计理论	33
4.1	M 估计	33
4.1.1	基本定义	33
4.1.2	相合性	34

4.1.3	渐进正态性	36
4.2	经验分布	38
4.2.1	经验分布函数	38
4.2.2	经验过程	40
4.2.3	经验分布	40
4.3	例子——得分检验	41

Chapter 1

测度理论

§ 1.1 集类与其运算

1.1.1 随机事件

Definition 1.1 设 $\{A_n\}_{n=1}^{\infty}$ 是一个集序列，则

1. A_n 的上极限定义为

$$\limsup_n A_n := \{\omega \text{ 属于无穷多个 } A_n\}$$

2. A_n 的下极限定义为

$$\liminf_n A_n := \{\omega \text{ 不属于有限多个 } A_n\}$$

Proposition 1.2 设 $\{A_n\}_{n=1}^{\infty}$ 是一个集序列

$$1. \liminf_n A_n = \bigcup_{n=1}^{\infty} \bigcap_{m=n}^{\infty} A_m, \limsup_n A_n = \bigcap_{n=1}^{\infty} \bigcup_{m=n}^{\infty} A_m$$

$$2. \liminf_n A_n \subseteq \limsup_n A_n$$

Definition 1.3 设 C 为一集类.

1. 称 C 为 π 类，如果它对有限交封闭.

2. 称 C 为 半环，如果 $\emptyset \in C$ ，且有

$$A, B \in C \implies A \cap B \in C, A \setminus B \in C_{\Sigma f}$$

3. 称 C 为 半代数，如果它是半环，且 $\Omega \in C$.

4. 称 C 为 单调类，如果它对单调序列极限封闭.

Definition 1.4 设 C 为一集类，称 C 为 代数，如果

1. $\emptyset \in C, \Omega \in C$

2. 对有限并和补运算封闭, 即

$$E_1, E_2 \in C \implies E_1 \cup E_2 \in C, \quad E \in C \implies E^c \in C$$

如果上述运算可以操作可数次, 则称 C 为 σ 代数.

Remark 1.5 由定义可以立即推断代数对“交”, “并”, “差”, “补”都封闭.

Proposition 1.6 设 C 为半代数, 则 $\mathcal{A}(C) = C_{\Sigma f}$

Definition 1.7 设 C 是一集类, 则存在唯一的 σ -代数 (记为 $\sigma(C)$), 具有下列性质:

1. $C \subset \sigma(C)$

2. $\sigma(C)$ 是包含 C 的最小 σ -代数.

称其为 C 生成的 σ -代数.

Proof. 验证; 良定义: 由于 $\mathcal{P}(\Omega)$ 是一 σ 代数, 于是包含 C 的 σ -代数全体构成的集合是非空的. 考虑该集合中所有元素的交, 自动满足存在唯一性. \square

1.1.2 乘积空间与乘积 σ 代数

Definition 1.8 集合 A_1 和 A_2 的乘积集记为 $A_1 \times A_2$, 是指的下列集合:

$$A_1 \times A_2 = \{(\omega_1, \omega_2) : \omega_1 \in A_1, \omega_2 \in A_2\}.$$

称 $\Omega_1 \times \Omega_2$ 为乘积空间, $A_1 \times A_2$ 为其中的矩形.

Definition 1.9 设 $(\Omega_1, \mathcal{A}_1)$ 和 $(\Omega_2, \mathcal{A}_2)$ 是两个可测空间. 定义集合

$$E = \{A_1 \times A_2 : A_1 \in \mathcal{A}_1, A_2 \in \mathcal{A}_2\}$$

称包含 E 的最小 σ -代数 $\sigma(E)$ 为 \mathcal{A}_1 和 \mathcal{A}_2 的乘积 σ -代数, 记为 $\mathcal{A}_1 \times \mathcal{A}_2$.

Remark 1.10 E 本身是一个半集代数, 但不是 σ -代数.

Definition 1.11 设 $(\Omega_i, \mathcal{A}_i), i = 1, \dots, n$ 是 n 个可测空间. 定义

$$E_n = \left\{ \prod_{i=1}^n A_i : A_i \in \mathcal{A}_i, i = 1, \dots, n \right\}$$

乘积 σ -代数定义为

$$\bigotimes_{i=1}^n \mathcal{A}_i = \sigma(E_n)$$

Example 1.12 (Borel σ -代数的乘积) 当 $\Omega_1 = \Omega_2 = \mathbb{R}, \mathcal{A}_1 = \mathcal{A}_2 = \mathcal{B}(\mathbb{R})$ 时, 有

$$\mathcal{B}(\mathbb{R}^2) = \mathcal{B}(\mathbb{R}) \times \mathcal{B}(\mathbb{R})$$

即二维 Borel σ -代数等于两个一维 Borel σ -代数的乘积 σ -代数.

§1.2 集函数, 测度, 概率

1.2.1 集函数与测度

Definition 1.13 (集函数) 设 C 为任一集类. 映射

$$\mu : C \rightarrow [-\infty, \infty]$$

称为 C 上的集函数. 若 μ 值域为 $[0, \infty]$ 则称其为 C 上的非负集函数.

Remark 1.14 在测度论中, 我们一般约定非负集函数 μ 满足

1. $\mu(\emptyset) = 0$

2. 单调性:

$$A, B \in C, A \subset B \implies \mu(A) \leq \mu(B)$$

Theorem 1.15 如果 μ 是 σ -代数 \mathcal{A} 上的 σ -可加集函数, 则 μ 有限可加且连续.

Proof. 设 $\{A_n\}_{n=1}^{\infty} \subset \mathcal{A}$ 是非降序列, 即 $A = \bigcup_{n=1}^{\infty} A_n \in \mathcal{A}$. 定义序列 $\{B_n\}_{n=1}^{\infty}$ 如下:

$$B_1 = A_1, \quad B_n = A_n \setminus A_{n-1} \quad (n \geq 2)$$

由于 \mathcal{A} 是 σ -代数, 对差运算封闭, 所以 $B_n \in \mathcal{A}$. 显然, B_n 两两不交, 且:

$$A_n = \bigsqcup_{k=1}^n B_k, \quad A = \bigcup_{k=1}^{\infty} B_k$$

由 σ -可加性:

$$\mu(A) = \mu\left(\bigsqcup_{k=1}^{\infty} B_k\right) = \sum_{k=1}^{\infty} \mu(B_k)$$

另一方面, 由有限可加性:

$$\mu(A_n) = \mu\left(\bigsqcup_{k=1}^n B_k\right) = \sum_{k=1}^n \mu(B_k)$$

因此:

$$\lim_{n \rightarrow \infty} \mu(A_n) = \lim_{n \rightarrow \infty} \sum_{k=1}^n \mu(B_k) = \sum_{k=1}^{\infty} \mu(B_k) = \mu(A)$$

这就证明了 μ 是下连续的.

设 $\{A_n\}_{n=1}^{\infty} \subset \mathcal{A}$ 是非增序列, 即 $A_1 \supset A_2 \supset \cdots$, 且 $A = \bigcap_{n=1}^{\infty} A_n \in \mathcal{A}$, 且存在 m 使得 $\mu(A_m) < \infty$. 由于序列是非增的, 我们可以考虑补集序列 $\{A_m \setminus A_n\}_{n=m}^{\infty}$. 定义 $C_n = A_m \setminus A_n$, 则 $\{C_n\}_{n=m}^{\infty}$ 是非降序列, 且:

$$\bigcup_{n=m}^{\infty} C_n = A_m \setminus \bigcap_{n=m}^{\infty} A_n = A_m \setminus A$$

由下连续性 (已证):

$$\lim_{n \rightarrow \infty} \mu(C_n) = \mu\left(\bigcup_{n=m}^{\infty} C_n\right) = \mu(A_m \setminus A)$$

由于 $\mu(A_m) < \infty$, 我们可以使用可减性:

$$\mu(C_n) = \mu(A_m \setminus A_n) = \mu(A_m) - \mu(A_n) \quad (\text{因为 } A_n \subset A_m)$$

$$\mu(A_m \setminus A) = \mu(A_m) - \mu(A) \quad (\text{因为 } A \subset A_m)$$

因此:

$$\lim_{n \rightarrow \infty} [\mu(A_m) - \mu(A_n)] = \mu(A_m) - \mu(A)$$

即:

$$\mu(A_m) - \lim_{n \rightarrow \infty} \mu(A_n) = \mu(A_m) - \mu(A)$$

所以:

$$\lim_{n \rightarrow \infty} \mu(A_n) = \mu(A)$$

这就证明了 μ 是上连续的. □

Definition 1.16 设 $\{A_t, t \in T\}$ 是 \mathcal{A} 中的事件类, 若对于 T 的任意子集列 $\{t_1, \dots, t_n\}$ 均有

$$P\left(\bigcap_{j=1}^n A_{t_j}\right) = \prod_{j=1}^n P(A_{t_j})$$

则称 $\{A_t, t \in T\}$ 独立.

§ 1.3 随机变量及其分布函数

Definition 1.17 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, 定义函数

$$\begin{aligned} X : \Omega &\rightarrow \mathbb{R} \\ \omega &\mapsto X(\omega) \end{aligned}$$

并且满足

$$\{\omega : X(\omega) \leq x\} \in \mathcal{F}$$

则称 X 是 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的实随机变量.

Definition 1.18 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间. 定义集函数

$$\begin{aligned} P_X : \mathcal{B} &\rightarrow [0, 1] \\ B &\mapsto P_X(B) \end{aligned}$$

其中

$$P_X(B) = \mathbb{P}(\{\omega : X(\omega) \in B\})$$

则称 P_X 为随机变量 X 的概率分布. 由此, X 诱导出一个新的概率空间 $(\mathbb{R}, \mathcal{B}, P_X)$.

Definition 1.19 记

$$F(x) = P_X\{(-\infty, x]\} = \mathbb{P}(X \leq x) (x \in \mathbb{R})$$

称它是 X 的分布函数(简记为 d.f.) 易知它具有性质:

1. $F(x)$ 是不减、右连续的;
2. $\lim_{x \rightarrow -\infty} F(x) = 0, \lim_{x \rightarrow \infty} F(x) = 1$.

Theorem 1.20 设 $\{X_k\}_{k=1}^n$ 独立的充分必要条件是对于任意 $B_k \in \mathcal{B}^{(m_k)}$, 均有

$$P\left(\bigcap_{k=1}^n \{X^{(k)} \in B_k\}\right) = \prod_{k=1}^n P(X^{(k)} \in B_k).$$

§1.4 收敛方式

若不加说明, 我们用大写字母 X, Y, Z 表示 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的随机变量.

1.4.1 几乎必然收敛

Definition 1.21 设 $\{X_n\}_{n=1}^\infty$ 为一随机变量序列, X 亦是一随机变量, 若存在 $N \in \mathcal{F}$ 满足 $\mathbb{P}(N) = 0$, 使得

$$X_n(\omega) \rightarrow X(\omega) \quad \forall \omega \in \Omega \setminus N$$

则称 X_n 几乎必然收敛到 X .

Proposition 1.22 设 X_n 是随机变量序列, 且 $X_n \rightarrow X$ a.s. 则

1. 若 X_{n_k} 是 X_n 的子列, 则 $X_{n_k} \rightarrow X$ a.s.
2. 几乎必然收敛序列的极限函数是几乎必然唯一的
3. 若 $X_n = Y_n, X = Y$ a.s. 则 $Y_n \rightarrow Y$ a.s.

Theorem 1.23 若 $X_n^{(k)} \rightarrow X^{(k)}$ a.s. $\forall 1 \leq k \leq m$, F 是 \mathbb{R}^m 上的连续函数, 则

$$G(X_n^{(1)}, \dots, X_n^{(m)}) \rightarrow G(X^{(1)}, \dots, X^{(m)}) \quad \text{a.s.}$$

Proof. 由条件知存在零测集 $N_k \in \mathcal{F}$, 使得对于所有 $\omega \in \Omega \setminus N_k$, 有

$$\lim_{n \rightarrow \infty} X_n^{(k)}(\omega) = X^{(k)}(\omega).$$

令 $N = \bigcup_{k=1}^m N_k$, 则 $\mathbb{P}(N) = 0$, 且对于所有 $\omega \in \Omega \setminus N$ 和每个 k , 均有 $X_n^{(k)}(\omega) \rightarrow X^{(k)}(\omega)$.

现在考虑函数 $G: \mathbb{R}^m \rightarrow \mathbb{R}$, 已知 G 连续. 对于任意 $\omega \in \Omega \setminus N$, 向量序列

$$\left(X_n^{(1)}(\omega), \dots, X_n^{(m)}(\omega)\right) \rightarrow \left(X^{(1)}(\omega), \dots, X^{(m)}(\omega)\right)$$

由 G 的连续性, 有

$$G\left(X_n^{(1)}(\omega), \dots, X_n^{(m)}(\omega)\right) \rightarrow G\left(X^{(1)}(\omega), \dots, X^{(m)}(\omega)\right).$$

由于这对所有 $\omega \in \Omega \setminus N$ 成立, 且 $\mathbb{P}(N) = 0$, 因此

$$G\left(X_n^{(1)}, \dots, X_n^{(m)}\right) \rightarrow G\left(X^{(1)}, \dots, X^{(m)}\right) \quad \text{几乎必然.}$$

□

Corollary 1.24 设 $X_n \rightarrow X, Y_n \rightarrow Y$ a.s., 则

1. $X_n + Y_n \rightarrow X + Y$ a.s.
2. $X_n \cdot Y_n \rightarrow X \cdot Y$ a.s.
3. $cX_n \rightarrow cX$ a.s. $c \in \mathbb{R}$

Theorem 1.25 随机变量列 X_n 收敛到某随机变量 X 的充要条件是:

$$X_m - X_n \rightarrow 0 \quad \text{a.s.} \quad (m, n \rightarrow \infty)$$

Proof. 必要性: 由于 $X_n \rightarrow X$ a.s. 故存在零测集 $N \in \mathcal{F}$ 使得

$$X_n(\omega) \rightarrow X(\omega) \quad \forall \omega \in \Omega \setminus N$$

利用 Cauchy 准则立刻获得当 $m, n \rightarrow \infty$ 时, $X_m(\omega) - X_n(\omega) \rightarrow 0, \forall \omega \in \Omega \setminus N$, 即 $X_m - X_n \rightarrow 0$ a.s.

充分性: 由条件知存在零测集 $M \in \mathcal{F}$ 使得

$$X_m(\omega) - X_n(\omega) \rightarrow 0 \quad \forall \omega \in \Omega \setminus M$$

由 Cauchy 准则: 在 X_n 收敛到某随机变量 $X'(\forall \omega \in \Omega \setminus M)$ 于是可以构造

$$X(\omega) = \begin{cases} X' & \omega \in M^c \\ 0 & \omega \in M \end{cases}$$

则 X 即为所求.

□

Theorem 1.26 $X_n \rightarrow X$ a.s. $\iff \forall \varepsilon > 0$

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\bigcup_{m=n} \{|X_m - X| \geq \varepsilon\}\right) = 0$$

Proof. 几乎必然收敛的定义为：

$$X_n \rightarrow X \quad \text{a.s.} \iff \mathbb{P} \left(\left\{ \omega : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega) \right\} \right) = 1.$$

这等价于：对任意 $\varepsilon > 0$ ，有

$$\mathbb{P} \left(\limsup_{n \rightarrow \infty} \{ |X_n - X| \geq \varepsilon \} \right) = 0,$$

设 $A_m(\varepsilon) = \{ |X_m - X| \geq \varepsilon \}$ ，则

$$\limsup_{n \rightarrow \infty} A_n(\varepsilon) = \bigcap_{n=1}^{\infty} \bigcup_{m=n}^{\infty} A_m(\varepsilon).$$

因此，

$$X_n \rightarrow X \quad \text{a.s.} \iff \forall \varepsilon > 0, \quad \mathbb{P} \left(\bigcap_{n=1}^{\infty} \bigcup_{m=n}^{\infty} A_m(\varepsilon) \right) = 0.$$

令 $B_n = \bigcup_{m=n}^{\infty} A_m(\varepsilon)$ ，则 $\{B_n\}$ 是递减集合列。根据概率的连续性，有：

$$\mathbb{P} \left(\bigcap_{n=1}^{\infty} B_n \right) = \lim_{n \rightarrow \infty} \mathbb{P}(B_n).$$

代入 B_n 的定义，得：

$$\mathbb{P} \left(\bigcap_{n=1}^{\infty} \bigcup_{m=n}^{\infty} A_m(\varepsilon) \right) = \lim_{n \rightarrow \infty} \mathbb{P} \left(\bigcup_{m=n}^{\infty} A_m(\varepsilon) \right).$$

结合以上结果，有：

$$X_n \rightarrow X \quad \text{a.s.} \iff \forall \varepsilon > 0, \quad \lim_{n \rightarrow \infty} \mathbb{P} \left(\bigcup_{m=n}^{\infty} \{ |X_m - X| \geq \varepsilon \} \right) = 0.$$

□

Theorem 1.27 (Borel-Cantelli) 设 $\{A_k\}_{k=1}^{\infty}$ 为一可测集列，则

$$\sum_{k=1}^{\infty} P(A_k) < \infty \implies \mathbb{P} \left(\bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k \right) = 0$$

Proof. 由于

$$\sum_{k=1}^{\infty} P(A_k) < \infty \implies \sum_{k=n}^{\infty} P(A_k) = 0$$

故

$$\mathbb{P} \left(\bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k \right) \leq \mathbb{P} \left(\bigcup_{k=n}^{\infty} A_k \right) \leq \sum_{k=n}^{\infty} P(A_k) = 0$$

□

1.4.2 依概率收敛

Definition 1.28 设 $\{X_n\}_{n=1}^{\infty}$ 是随机变量序列, X 是随机变量, 若对于任意 $\varepsilon > 0$ 有

$$\lim_{n \rightarrow \infty} \mathbb{P}(\{|X_n - X| > \varepsilon\}) = 0$$

则称序列 X_n 依概率收敛于 X , 记为 $X_n \xrightarrow{p} X$.

Proposition 1.29 设 $X_n \xrightarrow{p} X$ 则

1. 若 X_{n_k} 是 X_n 的子列, 则 $X_{n_k} \xrightarrow{p} X$
2. 若另有 $X_n \xrightarrow{p} Y$ 则 $X = Y$ a.s.
3. 若 $X_n \xrightarrow{p} X, X_n = Y_n, X = Y$ a.s. 则 $Y_n \xrightarrow{p} Y$.

Proof.

1. 显然
2. 注意到:

$$P(|X - Y| \geq \varepsilon) \leq P\left(|X_n - X| \geq \frac{\varepsilon}{2}\right) + P\left(|X_n - Y| \geq \frac{\varepsilon}{2}\right)$$

由于 $X_n \xrightarrow{p} X$ 和 $X_n \xrightarrow{p} Y$ 故

$$\lim_{n \rightarrow \infty} P(|X - Y| \geq \varepsilon) = P(|X - Y| \geq \varepsilon) = 0 \quad \forall \varepsilon > 0$$

取 $\varepsilon = \frac{1}{m}$, 则:

$$P(|X - Y| > 0) = P\left(\bigcup_{m=1}^{\infty} \left(|X - Y| \geq \frac{1}{m}\right)\right) \leq \sum_{m=1}^{\infty} P\left(|X - Y| \geq \frac{1}{m}\right) = 0$$

3. 由题设, 存在零测集 A_n 和 B , 使得:

$$Y_n = X_n, \forall \omega \in A_n^c \quad X = Y, \forall \omega \in B^c$$

令 $M = B \cup A, A = \bigcup_{n=1}^{\infty} A_n$ 则 $P(M) = 0$. 于是

$$\begin{aligned} \{|Y_n - Y| > \varepsilon\} &= \{|Y_n - Y| > \varepsilon\} \cap M^c + \{|Y_n - Y| > \varepsilon\} \cap M \\ &\subset \{|X_n - X| > \varepsilon\} \cap M^c + M \\ &\subset \{|X_n - X| > \varepsilon\} \cup M. \end{aligned}$$

带上概率符号 P 立刻得到结果.

□

Theorem 1.30 本定理描述了概率收敛和几乎必然收敛的关系

1. $X_n \rightarrow X \text{ a.s.} \implies X_n \xrightarrow{p} X$
2. $X_n \xrightarrow{p} X \implies \exists \{X_{n_k}\}_{k=1}^\infty \subseteq \{X_n\}_{n=1}^\infty$ 使得 $X_{n_k} \rightarrow X \text{ a.s.}$
3. $X_n \xrightarrow{p} X \iff \forall \{X_{n_k}\}_{k=1}^\infty \subseteq \{X_n\}_{n=1}^\infty, \exists \{X_{n_{k_j}}\}_{j=1}^\infty \subseteq \{X_{n_k}\}_{k=1}^\infty$ 使得 $X_{n_{k_j}} \rightarrow X \text{ a.s.}$

Proof.

1. 易得
2. 由于 $X_n \xrightarrow{p} X$, 即对任意 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P(|X_n - X| > \varepsilon) = 0.$$

取 $\varepsilon_k = \frac{1}{k} (k \in \mathbb{N})$, 则对每个 k , 存在 n_k 使得

$$P\left(|X_{n_k} - X| > \frac{1}{k}\right) < \frac{1}{2^k},$$

且可选取 $n_1 < n_2 < \cdots < n_k < \cdots$, 即 $\{X_{n_k}\}$ 为递增子序列. 定义

$$A_k = \left\{|X_{n_k} - X| > \frac{1}{k}\right\}$$

由构造可知:

$$\sum_{k=1}^{\infty} P(A_k) < \sum_{k=1}^{\infty} \frac{1}{2^k} = 1 < \infty \implies P\left(\limsup_{k \rightarrow \infty} A_k\right) = 0$$

即就是

$$X_{n_k} \xrightarrow{\text{a.s.}} X$$

3. 必要性显然, 下证充分性: 假设不成立, 则存在 $\varepsilon > 0, \delta > 0$ 及无穷多个 n 使得

$$P(|X_n - X| > \varepsilon) \geq \delta$$

设这些 n 为 $n_1 < n_2 < \cdots$, 则 $\{X_{n_k}\}$ 为子序列且满足

$$P(|X_{n_k} - X| > \varepsilon) \geq \delta \quad \forall k \geq 1$$

由假设, 存在子序列 $\{X_{n_{k_j}}\}$ 使得 $X_{n_{k_j}} \xrightarrow{\text{a.s.}} X$. 但几乎必然收敛蕴含依概率收敛, 故对充分大的 j , 有

$$P(|X_{n_{k_j}} - X| > \varepsilon) < \delta,$$

矛盾. 因此假设错误, 必有 $X_n \xrightarrow{p} X$.

□

Theorem 1.31 若 $X_n^{(k)} \xrightarrow{p} X^{(k)} \quad \forall 1 \leq k \leq m$, G 是 \mathbb{R}^m 上的一致连续函数, 则

$$G(X_n^{(1)}, \dots, X_n^{(m)}) \xrightarrow{p} G(X^{(1)}, \dots, X^{(m)})$$

不妨记

$$Y_n = (X_n^{(1)}, \dots, X_n^{(m)}), \quad Y = (X^{(1)}, \dots, X^{(m)})$$

故结论等价于

$$G(Y_n) \xrightarrow{p} G(Y).$$

Proof. 对任意 $\delta > 0$, 有:

$$P(\|Y_n - Y\|_\infty \geq \delta) = P\left(\max_{1 \leq k \leq m} |X_n^{(k)} - X^{(k)}| \geq \delta\right).$$

注意到:

$$\left\{\max_{1 \leq k \leq m} |X_n^{(k)} - X^{(k)}| \geq \delta\right\} = \bigcup_{k=1}^m \left\{|X_n^{(k)} - X^{(k)}| \geq \delta\right\},$$

由概率的次可加性:

$$P(\|Y_n - Y\|_\infty \geq \delta) \leq \sum_{k=1}^m P(|X_n^{(k)} - X^{(k)}| \geq \delta).$$

由于每个 $X_n^{(k)} \xrightarrow{p} X^{(k)}$, 右边每一项都趋于 0, 故:

$$\lim_{n \rightarrow \infty} P(\|Y_n - Y\|_\infty \geq \delta) = 0,$$

即 $Y_n \xrightarrow{p} Y$.

设 $\varepsilon > 0$. 由于 G 在 D 上一致连续, 存在 $\delta > 0$, 使得对任意 $y, y' \in D$ 满足 $\|y - y'\|_\infty < \delta$, 有:

$$|G(y) - G(y')| < \varepsilon.$$

考虑事件:

$$A_n = \{|G(Y_n) - G(Y)| > \varepsilon\}.$$

由于 $Y_n, Y \in D$ 几乎必然, 若 $\|Y_n - Y\|_\infty < \delta$, 则 $|G(Y_n) - G(Y)| < \varepsilon$. 因此:

$$A_n \subseteq \{\|Y_n - Y\|_\infty \geq \delta\}.$$

故:

$$P(A_n) \leq P(\|Y_n - Y\|_\infty \geq \delta) \rightarrow 0 \quad (n \rightarrow \infty),$$

即 $G(Y_n) \xrightarrow{p} G(Y)$. □

Remark 1.32 我们实际证明了对于子集 $D \in \mathbb{R}^m$ 的情形, 此时只需要保证各随机变量都以概率 1 落在 D 中即可.

Theorem 1.33 若 $X_n^{(k)} \xrightarrow{p} X^{(k)} \quad \forall 1 \leq k \leq m$, G 是 \mathbb{R}^m 上的连续函数, 则

$$G(X_n^{(1)}, \dots, X_n^{(m)}) \xrightarrow{p} G(X^{(1)}, \dots, X^{(m)})$$

不妨记

$$Y_n = (X_n^{(1)}, \dots, X_n^{(m)}), \quad Y = (X^{(1)}, \dots, X^{(m)})$$

故结论等价于

$$G(Y_n) \xrightarrow{p} G(Y).$$

Proof. 要证明 $G(Y_n) \xrightarrow{p} G(Y)$, 只需证明 $\forall \{Y_{n_k}\} \subset \{Y_n\}, \exists \{Y_{n_{k_j}}\} \subset \{Y_{n_k}\}$ 使得

$$G(Y_{n_{k_j}}) \xrightarrow{\text{a.s.}} G(Y).$$

设 $\{Y_{n_k}\}$ 是任意子列. 由于 $Y_n \xrightarrow{p} Y$, 根据依概率收敛的性质, 存在子子列 $\{Y_{n_{k_j}}\}$ 使得

$$Y_{n_{k_j}} \xrightarrow{\text{a.s.}} Y.$$

由于 $Y_{n_{k_j}} \xrightarrow{\text{a.s.}} Y$ 且 G 是连续函数, 由连续映射定理 (几乎处处收敛版本) 可得:

$$G(Y_{n_{k_j}}) \xrightarrow{\text{a.s.}} G(Y).$$

故定理得证. □

1.4.3 依分布收敛

我们记函数 F 的连续点全体为 $C(F)$

Definition 1.34 设 X_n 的分布函数为 F_n , X 的分布函数为 F , 若有

$$F_n(x) \rightarrow F(x) \quad \forall x \in C(F)$$

则称 X_n 依分布收敛到 X , 记为 $X_n \xrightarrow{d} X$.

Theorem 1.35 $X_n \xrightarrow{p} X \implies X_n \xrightarrow{d} X$

Proof. 只需证: 对所有的 x , 有

$$F(x-0) \leq \liminf_{n \rightarrow \infty} F_n(x) \leq \overline{\lim}_{n \rightarrow \infty} F_n(x) \leq F(x+0). \quad (1.1)$$

令 $x' < x$, 则

$$\begin{aligned} \{X \leq x'\} &= \{X_n \leq x, X \leq x'\} \cup \{X_n > x, X \leq x'\} \\ &\subset \{X_n \leq x\} \cup \{|X_n - X| \geq x - x'\} \end{aligned}$$

\implies

$$F(x') \leq F_n(x) + P(|X_n - X| \geq x - x').$$

$X_n \xrightarrow{P} X$, 蕴含 $P(|X_n - X| \geq x - x') \rightarrow 0 (n \rightarrow \infty)$. 所以有

$$F(x') \leq \lim_{n \rightarrow \infty} F_n(x).$$

令 $x' \rightarrow x$, 即得

$$F(x-0) \leq \varliminf_{n \rightarrow \infty} F_n(x).$$

同理, 当 $x'' > x$ 时, 有

$$\varlimsup_{n \rightarrow \infty} F_n(x) \leq F(x'').$$

令 $x'' \rightarrow x$, 即得

$$\varlimsup_{n \rightarrow \infty} F_n(x) \leq F(x+0).$$

这就证明了定理. □

Corollary 1.36 当 $X = c$ 为一常数时,

$$X_n \xrightarrow{P} c \iff X_n \xrightarrow{d} c$$

Proof. 仍然记 X_n 的分布函数为 $F_n(x)$, 常数 c 的分布函数为:

$$F_c(x) = \begin{cases} 0 & x < c, \\ 1 & x \geq c. \end{cases}$$

需要证明对任意 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P(|X_n - c| > \varepsilon) = 0$$

注意:

$$P(|X_n - c| > \varepsilon) = P(X_n < c - \varepsilon) + P(X_n > c + \varepsilon).$$

由于 $c - \varepsilon, c + \varepsilon \in C(F_c)$, 于是

$$F_n(c - \varepsilon) = P(X_n \leq c - \varepsilon) \rightarrow F_c(c - \varepsilon) = 0$$

$$F_n(c + \varepsilon) = P(X_n \leq c + \varepsilon) \rightarrow F_c(c + \varepsilon) = 1$$

因此,

$$P(|X_n - c| > \varepsilon) = P(X_n < c - \varepsilon) + P(X_n > c + \varepsilon) \rightarrow 0$$

即 $X_n \xrightarrow{P} c$. □

Theorem 1.37 (Slutsky 引理) 设 $X_n \xrightarrow{d} X, Y_n \xrightarrow{P} c$ 则

$$1. X_n + Y_n \xrightarrow{d} X + c$$

$$2. X_n Y_n \xrightarrow{d} X \cdot c$$

$$3. \text{ 若 } c \neq 0, \text{ 则 } \frac{X_n}{Y_n} \xrightarrow{d} \frac{X}{c}$$

Lemma 1.38 如果 $X_n \xrightarrow{d} X$ 且 $Y_n \xrightarrow{p} c$, 那么随机向量序列 (X_n, Y_n) 依分布收敛于 (X, c) , 即:

$$(X_n, Y_n) \xrightarrow{d} (X, c)$$

Slutsky 引理的证明. 分别定义函数

$$f_1(x, y) = x + y, \quad f_2(x, y) = x \cdot y, \quad f_3(x, y) = \frac{x}{y}$$

利用连续映射定理和上述引理直接完成证明. □

Lemma 1.39 设 $X_n - X'_n \xrightarrow{p} 0$ 且 $X'_n \xrightarrow{d} X$, 则 $X_n \xrightarrow{d} X$.

Proof. 设 X 的分布函数为 $F(x) = P(X \leq x)$, 需要证明:

$$\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P(X_n \leq x) = F(x) \quad \forall x \in C(F)$$

其中 $C(F)$ 是 F 的连续点集. 我们有:

$$\begin{aligned} P(X_n \leq x) &= P(X_n \leq x, |X'_n - X_n| \leq \varepsilon) + P(X_n \leq x, |X'_n - X_n| > \varepsilon) \\ &\leq P(X'_n \leq x + X'_n - X_n, |X'_n - X_n| \leq \varepsilon) + P(|X'_n - X_n| > \varepsilon) \\ &\leq P(X'_n \leq x + \varepsilon) + P(|X'_n - X_n| > \varepsilon) \\ &= P(X'_n \leq x + \varepsilon) + o(1) \end{aligned}$$

同时:

$$\begin{aligned} P(X'_n \leq x - \varepsilon) &\leq P(X'_n \leq x - \varepsilon, |X'_n - X_n| \leq \varepsilon) + P(|X'_n - X_n| \geq \varepsilon) \\ &\leq P(X_n \leq x) + P(|X'_n - X_n| \geq \varepsilon) \\ &= P(X_n \leq x) + o(1) \end{aligned}$$

因此得到不等式:

$$P(X'_n \leq x - \varepsilon) + o(1) \leq P(X_n \leq x) \leq P(X'_n \leq x + \varepsilon) + o(1)$$

由于 $X'_n \xrightarrow{d} X$, 且 F 的间断点至多可数, 可以选择 $\varepsilon_k \downarrow 0$ 使得 $x \pm \varepsilon_k \in C(F)$, 则:

$$\lim_{n \rightarrow \infty} P(X'_n \leq x \pm \varepsilon_k) = F(x \pm \varepsilon_k)$$

取极限得:

$$F(x - \varepsilon_k) \leq \liminf_{n \rightarrow \infty} P(X_n \leq x) \leq \limsup_{n \rightarrow \infty} P(X_n \leq x) \leq F(x + \varepsilon_k)$$

令 $\varepsilon_k \rightarrow 0$, 由 $x \in C(F)$ 得 $F(x \pm \varepsilon_k) \rightarrow F(x)$, 故:

$$\lim_{n \rightarrow \infty} P(X_n \leq x) = F(x)$$

因此 $X_n \xrightarrow{d} X$. □

基于引理1.39对 Slutsky 第一条的证明. 注意到:

$$(X_n + Y_n) - (X_n + c) \xrightarrow{d} 0 \iff (X_n + Y_n) - (X_n + c) \xrightarrow{p} 0$$

又由于 $X_n + c \xrightarrow{d} X + c$ 故 $X_n + Y_n \xrightarrow{d} X + c$ □

§1.5
例子

Example 1.40 若 $X_1, \dots, X_n \sim U[0, 1]$, $\hat{\theta}$ 是其极大似然估计, 证明

1. $\hat{\theta} \xrightarrow{\text{a.s.}} \theta$
2. $n(\theta - \hat{\theta}) \xrightarrow{d} \text{Exp}(\frac{1}{\theta})$

Example 1.41 设 $X_1, \dots, X_n \sim \text{Exp}(\lambda, a)$ 即

$$f_{\lambda, a}(x) = \lambda \exp(-\lambda(x-a)) \mathbb{I}_{\{x \geq a\}}$$

设 $(\hat{\lambda}_n, \hat{a}_n)$ 为其极大似然估计, 证明

$$(\hat{\lambda}_n, \hat{a}_n) \xrightarrow{P} (\lambda, a)$$

Solution. 计算其对数似然函数为:

$$\ell(\lambda, a) = n \ln \lambda - \lambda \sum_{i=1}^n (x_i - a) + \ln \mathbf{1}\{\min\{x_1, \dots, x_n\} \geq a\}$$

对数似然函数关于 a 单调递增, 因此最大似然估计量为:

$$\hat{a}_n = \min\{X_1, \dots, X_n\}$$

代入并求导

$$\frac{\partial \ell}{\partial \lambda} = \frac{n}{\lambda} - \sum_{i=1}^n (X_i - \hat{a}_n) = 0 \implies \hat{\lambda}_n = \frac{n}{\sum_{i=1}^n (X_i - \hat{a}_n)}$$

由于 $\hat{a}_n = \min\{X_1, \dots, X_n\}$, 且每个 $X_i \geq a$, 有:

$$\mathbb{P}(\hat{a}_n > a + \varepsilon) = [\mathbb{P}(X_1 > a + \varepsilon)]^n = (e^{-\lambda \varepsilon})^n = e^{-n\lambda \varepsilon} \rightarrow 0$$

因此 $\hat{a}_n \xrightarrow{P} a$.

令:

$$Y_n = \frac{1}{n} \sum_{i=1}^n (X_i - a), \quad Z_n = \hat{a}_n - a$$

则:

$$\hat{\lambda}_n = \frac{1}{Y_n - Z_n}$$

由大数定律:

$$Y_n \xrightarrow{P} \mathbb{E}[X_1 - a] = \frac{1}{\lambda}$$

由 $Z_n \xrightarrow{P} 0$, 因此:

$$Y_n - Z_n \xrightarrow{P} \frac{1}{\lambda}$$

由连续映射定理:

$$\hat{\lambda}_n = \frac{1}{Y_n - Z_n} \xrightarrow{P} \lambda$$

□

Chapter 2

积分理论

§2.1 o_p, O_p 记号

Definition 2.1 对于两个确定性序列 $\{a_n\}_{n=1}^{\infty}$ 和 $\{b_n\}_{n=1}^{\infty}$:

- 若存在常数 $c > 0$ 使得 $|\frac{a_n}{b_n}| \leq c$ 对所有 n 成立, 则称 $\frac{a_n}{b_n}$ 有界, 记作 $a_n = O(b_n)$;
- 若 $\{b_n\}_{n=1}^{\infty}$ 非负且 $\frac{a_n}{b_n} \rightarrow 0$, 则记作 $a_n = o(b_n)$
- 若 $a_n = O(b_n)$ 且 $b_n = O(a_n)$, 则称它们同阶, 记作 $a_n \asymp b_n$;
- 若 $\frac{a_n}{b_n} \rightarrow 1$, 则称它们渐近等价, 记作 $a_n \sim b_n$

Definition 2.2 (矩阵范数) 设 $\mathbf{A} = (a_{ij})_{p \times q}$, 常见矩阵范数定义如下:

1. 谱范数:

$$\|\mathbf{A}\|_2 = \sup_{\mathbf{u} \in \mathbb{R}^q \setminus \{0\}} \frac{\|\mathbf{A}\mathbf{u}\|_2}{\|\mathbf{u}\|_2} = \sqrt{\lambda_{\max}(\mathbf{A}^T \mathbf{A})},$$

其中 $\lambda_{\max}(\cdot)$ 表示最大特征值.

2. l_1 范数 (最大列和范数):

$$\|\mathbf{A}\|_1 = \sup_{\mathbf{u} \in \mathbb{R}^q \setminus \{0\}} \frac{\|\mathbf{A}\mathbf{u}\|_1}{\|\mathbf{u}\|_1} = \max_{1 \leq j \leq q} \sum_{i=1}^p |a_{ij}|.$$

3. l_{∞} 范数 (最大行和范数):

$$\|\mathbf{A}\|_{\infty} = \sup_{\mathbf{u} \in \mathbb{R}^q \setminus \{0\}} \frac{\|\mathbf{A}\mathbf{u}\|_{\infty}}{\|\mathbf{u}\|_{\infty}} = \max_{1 \leq i \leq p} \sum_{j=1}^q |a_{ij}|.$$

Theorem 2.3 对向量 $\mathbf{v} \in \mathbb{R}^q$ 、矩阵 $\mathbf{A} \in \mathbb{R}^{p \times q}$ 和 $\mathbf{B} \in \mathbb{R}^{q \times k}$, 其范数满足以下性质 ($\alpha \in \{2, 1, \infty\}$):

1. $\|\mathbf{A}\mathbf{v}\|_\alpha \leq \|\mathbf{A}\|_\alpha \|\mathbf{v}\|_\alpha$;
2. $\|\mathbf{AB}\|_\alpha \leq \|\mathbf{A}\|_\alpha \|\mathbf{B}\|_\alpha$;
3. $\|\mathbf{A} + \mathbf{B}\|_\alpha \leq \|\mathbf{A}\|_\alpha + \|\mathbf{B}\|_\alpha$

Proof. 我们分别对 $\alpha = 2, 1, \infty$ 三种范数证明这三个性质. 以下记

$$\mathbf{A} = (a_{ij})_{p \times q} \quad \mathbf{B} = (b_{ij})_{q \times k} \quad \mathbf{v} = (v_1, \dots, v_q)^\top$$

性质 1: $\|\mathbf{Av}\|_\alpha \leq \|\mathbf{A}\|_\alpha \|\mathbf{v}\|_\alpha$

1. 当 $\alpha = 2$ 时, 由矩阵 2-范数的定义:

$$\|\mathbf{A}\|_2 = \sup_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{Ax}\|_2}{\|\mathbf{x}\|_2},$$

因此对任意 $\mathbf{v} \neq \mathbf{0}$, 有 $\|\mathbf{Av}\|_2 \leq \|\mathbf{A}\|_2 \|\mathbf{v}\|_2$; 当 $\mathbf{v} = \mathbf{0}$ 时等式自然成立.

2. 当 $\alpha = 1$ 时:

$$\begin{aligned} \|\mathbf{Av}\|_1 &= \sum_{i=1}^p \left| \sum_{j=1}^q a_{ij} v_j \right| \leq \sum_{i=1}^p \sum_{j=1}^q |a_{ij}| |v_j| \\ &= \sum_{j=1}^q |v_j| \left(\sum_{i=1}^p |a_{ij}| \right) \leq \left(\max_{1 \leq j \leq q} \sum_{i=1}^p |a_{ij}| \right) \sum_{j=1}^q |v_j| \\ &= \|\mathbf{A}\|_1 \|\mathbf{v}\|_1. \end{aligned}$$

3. 当 $\alpha = \infty$ 时:

$$\begin{aligned} \|\mathbf{Av}\|_\infty &= \max_{1 \leq i \leq p} \left| \sum_{j=1}^q a_{ij} v_j \right| \leq \max_{1 \leq i \leq p} \sum_{j=1}^q |a_{ij}| |v_j| \\ &\leq \left(\max_{1 \leq i \leq p} \sum_{j=1}^q |a_{ij}| \right) \left(\max_{1 \leq j \leq q} |v_j| \right) = \|\mathbf{A}\|_\infty \|\mathbf{v}\|_\infty. \end{aligned}$$

性质 2: $\|\mathbf{AB}\|_\alpha \leq \|\mathbf{A}\|_\alpha \|\mathbf{B}\|_\alpha$

1. 当 $\alpha = 2$ 时, 对任意非零向量 \mathbf{x} :

$$\|\mathbf{ABx}\|_2 \leq \|\mathbf{A}\|_2 \|\mathbf{Bx}\|_2 \leq \|\mathbf{A}\|_2 \|\mathbf{B}\|_2 \|\mathbf{x}\|_2,$$

因此 $\|\mathbf{AB}\|_2 \leq \|\mathbf{A}\|_2 \|\mathbf{B}\|_2$.

2. 当 $\alpha = 1$ 时:

$$\begin{aligned}\|AB\|_1 &= \max_{1 \leq j \leq k} \sum_{i=1}^p \left| \sum_{l=1}^q a_{il} b_{lj} \right| \leq \max_{1 \leq j \leq k} \sum_{i=1}^p \sum_{l=1}^q |a_{il}| |b_{lj}| \\ &= \max_{1 \leq j \leq k} \sum_{l=1}^q |b_{lj}| \left(\sum_{i=1}^p |a_{il}| \right) \leq \left(\max_{1 \leq l \leq q} \sum_{i=1}^p |a_{il}| \right) \left(\max_{1 \leq j \leq k} \sum_{l=1}^q |b_{lj}| \right) \\ &= \|A\|_1 \|B\|_1.\end{aligned}$$

3. 当 $\alpha = \infty$ 时:

$$\begin{aligned}\|AB\|_\infty &= \max_{1 \leq i \leq p} \sum_{j=1}^k \left| \sum_{l=1}^q a_{il} b_{lj} \right| \leq \max_{1 \leq i \leq p} \sum_{j=1}^k \sum_{l=1}^q |a_{il}| |b_{lj}| \\ &= \max_{1 \leq i \leq p} \sum_{l=1}^q |a_{il}| \left(\sum_{j=1}^k |b_{lj}| \right) \leq \left(\max_{1 \leq i \leq p} \sum_{l=1}^q |a_{il}| \right) \left(\max_{1 \leq l \leq q} \sum_{j=1}^k |b_{lj}| \right) \\ &= \|A\|_\infty \|B\|_\infty.\end{aligned}$$

性质 3: $\|A + B\|_\alpha \leq \|A\|_\alpha + \|B\|_\alpha$

1. 当 $\alpha = 2$ 时, 对任意非零向量 \mathbf{x} :

$$\|(A + B)\mathbf{x}\|_2 = \|A\mathbf{x} + B\mathbf{x}\|_2 \leq \|A\mathbf{x}\|_2 + \|B\mathbf{x}\|_2 \leq (\|A\|_2 + \|B\|_2) \|\mathbf{x}\|_2,$$

因此 $\|A + B\|_2 \leq \|A\|_2 + \|B\|_2$ 。

2. 当 $\alpha = 1$ 时:

$$\begin{aligned}\|A + B\|_1 &= \max_{1 \leq j \leq q} \sum_{i=1}^p |a_{ij} + b_{ij}| \leq \max_{1 \leq j \leq q} \sum_{i=1}^p (|a_{ij}| + |b_{ij}|) \\ &\leq \max_{1 \leq j \leq q} \sum_{i=1}^p |a_{ij}| + \max_{1 \leq j \leq q} \sum_{i=1}^p |b_{ij}| \\ &= \|A\|_1 + \|B\|_1.\end{aligned}$$

3. 当 $\alpha = \infty$ 时:

$$\begin{aligned}\|A + B\|_\infty &= \max_{1 \leq i \leq p} \sum_{j=1}^q |a_{ij} + b_{ij}| \leq \max_{1 \leq i \leq p} \sum_{j=1}^q (|a_{ij}| + |b_{ij}|) \\ &\leq \max_{1 \leq i \leq p} \sum_{j=1}^q |a_{ij}| + \max_{1 \leq i \leq p} \sum_{j=1}^q |b_{ij}| \\ &= \|A\|_\infty + \|B\|_\infty.\end{aligned}$$

□

Theorem 2.4 (谱范数的紧性) 对于对称矩阵 $A = (a_{ij})_{p \times p}$, 其谱范数是最“紧”的, 即

$$\|A\|_2 \leq \|A\|_\alpha \quad \alpha \in \{1, \infty\}.$$

Proof. 首先注意到

$$\max_{1 \leq i \leq p} |\lambda_i(A)| = \max_{1 \leq i \leq p} \left| \lambda_i^{1/2}(A^T A) \right| = \|A\|_2.$$

对任意特征值 $\lambda_i(A)$ 及其对应的特征向量 v_i , 有

$$|\lambda_i(A)| \cdot \|v_i\|_\alpha = \|\lambda_i(A)v_i\|_\alpha = \|Av_i\|_\alpha \leq \|A\|_\alpha \|v_i\|_\alpha.$$

因此,

$$\|A\|_2 = \max_{1 \leq i \leq p} |\lambda_i(A)| \leq \|A\|_\alpha.$$

□

2.1.1

Definition 2.5 称随机变量序列 $\{X_n\}_{n \geq 1}$ 依概率有界, 如果对于任意给定的 $\varepsilon > 0$, 存在 $M > 0$ 使得

$$\sup_n P(|X_n| > M) < \varepsilon$$

此时记 $X_n = O_p(1)$

Definition 2.6 称 $\{X_\alpha, \alpha \in A\}$ 一致紧, 如果对于任意给定的 $\varepsilon > 0$, 存在 $M > 0$, 使得

$$\sup_{\alpha \in A} P(\|X_\alpha\| > M) < \varepsilon$$

Theorem 2.7 (Portmanteau) 对于任意的随机向量 X_n 和 X , 下列表述等价:

1. $X_n \xrightarrow{d} X$;
2. 对一切有界实值连续函数 f , 均有 $\mathbb{E}\{f(X_n)\} \rightarrow \mathbb{E}\{f(X)\}$;
3. 对一切有界实值一致连续函数 f , 均有 $\mathbb{E}\{f(X_n)\} \rightarrow \mathbb{E}\{f(X)\}$;
4. 对一切闭集 C , $\overline{\lim}_{n \rightarrow \infty} P(X_n \in C) \leq P(X \in C)$,
5. 对一切开集 G , $\underline{\lim}_{n \rightarrow \infty} P(X_n \in G) \geq P(X \in G)$;
6. 若 A 是 Borel 集, $P(\partial A) = 0$, 则 $\lim_{n \rightarrow \infty} P(X_n \in A) = P(X \in A)$.

Theorem 2.8 (Prohorov) 设 $\{X_n\}_{n=1}^\infty$ 是随机向量序列, 且依分布收敛到一随机向量 X , 则

$$\|X_n\| = O_p(1)$$

Proof. 证明 $\|X_n\| = O_p(1)$, 即对任意 $\varepsilon > 0$, 存在 $M > 0$, 使得

$$\sup_n \mathbb{P}(\|X_n\| > M) < \varepsilon.$$

固定 $\varepsilon > 0$. 由于 X 是随机向量, 存在 $M_0 > 0$, 使得

$$\mathbb{P}(\|X\| \geq M_0) < \frac{\varepsilon}{2}.$$

令闭集 $F = \{x : \|x\| \geq M_0\}$, 则

$$\mathbb{P}(X \in F) = \mathbb{P}(\|X\| \geq M_0) < \frac{\varepsilon}{2}.$$

由于 $X_n \xrightarrow{d} X$, 根据 Portmanteau 定理

$$\limsup_{n \rightarrow \infty} \mathbb{P}(\|X_n\| \geq M_0) = \limsup_{n \rightarrow \infty} \mathbb{P}(X_n \in F) \leq \mathbb{P}(X \in F) < \frac{\varepsilon}{2}.$$

因此, 存在正整数 N , 使得对任意 $n \geq N$,

$$\mathbb{P}(\|X_n\| \geq M_0) < \varepsilon.$$

对 $n = 1, 2, \dots, N-1$, 由于每个 X_n 是随机向量, 存在 $M_n > 0$, 使得

$$\mathbb{P}(\|X_n\| > M_n) < \varepsilon.$$

令

$$M = \max\{M_0, M_1, \dots, M_{N-1}\}.$$

则

$$\sup_n \mathbb{P}(\|X_n\| > M) < \varepsilon.$$

□

Theorem 2.9 设 $f : \mathbb{R}^m \rightarrow \mathbb{R}^1$ 在 **Borel** 集 C 内连续且 $P(X \in C) = 1$, 那么

1. $X_n \xrightarrow{p} X \implies f(X_n) \xrightarrow{p} f(X)$
2. $X_n \xrightarrow{\text{a.s.}} X \implies f(X_n) \xrightarrow{\text{a.s.}} f(X)$
3. $X_n \xrightarrow{d} X \implies f(X_n) \xrightarrow{d} f(X)$

仅证 $X_n \xrightarrow{d} X$. 设 $F \subset \mathbb{R}$ 为任意闭集. 注意到:

$$f^{-1}(F) \subset \overline{f^{-1}(F)} \subset f^{-1}(F) \cup C^c$$

其中第二个包含关系证明如下: 任取 $x \in \overline{f^{-1}(F)}$, 存在序列 $\{x_m\} \subset f^{-1}(F)$ 使得 $x_m \rightarrow x$. 分两种情况:

1. 若存在子列 $\{x_{m_k}\} \subset C$, 则由 f 在 C 上连续性和 F 的闭性得 $f(x) \in F$, 即 $x \in f^{-1}(F)$

2. 若存在 N 使当 $m \geq N$ 时 $x_m \in C^c$, 则 $x \in C^c$

故 $x \in f^{-1}(F) \cup C^c$. 由 Portmanteau 定理可得:

$$\begin{aligned} \limsup_{n \rightarrow \infty} P(f(X_n) \in F) &= \limsup_{n \rightarrow \infty} P(X_n \in f^{-1}(F)) \\ &\leq \limsup_{n \rightarrow \infty} P(X_n \in \overline{f^{-1}(F)}) \\ &\leq P(X \in \overline{f^{-1}(F)}) \end{aligned}$$

由 $P(X \in C^c) = 0$ 得:

$$\begin{aligned} P(X \in \overline{f^{-1}(F)}) &\leq P(X \in f^{-1}(F) \cup C^c) \\ &\leq P(X \in f^{-1}(F)) + P(X \in C^c) \\ &= P(X \in f^{-1}(F)) = P(f(X) \in F) \end{aligned}$$

综合上述不等式:

$$\limsup_{n \rightarrow \infty} P(f(X_n) \in F) \leq P(f(X) \in F)$$

根据 Portmanteau 定理中 (1) \Leftrightarrow (2) 的等价性, 这正好表明:

$$f(X_n) \xrightarrow{d} f(X)$$

□

Theorem 2.10 我们有

1. 如果 $X_n \xrightarrow{d} X$ 且 $d(X_n, Y_n) \xrightarrow{p} 0$, 则 $Y_n \xrightarrow{d} X$;
2. 如果 $X_n \xrightarrow{d} X$ 且 $Y_n \xrightarrow{p} \mathbf{a}$, 则 $(X_n, Y_n^T)^T \xrightarrow{d} (X, \mathbf{a}^T)^T$

§2.2 例——线性模型的收敛速率

Example 2.11 考虑线性回归模型:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

其中 \mathbf{X} 是 $n \times p$ 维列满秩随机协变量矩阵, $\boldsymbol{\varepsilon} = (\varepsilon_1, \dots, \varepsilon_n)^T$ 是误差项. 基本假设:

1. $\mathbb{E}(\boldsymbol{\varepsilon}|\mathbf{X}) = \mathbf{0}_{n \times 1}$
2. $\mathbb{E}(\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^T|\mathbf{X}) = \sigma^2 \mathbf{I}_n$, 其中 $\sigma^2 > 0$ 是常数
3. 对于充分大的 n , 几乎必然成立:

$$\infty > c_1 \geq \lambda_{\max}(\mathbf{X}^T \mathbf{X}/n) \geq \lambda_{\min}(\mathbf{X}^T \mathbf{X}/n) \geq c_0 > 0$$

Example 2.12 证明最小二乘估计 $\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$ 满足：

$$\|\hat{\beta} - \beta\|_2 = O_p(p^{1/2}n^{-1/2})$$

Proof. 我们有

$$\|\hat{\beta} - \beta\|_2 = \|(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \boldsymbol{\varepsilon}\|_2$$

由假设 3, $\mathbf{X}^T \mathbf{X}/n$ 的特征值在 $[c_0, c_1]$ 之间, 因此:

$$\|(\mathbf{X}^T \mathbf{X}/n)^{-1}\|_2 \leq \frac{1}{c_0}$$

于是:

$$\begin{aligned} \|\hat{\beta} - \beta\|_2 &= \|(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \boldsymbol{\varepsilon}\|_2 \\ &= \left\| \left(\frac{1}{n} \mathbf{X}^T \mathbf{X} \right)^{-1} \frac{1}{n} \mathbf{X}^T \boldsymbol{\varepsilon} \right\|_2 \\ &\leq \left\| \left(\frac{1}{n} \mathbf{X}^T \mathbf{X} \right)^{-1} \right\|_2 \cdot \left\| \frac{1}{n} \mathbf{X}^T \boldsymbol{\varepsilon} \right\|_2 \\ &\leq \frac{1}{c_0} \left\| \frac{1}{n} \mathbf{X}^T \boldsymbol{\varepsilon} \right\|_2 \end{aligned}$$

现在考虑 $\left\| \frac{1}{n} \mathbf{X}^T \boldsymbol{\varepsilon} \right\|_2$. 在给定 \mathbf{X} 的条件下:

$$\begin{aligned} \mathbb{E} \left[\frac{1}{n} \mathbf{X}^T \boldsymbol{\varepsilon} \middle| \mathbf{X} \right] &= \mathbf{0} \\ \text{Var} \left[\frac{1}{n} \mathbf{X}^T \boldsymbol{\varepsilon} \middle| \mathbf{X} \right] &= \frac{1}{n^2} \mathbf{X}^T \mathbb{E}[\boldsymbol{\varepsilon} \boldsymbol{\varepsilon}^T | \mathbf{X}] \mathbf{X} = \frac{\sigma^2}{n^2} \mathbf{X}^T \mathbf{X} \end{aligned}$$

因此:

$$\mathbb{E} \left[\left\| \frac{1}{n} \mathbf{X}^T \boldsymbol{\varepsilon} \right\|_2^2 \middle| \mathbf{X} \right] = \text{tr} \left(\frac{\sigma^2}{n^2} \mathbf{X}^T \mathbf{X} \right) = \frac{\sigma^2}{n^2} \text{tr}(\mathbf{X}^T \mathbf{X})$$

由假设 3, $\text{tr}(\mathbf{X}^T \mathbf{X}) \leq p \lambda_{\max}(\mathbf{X}^T \mathbf{X}) \leq p c_1 n$, 所以:

$$\mathbb{E} \left[\left\| \frac{1}{n} \mathbf{X}^T \boldsymbol{\varepsilon} \right\|_2^2 \middle| \mathbf{X} \right] \leq \frac{\sigma^2 p c_1}{n}$$

由马尔可夫不等式, 对任意 $M > 0$:

$$\mathbb{P} \left(\left\| \frac{1}{n} \mathbf{X}^T \boldsymbol{\varepsilon} \right\|_2 > M \sqrt{\frac{p}{n}} \middle| \mathbf{X} \right) \leq \frac{\mathbb{E} \left[\left\| \frac{1}{n} \mathbf{X}^T \boldsymbol{\varepsilon} \right\|_2^2 \middle| \mathbf{X} \right]}{M^2 p/n} \leq \frac{\sigma^2 c_1}{M^2}$$

因此:

$$\left\| \frac{1}{n} \mathbf{X}^T \boldsymbol{\varepsilon} \right\|_2 = O_p \left(\sqrt{\frac{p}{n}} \right)$$

最终得到:

$$\|\hat{\beta} - \beta\|_2 \leq \frac{1}{c_0} \cdot O_p \left(\sqrt{\frac{p}{n}} \right) = O_p \left(\sqrt{\frac{p}{n}} \right)$$

□

Example 2.13 考虑岭估计：

$$\hat{\beta}_\lambda = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1} \mathbf{X}^T \mathbf{y}$$

1. 若 p 固定不变, $\|\beta\|_2 = O(1)$, 证明对于任意 λ 满足 $\lambda = o(n^{1/2})$, 有：

$$\|\hat{\beta}_\lambda - \beta\|_2 = O_p(n^{-1/2})$$

2. 若去掉“ p 固定不变”的假定, 建立 $\|\hat{\beta}_\lambda - \beta\|_2$ 的收敛速率.

Proof. p 固定情形岭估计的偏差为：

$$\begin{aligned} \hat{\beta}_\lambda - \beta &= (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1} \mathbf{X}^T \mathbf{y} - \beta \\ &= (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1} \mathbf{X}^T (\mathbf{X} \beta + \varepsilon) - \beta \\ &= [(\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1} \mathbf{X}^T \mathbf{X} - \mathbf{I}_p] \beta + (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1} \mathbf{X}^T \varepsilon \end{aligned}$$

注意恒等式：

$$(\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1} \mathbf{X}^T \mathbf{X} = \mathbf{I}_p - \lambda (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1}$$

因此：

$$\hat{\beta}_\lambda - \beta = -\lambda (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1} \beta + (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1} \mathbf{X}^T \varepsilon$$

取范数：

$$\|\hat{\beta}_\lambda - \beta\|_2 \leq \lambda \|(\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1} \beta\|_2 + \|(\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1} \mathbf{X}^T \varepsilon\|_2$$

分析第一项：

$$\begin{aligned} \lambda \|(\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1} \beta\|_2 &\leq \lambda \|(\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1}\|_2 \|\beta\|_2 \\ &\leq \lambda \cdot \frac{1}{\lambda_{\min}(\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)} \cdot O(1) \\ &\leq \lambda \cdot \frac{1}{nc_0 + \lambda} \cdot O(1) \\ &= O\left(\frac{\lambda}{n}\right) \\ &= o(n^{-1/2}) \end{aligned}$$

分析第二项：

$$\begin{aligned} \|(\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1} \mathbf{X}^T \varepsilon\|_2 &\leq \|(\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1}\|_2 \|\mathbf{X}^T \varepsilon\|_2 \\ &\leq \frac{1}{nc_0 + \lambda} \|\mathbf{X}^T \varepsilon\|_2 \\ &\leq \frac{1}{nc_0} \|\mathbf{X}^T \varepsilon\|_2 \end{aligned}$$

由问题一的证明, $\|\mathbf{X}^T \varepsilon\|_2 = O_p(\sqrt{np})$, 当 p 固定时：

$$\frac{1}{nc_0} \|\mathbf{X}^T \varepsilon\|_2 = O_p\left(\frac{\sqrt{n}}{n}\right) = O_p(n^{-1/2})$$

因此：

$$\|\hat{\beta}_\lambda - \beta\|_2 \leq o(n^{-1/2}) + O_p(n^{-1/2}) = O_p(n^{-1/2})$$

在 p 不固定的情况下，我们需要更强的正则性条件. 假设：

1. $\|\beta\|_2 = O(1)$ 或者 $\|\beta\|_2 = O(\sqrt{p})$
2. $p = o(n)$ 或 $p/n \rightarrow \gamma \in [0, 1)$
3. λ 的选择满足 $\lambda = O(\sqrt{np})$

沿用 (i) 中的分解：

$$\begin{aligned} \|\hat{\beta}_\lambda - \beta\|_2 &\leq \lambda \|(\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1} \beta\|_2 + \|(\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1} \mathbf{X}^T \varepsilon\|_2 \\ &= O\left(\frac{\lambda}{n}\right) + O_p\left(\sqrt{\frac{p}{n}}\right) \quad (\text{或者 } O_p\left(\frac{\lambda \sqrt{p}}{n}\right) + O_p\left(\sqrt{\frac{p}{n}}\right)) \end{aligned}$$

特别地，如果 p 固定，则回到 $O_p(n^{-1/2})$ 的结论. □

Chapter 3

渐进理论

§3.1 引入

Example 3.1 记 $\mathbf{x}_i = (1, x_i)^T$, 其中 x_i 是控制 y_i 取值为“0”或“1”的重要特征变量. 条件概率为 $P(y_i = 1 | \mathbf{x}_i) = p_i = 1 - P(y_i = 0 | \mathbf{x}_i)$, 且

$$p_i = \frac{\exp(\eta_i)}{1 + \exp(\eta_i)},$$

其中 $\eta_i = \mathbf{x}_i^T \boldsymbol{\beta}$. 数理统计中, $\boldsymbol{\beta}$ 的对数似然函数为:

$$I(\boldsymbol{\beta}) = \sum_{i=1}^n [y_i \eta_i - \log \{1 + \exp(\eta_i)\}].$$

需要回答两个核心问题:

1. $\hat{\boldsymbol{\beta}} = \operatorname{argmax} I(\boldsymbol{\beta})$ 的含义和求解方法.
2. $\hat{p}_i = \exp(\mathbf{x}_i^T \hat{\boldsymbol{\beta}}) / \{1 + \exp(\mathbf{x}_i^T \hat{\boldsymbol{\beta}})\}$ 的统计性质, 以及如何构造区间 \hat{C} 使得 $P(\hat{p}_i \in \hat{C}) \geq 95\%$.

§3.2 Taylor 展开

此处从有限增量定理开始叙述 (参考了笔者的数学分析笔记).

Definition 3.2 (\mathbb{R}^n 中的范数) 设 $L \in \mathcal{L}(\mathbb{R}^n, \mathbb{R}^m)$, 定义 L 的范数 $\|L\|$ 为

$$\|L\| = \sup_{|h|=1} |Lh|.$$

Lemma 3.3 (有限增量定理) 设 E 是 \mathbb{R}^n 中的凸开集, $f: E \rightarrow \mathbb{R}^m$ 在 E 上可微, 且存在 $M > 0$ 使得对任意的 $\mathbf{x} \in E$ 均有 $\|f'(\mathbf{x})\| \leq M$. 那么对任意的 $\mathbf{a}, \mathbf{b} \in E$ 有

$$|f(\mathbf{b}) - f(\mathbf{a})| \leq M|\mathbf{b} - \mathbf{a}|.$$

Lemma 3.4 设 E 是 \mathbb{R}^n 中的区域, $f \in C(E)$ 具有 k 阶导数, $\mathbf{a}, \mathbf{h} \in X$ 满足 $[\mathbf{a}, \mathbf{a} + \mathbf{h}] \subseteq E$. 定义函数 $g(t) = f(\mathbf{a} + t\mathbf{h})$, 则 g 也 k 阶可导, 且有

$$g^{(k)}(t) = f^{(k)}(\mathbf{a} + t\mathbf{h}) \mathbf{h}^{\otimes k}$$

(其中 $\overbrace{(\mathbf{h}, \dots, \mathbf{h})}^{k \text{ 个}}$ 记为 $\mathbf{h}^{\otimes k}$)

Proof. 对 k 用归纳法, $k=0$ 的情形平凡地成立, 假设 $f \in C^\ell(E)$ ($\ell < k$) 时结论成立, 考虑 $\ell+1$ 的情况. 因为 $f^{(\ell)}$ 可导, 所以有如下方向导数

$$f^{(\ell+1)}(\mathbf{a} + t\mathbf{h})(\mathbf{h}) = \lim_{\varepsilon \rightarrow 0} \frac{1}{\varepsilon} \left(f^{(\ell)}(\mathbf{a} + t\mathbf{h} + \varepsilon\mathbf{h}) - f^{(\ell)}(\mathbf{a} + t\mathbf{h}) \right)$$

将左右两边作用在 $\mathbf{h}^{\otimes \ell}$ 上, 并利用多重线性映射的连续性可得

$$f^{(\ell+1)}(\mathbf{a} + t\mathbf{h})(\mathbf{h})\mathbf{h}^{\otimes \ell} = \lim_{\varepsilon \rightarrow 0} \frac{1}{\varepsilon} \left(f^{(\ell)}(\mathbf{a} + t\mathbf{h} + \varepsilon\mathbf{h})\mathbf{h}^{\otimes \ell} - f^{(\ell)}(\mathbf{a} + t\mathbf{h})\mathbf{h}^{\otimes \ell} \right).$$

□

Remark 3.5 条件 $[\mathbf{a}, \mathbf{a} + \mathbf{h}] \subseteq E$ 也可以直接替换为 E 是凸集

Theorem 3.6 (Taylor 公式 (Lagrange 余项) (标量版)) 设 $E, \mathbf{a}, \mathbf{h}$ 同前, 若 $f \in C(E)$ 具有 $k+1$ 阶导数, 则存在一个 $\theta \in (0, 1)$, 使得

$$f(\mathbf{a} + \mathbf{h}) = \sum_{\ell=0}^k \frac{1}{\ell!} f^{(\ell)}(\mathbf{a}) \mathbf{h}^{\otimes \ell} + R_k(\mathbf{x}; f, \mathbf{a}), R_k(\mathbf{x}; f, \mathbf{a}) = \frac{1}{(k+1)!} f^{(k+1)}(\mathbf{a} + \theta\mathbf{h}) \mathbf{h}^{\otimes (k+1)}.$$

Remark 3.7 Taylor 多项式的前三项是很重要的, 它们是

$$f(\mathbf{a}) + \sum_{j=1}^n \frac{\partial f}{\partial x_j}(\mathbf{a}) h_j + \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \frac{\partial^2 f}{\partial x_i \partial x_j}(\mathbf{a}) h_i h_j = f(\mathbf{a}) + f'(\mathbf{a})\mathbf{h} + \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \frac{\partial^2 f}{\partial x_i \partial x_j}(\mathbf{a}) h_i h_j.$$

若记

$$H_f(\mathbf{a}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2}(\mathbf{a}) & \frac{\partial^2 f}{\partial x_1 \partial x_2}(\mathbf{a}) & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n}(\mathbf{a}) \\ \frac{\partial^2 f}{\partial x_2 \partial x_1}(\mathbf{a}) & \frac{\partial^2 f}{\partial x_2^2}(\mathbf{a}) & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n}(\mathbf{a}) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1}(\mathbf{a}) & \frac{\partial^2 f}{\partial x_n \partial x_2}(\mathbf{a}) & \cdots & \frac{\partial^2 f}{\partial x_n^2}(\mathbf{a}) \end{bmatrix}.$$

则前三项可表示为

$$f(\mathbf{a}) + f'(\mathbf{a})\mathbf{h} + \frac{1}{2} \mathbf{h}^T H_f(\mathbf{a}) \mathbf{h}.$$

我们称 $H_f(\mathbf{a})$ 为 f 在 \mathbf{a} 处的 Hesse 矩阵.

Remark 3.8 此处我们引进了多重线性映射的符号, 若采用常规符号, 还有下列表示方法

1. 设 E 是 \mathbb{R}^n 中的凸开集, $f: E \rightarrow \mathbb{R}$. 如果 $f \in C^{r+1}(E)$, 则对 E 中任意两点 \mathbf{a} 和 $\mathbf{a} + \mathbf{h}$, 存在 $\theta \in (0, 1)$ 使得

$$f(\mathbf{a} + \mathbf{h}) = f(\mathbf{a}) + \sum_{1 \leq |\alpha| \leq r} \frac{1}{\alpha!} \frac{\partial^\alpha f}{\partial \mathbf{x}^\alpha}(\mathbf{a}) \mathbf{h}^\alpha + \sum_{|\alpha|=r+1} \frac{1}{\alpha!} \frac{\partial^\alpha f}{\partial \mathbf{x}^\alpha}(\mathbf{a} + \theta \mathbf{h}) \mathbf{h}^\alpha.$$

2. 假设 E 是 \mathbb{R}^n 中的凸开集, $f: E \rightarrow \mathbb{R}$. 如果 $f \in C^r(E)$, 则对任意的 $\mathbf{a} \in E$, 当 $\mathbf{h} \rightarrow \mathbf{0}$ 时有

$$f(\mathbf{a} + \mathbf{h}) = f(\mathbf{a}) + \sum_{1 \leq |\alpha| \leq r} \frac{1}{\alpha!} \frac{\partial^\alpha f}{\partial \mathbf{x}^\alpha}(\mathbf{a}) \mathbf{h}^\alpha + o(|\mathbf{h}|^r).$$

其中对 $\alpha = (\alpha_1, \dots, \alpha_n)$ 记

$$|\alpha| = \alpha_1 + \dots + \alpha_n, \quad \alpha! = \alpha_1! \cdots \alpha_n!$$

以及

$$\frac{\partial^\alpha f}{\partial \mathbf{x}^\alpha} = \frac{\partial^{|\alpha|} f}{\partial x_1^{\alpha_1} \cdots \partial x_n^{\alpha_n}},$$

并对 $\mathbf{h} = (h_1, \dots, h_n)^T \in \mathbb{R}^n$ 记 $\mathbf{h}^\alpha = h_1^{\alpha_1} \cdots h_n^{\alpha_n}$.

例 (3.1) 第一问. 回忆逻辑回归的对数似然函数

$$\ell(\beta) = \sum_{i=1}^n [y_i \mathbf{x}_i^T \beta - \log(1 + \exp(\mathbf{x}_i^T \beta))]$$

分别计算其梯度和 Hessian 矩阵:

$$\nabla \ell(\beta) = \sum_{i=1}^n [y_i \mathbf{x}_i - p_i \mathbf{x}_i] = \mathbf{X}^T (\mathbf{y} - \mathbf{p})$$

$$\nabla^2 \ell(\beta) = - \sum_{i=1}^n p_i (1 - p_i) \mathbf{x}_i \mathbf{x}_i^T = -\mathbf{X}^T \mathbf{W} \mathbf{X}$$

其中 $p_i = \frac{\exp(\mathbf{x}_i^T \beta)}{1 + \exp(\mathbf{x}_i^T \beta)}$, $\mathbf{W} = \text{diag}(p_i(1 - p_i))$ 利用 Newton-Raphson 算法:

$$\beta = \beta^{(t)} - [\mathbf{H}(\beta^{(t)})]^{-1} \mathbf{g}(\beta^{(t)})$$

代入得

$$\beta^{(t+1)} = \beta^{(t)} + (\mathbf{X}^T \mathbf{W}^{(t)} \mathbf{X})^{-1} \mathbf{X}^T (\mathbf{y} - \mathbf{p}^{(t)})$$

□

§3.3 Delta 方法及其应用

3.3.1 基本定理

Theorem 3.9 (一阶 Delta 方法) 设 $\{T_n\}$ 是一列随机变量, $\{\alpha_n\}$ 是一列实数且 $\alpha_n \rightarrow \infty$ (通常 $\alpha_n = \sqrt{n}$). 如果存在参数 θ 和常数 $\sigma^2 > 0$, 使得

$$\alpha_n(T_n - \theta) \xrightarrow{d} N(0, \sigma^2)$$

且函数 $g: \mathbb{R} \rightarrow \mathbb{R}$ 在点 θ 处可导, 那么有:

$$\alpha_n[g(T_n) - g(\theta)] \xrightarrow{d} N(0, [g'(\theta)]^2 \sigma^2)$$

Proof. 由于 g 在 θ 处可导, 根据 Taylor 定理:

$$g(T_n) = g(\theta) + g'(\theta)(T_n - \theta) + R_n$$

其中余项 $R_n = o_p(|T_n - \theta|)$. 重整化并整理得:

$$\alpha_n[g(T_n) - g(\theta)] = g'(\theta) \cdot [\alpha_n(T_n - \theta)] + \alpha_n R_n$$

由于 $\alpha_n(T_n - \theta) = O_p(1)$, 有 $T_n - \theta = O_p(1/\alpha_n)$, 因此:

$$\alpha_n R_n = \alpha_n \cdot o_p(1/\alpha_n) = o_p(1) \xrightarrow{p} 0$$

应用 Slutsky 定理:

$$\alpha_n[g(T_n) - g(\theta)] = g'(\theta) \cdot \underbrace{[\alpha_n(T_n - \theta)]}_{\xrightarrow{d} N(0, \sigma^2)} + \underbrace{\alpha_n R_n}_{\xrightarrow{p} 0} \xrightarrow{d} N(0, [g'(\theta)]^2 \sigma^2)$$

□

Theorem 3.10 (二阶 Delta 方法) 在相同的前提条件下, 如果 $g'(\theta) = 0$ 且 $g''(\theta)$ 存在且连续, 那么:

$$\alpha_n^2[g(T_n) - g(\theta)] \xrightarrow{d} \frac{1}{2}g''(\theta)\sigma^2\chi_1^2$$

其中 χ_1^2 是自由度为 1 的卡方分布.

Proof. 由二阶泰勒展开:

$$g(T_n) = g(\theta) + \underbrace{g'(\theta)}_{=0}(T_n - \theta) + \frac{1}{2}g''(\theta)(T_n - \theta)^2 + o_p((T_n - \theta)^2)$$

重整化得:

$$\alpha_n^2[g(T_n) - g(\theta)] = \frac{1}{2}g''(\theta)[\alpha_n(T_n - \theta)]^2 + \alpha_n^2 o_p((T_n - \theta)^2)$$

由于 $\alpha_n(T_n - \theta) \xrightarrow{d} Z \sim N(0, \sigma^2)$, 根据连续映射定理:

$$[\alpha_n(T_n - \theta)]^2 \xrightarrow{d} Z^2 = \sigma^2 \chi_1^2$$

余项 $\alpha_n^2 o_p((T_n - \theta)^2) = o_p(1) \xrightarrow{p} 0$. 应用 Slutsky 定理即得结论. \square

Theorem 3.11 (多元 Delta 方法) 设 \mathbf{T}_n 是一个 k 维随机向量, 满足:

$$\alpha_n(\mathbf{T}_n - \boldsymbol{\theta}) \xrightarrow{d} N(\mathbf{0}, \Sigma)$$

且函数 $g: \mathbb{R}^k \rightarrow \mathbb{R}^m$ 在 $\boldsymbol{\theta}$ 处可微, 其雅可比矩阵为 $Dg(\boldsymbol{\theta})$ ($m \times k$ 矩阵). 那么:

$$\alpha_n[g(\mathbf{T}_n) - g(\boldsymbol{\theta})] \xrightarrow{d} N(\mathbf{0}, Dg(\boldsymbol{\theta})\Sigma[Dg(\boldsymbol{\theta})]^T)$$

Proof. 由多元泰勒展开:

$$g(\mathbf{T}_n) = g(\boldsymbol{\theta}) + Dg(\boldsymbol{\theta})(\mathbf{T}_n - \boldsymbol{\theta}) + \mathbf{R}_n$$

其中 $\mathbf{R}_n = o_p(\|\mathbf{T}_n - \boldsymbol{\theta}\|)$. 重整化得:

$$\alpha_n[g(\mathbf{T}_n) - g(\boldsymbol{\theta})] = Dg(\boldsymbol{\theta}) \cdot [\alpha_n(\mathbf{T}_n - \boldsymbol{\theta})] + \alpha_n \mathbf{R}_n$$

由于 $\alpha_n \mathbf{R}_n = o_p(1) \xrightarrow{p} 0$, 应用 Slutsky 定理和多元正态分布的性质即得结论. \square

3.3.2 例子

例 (3.1) 第二问. 由极大似然估计理论 (Cramér 定理), 对于 logistic 回归模型, 有:

$$\sqrt{n}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}_0) \xrightarrow{d} N(\mathbf{0}, \Sigma)$$

其中 $\Sigma = I^{-1}(\boldsymbol{\beta}_0)$ 是 Fisher 信息矩阵的逆矩阵. 对于 logistic 回归, Fisher 信息矩阵为:

$$I(\boldsymbol{\beta}_0) = \mathbb{E} \left[-\frac{\partial^2 \ell(\boldsymbol{\beta})}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}^T} \right]_{\boldsymbol{\beta}=\boldsymbol{\beta}_0} \implies \Sigma = \left[\sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^T p_{0i}(1 - p_{0i}) \right]^{-1}$$

定义函数 $g: \mathbb{R}^2 \rightarrow \mathbb{R}$ 为:

$$g(\boldsymbol{\beta}) = \frac{\exp(\mathbf{x}_i^T \boldsymbol{\beta})}{1 + \exp(\mathbf{x}_i^T \boldsymbol{\beta})}$$

则 $\hat{p}_i = g(\hat{\boldsymbol{\beta}})$, $p_{0i} = g(\boldsymbol{\beta}_0)$. 计算 g 的梯度:

$$\nabla g(\boldsymbol{\beta}) = \frac{\partial g(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = g(\boldsymbol{\beta})[1 - g(\boldsymbol{\beta})]\mathbf{x}_i$$

特别地,

$$\nabla g(\boldsymbol{\beta}_0) = p_{0i}(1 - p_{0i})\mathbf{x}_i$$

由 Delta 方法（一阶展开）：

$$\widehat{p}_i - p_{0i} = g(\widehat{\boldsymbol{\beta}}) - g(\boldsymbol{\beta}_0) \approx [\nabla g(\boldsymbol{\beta}_0)]^T (\widehat{\boldsymbol{\beta}} - \boldsymbol{\beta}_0)$$

进而

$$\sqrt{n}(\widehat{p}_i - p_{0i}) \approx [\nabla g(\boldsymbol{\beta}_0)]^T \sqrt{n}(\widehat{\boldsymbol{\beta}} - \boldsymbol{\beta}_0)$$

由 Slutsky 定理和连续映射定理：

$$\sqrt{n}(\widehat{p}_i - p_{0i}) \xrightarrow{d} N(0, \sigma^2)$$

其中

$$\sigma^2 = [\nabla g(\boldsymbol{\beta}_0)]^T \boldsymbol{\Sigma} [\nabla g(\boldsymbol{\beta}_0)] = p_{0i}^2 (1 - p_{0i})^2 \mathbf{x}_i^T \boldsymbol{\Sigma} \mathbf{x}_i$$

由渐近正态性：

$$\frac{\sqrt{n}(\widehat{p}_i - p_{0i})}{\sigma} \xrightarrow{d} N(0, 1)$$

因此，

$$P\left(\left|\frac{\sqrt{n}(\widehat{p}_i - p_{0i})}{\sigma}\right| \leq z_{0.975}\right) \rightarrow 0.95$$

其中 $z_{0.975} \approx 1.96$ 是标准正态分布的 0.975 分位数。等价地，

$$P\left(p_{0i} \in \left[\widehat{p}_i - 1.96 \frac{\sigma}{\sqrt{n}}, \widehat{p}_i + 1.96 \frac{\sigma}{\sqrt{n}}\right]\right) \rightarrow 0.95$$

由于 σ^2 依赖于未知参数 $\boldsymbol{\beta}_0$ ，用一致估计量代替：

- 用 \widehat{p}_i 估计 p_{0i}
- 用 $\widehat{\boldsymbol{\Sigma}} = \left[\sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^T \widehat{p}_i (1 - \widehat{p}_i)\right]^{-1}$ 估计 $\boldsymbol{\Sigma}$

得到方差估计：

$$\widehat{\sigma}^2 = \widehat{p}_i^2 (1 - \widehat{p}_i)^2 \mathbf{x}_i^T \widehat{\boldsymbol{\Sigma}} \mathbf{x}_i$$

最终置信区间为：

$$\widehat{C} = \left[\widehat{p}_i - 1.96 \sqrt{\frac{\widehat{\sigma}^2}{n}}, \widehat{p}_i + 1.96 \sqrt{\frac{\widehat{\sigma}^2}{n}}\right]$$

由 Slutsky 定理，替换一致估计量不影响渐近分布，因此：

$$P(p_{0i} \in \widehat{C}) \rightarrow 0.95$$

□

§3.4 逆矩阵方法

Definition 3.12 (Neumann 级数) 设 A 和 B 是 $p \times p$ 矩阵, 且 A 可逆. 若矩阵级数

$$\sum_{k=0}^{\infty} [I - A^{-1}B]^k$$

收敛, 则 B^{-1} 存在且满足

$$B^{-1} = \left(\sum_{k=0}^{\infty} [I - A^{-1}B]^k \right) A^{-1}$$

特别地, 当 $\|I - A^{-1}B\| < 1$ (在某种矩阵范数下) 时, 该级数绝对收敛.

Theorem 3.13 (矩阵逆的扰动展开) 设 A 和 $B = A + \Delta$ 是 $p \times p$ 矩阵, A 可逆, 且 $\|A^{-1}\Delta\| < 1$. 则 B 可逆, 且

$$B^{-1} = A^{-1} - A^{-1}\Delta A^{-1} + A^{-1}\Delta A^{-1}\Delta A^{-1} - \dots$$

等价地, 可以写成

$$B^{-1} = \sum_{k=0}^l (-1)^k (A^{-1}\Delta)^k A^{-1} + R_{l+1}$$

其中余项 $R_{l+1} = (-1)^{l+1} (A^{-1}\Delta)^{l+1} B^{-1}$.

Proof. 由条件 $\|A^{-1}\Delta\| < 1$, Neumann 级数收敛. 注意到

$$B = A(I + A^{-1}\Delta)$$

因此

$$B^{-1} = (I + A^{-1}\Delta)^{-1} A^{-1} = \left(\sum_{k=0}^{\infty} (-1)^k (A^{-1}\Delta)^k \right) A^{-1}$$

截断到第 l 项即得所需结果. □

§3.5 Laplace 方法

Definition 3.14 (Laplace 方法) 设 $f : [a, b] \rightarrow \mathbb{R}$ 是一个充分光滑的函数, $M > 0$ 是一个大参数. 假设存在唯一的 $x_0 \in (a, b)$ 使得:

1. $f'(x_0) = 0$ (临界点条件)
2. $f''(x_0) < 0$ (极大值条件)
3. 对任意 $\delta > 0$, $\sup_{|x-x_0| \geq \delta} f(x) < f(x_0)$ (唯一最大值条件)

考虑积分：

$$I(M) = \int_a^b e^{Mf(x)} dx$$

则当 $M \rightarrow \infty$ 时，有如下渐近展开：

$$I(M) = e^{Mf(x_0)} \sqrt{\frac{2\pi}{-Mf''(x_0)}} \left[1 + O\left(\frac{1}{M}\right) \right]$$

Definition 3.15 设 $\mathbf{x} \in \mathbb{R}^d$, $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 充分光滑，存在唯一的 $\mathbf{x}_0 \in \mathbb{R}^d$ 使得：

1. $\nabla f(\mathbf{x}_0) = 0$
2. Hessian 矩阵 $H(\mathbf{x}_0)$ 负定
3. 对任意 $\delta > 0$, $\sup_{\|\mathbf{x}-\mathbf{x}_0\| \geq \delta} f(\mathbf{x}) < f(\mathbf{x}_0)$

考虑积分：

$$I(M) = \int_{\mathbb{R}^d} e^{Mf(\mathbf{x})} d\mathbf{x}$$

则当 $M \rightarrow \infty$ 时，有如下渐近展开：

$$I(M) = e^{Mf(\mathbf{x}_0)} \frac{(2\pi)^{d/2}}{M^{d/2} \sqrt{|\det(H(\mathbf{x}_0))|}} \left[1 + O\left(\frac{1}{M}\right) \right]$$

Proof. 步骤 1：局部化：对于任意 $\delta > 0$ ，将积分分解为：

$$I(M) = \int_{x_0-\delta}^{x_0+\delta} e^{Mf(x)} dx + \int_{|x-x_0|>\delta} e^{Mf(x)} dx$$

由于 $f(x)$ 在 x_0 处取得唯一最大值，存在 $\eta > 0$ 使得：

$$\sup_{|x-x_0|>\delta} f(x) \leq f(x_0) - \eta$$

因此第二项满足：

$$\int_{|x-x_0|>\delta} e^{Mf(x)} dx = O\left(e^{M(f(x_0)-\eta)}\right)$$

步骤 2：泰勒展开与变量替换：在 x_0 的邻域内， $f(x)$ 的泰勒展开为：

$$f(x) = f(x_0) + \frac{1}{2}f''(x_0)(x-x_0)^2 + R(x)$$

令 $t = \sqrt{-Mf''(x_0)}(x-x_0)$ ，则：

$$x-x_0 = \frac{t}{\sqrt{-Mf''(x_0)}}, \quad dx = \frac{dt}{\sqrt{-Mf''(x_0)}}$$

且

$$\frac{M}{2}f''(x_0)(x-x_0)^2 = -\frac{t^2}{2}$$

步骤 3: 主要项的估计: 主要积分项变为:

$$I_0(M) = \frac{e^{Mf(x_0)}}{\sqrt{-Mf''(x_0)}} \int_{-\delta\sqrt{-Mf''(x_0)}}^{\delta\sqrt{-Mf''(x_0)}} \exp \left\{ -\frac{t^2}{2} + MR \left(x_0 + \frac{t}{\sqrt{-Mf''(x_0)}} \right) \right\} dt$$

由于 $R(x) = o((x - x_0)^2)$, 当 $M \rightarrow \infty$ 时:

$$MR \left(x_0 + \frac{t}{\sqrt{-Mf''(x_0)}} \right) = o(1)$$

因此:

$$e^{MR \left(x_0 + \frac{t}{\sqrt{-Mf''(x_0)}} \right)} = 1 + o(1)$$

步骤 4: 扩展到整个实轴当 $M \rightarrow \infty$ 时, 积分限趋于无穷, 且误差项一致收敛到 0, 因此:

$$I_0(M) = \frac{e^{Mf(x_0)}}{\sqrt{-Mf''(x_0)}} \left[\int_{-\infty}^{\infty} e^{-\frac{t^2}{2}} dt + o(1) \right]$$

利用高斯积分公式 $\int_{-\infty}^{\infty} e^{-\frac{t^2}{2}} dt = \sqrt{2\pi}$, 得到:

$$I_0(M) = e^{Mf(x_0)} \sqrt{\frac{2\pi}{-Mf''(x_0)}} (1 + o(1))$$

步骤 5: 总积分估计结合局部化步骤的结果:

$$I(M) = I_0(M) + O \left(e^{M(f(x_0) - \eta)} \right) = e^{Mf(x_0)} \sqrt{\frac{2\pi}{-Mf''(x_0)}} (1 + o(1))$$

更精确地, 可以证明误差项为 $O(M^{-1})$:

$$I(M) = e^{Mf(x_0)} \sqrt{\frac{2\pi}{-Mf''(x_0)}} \left[1 + O \left(\frac{1}{M} \right) \right]$$

□

Chapter 4

估计理论

§4.1 M 估计

4.1.1 基本定义

Definition 4.1 (Kullback-Leibler 离差) 考虑两个概率密度函数 $f(x)$ 和 $g(x)$. 由 $g(x)$ 到 $f(x)$ 的 Kullback-Leibler (KL) 离差或者相对熵被定义为

$$I_{\text{KL}} = \int f(x) \log \left\{ \frac{f(x)}{g(x)} \right\} d\mu(x) = \mathbb{E}_X \left[\log \left\{ \frac{f(X)}{g(X)} \right\} \right]$$

其中 $\mu(\cdot)$ 是 \mathbb{R} 上的固定测度.

Definition 4.2 (M 估计) 设 X_1, \dots, X_n 为来自分布 P 的独立同分布随机变量. M 估计量 $\hat{\theta}_n$ 定义为:

$$\hat{\theta}_n = \arg \max_{\theta \in \Theta} M_n(\theta) = \arg \max_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n m(\theta, X_i)$$

其中 $\Theta \subseteq \mathbb{R}^p$ 为参数空间. 等价地, $\hat{\theta}_n$ 满足:

$$\Psi_n(\hat{\theta}_n) = \frac{1}{n} \sum_{i=1}^n \psi(\theta, X_i) = 0$$

其中 $\psi(\theta, X) = \nabla_{\theta} m(\theta, X)$ 为影响函数.

Definition 4.3 在最大化框架中:

- 个体目标函数: $m(\theta, X)$
- 样本目标函数: $M_n(\theta) = \frac{1}{n} \sum_{i=1}^n m(\theta, X_i) = \mathbb{P}_n m_{\theta}$
- 总体目标函数: $M(\theta) = \mathbb{E}[m(\theta, X)] = P m_{\theta}$

M 估计量定义为: $\hat{\theta}_n = \arg \max_{\theta \in \Theta} M_n(\theta)$

Definition 4.4 在估计方程框架中:

- 个体估计函数: $\psi(\theta, X) = \nabla_{\theta} m(\theta, X)$
- 样本估计方程: $\Psi_n(\theta) = \frac{1}{n} \sum_{i=1}^n \psi(\theta, X_i) = \mathbb{P}_n \psi_{\theta}$
- 总体估计方程: $\Psi(\theta) = \mathbb{E}[\psi(\theta, X)] = P \psi_{\theta}$

M 估计量满足: $\Psi_n(\hat{\theta}_n) = 0$

Definition 4.5

个体海森函数: $\nabla_{\theta} \psi(\theta, X)^T = \nabla_{\theta}^2 m(\theta, X)$

经验海森矩阵: $\mathbf{H}_n(\theta) = \frac{1}{n} \sum_{i=1}^n \nabla_{\theta} \psi(\theta, X_i)^T = \mathbb{P}_n \nabla_{\theta} \psi_{\theta}$

总体海森矩阵: $\mathbf{H}(\theta) = \mathbb{E}[\nabla_{\theta} \psi(\theta, X)^T] = P \nabla_{\theta} \psi_{\theta}$

Definition 4.6 影响函数协方差矩阵:

$$\Sigma(\theta) = \mathbb{E}[\psi(\theta, X) \psi(\theta, X)^T] = P[\psi_{\theta} \psi_{\theta}^T]$$

4.1.2 相合性

Theorem 4.7 若 $M_n(\cdot)$ 为一随机函数, $M(\cdot)$ 为一非随机函数, 满足

$$\sup_{\theta \in \Theta} |M_n(\theta) - M(\theta)| = o_p(1)$$

另外, θ_0 为 $M(\theta)$ 的可分离的最大值点, 即对于任意固定的 $\delta > 0$,

$$\sup_{\theta \in \{\theta: d(\theta, \theta_0) > \delta\}} M(\theta) < M(\theta_0),$$

则任意满足 $M_n(\tilde{\theta}) \geq \sup_{\theta \in \Theta} M_n(\theta) - o_p(1)$ 的 $\tilde{\theta}$ 均是 θ_0 的弱相合估计.

Proof. 由 $\tilde{\theta}$ 的定义以及一致收敛条件知

$$\begin{aligned} M_n(\tilde{\theta}) &\geq M_n(\theta_0) - o_p(1) \\ &= M(\theta_0) + [M_n(\theta_0) - M(\theta_0)] - o_p(1) \\ &= M(\theta_0) - o_p(1). \end{aligned}$$

因此

$$\begin{aligned} 0 &\leq M(\theta_0) - M(\tilde{\theta}) \\ &\leq [M(\theta_0) - M_n(\tilde{\theta})] + [M_n(\tilde{\theta}) - M(\tilde{\theta})] \\ &\leq o_p(1) + |M_n(\tilde{\theta}) - M(\tilde{\theta})| \\ &\leq \sup_{\theta \in \Theta} |M_n(\theta) - M(\theta)| + o_p(1) \\ &= o_p(1). \end{aligned}$$

另外，在条件 (2) 下，对于任意的 $\delta > 0$ ，总存在 $\eta > 0$ 使得

$$\{d(\tilde{\theta}, \theta_0) > \delta\} \subseteq \{M(\theta_0) - M(\tilde{\theta}) > \eta\}$$

因此，对于任意固定的 $\delta > 0$ ，

$$P(d(\tilde{\theta}, \theta_0) > \delta) \leq P(M(\theta_0) - M(\tilde{\theta}) > \eta) \rightarrow 0.$$

□

Definition 4.8 设 Θ 为参数空间， $\{M_n(\cdot)\}_{n=1}^\infty \subseteq \Theta$. 对任意的正数 ε 与 η ，总存在一个正的随机变量 $\Delta_n(\varepsilon, \eta)$ 和一个不依赖于随机因素的正整数 $N_{\varepsilon, \eta}$ ，满足以下两个条件：

1. 当 $n \geq N_{\varepsilon, \eta}$ 时，随机变量 $\Delta_n(\varepsilon, \eta)$ 超过 ε 的概率小于 η ，即

$$P(\Delta_n(\varepsilon, \eta) > \varepsilon) < \eta;$$

2. 对任意的参数 $\theta \in \Theta$ ，存在一个包含 θ 的开集 $E(\theta, \varepsilon, \eta)$ ，使得对该开集中的任意参数 θ' ，均有

$$\sup_{\theta' \in E(\theta, \varepsilon, \eta)} |M_n(\theta') - M_n(\theta)| \leq \Delta_n(\varepsilon, \eta),$$

则称函数列 $\{M_n(\cdot)\}_{n=1}^\infty$ 是随机等度连续的。

Theorem 4.9 (Newey) 若参数空间 Θ 是紧的，并且

$$M_n(\theta) - M(\theta) = o_p(1) \quad \forall \theta \in \Theta$$

若 $M_n(\cdot)$ 是随机等度连续的，则

$$\sup_{\theta \in \Theta} |M_n(\theta) - M(\theta)| = o_p(1)$$

Theorem 4.10 若参数空间 Θ 是紧的，并且

$$M_n(\theta) - M(\theta) = o_p(1) \quad \forall \theta \in \Theta$$

若存在 $K_n = O_p(1)$ 且

$$|M_n(\theta') - M_n(\theta)| \leq K_n d(\theta', \theta)$$

则

$$\sup_{\theta \in \Theta} |M_n(\theta) - M(\theta)| = o_p(1)$$

Proof. 由于 Θ 是紧集，对于任意 $\varepsilon > 0$ ，存在有限个点 $1, 2, \dots, m(\varepsilon)$ 使得：

$$\Theta \subset \bigcup_{i=1}^{m(\varepsilon)} B(\theta_i, \varepsilon)$$

由点态收敛条件，对每个中心点 θ_i ：

$$|M_n(\theta_i) - M(\theta_i)| = o_p(1)$$

由于只有有限个点，可得：

$$\max_{1 \leq i \leq m(\varepsilon)} |M_n(\theta_i) - M(\theta_i)| = o_p(1)$$

对于任意 $\theta \in \Theta$ ，存在某个 $i \in \{1, 2, \dots, m(\varepsilon)\}$ 使得 $\theta \in B(\theta_i, \varepsilon)$ 。于是有：

$$\begin{aligned} |M_n(\theta) - M(\theta)| &\leq |M_n(\theta) - M_n(\theta_i)| + |M_n(\theta_i) - M(\theta_i)| + |M(\theta_i) - M(\theta)| \\ &\leq \underbrace{K_n d(\theta, \theta_i)}_{\leq K_n \varepsilon} + \underbrace{|M_n(\theta_i) - M(\theta_i)|}_{o_p(1)} + \underbrace{\sup_{(\theta, \theta_i) < \varepsilon} |M(\theta_i) - M(\theta)|}_{\rightarrow 0} \end{aligned}$$

完成证明。 □

4.1.3 渐进正态性

Theorem 4.11 (经典泰勒展开方法) 假设：

1. $\hat{\theta}_n \xrightarrow{p} \theta_0$ (相合性)
2. $\psi_{\theta}(X)$ 在 θ_0 的邻域内二阶连续可微
3. $\mathbb{E}[\|\psi_{\theta_0}(X)\|^2] < \infty$
4. $\mathbb{E}[\nabla_{\theta} \psi_{\theta_0}(X)]$ 非奇异

则：

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N\left(\mathbf{0}, \mathbf{V}_{\theta_0}^{-1} \boldsymbol{\Sigma}_{\theta_0} (\mathbf{V}_{\theta_0}^{-1})^T\right)$$

其中 $\mathbf{V}_{\theta_0} = \mathbb{E}[\nabla_{\theta} \psi_{\theta_0}(X)]$ ， $\boldsymbol{\Sigma}_{\theta_0} = \mathbb{E}[\psi_{\theta_0}(X) \psi_{\theta_0}(X)^T]$

Proof. 在 θ_0 处对 $\Psi_n(\hat{\theta}_n)$ 进行 Taylor 展开：

$$\mathbf{0} = \Psi_n(\hat{\theta}_n) = \Psi_n(\theta_0) + \nabla_{\theta} \Psi_n(\theta_0)(\hat{\theta}_n - \theta_0) + \mathbf{R}_n$$

其中余项 \mathbf{R}_n 满足：

$$\mathbf{R}_n = \frac{1}{2}(\hat{\theta}_n - \theta_0)^T \nabla_{\theta}^2 \Psi_n(\tilde{\theta}_n)(\hat{\theta}_n - \theta_0)$$

这里 $\tilde{\theta}_n$ 位于 $\hat{\theta}_n$ 和 θ_0 之间，整理上式子得到：

$$\sqrt{n} \nabla_{\theta} \Psi_n(\theta_0)(\hat{\theta}_n - \theta_0) = -\sqrt{n} \Psi_n(\theta_0) - \sqrt{n} \mathbf{R}_n$$

由于 $\nabla_{\theta} \Psi_n(\theta_0) = \mathbf{H}_n(\theta_0)$ ，我们有：

$$\sqrt{n}(\hat{\theta}_n - \theta_0) = -\mathbf{H}_n(\theta_0)^{-1} [\sqrt{n} \Psi_n(\theta_0) + \sqrt{n} \mathbf{R}_n]$$

由定义：

$$\sqrt{n} \Psi_n(\theta_0) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \psi_{\theta_0}(X_i)$$

根据条件 3, $\mathbb{E}[\|\psi_{\theta_0}(X)\|^2] < \infty$, 且 $\mathbb{E}[\psi_{\theta_0}(X)] = \Psi(\theta_0) = \mathbf{0}$. 由多元中心极限定理:

$$\sqrt{n}\Psi_n(\theta_0) \xrightarrow{d} N(\mathbf{0}, \Sigma_{\theta_0})$$

其中 $\Sigma_{\theta_0} = \mathbb{E}[\psi_{\theta_0}(X)\psi_{\theta_0}(X)^T]$. 由定义:

$$\mathbf{H}_n(\theta_0) = \frac{1}{n} \sum_{i=1}^n \nabla_{\theta} \psi_{\theta_0}(X_i)^T$$

根据大数定律:

$$\mathbf{H}_n(\theta_0) \xrightarrow{p} \mathbb{E}[\nabla_{\theta} \psi_{\theta_0}(X)^T] = \mathbf{V}_{\theta_0}^T$$

由于矩阵求逆是连续函数, 由连续映射定理:

$$\mathbf{H}_n(\theta_0)^{-1} \xrightarrow{p} (\mathbf{V}_{\theta_0}^T)^{-1}$$

余项可以写为:

$$\mathbf{R}_n = \frac{1}{2}(\hat{\theta}_n - \theta_0)^T \nabla_{\theta}^2 \Psi_n(\tilde{\theta}_n)(\hat{\theta}_n - \theta_0)$$

由于 $\hat{\theta}_n - \theta_0 = O_p(n^{-1/2})$ (这可以从相合性推导出来), 我们有:

$$(\hat{\theta}_n - \theta_0)^T (\hat{\theta}_n - \theta_0) = O_p(n^{-1})$$

如果二阶导数 $\nabla_{\theta}^2 \Psi_n(\tilde{\theta}_n)$ 有概率界 (这由条件 2 和相合性保证), 那么:

$$\mathbf{R}_n = O_p(n^{-1})$$

因此:

$$\sqrt{n}\mathbf{R}_n = \sqrt{n} \cdot O_p(n^{-1}) = O_p(n^{-1/2}) = o_p(1)$$

将上述结果组合:

$$\sqrt{n}(\hat{\theta}_n - \theta_0) = -\mathbf{H}_n(\theta_0)^{-1} [\sqrt{n}\Psi_n(\theta_0) + o_p(1)]$$

由 Slutsky 定理:

$$\begin{aligned} \sqrt{n}(\hat{\theta}_n - \theta_0) &\xrightarrow{d} -(\mathbf{V}_{\theta_0}^T)^{-1} \cdot N(\mathbf{0}, \Sigma_{\theta_0}) \\ &= N\left(\mathbf{0}, (\mathbf{V}_{\theta_0}^T)^{-1} \Sigma_{\theta_0} [(\mathbf{V}_{\theta_0}^T)^{-1}]^T\right) \\ &= N\left(\mathbf{0}, \mathbf{V}_{\theta_0}^{-1} \Sigma_{\theta_0} (\mathbf{V}_{\theta_0}^{-1})^T\right) \end{aligned}$$

其中最后一个等式是因为 $(\mathbf{V}_{\theta_0}^T)^{-1} = (\mathbf{V}_{\theta_0}^{-1})^T$. □

Theorem 4.12 当样本量 $n \rightarrow \infty$ 且参数维度 p 固定时, 如果:

1. $n^{1/2}\Psi_n(\theta_0) \xrightarrow{d} \mathbf{Z}_0$
2. 存在 $\widehat{K}_n = O_p(1)$ 使得 $\|\mathbf{H}_n(\theta_0 + \mathbf{u}) - \mathbf{H}_n(\theta_0)\| \leq \widehat{K}_n \|\mathbf{u}\|$
3. $-\mathbf{H}_n(\theta_0) \xrightarrow{p} \mathbf{J}_0$ (正定)

则：

1. $\|n^{1/2}(\hat{\theta} - \theta_0)\| = O_P(1)$
2. $n^{1/2}(\hat{\theta} - \theta_0) \xrightarrow{d} \mathbf{J}_0^{-1} \mathbf{Z}_0$

Proof. 在 θ_0 处进行泰勒展开：

$$\begin{aligned} 0 &= \Psi_n(\hat{\theta}_n) = \Psi_n(\theta_0) + \mathbf{H}_n(\tilde{\theta}_n)(\hat{\theta}_n - \theta_0) \\ \implies \mathbf{H}_n(\tilde{\theta}_n)(\hat{\theta}_n - \theta_0) &= -\Psi_n(\theta_0) \\ \implies \sqrt{n}\mathbf{H}_n(\tilde{\theta}_n)(\hat{\theta}_n - \theta_0) &= -\sqrt{n}\Psi_n(\theta_0) \\ \implies \sqrt{n}(\hat{\theta}_n - \theta_0) &= -\mathbf{H}_n(\tilde{\theta}_n)^{-1}\sqrt{n}\Psi_n(\theta_0) \end{aligned}$$

其中 $\tilde{\theta}_n$ 在 $\hat{\theta}_n$ 和 θ_0 之间. 由条件 2: $\|\mathbf{H}_n(\theta_0 + \mathbf{u}) - \mathbf{H}_n(\theta_0)\| \leq \hat{K}_n\|\mathbf{u}\|$, 且 $\hat{K}_n = O_P(1)$, 可得：

$$\mathbf{H}_n(\tilde{\theta}_n) = \mathbf{H}_n(\theta_0) + O_P(\|\hat{\theta}_n - \theta_0\|) \implies \mathbf{H}_n(\tilde{\theta}_n) = \mathbf{H}_n(\theta_0) + o_P(1) \quad (\text{相合性})$$

由 Slutsky 定理：

$$\begin{aligned} \sqrt{n}(\hat{\theta}_n - \theta_0) &= - \underbrace{\mathbf{H}_n(\tilde{\theta}_n)^{-1}}_{\xrightarrow{p} \mathbf{H}_n(\theta_0)^{-1} \xrightarrow{p} \mathbf{J}_0^{-1}} \underbrace{\sqrt{n}\Psi_n(\theta_0)}_{\xrightarrow{d} \mathbf{Z}_0} \xrightarrow{d} -\mathbf{J}_0^{-1} \mathbf{Z}_0 \end{aligned}$$

由上述表达式，显然有：

$$\|n^{1/2}(\hat{\theta} - \theta_0)\| = O_P(1)$$

□

§4.2 经验分布

4.2.1 经验分布函数

Definition 4.13 设 X_1, \dots, X_n 是由实数轴上分布函数 F 产生的随机样本，则经验分布函数被定义为

$$F_n(x) = \frac{\sum_{i=1}^n \mathbb{I}[x_i, +\infty)(x)}{n} = \frac{\sum_{i=1}^n \mathbb{I}(X_i \leq x)}{n}$$

这里 $\mathbb{I}_A(x)$ 表示集合 A 对应的示性函数.

Theorem 4.14 经验分布函数具有很多良好的性质

1. 分布函数： $F_n(x)$ 非递减，右连续.
2. 无偏性： $F_n(x)$ 是 $F(x)$ 的无偏估计： $E[F_n(x)] = F(x)$
3. 相合性： $F_n(x) \xrightarrow{P} F(x) \quad n \rightarrow \infty$

4. 渐进正态性: $\sqrt{n}(F_n(x) - F(x)) \xrightarrow{d} N(0, F(x)(1 - F(x)))$

5. 分布性质: $nF_n(x) \sim \text{Binomial}(n, F(x))$

Proof. 仅证 (3)(4)(5)

1. 由强大数定律:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I(X_i \leq x) \xrightarrow{a.s.} E[I(X_1 \leq x)] = F(x)$$

几乎必然收敛蕴含依概率收敛.

2. 令 $Y_i = I(X_i \leq x)$, 则 Y_1, \dots, Y_n 是独立同分布的 Bernoulli 随机变量, 均值为 $F(x)$, 方差为 $F(x)(1 - F(x))$. 由中心极限定理:

$$\frac{\sum_{i=1}^n Y_i - nF(x)}{\sqrt{nF(x)(1 - F(x))}} \xrightarrow{d} N(0, 1)$$

即:

$$\sqrt{n}(F_n(x) - F(x)) \xrightarrow{d} N(0, F(x)(1 - F(x)))$$

3.

$$nF_n(x) = \sum_{i=1}^n I(X_i \leq x)$$

每个 $I(X_i \leq x)$ 是独立的 Bernoulli 试验, 成功概率为 $F(x)$, 因此和为二项分布.

□

Theorem 4.15 (Glivenko-Cantelli) 设 X_1, \dots, X_n 是取自总体分布函数为 $F(x)$ 的独立同分布样本, $\mathbb{F}_n(x)$ 是其经验分布函数. 则当 $n \rightarrow \infty$ 时, 有

$$\sup_{x \in \mathbb{R}} |F_n(x) - F(x)| \xrightarrow{a.s.} 0$$

Proof. 由 Kolmogorov 强大数定律, 对任意固定的 $t \in \mathbb{R}$:

$$\mathbb{F}_n(t) \xrightarrow{a.s.} F(t), \quad \mathbb{F}_n(t-) \xrightarrow{a.s.} F(t-)$$

由于 F 是单调非降函数, 值域在 $[0, 1]$ 中. 给定 $\varepsilon > 0$, 构造分割:

$$-\infty = t_0 < t_1 < \dots < t_k = \infty$$

使得对每个 $i = 1, \dots, k$:

$$F(t_i-) - F(t_{i-1}) < \varepsilon$$

对于任意 $t \in [t_{i-1}, t_i)$, 利用单调性:

$$\mathbb{F}_n(t) - F(t) \leq \mathbb{F}_n(t_i-) - F(t_{i-1}) \leq [\mathbb{F}_n(t_i-) - F(t_i-)] + \varepsilon$$

$$\mathbb{F}_n(t) - F(t) \geq \mathbb{F}_n(t_{i-1}) - F(t_i-) \geq [\mathbb{F}_n(t_{i-1}) - F(t_{i-1})] - \varepsilon$$

上述论证表明, $\mathbb{F}_n(t)$ 和 $\mathbb{F}_n(t-)$ 在 $(t_{i-1}, t_i]$ 内一致收敛. 再利用 k 的有限性得到结论. □

Corollary 4.16 定理表明经验分布函数 F_n 是总体分布函数 F 的强相合一致估计. 这意味着:

$$\lim_{n \rightarrow \infty} P \left(\sup_{x \in \mathbb{R}} |F_n(x) - F(x)| > \varepsilon \right) = 0 \quad \forall \varepsilon > 0$$

4.2.2 经验过程

Definition 4.17 (经验过程) 设 $F_n(x)$ 是经验分布函数, $F(x)$ 是总体分布函数. 定义经验过程 \mathbb{G}_n 为:

$$\mathbb{G}_n(x) = \sqrt{n}(F_n(x) - F(x))$$

Proposition 4.18 (数字特征) 对任意的 $x, s, t \in \mathbb{R}$ 我们有

1. $E[\mathbb{G}_n(x)] = 0$
2. $\text{Cov}[\mathbb{G}_n(s), \mathbb{G}_n(t)] = F(s \wedge t) - F(s)F(t)$

协方差结构的推导. 对于 $s, t \in \mathbb{R}$:

$$\begin{aligned} \text{Cov}[G_n(s), G_n(t)] &= n \cdot \text{Cov}[F_n(s), F_n(t)] \\ &= n \cdot \text{Cov} \left[\frac{1}{n} \sum I(X_i \leq s), \frac{1}{n} \sum I(X_j \leq t) \right] \\ &= \frac{1}{n} \sum_{i=1}^n \text{Cov}[I(X_i \leq s), I(X_i \leq t)] \\ &= E[I(X \leq s)I(X \leq t)] - E[I(X \leq s)]E[I(X \leq t)] \\ &= F(s \wedge t) - F(s)F(t) \end{aligned}$$

□

Theorem 4.19 对于任意有限个点 x_1, x_2, \dots, x_k , 随机向量:

$$(\mathbb{G}_n(x_1), \mathbb{G}_n(x_2), \dots, \mathbb{G}_n(x_k)) \xrightarrow{d} N(0, \Sigma)$$

其中 $\Sigma_{ij} = F(x_i \wedge x_j) - F(x_i)F(x_j)$.

Proof. 这是多元中心极限定理的直接推论.

□

4.2.3 经验分布

Definition 4.20 (经验分布) 在概率空间 (Ω, \mathcal{A}, P) 上, 设 X_1, \dots, X_n 是独立同分布的随机变量. 定义经验分布为:

$$\mathbb{P}_n = \frac{1}{n} \sum_{i=1}^n \delta_{X_i}$$

其中 δ_x 是在点 x 的 **Dirac** 测度 (退化分布).

Remark 4.21 Dirac 测度 δ_x 的定义为：

$$\delta_x(A) = \begin{cases} 1 & \text{如果 } x \in A \\ 0 & \text{如果 } x \notin A \end{cases}$$

对于任何可测集合 A .

Definition 4.22 (经验过程的一般定义) 对于任意可测函数 f ，定义经验过程为：

$$G_n f = n^{1/2}(\mathbb{P}_n f - P f)$$

其中：

$$\begin{aligned} \mathbb{P}_n f &= \int f d\mathbb{P}_n = \frac{1}{n} \sum_{i=1}^n f(X_i) \\ P f &= \int f dP = E[f(X)] \end{aligned}$$

Example 4.23 取 $f(x) = I(x \leq t)$ ，则：

$$\begin{aligned} \mathbb{P}_n f &= \frac{1}{n} \sum_{i=1}^n I(X_i \leq t) = F_n(t) \\ P f &= E[I(X \leq t)] = F(t) \end{aligned}$$

此时 $G_n f = \sqrt{n}(F_n(t) - F(t))$ 就是经典的经验过程.

§ 4.3

例子——得分检验

Example 4.24 我们有一个统计模型，数据来自分布 $f(x|\theta_{01}, \theta_{02})$ ，参数为：

$$\theta = (\theta_1^T, \theta_2^T)^T \in \mathbb{R}^p, \quad \theta_1 \in \mathbb{R}^{p-q}, \quad \theta_2 \in \mathbb{R}^q$$

要检验的假设：

$$H_0 : \theta_{02} = \mathbf{0}_{q \times 1}$$

$$H_1 : \theta_{02} \neq \mathbf{0}_{q \times 1}$$

Definition 4.25 (得分函数) 得分函数是对数似然函数的梯度：

$$U(\theta) = \frac{\partial \ell(\theta)}{\partial \theta} = \begin{pmatrix} U_1(\theta) \\ U_2(\theta) \end{pmatrix} = \begin{pmatrix} \frac{\partial \ell(\theta)}{\partial \theta_1} \\ \frac{\partial \ell(\theta)}{\partial \theta_2} \end{pmatrix}$$

Definition 4.26 (观测矩阵) 观测矩阵是对数似然函数的二阶导数矩阵：

$$H(\theta) = \frac{\partial^2 \ell(\theta)}{\partial \theta \partial \theta^T} = \begin{pmatrix} H_{11}(\theta) & H_{12}(\theta) \\ H_{21}(\theta) & H_{22}(\theta) \end{pmatrix}$$

Definition 4.27 (Fisher 信息矩阵) Fisher 信息矩阵是观测矩阵的负期望值：

$$I(\theta) = -\mathbb{E}[H(\theta)] = -\mathbb{E} \left[\frac{\partial^2 \ell(\theta)}{\partial \theta \partial \theta^T} \right]$$

分块形式为：

$$I(\theta) = \begin{pmatrix} I_{11}(\theta) & I_{12}(\theta) \\ I_{21}(\theta) & I_{22}(\theta) \end{pmatrix}$$

分析. 在 H_0 下, $\theta_2 = 0$, 我们求解约束方程：

$$U_1(\theta_1, 0) = \frac{\partial \ell(\theta)}{\partial \theta_1} \Big|_{\theta_2=0} = 0$$

得到约束估计量 $\tilde{\theta}_1$. 检验统计量基于：

$$U_2(\tilde{\theta}_1, 0) = \frac{\partial \ell(\theta)}{\partial \theta_2} \Big|_{\theta_2=0, \theta_1=\tilde{\theta}_1}$$

如果 H_0 为真, 在真实参数处, 关于 θ_2 的得分应该接近零. 如果 $U_2(\tilde{\theta}_1, 0)$ 显著不为零, 就拒绝 H_0 . \square

Solution. 在 H_0 为真的假设下 ($\theta_{02} = 0$), 对 $U_2(\tilde{\theta}_1, \mathbf{0})$ 进行泰勒展开：

$$\begin{aligned} \frac{1}{\sqrt{n}} U_2(\tilde{\theta}_1, \mathbf{0}) &= \frac{1}{\sqrt{n}} U_2(\theta_{01}, \mathbf{0}) + H_{21}(\bar{\theta}_{01}, \mathbf{0}) \sqrt{n}(\tilde{\theta}_1 - \theta_{01}) \\ &= \frac{1}{\sqrt{n}} U_2(\theta_{01}, \mathbf{0}) + H_{21}(\theta_{01}, \mathbf{0}) \sqrt{n}(\tilde{\theta}_1 - \theta_{01}) + R + o_p(1) \end{aligned}$$

其中 $R = (H_{21}(\bar{\theta}_{01}, \mathbf{0}) - H_{21}(\theta_{01}, \mathbf{0})) \sqrt{n}(\tilde{\theta}_1 - \theta_{01})$, $\bar{\theta}_{01}$ 位于 $\tilde{\theta}_1$ 与 θ_{01} 的连线上. 具体地：

$$\begin{aligned} \|R\| &\leq K_n \|\bar{\theta}_{01} - \theta_{01}\| \cdot \left\| \sqrt{n}(\tilde{\theta}_1 - \theta_{01}) \right\| \\ &\leq K_n \cdot \frac{1}{\sqrt{n}} \left\| \sqrt{n}(\tilde{\theta}_1 - \theta_{01}) \right\|^2 \\ &= O_p(n^{-1/2}) \end{aligned}$$

于是我们有

$$\frac{1}{\sqrt{n}} U_2(\tilde{\theta}_1, \mathbf{0}) = \frac{1}{\sqrt{n}} U_2(\theta_{01}, \mathbf{0}) + H_{21}(\theta_{01}, \mathbf{0}) \sqrt{n}(\tilde{\theta}_1 - \theta_{01}) + o_p(1) \quad (1)$$

由约束方程 $U_1(\tilde{\theta}_1, \mathbf{0}) = \mathbf{0}$ 出发：

$$\mathbf{0} = U_1(\tilde{\theta}_1, \mathbf{0}) = U_1(\theta_{01}, \mathbf{0}) + H_{11}(\theta^*, \mathbf{0})(\tilde{\theta}_1 - \theta_{01}) + o_p(1)$$

解得：

$$\sqrt{n}(\tilde{\theta}_1 - \theta_{01}) = -H_{11}^{-1}(\theta^*, \mathbf{0}) \cdot \frac{1}{\sqrt{n}} U_1(\theta_{01}, \mathbf{0}) + o_p(1) \quad (2)$$

其中 θ^{**} 在 $\tilde{\theta}_1$ 与 θ_{01} 之间. 将 (2) 式代入 (1) 式:

$$\frac{1}{\sqrt{n}}U_2(\tilde{\theta}_1, \mathbf{0}) = \frac{1}{\sqrt{n}}U_2(\theta_{01}, \mathbf{0}) - H_{21}(\theta_{01}, \mathbf{0})H_{11}^{-1}(\theta^{**}, \mathbf{0}) \cdot \frac{1}{\sqrt{n}}U_1(\theta_{01}, \mathbf{0}) + o_p(1)$$

不容易得到 (详细见下面的引理):

$$\frac{1}{\sqrt{n}}U_2(\tilde{\theta}_1, \mathbf{0}) \xrightarrow{d} N(\mathbf{0}, I_{22} - I_{21}I_{11}^{-1}I_{12})$$

□

Lemma 4.28 在正则条件下:

$$\frac{1}{\sqrt{n}} \begin{pmatrix} U_1(\theta_{01}, \mathbf{0}) \\ U_2(\theta_{01}, \mathbf{0}) \end{pmatrix} \xrightarrow{d} N(\mathbf{0}, I(\theta_0)) \quad H_{ij}(\theta) \xrightarrow{p} -I_{ij}(\theta_0)$$

Lemma 4.29 若

$$\frac{1}{\sqrt{n}}U_2(\tilde{\theta}_1, \mathbf{0}) = \frac{1}{\sqrt{n}}U_2(\theta_{01}, \mathbf{0}) - H_{21}(\theta_{01}, \mathbf{0})H_{11}^{-1}(\theta^{**}, \mathbf{0}) \cdot \frac{1}{\sqrt{n}}U_1(\theta_{01}, \mathbf{0}) + o_p(1)$$

则

$$\frac{1}{\sqrt{n}}U_2(\tilde{\theta}_1, \mathbf{0}) \xrightarrow{d} N(\mathbf{0}, I_{22} - I_{21}I_{11}^{-1}I_{12})$$

Proof. 我们记

$$A_n = \frac{1}{\sqrt{n}}U_2(\theta_{01}, \mathbf{0}), \quad B_n = \frac{1}{\sqrt{n}}U_1(\theta_{01}, \mathbf{0}), \quad C_n = H_{21}(\theta_{01}, \mathbf{0})H_{11}^{-1}(\theta^{**})$$

则原式可写为:

$$\frac{1}{\sqrt{n}}U_2(\tilde{\theta}_1, \mathbf{0}) = A_n - C_n B_n + o_p(1)$$

由假设:

$$\begin{pmatrix} B_n \\ A_n \end{pmatrix} \xrightarrow{d} N\left(\mathbf{0}, \begin{pmatrix} I_{11} & I_{12} \\ I_{21} & I_{22} \end{pmatrix}\right)$$

因此 B_n 和 A_n 是联合渐近正态的. 先分析 C_n 的渐进形式, 由正则条件:

$$H_{21}(\theta_{01}, \mathbf{0}) \xrightarrow{p} -I_{21} \quad H_{11}(\theta^{**}, \mathbf{0}) \xrightarrow{p} -I_{11} \quad (\theta^{**} \xrightarrow{p} \theta_{01})$$

因此 (利用连续映射定理和 Slutsky 引理):

$$C_n = H_{21}(\theta_{01}, \mathbf{0})H_{11}^{-1}(\theta^{**}, \mathbf{0}) \xrightarrow{p} (-I_{21}) \cdot (-I_{11}^{-1}) = I_{21}I_{11}^{-1}$$

将 C_n 代入:

$$\frac{1}{\sqrt{n}}U_2(\tilde{\theta}_1, \mathbf{0}) = A_n - C_n B_n + o_p(1) = A_n - I_{21}I_{11}^{-1}B_n + (I_{21}I_{11}^{-1} - C_n)B_n + o_p(1)$$

由于 $C_n \xrightarrow{p} I_{21}I_{11}^{-1}$ ，且 $B_n = O_p(1)$ (因为渐近正态)，有：

$$(I_{21}I_{11}^{-1} - C_n) B_n = o_p(1)$$

因此：

$$\frac{1}{\sqrt{n}} U_2(\tilde{\theta}_1, 0) = A_n - I_{21}I_{11}^{-1}B_n + o_p(1)$$

令： $Z_n = A_n - I_{21}I_{11}^{-1}B_n$ ，则 Z_n 是 A_n 和 B_n 的线性组合，且：

$$\frac{1}{\sqrt{n}} U_2(\tilde{\theta}_1, \mathbf{0}) = Z_n + o_p(1) \xrightarrow{d} Z$$

其中 Z 是 Z_n 的极限分布. □

Definition 4.30 (统计量的构造) 构造二次型：

$$LM = \left[\frac{1}{\sqrt{n}} U_2(\tilde{\theta}_1, 0) \right]^T (I_{22} - I_{21}I_{11}^{-1}I_{12})^{-1} \left[\frac{1}{\sqrt{n}} U_2(\tilde{\theta}_1, 0) \right] \xrightarrow{d} \chi^2(q)$$

Remark 4.31 用约束估计量 $\tilde{\theta}$ 处的信息矩阵估计：

$$LM = \left[\frac{1}{\sqrt{n}} U_2(\tilde{\theta}_1, 0) \right]^T [I_{22}(\tilde{\theta}) - I_{21}(\tilde{\theta})I_{11}^{-1}(\tilde{\theta})I_{12}(\tilde{\theta})]^{-1} \left[\frac{1}{\sqrt{n}} U_2(\tilde{\theta}_1, 0) \right]$$

利用连续映射和 Slutsky 引理可以得到这个估计也依分布收敛于 $\chi^2(q)$ ，称其为 C.R.Rao 统计量.

进一步当期望信息矩阵 $I(\theta)$ 难以计算时，用观测矩阵：

$$LM = \left[\frac{1}{\sqrt{n}} U_2(\tilde{\theta}_1, 0) \right]^T [H_{22}(\tilde{\theta}_1) - H_{21}(\tilde{\theta}_1)H_{11}^{-1}(\tilde{\theta}_1)H_{12}(\tilde{\theta}_1)]^{-1} \left[\frac{1}{\sqrt{n}} U_2(\tilde{\theta}_1, 0) \right]$$

代替，由于我们假设了矩阵的随机等度连续性，即

$$H(\tilde{\theta}) - H(\theta_0) = o_p(1)$$

再次使用连续映射和 Slutsky 引理可以得到结果.